ARTI2001 机器学习 • Module 1 Topic 1 知识点全集

完整版：课件第 17–31 页 + 专题深入 + Practical 代码精讲 + 考前速查

> 本版相对旧版新增：第 17–18 页（本周焦点）与第 21–23 页（Part 3 开篇、机器学习的数学基础、线性代数），并整合为单一文件。课件第 1–16 页为课程管理与行政信息，与考试内容无关，未收录。用浏览器打印为 PDF 即得 A4 版式。

目录

1. 第一部分　课件知识点（第 17–31 页）
2. 第二部分　专题深入：损失函数、概率解题框架
3. 第三部分　Practical 代码逐行精讲
4. 第四部分　考前速查

第一部分　课件知识点（第 17–31 页）

1. 本周焦点（第 17–18 页）

第 17 页是 Part 2 的分隔页。第 18 页给出本周三个目标：

1. 复习支撑机器学习算法的**核心数学概念**。
2. 建立对**关键机器学习思想与术语**的基础理解。
3. **配置开发环境**，保证整学期编码顺畅。

建议参与的活动：`M1 T1 Discussion: You and AI` 与 `M1 T1 Setup your environment`。

注意这三条正好对应后面三块内容：数学复习（第 22–27 页）、概念与术语（第 19–20 页）、环境与 practical（第 28–31 页）。

2. 第 19 页　人工智能 vs 机器学习

2.1 什么是「智能」

课件定义：智能是一个 agent（智能体）**学习、推理、适应，并运用知识在不同情境下达成目标**的能力。关键词是 *across different situations*——能迁移到新情境才算智能，只会做一件死板的事不算。

2.2 AI 与 ML 的层级关系

AI 是总的伞状术语（umbrella term），ML 只是它下面的一个分支：

人工智能 ⊃ 机器学习 ⊃ 深度学习 ⊃ 生成式 AI

2.3 四个层次

层次	定义	典型方法／例子
经典／符号 AI Classical / Symbolic AI	靠人写的规则、逻辑、搜索、规划来工作。知识是人塞进去的，不是学出来的。	专家系统、下棋搜索算法
机器学习 Machine Learning	系统从数据中学习模式，规则不是人写死的。	决策树、回归、SVM、聚类
深度学习 Deep Learning	ML 的子领域，基于多层神经网络。	CNN、RNN、Transformer
生成式 AI Generative AI	会生成内容的深度学习系统。	ChatGPT、Claude（基于 LLM）

> ★ 最重要的分界线：**规则是人给的，还是从数据里学的。**前者是符号 AI，后者是 ML。考试非常爱考这个区分。

2.4 AI 与数据科学、大数据的关系

- 数据科学提供数据处理与分析的方法
- 大数据提供让 ML 能真正跑起来的数据量
- 三者是**互相支撑**的关系，不是包含关系

3. 第 20 页　学习范式（Learning Paradigms）

这一页是整门课的骨架——之后每学一个算法，都要能立刻说出它属于哪个范式。区分的关键：**数据里有没有标签（label）**。

3.1 监督学习（Supervised learning）

从有标签的输入–输出对（labelled input–output pairs）中学习。训练数据里每个样本 x 都配了正确答案 y，模型学的是从 x 到 y 的映射。

子类	输出类型	例子
分类 Classification	离散类别	判断邮件是否垃圾邮件、图片是猫还是狗
回归 Regression	连续实数	预测房价、气温、生活满意度

3.2 无监督学习（Unsupervised learning）

数据没有标签，模型自己去发现数据中的模式或结构。三类常见任务：

- **聚类（Clustering）**：把相似样本分组，如 K-means
- **降维（Dimensionality reduction）**：把高维数据压到低维，如 PCA
- **关联规则挖掘（Association rule mining）**：找「买了 A 的人也常买 B」这类规律

3.3 强化学习（Reinforcement learning, RL）

一个 agent 通过与**环境（environment）**交互来学习。流程：agent 选择**动作（action）** → 环境给出**奖励／惩罚（reward / penalty）**。目标是学到一个**策略（policy）**，使**累积奖励（cumulative reward）**最大化。

> ★ 注意 *cumulative* 这个词——RL 关心的不是眼前这一步的奖励，而是长期总收益，所以有时要牺牲短期利益。

3.4 半监督学习（Semi-supervised learning）

把**少量有标签数据**和**大量无标签数据**结合起来用。现实动机很直接：打标签又贵又慢，无标签数据却很便宜。

3.5 自监督学习（Self-supervised learning）

从数据本身构造出学习目标，不需要人工标注。例如遮住句子里的一个词让模型去预测。它是**基础模型（foundation models）**，也就是大语言模型这类系统的主流训练方式。

3.6 五范式速记表

范式	数据	学什么
监督	有标签	x→y 映射函数
无监督	无标签	数据的结构
强化	环境反馈（奖励／惩罚）	最大化累积奖励的策略
半监督	少量标签 + 大量无标签	映射函数
自监督	无标签，但自造标签	通用表示

4. 第 21 页　Part 3 开篇：Tutorial introduction / Mathematics recap

这是一张章节分隔页（section divider），没有实质知识点。它标记课程从「课程概览 + AI 概念」转向**为 tutorial 做准备的数学复习**。

它承担的作用是：让你具备完成 M1 T1 tutorial 所需的概念与记号约定（conventions）。所以接下来几页的数学不是为了考数学本身，而是**为后面的算法打记号基础**。

5. 第 22 页　机器学习的数学基础

这页把整门课要用的数学分成四大块，每块配一句「它在 ML 里干什么」。这个对应关系本身就是考点。

板块	内容	在 ML 中的作用
线性代数 Linear Algebra	向量、矩阵、点积、矩阵乘法	表示数据和变换
微积分 Calculus	导数、梯度、链式法则	反向传播的引擎
概率与统计 Probability & Statistics	分布、期望、方差、贝叶斯法则	建模不确定性与似然
优化 Optimization	损失函数、梯度下降	模型真正「学」的过程

> ★ 课件明确说明：本次 tutorial **聚焦微积分和概率**；线性代数与优化提供更广的课程背景（wider course context）。

四块的分工串成一句话：线性代数负责*表示*数据 → 概率统计负责*描述不确定性*并给出损失 → 微积分负责*算梯度* → 优化负责*用梯度更新参数*。四者组成一个完整的学习循环。

6. 第 23 页　线性代数（Linear Algebra）

6.1 核心概念

- **向量、矩阵、张量**：一维叫向量，二维叫矩阵，更高维统称张量。一条数据样本 = 一个向量，一批数据 = 一个矩阵。
- **向量空间与维度**：维度就是特征的个数。
- **点积与范数**（dot product & norms）
- **转置、逆、秩**（transpose, inverse, rank）
- **特征值与特征向量**：PCA 降维的数学基础。

6.2 公式与规则

① 点积 Dot product

$$x^T y = \Sigma_i \; x_i y_i$$

两个**同长度**向量对应位置相乘再全部相加，结果是**一个标量**。例：x = (1,2,3)，y = (4,5,6) → 1×4 + 2×5 + 3×6 = 32。直觉：点积衡量两个向量的对齐／相似程度。

② 矩阵乘法 Matrix multiplication

$$(AB)_{ij} = \Sigma_k \; A_{ik} B_{kj}$$

> 结果矩阵第 i 行第 j 列的元素 = **A 的第 i 行**与 **B 的第 j 列**做点积。维度规则：A 是 (m×n)，B 必须是 (n×p)，结果为 (m×p)——A 的列数必须等于 B 的行数。★ 矩阵乘法不满足交换律，AB ≠ BA。

③ 转置 Transpose

$$(A^T)_{ij} = A_{ji}$$

行列互换，(m×n) 转置后变 (n×m)。

④ 逆 Inverse

$$AA^{-1} = A^{-1}A = I \quad \text{(when it exists)}$$

> ★ 注意课件加的 *when it exists*——**不是所有矩阵都可逆**：必须为方阵，且满秩（行列式不为 0）。这条会在 Topic 2 讲正规方程 $\theta = (X^TX)^{-1}X^Ty$ 时再次出现——列满秩条件正是从这里来的。

⑤ L2 范数 L2 norm

$$\|x\|_2 = \sqrt{(\Sigma_i\ x_i^2)}$$

各元素平方和再开根号，即向量的欧氏长度。例：x = (3,4) → √(9+16) = 5。

⑥ 线性层 Linear layer

$$z = Wx + b$$

★ 全课最重要的一个公式。x 是输入向量，W 是**权重矩阵**，b 是**偏置向量**，z 是输出。神经网络的一层、线性回归、逻辑回归，本质都是这个式子。W 和 b 就是第 26 页 $\theta \leftarrow \theta - \eta \nabla L(\theta)$ 里被更新的那个 θ，也就是 practical 里的 `coef_` 与 `intercept_`。

6.3 在机器学习中的用途

- 数据表示为特征向量／矩阵
- 回归模型里的权重
- 前向传播就是矩阵乘法（forward pass = matrix multiply）
- Embeddings 与 PCA 用来降维
- 张量运算可高效扩展——这是 GPU 能加速深度学习的原因

7. 第 24 页　微积分（Calculus）

这页是 tutorial 的重点之一，要能动手算。

7.1 核心概念

- 函数与极限（Functions & limits）
- 导数与变化率：导数 = 函数在某点的变化速度／切线斜率
- **偏导数**：多变量函数中对某一变量求导，其他变量当常数，记号 $\partial f/\partial x$
- **梯度 = 偏导数组成的向量**（Gradient = vector of partials）
- 链式法则（Chain rule）

★ 梯度不是标量，是**向量**。d 个变量的函数，梯度就是 d 维向量。

7.2 公式与规则

① 幂法则 Power rule

$$d(x^n)/dx = n \cdot x^{n-1}$$

指数拿下来当系数，指数减一。例：$d(x^5)/dx = 5x^4$。

② 链式法则 Chain rule

$$d[f(g(x))]/dx = f'(g(x)) \cdot g'(x)$$

口诀：外层导数（内层保持不动）× 内层导数。例：$f(x) = (3x+1)^4 \rightarrow 4(3x+1)^3 \times 3 = 12(3x+1)^3$。这是反向传播的数学核心——神经网络就是一层套一层的复合函数。

③ 指数与对数

$$d(e^x)/dx = e^x \qquad d(\ln x)/dx = 1/x$$

e^x 求导还是它自己。这两个在逻辑回归和交叉熵损失里必用。

④ 梯度 Gradient

$$\nabla f = [\partial f/\partial x_1, \ldots, \partial f/\partial x_d]^T$$

例：$f(x,y) = x^2 + 3y \rightarrow \nabla f = [2x, 3]^T$。★ 几何意义：梯度指向函数**上升**最快的方向，所以梯度下降要往负梯度方向走。

⑤ 线性性 Linearity

$$d[af + bg]/dx = a \cdot f' + b \cdot g'$$

7.3 在机器学习中的用途

- 梯度衡量损失如何变化——参数动一点，损失会变多少
- 反向传播应用链式法则
- 导数指引损失最小化
- 激活函数的导数影响学习——如 sigmoid 在两端导数接近 0，导致**梯度消失**，学不动

8. 第 25 页　概率与统计

8.1 核心概念

- 随机变量与事件、概率分布、期望与方差
- 条件概率：P(A|B) 读作「在 B 发生的条件下 A 发生的概率」
- 独立性与贝叶斯法则

8.2 公式与规则

① 贝叶斯定理

$$P(A|B) = P(B|A) \cdot P(A) / P(B)$$

作用是把条件反过来——已知 P(B|A) 求 P(A|B)。

符号	名称	含义
P(A)	先验 prior	还没看到证据前的概率
P(A|B)	后验 posterior	看到证据 B 之后更新的概率
P(B|A)	似然 likelihood	如果 A 成立，观察到 B 的概率
P(B)	证据／归一化因子	通常用全概率公式算

② 离散期望

$$E[X] = \Sigma_x \; x \cdot P(X = x)$$

加权平均。例：掷公平骰子 E[X] = 3.5。

③ 连续期望

$$E[X] = \int x \cdot f_X(x) \, dx$$

f_X(x) 是概率密度函数（PDF）。

④ 方差

$$Var(X) = E[X^2] - (E[X])^2$$

「平方的期望减去期望的平方」。例：X 取 0 和 2 各 50% → E[X]=1，$E[X^2]$=2，Var = 1。

⑤ 正态标准化

$$Z = (X - \mu) / \sigma$$

转成标准正态（均值 0，标准差 1）。Z 表示「X 距均值有几个标准差」。这也是预处理里 standardisation 的做法。

⑥ 归一化

$$\Sigma_x \; P(X = x) = 1$$

softmax 输出也必须满足它。

⑦ 全概率公式

$$P(A) = \Sigma_i \; P(A|B_i) \cdot P(B_i)$$

把 A 拆到一组互斥且穷尽的情形上分别算再加起来，常用来算贝叶斯公式的分母。

8.3 在机器学习中的用途

- 建模不确定性与噪声
- **最大似然估计（MLE）**——很多损失函数是从 MLE 推出来的
- 交叉熵与概率化输出
- 采样与评估指标

8.4 常用标准正态数值（必背）

数值	规则
$\Phi(1) = 0.8413$	$P(Z > z) = 1 - \Phi(z)$
$\Phi(1.96) = 0.9750$	$\Phi(-z) = 1 - \Phi(z)$（对称性）
$\Phi(2) = 0.9772$	68–95–99.7 法则（$\pm1\sigma$ / $\pm2\sigma$ / $\pm3\sigma$）

9. 第 26 页　优化（Optimization）

训练模型 = 用梯度下降最小化损失函数，这是整个机器学习的核心机制。

9.1 核心概念

概念	说明
损失／目标函数	衡量「模型预测得有多差」的数值函数。参数 θ 是自变量，损失 $L(\theta)$ 是因变量。
局部 vs 全局最小值	全局最小是整个函数的最低点；局部最小只是「周围一小圈里最低」。梯度下降会在局部最小处停下（那里梯度也是 0）。
凸性 Convexity	凸函数只有一个最小值，局部最小就是全局最小。
梯度下降	沿着负梯度方向一步步走下山。
学习率 η 与收敛	控制每步走多远。

> ★ 凸性考点：线性回归、逻辑回归的损失是**凸**的（保证找到全局最优）；神经网络的损失是**非凸**的，有很多局部最小值和鞍点。

学习率的两个极端：太小 → 收敛极慢；太大 → 在山谷两侧来回震荡，甚至**发散**（损失越训越大）。

9.2 公式

① 梯度下降更新式

$$\theta \leftarrow \theta - \eta \; \nabla L(\theta)$$

新参数 = 旧参数 − 学习率 × 梯度。减号来源：梯度指向上升最快方向，取负才是下降。

② 均方误差 MSE（回归）

$$MSE = (1/n) \; \Sigma_i \; (y_i - \hat{y}_i)^2$$

③ 二元交叉熵（二分类）

$$L = -[\; y \cdot \log p + (1-y) \cdot \log(1-p) \;]$$

④ 正则化目标

$$L_{reg} = L_{data} + \lambda R(\theta)$$

在数据损失之外加惩罚项，限制参数别太大、模型别太复杂。λ 越大越简约保守，λ = 0 就是不正则化。

9.3 在机器学习中的用途

- **训练就是最小化训练损失**——对「训练」最本质的定义
- SGD 用小批量（mini-batch）估计梯度——快，但梯度带噪声
- 验证损失支持**早停（early stopping）**——验证损失开始上升而训练损失还在降，就是开始过拟合
- L1 促进稀疏（$\Sigma|\theta|$，权重压到正好 0，相当于自动特征选择）；L2 收缩权重（$\Sigma\theta^2$，整体压小但不归零）
- Adam 为每个参数自适应调整步长

一句话串联：损失函数定义「什么叫差」→ 梯度告诉你「往哪走能变好」→ 学习率决定「一步走多远」→ 正则化防止「学过头」→ 凸性决定「能不能保证走到最优」。

10. 第 27 页　Tutorial 数学题型

评分要求：写出代入过程和中间步骤，清楚交代记号。评分看的是过程，不是只写一个答案。

10.1 Q1–Q2：幂法则与链式法则求导

幂法则示范：$f(x) = 3x^4 - 5x^2 + 7$（用线性性逐项处理）→ $3 \cdot 4x^3 = 12x^3$；$-5 \cdot 2x = -10x$；常数 7 → 0。得 $f'(x) = 12x^3 - 10x$。

> **链式法则示范：**$f(x) = (2x^2 + 1)^3$ → 外层 $3(2x^2+1)^2$，内层导数 $4x$ → $f'(x) = 12x(2x^2+1)^2$。★ 最常见错误：只写 $3(2x^2+1)^2$，忘了乘内层导数。

指数／对数同理：$d(e^{3x})/dx = 3e^{3x}$；$d[\ln(5x)]/dx = 5 \cdot (1/5x) = 1/x$。

10.2 Q3–Q4：正态标准化与区间概率

示范：$X \sim N(100, 15^2)$，求 $P(85 < X < 115)$。

1. 转换端点：$z_1 = (85-100)/15 = -1$，$z_2 = (115-100)/15 = +1$
2. 区间概率 $= \Phi(z_2) - \Phi(z_1)$
3. 用对称性：$\Phi(-1) = 1 - 0.8413 = 0.1587$
4. 结果 $= 0.8413 - 0.1587 = 0.6826$

单尾示范：$P(X > 130)$：$z = 2 \to 1 - \Phi(2) = 0.0228$（约 2.28%）。

10.3 概率 Q1：期望、方差与标准差

示范：X 取 0、1、2、3，概率 0.1、0.3、0.4、0.2。

- $E[X] = 0(0.1)+1(0.3)+2(0.4)+3(0.2) = 1.7$
- $E[X^2] = 0(0.1)+1(0.3)+4(0.4)+9(0.2) = 3.7$（把 x^2 乘概率，不是把结果平方）
- $Var(X) = 3.7 - 1.7^2 = 0.81$　　$SD(X) = 0.9$

> ★ 最常见错误：把 $E[X^2]$ 和 $(E[X])^2$ 搞混。记住：「先平方再平均」减去「先平均再平方」。

10.4 概率 Q2：全概率公式 + 贝叶斯（筛查题）

示范：患病率 P(D)=1%；敏感度 $P(+|D)$=99%；假阳性率 $P(+|\neg D)$=5%。求 $P(D|+)$。

第一步，全概率公式算分母：$P(+) = 0.99 \times 0.01 + 0.05 \times 0.99 = 0.0099 + 0.0495 = 0.0594$。

第二步，套贝叶斯：$P(D|+) = 0.0099 / 0.0594 \approx 16.7\%$。

> ★ 为什么这么低？1000 人里只有 10 个病人（约 10 个真阳性），却有 990 个健康人（约 50 个误报）。假阳性淹没了真阳性——这就是**基础率谬误**。

10.5 Bonus：全期望定律与全方差定律

$$E[X] = E[\,E[X \mid Y]\,] \quad Var(X) = E[\,Var(X|Y)\,] + Var(\,E[X|Y]\,)$$

直观理解全方差：总波动 = 组内波动的平均 + 组间均值的波动。例如全校身高的方差 = 各班内部差异的平均 + 各班平均身高之间的差异。

11. 第 28 页　Practical 导论

目的：把 M1 T1 学到的概念落到实际 practical 工作流里去实现和解读。

核心表述：practical 不只考代码，同样考**正确的实验推理**（experimental reasoning）。

11.1 三条要求

1. **按顺序运行给定的工作流**——不要跳着执行 notebook 的 cell。每一步都会产生下一步要用的信息，顺序错了会造成数据泄漏。
2. **检查中间输出**——不是跑完看最后一个数字就完事。
3. **用证据支撑结论，而不是靠单一分数**——最关键的一条。

11.2 为什么不能只看一个分数

假设准确率 95%，不能直接说「模型很好」，因为可能来自**数据不平衡**（若 95% 样本本就属于同一类，无脑全猜也能拿 95%）、**过拟合**、或**数据泄漏**。应该看一组证据：训练 vs 验证表现对比、误差分布、拟合曲线可视化、不同模型的横向比较。

11.3 Study check（重点）

> ★ 测试集只能用一次，在所有选择都定下来之后，用来估计泛化能力。如果反复拿测试集调参（「深度 3 得 80%，深度 5 得 85%，那就用 5」），测试集实际上已参与开发，它给出的分数不再是对新数据表现的诚实估计。

一句话记：验证集用来做决定，测试集用来交答卷。

12. 第 29 页　ML 流水线与拟合诊断

12.1 流水线的五个阶段

#	阶段	内容与要点
1	数据与准备	收集有代表性的数据 → 清洗 → 探索 → 有理由的特征工程
2	训练	用训练数据拟合模型参数（即梯度下降在做的事）
3	验证与调参	用验证集的证据比较不同模型、不同复杂度
4	最终测试	在所有选择固定之后，**只估计一次**（原文关键词 once）
5	解释、部署与监控	理解模型犯了什么错 → 负责任地使用 → 监控数据漂移

流水线是**迭代的**：诊断出来的证据会反过来推动你改进数据、特征或建模选择。

12.2 拟合诊断（核心考点）

> ★ 方法就一句话：把训练集表现和「没见过的数据」表现**放在一起对比**。单看训练集表现完全没用。

训练表现	未见数据表现	名称	别名
差	差	欠拟合 Underfitting	高偏差 high bias
好	好，且接近	良好拟合 Good fit	—
好	差很多	过拟合 Overfitting	高方差 high variance

复杂度—误差曲线的三个区域：

区域	现象	处理办法
左侧（复杂度低）	两条线都很高	欠拟合 → 增加复杂度、加特征、训练更久
中间	验证误差最低点，两线较接近	最佳位置，选这个复杂度
右侧（复杂度高）	训练误差降到近 0，验证误差掉头向上	过拟合 → 降复杂度、加正则化、加数据、早停

★ 判断过拟合看的不是「训练误差有多低」，而是**两条线的差距（gap）有多大**。训练误差 1% 听起来很棒，但验证误差 45% 就是灾难。这张图必须画在验证集上。

13. 第 30 页　数据准备与防止泄漏

★ 贯穿全页的核心思想：**数据准备是模型训练的一部分，不是分割之前做的「中性编辑」**。填补器、编码器、缩放器、特征选择规则本身都包含从数据里学到的信息，既然要「学」，就必须只从训练集学。

13.1 七个步骤（顺序不能乱）

步	动作	要点
1	先分割 Split first	在做任何 fit 之前先切出验证集和测试集，之后每个 fit 都不许碰它们
2	检查 Inspect	数据类型、缺失、非法值、单位、类别频率（如身高出现 −5，或厘米与米混用）
3	填补 Impute	中位数、均值、类别规则只能从训练数据学
4	编码 Encode	名义类别用 one-hot；序数编码只在类别真有顺序时用
5	缩放与变换	对基于距离、间隔、梯度的模型要标准化；偏态数据可做对数变换但要有理由
6	复用 Reuse	训练集上拟合好的准备步骤，原封不动应用到验证／测试／新数据
7	防止泄漏	见下方三类泄漏源

第 3 步例子：训练集年龄均值 30，全数据（含测试集）均值 32。用 32 去填补，测试集信息就渗进了训练过程，最终分数虚高。

第 4 步：颜色 = 红／蓝／绿之间没有大小关系。编成 0/1/2 会让模型误以为「绿 > 蓝 > 红」，甚至「蓝是红和绿的平均」。序数编码只用于真有顺序的类别：学历、评级。

第 5 步：课件点名了 **SVM、k-means、DBSCAN、神经网络**，因为它们的几何结构或优化过程依赖特征量级。例：KNN 用年龄（0–100）和收入（0–100000），不缩放的话距离几乎只由收入决定。

第 6 步术语区别（考点）：★ 训练集用 `fit_transform`（学 + 用）；验证／测试集只能用 `transform`（只用不学）。

13.2 三类泄漏源

类型	含义	例子
未来信息	用了预测时点之后才知道的东西	预测客户是否流失，特征含「账户取消日期」
目标衍生字段	特征其实是答案的变形	预测是否患病，特征含「是否在服用该病特效药」
测试集统计量	用全数据算的均值／标准差／中位数	上面第 3 步那个例子

典型症状：**分数好得不真实**。看到 99.8% 准确率时第一反应应该是怀疑。

13.3 工程做法：Pipeline + ColumnTransformer

- **Pipeline**：把「预处理 + 模型」打包成一个整体
- **ColumnTransformer**：让不同列走不同处理（数值列标准化、类别列 one-hot）

★ 为什么必须这么做：交叉验证会反复把数据分成不同的训练／验证折。若在 CV 之前就把整个数据集标准化，每一折的验证部分都参与了均值和标准差的计算——泄漏。Pipeline 会在每一折内部重新执行正确的 fit/transform 顺序。

一句话记住整页：先分割 → 只在训练集上 fit → 在其他数据上只 transform → 全程用 Pipeline 包住。

14. 第 31 页　Week 1 Practical 概览

任务：用人均 GDP 预测生活满意度——一个特征、一个连续输出，属于**监督学习中的回归**。

课件定心丸：这是第一个 practical，不要求理解每个模型的细节，重点是看到完整流水线长什么样。

14.1 Q1.1 查看前五行

用 `df.head()`。要看出：有几列、哪列是特征 X 哪列是目标 y、每列的数据类型和单位、有多少行（样本量很小，这会成为 Q1.3 的关键局限）。

14.2 Q1.2 给定 GDP 预测满意度

线性回归学的是：满意度 = w × GDP + b。w（斜率）= GDP 每增加一个单位满意度平均变化多少；b（截距）= GDP 为 0 时的预测值，往往没有现实意义，只是数学锚点。

14.3 Q1.3 解释关系与局限（最重要）

关系本身：正相关——人均 GDP 越高，生活满意度倾向越高。

局限性（至少说出三条）：

1. **相关不等于因果。**可能有共同原因（医疗、教育、治安），都没进模型。
2. **真实关系可能不是直线。**经济学上常见边际递减——从穷到小康提升巨大，从富到更富提升很小。
3. **单一特征太简陋。**满意度还受健康、社会支持、自由度影响，只用 GDP 属于欠拟合。
4. **外推危险。**拿远超数据范围的 GDP 去预测，模型只是盲目延长直线。
5. **样本量小**，每个国家只有一个点，结论不稳健。

14.4 Q2.1 改变超参数观察拟合变化

设置	现象	诊断
树深度很浅／K 很大	预测曲线很平、很粗糙	欠拟合
树深度很深／K = 1	曲线剧烈锯齿，穿过每个训练点	过拟合
中间值	跟随趋势但不追逐噪声	良好拟合

> ★ K 的方向是反的：K 越小模型越复杂（K=1 就是照抄最近邻居），K 越大越平滑。决策树则是深度越大越复杂。

14.5 Q2.2 三模型对比

	线性回归	决策树	KNN
怎么工作	拟合一条直线	按特征反复切分，分区取平均	找最近的 K 个邻居取平均
优势	简单、可解释、能外推	能捕捉非线性、不需缩放、可解释	极简单、无需真正训练、能捕捉局部模式
局限	只能表达线性关系；外推可能不切实际	容易过拟合，对扰动敏感，预测呈阶梯	必须标准化；数据大时预测慢；无法自然外推
曲线形状	平滑直线	阶梯	阶梯／锯齿，两端变平

第二部分　专题深入

15. 损失函数专题：MSE 与二元交叉熵

两者都是损失函数——给「模型预测得有多差」打分。区别在于服务的任务类型：MSE 用于**回归**，交叉熵用于**分类**。

15.1 均方误差 MSE

$$MSE = (1/n)\ \Sigma_i\ (y_i - \hat{y}_i)^2$$

三步走：① 每个样本算「真实值 − 预测值」 ② 每个误差平方 ③ 所有平方误差求平均。

真实 y	预测 ŷ	误差	误差²
100	110	−10	100
200	190	+10	100
300	350	−50	2500

MSE = (100 + 100 + 2500) / 3 = 900。

为什么要平方？ ① **防止正负抵消**：−10 和 +10 直接相加变成 0，看起来「完全没错」。② **重罚大误差**：差 50 的那套贡献 2500，占绝大部分——同时也意味着 MSE 对离群点很敏感。③ **可导**：平方处处光滑可导，梯度下降才能用（绝对值在 0 点不可导）。

15.2 二元交叉熵 Binary Cross-Entropy

$$L = -[\, y \cdot \log p + (1-y) \cdot \log(1-p) \,]$$

y 是真实标签（只能是 0 或 1），p 是模型输出的概率。公式其实是个「开关」：

情况	化简为	含义
y = 1	L = −log p	(1−y)=0，第二项消失
y = 0	L = −log(1−p)	y=0，第一项消失

★ 本质一句话：取「模型分配给正确答案的那个概率」，然后取负对数。

模型预测 p（真实 y=1）	损失 −log p	解读
0.99	0.01	自信且答对，几乎无惩罚
0.9	0.105	答对，很小的惩罚
0.5	0.693	完全瞎猜
0.1	2.30	答错了
0.01	4.61	自信地答错，重罚

★ 交叉熵的设计意图：**不怕你不确定，就怕你自信地错。**

15.3 为什么分类不用 MSE（考点）

1. **惩罚力度不对。**「90% 确信却错了」和「51% 确信却错了」性质完全不同，MSE 对两者惩罚差别不大，交叉熵则差很远。
2. **梯度会消失。**分类模型末端通常接 sigmoid，sigmoid 在两端导数趋近 0。用 MSE 的话，模型一旦「自信地错」，梯度几乎为 0，学不动。

★ 配上交叉熵后，梯度化简成漂亮的 $\partial L/\partial z = p - y$——错得越离谱，梯度越大，纠正越快。这正是第 24 页「激活函数的导数影响学习」所铺垫的内容。

自测： y = 0，p = 0.2 → L = −log(0.8) ≈ 0.223。

16. 概率解题两大固定框架

16.1 框架一：期望、方差、标准差 → 四列表格法

例：X 取 1、2、3，概率 0.5、0.3、0.2。

第 0 步：检查概率和是否为 1（0.5+0.3+0.2 = 1 ✓）。

x	P(x)	x · P(x)	x^2	x^2 · P(x)
1	0.5	0.5	1	0.5
2	0.3	0.6	4	1.2
3	0.2	0.6	9	1.8
求和		**E[X] = 1.7**		**$E[X^2] = 3.5$**

★ 最容易错的一步：**先把 x 平方，再乘概率**，不是把上一列结果平方。

$Var(X) = 3.5 - 1.7^2 = 0.61$　　$SD(X) = \sqrt{0.61} \approx 0.78$

五步流程固定不变：列表 → 第三列求和得 E[X] → 第五列求和得 $E[X^2]$ → 相减 → 开方。

16.2 框架二：贝叶斯筛查 → 假想 10000 人法

例题：患病率 2%，敏感度 P(+|病)=90%，假阳性率 P(+|健康)=10%。求阳性者真正患病的概率。

1. 假设有 10000 人
2. 病人 = 10000×2% = 200；健康人 = 9800
3. 病人中阳性 = 200×90% = 180（真阳性）；健康人中阳性 = 9800×10% = 980（假阳性）

	检测阳性	检测阴性	合计
患病	180	20	200
健康	980	8820	9800
合计	1160	8840	10000

P(患病 | 阳性) = 180 / 1160 ≈ 15.5%

表格里的东西	公式符号
200 / 10000	P(D) = 0.02，先验
180 / 200	P(+|D) = 0.9，似然
1160 / 10000	P(+) = 0.116，全概率公式算出的分母
180 / 1160	P(D|+) ≈ 0.155，后验

> ★ 最关键的一句：**条件概率 P(A|B) 中，竖线后面的 B 就是你的分母。**分不清方向时问自己：题目说「已知」的是什么？

两道练习：① X 取 0、1、2、3，概率 0.2、0.4、0.3、0.1，求 E[X]、$E[X^2]$、Var(X)、SD(X)。② 某病患病率 5%，敏感度 80%，假阳性率 4%，用 10000 人法求阳性者真正患病的概率。

第三部分　Practical 代码逐行精讲

17. Exercise 1：加载 → 检查 → 拟合 → 预测 → 解释

17.1 导入库

库	职责
pandas	读取和处理表格数据
matplotlib	画图
numpy	数值数组运算
scikit-learn	提供模型（这里取 `LinearRegression`）

17.2 加载数据

`load_lifesat()` 先试网络，失败就依次在 notebook 同目录、`data/` 子文件夹、Downloads 里找 `lifesat.csv`，都没有就抛 FileNotFoundError。`if "lifesat" not in globals()` 的意思是「变量不存在才加载」，所以重复运行不会重复下载。

17.3 分出 X 和 y（★ 考点）

```
X = lifesat[["GDP per capita (USD)"]].values y = lifesat[["Life satisfaction"]].values
```

> ★ 双层方括号不是笔误：`lifesat["列名"]` 返回一维 Series，`lifesat[["列名"]]` 返回二维 DataFrame。scikit-learn 要求特征 X 必须是二维的，形状 (样本数, 特征数)，这里是 (n, 1)。`.values` 再转成 numpy 数组。大写 X、小写 y 是行业惯例。

17.4 Q1.1 查看前五行

要读出：每行 = 一个国家；GDP per capita 是特征 X，单位美元，量级 2 万–6 万；Life satisfaction 是目标 y，0–10 连续 → 回归任务；样本量很

小。

> ★ 容易忽略的细节：数据似乎按 GDP **升序**排列。以后分割数据集时绝不能直接取前 80% 当训练集，否则训练集全是穷国、测试集全是富国。

17.5 可视化与训练

`kind='scatter'` 画散点图；`plt.axis([xmin,xmax,ymin,ymax])` 手动设范围；数字里的下划线 `23_500` 等价于 23500。散点呈现总体向上但比较分散——这个「分散」正是 Q1.3 的重点。

```
model = LinearRegression() # 创建模型 model.fit(X, y) # 训练：从数据学参数
```

scikit-learn 通用套路：先实例化，再 fit（estimator API）。

17.6 看学到了什么

> `coef_` = 6.77889969e-05，`intercept_` = 3.749。★ sklearn 里训练后才产生的属性都带**尾部下划线**。

```
满意度 = 3.749 + 0.0000678 × GDP
```

> ★ 斜率的正确表述方式：说「每增加 1 美元满意度增加 0.0000678」太小没感觉，换个量级——**人均 GDP 每增加 10000 美元，预测满意度平均上升约 0.68 分**。

截距 3.749 数学上是 GDP=0 时的预测值，但数据里最低 GDP 约 2.6 万，GDP=0 远在范围之外，所以没有现实解释意义，只是直线的锚点。

17.7 Q1.2 预测

```
X_new = [[37_655.2]] model.predict(X_new) # [[6.30165767]]
```

又是双层方括号——predict 的输入必须与训练时结构一致。手算验证：3.749 + 0.0000678×37655.2 ≈ 6.3017 ✓

`.item()` 把嵌套数组里的单个数字取成普通浮点数；`f"{x:.2f}"` 保留两位小数。GDP=50000 → 7.14。

> ★ 关键区分：50000 落在数据范围（2.6 万–6.2 万）之内 = **内插 interpolation**，相对可信；200000 在范围外 = **外推 extrapolation**，要格外小心。

17.8 Q1.3 参考答案框架

要点	内容
① 观察到的关系	总体正相关，但点并不精确落在直线上，说明 GDP 单独无法解释国家间的全部差异
② 被忽略的影响	健康水平、不平等程度、社会支持、文化差异、各国「满意度」测量方式本身的差异
③ 线性模型局限	直线假设整个 GDP 区间变化率恒定，很可能不成立。更灵活的模型能跟随非线性形状，但也会拟合噪声，尤其在小数据集上——不能只凭训练拟合度判定复杂模型更好
④ 因果警告	散点图支持「相关」，但不能证明提高 GDP 会导致满意度提升

18. Exercise 2：三模型对比与超参数实验

18.1 创建三个模型

```
linear_model = LinearRegression() tree_model = DecisionTreeRegressor(max_depth=3, random_state=42)
knn_model = KNeighborsRegressor(n_neighbors=5)
```

> ★ 括号里的是**超参数**（人设定的）；参数是学出来的（`coef_`）。`random_state=42` 固定随机种子保证结果可复现。

18.2 分数与最大陷阱

三个 `score(X, y)` 结果：线性 0.727、决策树 0.920、KNN 0.814。这个分数是 **R^2（决定系数）**：

R^2 值	含义
$R^2 = 1$	完美拟合
$R^2 = 0$	和「永远预测 y 的平均值」一样好，等于没用
$R^2 < 0$	比瞎猜平均值还差

★ 陷阱：**打分用的是训练时用过的同一批数据**。这就像让学生做刚背过答案的卷子。更灵活的模型天然在训练数据上分更高——`max_depth=None` 时树会分裂到每个叶子只剩一个国家，训练 R^2 直逼 1.0，但那是纯粹的背诵。正确做法是在未见数据上打分或用交叉验证；这个 notebook 故意没做分割，你要知道它「少了这一步」。

18.3 三条曲线的形状

`np.linspace(X.min(), X.max(), 100).reshape(-1, 1)`：均匀取 100 个点；`-1` 表示「这个维度自己算」。reshape 的原因和双层方括号相同——sklearn 要二维。

模型	曲线形状
线性回归	一条平滑直线
决策树	阶梯状——水平段 + 垂直跳变
KNN	阶梯／锯齿状，两端变平

★ **为什么决策树是阶梯？** 树把 GDP 轴切成若干区间，每个区间内所有输入返回同一预测值（该区间训练样本的平均），跨过分裂阈值就跳一下。

★ **为什么 KNN 两端变平？** 超出数据范围后，最近的 5 个邻居永远是最边上那 5 个，预测值不再变化——这就是「KNN 无法自然外推」。

18.4 Q2.1 超参数实验（2×3 图）

设置	曲线	诊断
max_depth=1	只有一级台阶	欠拟合
max_depth=3	几级台阶，跟随大趋势	比较合理
max_depth=None	台阶极多，穿过每个数据点	过拟合
n_neighbors=2	剧烈锯齿	偏过拟合
n_neighbors=5	中等平滑	比较合理
n_neighbors=10	很平，接近一条粗线	偏欠拟合

`sharex/sharey=True` 让所有子图共用坐标轴才能公平对比——课件「好习惯」里的「一次只改一个设置」就是这个意思。

★★ 两个超参数方向**相反**（最容易记混）：树深度 ↑ → 复杂度 ↑；KNN 的 K ↑ → 复杂度 ↓。理解方式：K=1 完全照抄最近的点（最复杂）；K = 全部样本时对所有输入返回全局平均（最简单）。

Solution 补了一句：这个实验展示的是「模型灵活性」，不是「哪个设置泛化最好」。要选最佳设置得用验证数据或交叉验证。

18.5 Q2.2 三段式参考答案

① 哪个模型最贴合训练模式？为什么不足以判定最优？ 决策树和 KNN 在图上比直线更贴合局部变化，但拟合和评估用的是同一批数据，所以更灵活的模型可能只是在拟合训练集特有的噪声。

② 三个模型各一个优点、一个局限： 见上方三模型对比表。最终选择取决于未见数据上的表现、模型用途、以及对可解释性的需求——不是「哪条曲线离训练点最近」。

③ 欠拟合／过拟合的设置与表现模式：

设置	训练表现	未见数据表现
过于严格（浅树、K 很大）→ 欠拟合	差	差

设置恰当 → 良好拟合	好	好，且与训练接近
过于灵活（无限树、K=1）→ 过拟合	很强	明显更弱

> ★ 核心结论：**模型只是更大流水线中的一环。曲线离训练点更近的模型，并不自动更好。**

第四部分　考前速查

19. 高频考点清单

#	考点	要点
1	AI／ML 分界线	规则是人给的（符号 AI）还是从数据学的（ML）
2	包含关系	AI ⊃ ML ⊃ DL ⊃ GenAI
3	监督 vs 无监督	唯一根本区别：数据有没有标签
4	分类 vs 回归	输出离散类别 vs 连续实数
5	RL 目标	最大化累积奖励，不是眼前奖励
6	梯度方向	指向上升最快方向 → 下降要取负
7	梯度是向量	不是标量；d 个变量就是 d 维
8	链式法则	外层导数（内层不动）× 内层导数——别漏乘
9	方差公式	「先平方再平均」减「先平均再平方」
10	贝叶斯分母	用全概率公式算，真阳性 + 假阳性两条路径
11	基础率谬误	低患病率下，阳性结果可信度也很低
12	凸 vs 非凸	线性／逻辑回归凸；神经网络非凸
13	学习率过大	震荡甚至发散；过小则收敛极慢
14	交叉熵特性	重罚「自信地答错」；sigmoid + 交叉熵梯度 = (p − y)
15	L1 vs L2	L1 产生稀疏（权重归零）；L2 收缩但不归零
16	参数 vs 超参数	`coef_`／`intercept_` 学出来；`max_depth`／`n_neighbors`／λ／η 人设的
17	验证集 vs 测试集	验证集做决定，测试集交答卷（只用一次）
18	过拟合的判据	看训练与验证的差距，不是训练误差多低
19	欠拟合的判据	两边都差（不是「两边接近」就叫良好拟合）
20	数据泄漏三类	未来信息／目标衍生字段／测试集统计量
21	缩放器只在训练集 fit	训练用 `fit_transform`，其他用 `transform`
22	先分割再准备	数据准备是训练的一部分，不是中性编辑
23	需要缩放的模型	SVM、k-means、DBSCAN、神经网络、KNN；决策树不需要
24	one-hot vs 序数	名义类别用 one-hot；只有真有顺序才用序数
25	Pipeline 的意义	让预处理留在 CV 每一折内部，避免泄漏
26	相关 ≠ 因果	系数解释题必写
27	内插 vs 外推	范围内 = 内插；范围外 = 外推，不可靠
28	KNN 无法外推	范围外邻居固定 → 预测变水平线
29	树是阶梯状	同区间内返回同一个预测值
30	sklearn 要二维 X	双层方括号 `[[ ]]`、`.reshape(-1,1)`

31	逆矩阵的前提	「when it exists」——方阵且满秩，呼应 Topic 2 正规方程的列满秩条件
32	矩阵乘法维度	$(m\times n)(n\times p)\to(m\times p)$；不满足交换律
33	$z = Wx + b$	线性回归、逻辑回归、神经网络一层共用同一形式；W、b 是参数不是超参数

20. 易混淆概念对照表

容易混淆的一对	左边	右边
参数 vs 超参数	模型学出来的（w、b、`coef_`）	人训练前设定的（η、λ、`max_depth`、K）
$E[X^2]$ vs $(E[X])^2$	先平方再求期望	先求期望再平方（Var = 左 − 右）
P(+|D) vs P(D|+)	敏感度：病人中阳性的比例	后验：阳性者中病人的比例
验证集 vs 测试集	用来做决定（比模型、调参）	用来交答卷（只用一次）
欠拟合 vs 过拟合	两边都差；高偏差	训练强、未见弱；高方差
MSE vs 交叉熵	回归，预测实数	分类，预测概率
L1 vs L2	$\Sigma\|\theta\|$，产生稀疏、权重归零	$\Sigma\theta^2$，整体收缩但不归零
树深度 vs KNN 的 K	深度 ↑ → 复杂度 ↑	K ↑ → 复杂度 ↓
fit_transform vs transform	只用在训练集（学＋用）	用在验证／测试／新数据（只用）
内插 vs 外推	输入在训练数据范围内	输入在范围外，不可靠
one-hot vs 序数编码	名义类别（无顺序）	真有顺序的类别
凸 vs 非凸	局部最小＝全局最小	有多个局部最小和鞍点
Series vs DataFrame	单层 `[]`，一维	双层 `[[]]`，二维（sklearn 要这个）
点积 vs 矩阵乘法	两个向量 → 一个标量	两个矩阵 → 一个矩阵，行点乘列
转置 vs 逆	行列互换，总是存在	$AA^{-1} = I$，仅方阵满秩时存在

21. 公式总表

名称	公式	备注
点积	$x^Ty = \Sigma_i x_i y_i$	结果是标量
矩阵乘法	$(AB)_{ij} = \Sigma_k A_{ik} B_{kj}$	$(m\times n)(n\times p)\to(m\times p)$
转置	$(A^T)_{ij} = A_{ji}$	行列互换
逆矩阵	$AA^{-1} = A^{-1}A = I$	仅当存在时（方阵且满秩）
L2 范数	$\|x\|_2 = \sqrt{(\Sigma x_i^2)}$	向量的欧氏长度
线性层	$z = Wx + b$	全课最核心的形式
幂法则	$d(x^n)/dx = n \cdot x^{n-1}$	指数下来当系数，指数减一
链式法则	$d[f(g(x))]/dx = f'(g(x)) \cdot g'(x)$	反向传播核心
指数导数	$d(e^x)/dx = e^x$	导数是它自己
对数导数	$d(\ln x)/dx = 1/x$	交叉熵求导必用
梯度	$\nabla f = [\partial f/\partial x_1, \cdots, \partial f/\partial x_d]^T$	是向量，指向上升最快方向
线性性	$d[af + bg]/dx = a \cdot f' + b \cdot g'$	加减可拆开
贝叶斯定理	$P(A\|B) = P(B\|A) \cdot P(A) / P(B)$	把条件反过来
离散期望	$E[X] = \Sigma_x x \cdot P(X=x)$	加权平均
连续期望	$E[X] = \int x \cdot f_X(x)\, dx$	求和换积分

方差	$\mathrm{Var}(X) = E[X^2] - (E[X])^2$	平方的期望 − 期望的平方
标准化	$Z = (X - \mu) / \sigma$	转标准正态；也是预处理做法
归一化约束	$\Sigma_x P(X=x) = 1$	softmax 也要满足
全概率公式	$P(A) = \Sigma_i P(A\|B_i) \cdot P(B_i)$	算贝叶斯的分母
全期望定律	$E[X] = E[E[X\|Y]]$	Bonus
全方差定律	$\mathrm{Var}(X) = E[\mathrm{Var}(X\|Y)] + \mathrm{Var}(E[X\|Y])$	组内平均 ＋ 组间波动
梯度下降	$\theta \leftarrow \theta - \eta \nabla L(\theta)$	负梯度方向
MSE	$\mathrm{MSE} = (1/n)\Sigma_i(y_i - \hat{y}_i)^2$	回归
二元交叉熵	$L = -[y \cdot \log p + (1-y) \cdot \log(1-p)]$	二分类
正则化目标	$L_{reg} = L_{data} + \lambda R(\theta)$	λ 控制简约程度
sigmoid＋交叉熵梯度	$\partial L / \partial z = p - y$	形式极简洁
线性回归模型	$\hat{y} = w \cdot x + b$	practical 中 w = 6.78e−05, b = 3.749