ARTI2001 机器学习 · Module 1 Topic 1 题库全集

完整版：68 道选择题 + 93 张术语速记卡 | 覆盖课件第 17–31 页、损失函数专题、概率解题框架、Practical Exercise 1 与 2

本版相对旧版新增 10 题：第 17–18 页与第 21–22 页（本周焦点与数学基础）5 题、第 23 页（线性代数）5 题；速记卡新增 8 张。课件第 1–16 页为课程管理信息，与知识点无关，未收录。使用建议：先遮住绿色答案区自测，做完再对照解析。带 ★ 的解析是高频考点或最易混淆之处。

目录

1. 第 19 页　人工智能 vs 机器学习　5 题
2. 第 20 页　学习范式　5 题
3. 第 17–18、21–22 页　本周焦点与数学基础　5 题
4. 第 23 页　线性代数　5 题
5. 第 24 页　微积分　5 题
6. 第 25 页　概率与统计　5 题
7. 第 26 页　优化　5 题
8. 第 27 页　Tutorial 数学题型　5 题
9. 第 28 页　Practical 导论　3 题
10. 第 29 页　流水线与拟合诊断　5 题
11. 第 30 页　数据准备与防泄漏　5 题
12. 第 31 页　Week 1 Practical 概览　5 题
13. Practical Exercise 1　5 题
14. Practical Exercise 2　5 题
15. 术语速记卡　90 张

第一部分　选择题

第 19 页　人工智能 vs 机器学习

1　以下哪个包含关系是正确的?

A. 三者是并列关系，互不包含
B. 人工智能 ⊃ 机器学习 ⊃ 深度学习
C. 机器学习 ⊃ 人工智能 ⊃ 深度学习
D. 深度学习 ⊃ 机器学习 ⊃ 人工智能

答案：B　AI 是伞状术语，ML 是它下面的分支，DL 又是 ML 的子领域，生成式 AI 再在 DL 之下。完整链条：AI ⊃ ML ⊃ DL ⊃ GenAI。

2　符号 AI（Symbolic AI）与机器学习最根本的区别是：

A. 符号 AI 只能处理文字，ML 只能处理数字
B. 符号 AI 更新，ML 更老
C. 符号 AI 的规则由人写入，ML 的规则从数据中学出来
D. 符号 AI 需要 GPU，ML 不需要

答案：C　★ 这是本页最重要的分界线：知识是人塞进去的（符号 AI），还是从数据里学出来的（ML）。专家系统、下棋搜索算法属于前者。

3　课件对「智能」的定义中，最关键的限定词是：

A. 速度要快
B. 能在不同情境下（across different situations）达成目标
C. 必须使用神经网络
D. 必须超过人类水平

答案：B　智能是 agent 学习、推理、适应并运用知识在不同情境下达成目标的能力。能迁移到新情境才算智能。

4　ChatGPT 和 Claude 属于哪一层?

A. 经典符号 AI
B. 机器学习但不属于深度学习
C. 生成式 AI（基于大语言模型的深度学习系统）
D. 大数据技术

答案：C　它们是会生成内容的深度学习系统，基于大语言模型（LLM）构建，属于生成式 AI 这一最内层。

5　关于 AI、数据科学与大数据的关系，正确的是：

A. 大数据包含 AI，AI 包含数据科学
B. 三者互相支撑：数据科学提供处理分析方法，大数据提供数据量
C. 数据科学是 AI 的子集
D. 三者完全无关

答案：B　课件描述的是互相支撑的关系，不是层层包含。

第 20 页　学习范式

6　监督学习与无监督学习最根本的区别是：

A. 监督学习只能做分类，无监督学习只能做回归
B. 监督学习用神经网络，无监督学习不用
C. 监督学习需要大量数据，无监督学习不需要
D. 监督学习的数据带标签，无监督学习的数据不带标签

答案：D　★ 唯一的根本区别就是数据里有没有标签（label）。其他说法都是无关或错误的附加条件。

7　预测明天的气温属于：

A. 监督学习中的分类
B. 监督学习中的回归
C. 无监督学习中的聚类
D. 强化学习

答案：B　气温是连续实数，输出连续值的监督任务叫回归。若输出是离散类别（如是否下雨）才是分类。

8　强化学习的目标是：

A. 最大化当前这一步的即时奖励
B. 最大化累积奖励（cumulative reward）
C. 最小化训练数据上的误差
D. 把数据分成若干个簇

答案：B　★ 注意 cumulative 这个词——RL 关心长期总收益，所以有时要牺牲短期利益。

9　「打标签又贵又慢，无标签数据却很便宜」这个现实动机对应哪个范式?

A. 强化学习
B. 自监督学习
C. 半监督学习
D. 无监督学习

答案：C　半监督学习把少量有标签数据和大量无标签数据结合起来用，正是为了解决标注成本问题。

10　「遮住句子里的一个词让模型去预测」属于：

A. 监督学习，因为有正确答案
B. 自监督学习，因为学习目标是从数据本身构造出来的
C. 强化学习，因为有奖励信号
D. 无监督学习中的降维

答案：B　自监督学习不需要人工标注，标签是从数据自身构造的。它是基础模型／大语言模型的主流训练方式。

第 17–18、21–22 页　本周焦点与数学基础

11　课件把哪一块数学称为「反向传播背后的引擎」？

A. 线性代数
B. 微积分
C. 概率与统计
D. 优化

答案：B　微积分（导数、梯度、链式法则）被描述为 *the engine behind backpropagation*。神经网络是复合函数，靠链式法则逐层向后传梯度。

12　课件说本次 tutorial 主要聚焦哪两块数学？

A. 线性代数和优化
B. 线性代数和概率
C. 微积分和概率
D. 四块均衡覆盖

答案：C　★课件底部明确写道：tutorial 聚焦 calculus 和 probability，而 linear algebra 与 optimisation 提供更广的课程背景（wider course context）。这直接决定了 tutorial 出题的重心。

13　损失函数与梯度下降被归在哪一块？

A. 优化
B. 线性代数
C. 概率与统计
D. 微积分

答案：A　课件把 loss functions 与 gradient descent 归在 Optimization 下，描述为「模型真正从数据中学习」的机制（how models actually learn from data）。

14　分布、期望、方差、贝叶斯法则在 ML 中的主要作用是：

A. 表示数据与变换
B. 建模不确定性与似然
C. 逐层传递误差
D. 更新模型参数

答案：B　概率与统计的定位是 *modelling uncertainty and likelihood*。选项 A 是线性代数，C 是微积分，D 是优化——这四个对应关系是第 22 页最可能出的考法。

15　第 18 页列出的本周三个目标不包括：

A. 复习支撑 ML 算法的核心数学概念
B. 建立对关键 ML 思想与术语的基础理解
C. 配置开发环境
D. 完成第一次模块测验

答案：D　三个目标是数学复习、概念与术语、环境配置，分别对应第 22–27 页、第 19–20 页、第 28–31 页。模块测验在整个模块结束时才进行。

第 23 页　线性代数

16　设 $x = (2, 0, -1)$，$y = (1, 5, 3)$，则 x^Ty = ?

A. 1
B. −1
C. 5
D. (2, 0, −3)

答案：B　对应位置相乘再求和：$2\times1 + 0\times5 + (-1)\times3 = -1$。点积的结果是一个**标量**，不是向量——选项 D 是把「逐元素相乘」误当成点积。

17　A 是 3×4 的矩阵，B 是 4×2 的矩阵，则 AB 的尺寸是：

A. 4×4
B. 2×3
C. 3×2
D. 无法相乘

答案：C　相乘要求 A 的列数 = B 的行数（4 = 4，满足），结果尺寸为（A 的行数 × B 的列数）= 3×2。口诀：$(m\times n)(n\times p) \to (m\times p)$，中间的 n 对消。

18　关于逆矩阵 A^{-1}，下列哪项正确?

A. 任何矩阵都有逆矩阵
B. 逆矩阵只在某些条件下存在（需为方阵且满秩）
C. 只要是方阵就一定可逆
D. 逆矩阵与转置是同一个东西

答案：B　★ 课件写的是 $AA^{-1} = A^{-1}A = I$, *when it exists*。这个限定词就是考点。它会在 Topic 2 讲正规方程 $\theta = (X^TX)^{-1}X^Ty$ 时再次出现——列满秩条件正是从这里来的。

19　向量 $x = (6, 8)$ 的 L2 范数 $\|x\|_2$ 等于：

A. 14
B. 100
C. 10
D. 48

答案：C　$\|x\|_2 = \sqrt{(6^2 + 8^2)} = \sqrt{100} = 10$。选项 A 是直接相加，B 是忘了开根号——最常见的两种错误。

20　线性层公式 $z = Wx + b$ 中，W 和 b 分别是：

A. W 是权重矩阵，b 是偏置向量
B. W 是偏置矩阵，b 是权重向量
C. W 是输入数据，b 是输出标签
D. W 和 b 都是从数据中直接读取的常量

答案：A　W = weights，b = bias。★ 关键补充：W 和 b 都是**参数**（学出来的），不是超参数，对应 practical 里的 `coef_` 与 `intercept_`；它们也正是 $\theta \leftarrow \theta - \eta\nabla L(\theta)$ 中被更新的 θ。

第 24 页　微积分

21　若 $f(x) = 4x^7 + 3$，则 $f'(x)$ = ?

A. $28x^6 + 3$
B. $4x^6$
C. $28x^6$
D. $7x^6$

答案：C　幂法则：指数下来当系数、指数减一 → $4 \cdot 7x^6 = 28x^6$。常数 3 的导数是 0，不能保留。

22　若 $f(x) = (3x + 1)^4$，则 $f'(x) = ?$

A. $4(3x+1)^3$
B. $12(3x+1)^3$
C. $3(3x+1)^3$
D. $12(3x+1)^4$

答案：B　链式法则：外层导数 $4(3x+1)^3$ × 内层导数 $3 = 12(3x+1)^3$。★ 最常见错误是漏乘内层导数。

23　$f(x, y) = x^2 + 3y$ 的梯度 ∇f 是：

A. $2x + 3$（一个标量）
B. $[2x, 3]^T$（一个向量）
C. $[x^2, 3y]^T$
D. $6xy$

答案：B　★ 梯度是由各偏导数组成的向量，不是标量。$\partial f/\partial x = 2x$，$\partial f/\partial y = 3$。

24　梯度的几何意义是：

A. 指向函数下降最快的方向
B. 指向函数上升最快的方向
C. 指向原点
D. 总是与 x 轴平行

答案：B　★ 梯度指向上升最快的方向，因此梯度下降要往负梯度方向走。这是理解 $\theta \leftarrow \theta - \eta\nabla L(\theta)$ 中减号的钥匙。

25　为什么 sigmoid 激活函数会导致「梯度消失」？

A. 因为它的输出总是负数
B. 因为它在两端的导数接近 0，误差信号传不回去
C. 因为它不可导
D. 因为它计算太慢

答案：B　课件指出「激活函数的导数影响学习」。sigmoid 在输出接近 0 或 1 时导数趋近 0，链式法则连乘后梯度几乎为 0，参数学不动。

第 25 页　概率与统计

26　随机变量 X 取值 0、1、2，概率分别为 0.2、0.5、0.3。$E[X] = ?$

A. 1.1
B. 1.0
C. 1.5
D. 3.0

答案：A　$E[X] = 0(0.2) + 1(0.5) + 2(0.3) = 1.1$。期望就是取值的加权平均。

27　接上题，$E[X^2] = ?$

A. 1.21
B. 1.7
C. 2.2
D. 1.1

答案：B　★ 把 x 先平方再乘概率：$0^2(0.2) + 1^2(0.5) + 2^2(0.3) = 1.7$。不是把 E[X] 平方。

28　接上题，Var(X) = ?

A. 1.7
B. 1.21
C. 0.49
D. 0.59

> **答案：C**　$\mathrm{Var}(X) = E[X^2] - (E[X])^2 = 1.7 - 1.1^2 = 1.7 - 1.21 = 0.49$。

29　贝叶斯定理中，P(A) 被称为：

A. 后验（posterior）
B. 似然（likelihood）
C. 先验（prior）
D. 证据（evidence）

> **答案：C**　P(A) 是先验，P(A|B) 是后验，P(B|A) 是似然，P(B) 是证据／归一化因子。

30　$Z = (X - \mu)/\sigma$ 的作用是：

A. 把数据变成 0 到 1 之间
B. 把任意正态分布转成均值 0、标准差 1 的标准正态分布
C. 计算方差
D. 删除离群点

> **答案：B**　Z 表示「X 距离均值有几个标准差」。这也是 ML 数据预处理里 standardisation 的做法。

第 26 页　优化

31　梯度下降的更新公式 $\theta \leftarrow \theta - \eta \nabla L(\theta)$ 中，为什么是「减去」梯度?

A. 因为梯度指向函数上升最快的方向，要下降就得反着走
B. 因为损失函数的值永远是负数
C. 因为学习率 η 是负数，两个负号抵消
D. 因为梯度指向函数下降最快的方向

> **答案：A**　梯度 $\nabla L(\theta)$ 指向上升最快的方向。要最小化损失就要往相反方向移动。η 是正的学习率，控制步长。

32　关于凸函数（convex function），下列说法正确的是：

A. 凸函数没有最小值
B. 凸函数的局部最小值一定就是全局最小值
C. 凸函数有很多个局部最小值，梯度下降容易卡住
D. 神经网络的损失函数一定是凸的

> **答案：B**　凸函数只有一个「碗底」，因此梯度下降保证能找到最优解。神经网络的损失是**非凸**的，存在多个局部最小值和鞍点。

33　如果把学习率 η 设得过大，最可能出现什么现象?

A. 训练速度变慢，但一定能收敛到全局最小值
B. 损失来回震荡甚至发散，无法收敛
C. 梯度会变成零向量
D. 模型会自动变成凸优化问题

> **答案：B**　学习率过大时每一步跨过谷底，在两侧来回跳跃，损失震荡甚至越来越大。学习率过小则相反：收敛极慢。

34　二元交叉熵 $L = -[y \log p + (1-y)\log(1-p)]$。当真实标签 $y = 1$、模型预测 $p = 0.99$ 时，损失大致是：

A. 接近 0，因为 $-\log(0.99)$ 很小

B. 接近 1，因为 $y = 1$

C. 非常大，趋于无穷

D. 恰好等于 0.99

答案：A　$y = 1$ 时第二项被 $(1-y)=0$ 消掉，只剩 $L = -\log(0.99) \approx 0.01$。★ 反过来若 p 接近 0，$-\log p$ 趋于无穷大，即「自信地答错」惩罚极重。

35　在正则化目标 $L_{reg} = L_{data} + \lambda R(\theta)$ 中，使用 L1 正则化（$R(\theta) = \Sigma|\theta|$）的典型效果是：

A. 让所有权重都均匀变大

B. 把部分权重压缩到正好为 0，产生稀疏解

C. 把所有权重按比例缩小，但不会变成 0

D. 自动为每个参数调整学习率

答案：B　L1 相当于自动做特征选择。L2（$\Sigma\theta^2$）把权重整体收缩但一般不归零。为每个参数自适应调整步长的是 Adam，不是正则化。

第 27 页　Tutorial 数学题型

36　若 $f(x) = (2x^2 + 1)^3$，则 $f'(x) = ?$

A. $3(2x^2 + 1)^2$

B. $6x(2x^2 + 1)^2$

C. $12x(2x^2 + 1)^2$

D. $3(4x)^2$

答案：C　外层 u^3 的导数是 $3u^2$，内层保持不动 → $3(2x^2+1)^2$；再乘内层导数 $4x$，得 $12x(2x^2+1)^2$。选项 A 是忘了乘内层导数的典型错误。

37　$X \sim N(100, 15^2)$，求 $P(X > 130)$。（已知 $\Phi(2) = 0.9772$）

A. 约 97.72%

B. 约 2.28%

C. 约 4.56%

D. 约 15.87%

答案：B　$z = (130 - 100)/15 = 2$。$P(X > 130) = 1 - \Phi(2) = 0.0228$。对应 68–95–99.7 法则里「超出 $\pm 2\sigma$ 约 5%，单边约 2.5%」。

38　随机变量 X 取值 0、1、2，概率分别为 0.4、0.4、0.2。Var(X) = ?

A. 0.64

B. 0.56

C. 1.20

D. 0.80

答案：B　$E[X] = 0.8$；$E[X^2] = 0(0.4) + 1(0.4) + 4(0.2) = 1.2$。$Var = 1.2 - 0.64 = 0.56$。

39　在疾病筛查题中，全概率公式 $P(A) = \Sigma_i P(A|B_i)P(B_i)$ 的作用是：

A. 验证敏感度是否大于 95%

B. 把先验概率 $P(D)$ 归一化为 1

C. 算贝叶斯公式的分母 $P(+)$，即把真阳性和假阳性两条路径加起来

D. 把连续分布转成离散分布

答案：C　阳性结果可能来自真病人（真阳性），也可能来自健康人（假阳性），两条路径都要算进去才是 $P(+)$。

40　患病率 1%，敏感度 P(+|D) = 99%，假阳性率 P(+|¬D) = 5%。检测呈阳性的人真正患病的概率最接近：

A. 约 99%，因为敏感度是 99%

B. 约 17%，因为健康人基数大，假阳性数量远超真阳性

C. 约 1%，就等于患病率

D. 约 95%，因为特异度是 95%

答案：B　1000 人中只有 10 个病人（约 10 个真阳性），却有 990 个健康人，其中 5% 误报 ≈ 50 个假阳性。P(D|+) ≈ 10/60 ≈ 17%。★ 关键不是检测不准，而是基础率太低（基础率谬误）。

第 28 页　Practical 导论

41　为什么不能用测试集（test set）来比较模型、调节参数?

A. 因为测试集样本太少，统计不可靠

B. 因为测试集没有标签，无法计算分数

C. 因为反复用测试集做决定后，它已参与开发，不再是对泛化能力的诚实估计

D. 因为测试集上的分数总是比验证集低

答案：C　测试集的唯一作用是在所有选择固定后给出一次诚实的泛化估计。开发阶段该用验证集。

42　模型准确率 95%，为什么不能直接下结论说「模型很好」?

A. 分数越高越可靠，不需要其他证据

B. 它可能来自数据不平衡、过拟合或数据泄漏，需要更多证据才能判断

C. 准确率高说明一定发生了欠拟合

D. 只要在训练集上达到 95%，模型就可以部署

答案：B　如果 95% 的样本本来就属于同一类，模型无脑全猜那一类也能拿 95%。这正是课件说「用证据支撑结论而不是单一分数」的原因。

43　课件对 practical 的要求中，下列哪项最符合「实验推理」的含义?

A. 只要代码能跑通就达标

B. 只要最终分数足够高就达标

C. 按顺序运行工作流、检查中间输出，并用证据论证结论

D. 尽量跳过中间步骤以节省时间

答案：C　课件强调 practical 同时考察正确的实验推理。代码能跑只是最低要求。

第 29 页　流水线与拟合诊断

44　某模型训练准确率 99%，验证准确率 62%。这是什么情况?

A. 欠拟合（高偏差）

B. 过拟合（高方差）

C. 良好拟合

D. 数据量不足导致的欠拟合

答案：B　训练表现强、未见数据表现弱很多，这个「差距大」就是过拟合（高方差）的定义。

45　另一个模型训练准确率 58%，验证准确率 56%。这是：

A. 良好拟合，因为两个分数很接近

B. 过拟合，应该加强正则化

C. 数据泄漏

D. 欠拟合（高偏差），模型太简单

答案：D　两边都差说明模型连训练数据的规律都没抓住。★ 良好拟合要求两边都「强」*且*接近，而不只是接近。

46　在「复杂度 vs 误差」图中，应该把模型复杂度选在哪里？

A. 训练误差最低的地方
B. 复杂度最大的地方
C. 验证误差最低的地方
D. 测试误差最低的地方

答案：C　训练误差随复杂度单调下降，不能用来选复杂度。应选验证误差最低的那一点，再往右就开始过拟合。

47　流水线中「最终测试」（final testing）阶段应该什么时候做？

A. 每调一次参数就跑一次，用来追踪进度
B. 在所有模型与参数选择都固定之后，只跑一次
C. 在训练之前先跑一次作为基准
D. 与验证集交替使用，取平均分数

答案：B　课件关键词是 after all choices are fixed 与 once。

48　发现模型欠拟合，下列哪个做法最合适？

A. 加大 L2 正则化系数 λ
B. 提早停止训练（early stopping）
C. 增加模型复杂度或加入更有用的特征
D. 减少决策树的深度

答案：C　欠拟合是模型能力不够。加正则化、早停、降低复杂度都是对付**过拟合**的手段，用在这里会适得其反。

第 30 页　数据准备与防泄漏

49　你先用整个数据集的年龄均值填补缺失值，然后才把数据分成训练集和测试集。这样做：

A. 没问题，填补缺失值只是数据清洗，不算训练
B. 有问题，这个均值包含了测试集的信息，造成泄漏
C. 有问题，应该用中位数而不是均值
D. 没问题，只要最后用测试集评分就行

答案：B　正确做法是先分割，只用训练集算均值，再用这个均值去填测试集。

50　特征「颜色」取值为红、蓝、绿。应该怎么编码？

A. 序数编码，红=0、蓝=1、绿=2
B. one-hot 编码，因为颜色之间没有真实的大小顺序
C. 直接标准化成 Z 分数
D. 删掉这一列，类别特征无法使用

答案：B　编成 0/1/2 会让模型误以为绿 > 蓝 > 红，甚至认为蓝是红和绿的平均。序数编码只用于真有顺序的类别，如学历或评级。

51　用 KNN 时，特征包括年龄（0–100）和收入（0–100000）。为什么必须标准化？

A. 为了把缺失值变成 0
B. 为了让数据服从正态分布，否则模型无法运行
C. 因为不缩放时量级大的收入会主导距离计算，年龄几乎不起作用
D. 因为 KNN 不能处理正数

答案：C　课件点名 SVM、k-means、DBSCAN 和神经网络，因为它们的几何结构或优化过程依赖特征量级。

52　预测病人是否患有某病，特征中包含「是否在服用该病特效药」。这个特征：

A. 非常好，这是很强的预测特征

B. 这是目标衍生字段造成的泄漏，特征其实是答案的变形

C. 这是测试集统计量泄漏

D. 没问题，只要做了 one-hot 编码就行

答案：B　只有已确诊的人才会服用该病特效药。模型在历史数据上表现完美，但面对未确诊的新病人时根本拿不到这个信息。

53　为什么要把预处理放进 scikit-learn 的 Pipeline，而不是提前对全部数据做好？

A. 它能让代码跑得更快

B. 它能自动选择最优的模型

C. 它让预处理留在交叉验证内部，每一折都重复正确的 fit/transform 顺序

D. 它能自动把所有类别特征变成序数编码

答案：C　若先对全量数据标准化，每一折的验证部分都参与了均值与标准差的计算，就泄漏了。

第 31 页　Week 1 Practical 概览

54　用人均 GDP 预测生活满意度，属于哪类任务？

A. 无监督学习中的聚类

B. 监督学习中的回归

C. 监督学习中的分类

D. 强化学习

答案：B　生活满意度是连续数值（如 5.8、7.2），不是离散类别。

55　把 KNN 的邻居数 K 从 10 改成 1，预测曲线会：

A. 变得更平滑，趋向欠拟合

B. 完全不变

C. 变得剧烈锯齿化，趋向过拟合

D. 变成一条直线

答案：C　K=1 时每个预测都直接照抄最近的那一个训练点，连噪声一起拿下。★ K 越大反而越平滑，这与决策树深度的方向相反。

56　有人根据这个模型得出结论：「提高人均 GDP 会导致生活满意度上升」。这个结论：

A. 合理，因为回归系数是正的

B. 不合理，相关不等于因果，可能存在未入模型的共同原因

C. 合理，只要 R^2 足够高

D. 不合理，因为应该用决策树而不是线性回归

答案：B　★ GDP 与满意度同时升高，可能是医疗、教育、治安等未入模型的共同原因造成的。模型拟合得好不能支撑因果声明。

57　关于特征缩放，下列说法正确的是：

A. 决策树必须缩放，KNN 不需要

B. KNN 必须缩放，决策树基本不受缩放影响

C. 两者都完全不需要缩放

D. 两者都必须缩放，否则无法运行

答案：B　决策树按单个特征的阈值切分，不比较不同特征之间的量级，因此不受缩放影响。

58　若拿一个远超数据范围的人均 GDP（比如数据里最高值的 5 倍）去预测，结果：

A. 可靠，因为模型已经拟合好了
B. 可靠，只要训练误差足够低
C. 不可靠，这是外推，模型只是盲目延长直线，没有数据支撑
D. 不可靠，因为线性回归无法输出小数

答案：C　现实中 GDP 对满意度的提升很可能存在边际递减。这是 Q1.3 要求指出的典型局限之一。

Practical Exercise 1　代码与解释

59　为什么要写 `lifesat[["GDP per capita (USD)"]]` 而不是 `lifesat["GDP per capita (USD)"]`？

A. 两者完全等价，只是习惯写法
B. 单层得到一维 Series，双层得到二维 DataFrame；sklearn 要求 X 是二维的
C. 双层方括号会自动删除缺失值
D. 双层方括号会自动做标准化

答案：B　★ scikit-learn 要求特征 X 必须是二维的，形状为（样本数, 特征数），这里是 (n, 1)。

60　模型斜率 `coef_` = 6.78e-05。人均 GDP 每增加 10000 美元，预测满意度大约上升：

A. 约 6.78 分
B. 约 0.068 分
C. 约 0.68 分
D. 约 67.8 分

答案：C　6.78e-05 = 0.0000678，乘以 10000 得 0.678。★ 把斜率换算到有意义的量级上叙述，比直接说「每美元 0.0000678」清楚得多。

61　截距 `intercept_` = 3.749 应该怎么解释？

A. 它是所有国家满意度的平均值
B. 数学上是 GDP=0 时的预测值，但远在数据范围之外，无现实解释意义
C. 它是模型的误差大小
D. 它是最穷国家的实际满意度

答案：B　数据中最低 GDP 约 2.6 万美元，所以这个数字只是直线的锚点。

62　用这个模型预测 GDP = 50000 和 GDP = 200000，两者的区别是：

A. 两者都是内插（interpolation）
B. 50000 是外推，200000 是内插
C. 50000 是内插，200000 是外推，后者风险大得多
D. 两者都是外推（extrapolation）

答案：C　数据中 GDP 范围约 2.6 万–6.2 万。

63　Q1.3 要求解释「为什么更灵活的模型不会自动更好」。最关键的理由是：

A. 因为复杂模型计算太慢
B. 因为更灵活的模型也会拟合噪声，必须在未见数据上比较才能下结论
C. 因为复杂模型无法做预测
D. 因为线性回归总是最准确的模型

答案：B　参考答案明确指出：更灵活的模型能跟随非线性形状，但也会拟合噪声，尤其在小数据集上。

Practical Exercise 2　三模型对比

64　三个模型的 score 分别是 0.727、0.920、0.814。据此判定「决策树最好」：

A. 合理，0.92 明显高于其他两个
B. 合理，因为决策树能捕捉非线性关系
C. 不合理，这三个分数都是在训练数据上算的，更灵活的模型天然分高
D. 不合理，因为 R^2 不能用于回归任务

答案：C　★ 三个分数都是用 `score(X, y)` 在训练时用过的同一批数据上算的。这就像让学生做刚背过答案的卷子。

65　关于两个超参数与模型复杂度的方向，正确的是：

A. `max_depth` ↑ 复杂度 ↓；`n_neighbors` ↑ 复杂度 ↑
B. `max_depth` ↑ 复杂度 ↑；`n_neighbors` ↑ 复杂度 ↓
C. 两者都是值越大复杂度越高
D. 两者都是值越大复杂度越低

答案：B　★★ 决策树深度越大能切出越多区域；KNN 的 K 越大参与平均的邻居越多，曲线越平滑。两者方向相反，最容易记混。

66　为什么决策树的拟合曲线是阶梯状的？

A. 因为数据里的 GDP 是整数
B. 因为绘图只用了 100 个点
C. 因为树把输入轴切成区间，同一区间内所有输入返回同一个预测值
D. 因为设了 `random_state=42`

答案：C　同一区间（叶子）内所有输入都返回该区间训练样本的平均，跨过分裂阈值就跳变一次。

67　KNN 的拟合曲线在数据范围的两端会：

A. 继续按原有斜率上升
B. 变成水平线，因为最近的 K 个邻居不再改变
C. 报错，无法预测
D. 自动切换到线性回归

答案：B　这就是参考答案说的「KNN 无法自然外推」。

68　下列哪些是参数（学出来的），哪些是超参数（人设的）？`coef_`、`max_depth`、`intercept_`、`n_neighbors`

A. 四个都是参数
B. `coef_` 和 `intercept_` 是参数；`max_depth` 和 `n_neighbors` 是超参数
C. `coef_` 和 `max_depth` 是参数；`intercept_` 和 `n_neighbors` 是超参数
D. 四个都是超参数

答案：B　★ `coef_` 和 `intercept_` 尾部带下划线，是 fit 之后从数据学出来的参数；`max_depth` 和 `n_neighbors` 写在构造函数里，是训练前自己选定的超参数。

第二部分　术语速记卡（93 张）

Quizlet 导入方法：新建学习集 → 选择「导入」→ 把下表左右两列复制进去 → 分隔符选「制表符 Tab」，行分隔选「换行」。也可直接遮住右栏当纸质抽认卡使用。

概念与范式

正面（术语）	背面（定义）
智能 Intelligence	agent 学习、推理、适应并运用知识在不同情境下达成目标的能力
AI 与 ML 的分界线	规则是人写入的（符号 AI）还是从数据中学出来的（ML）
包含关系	AI ⊃ 机器学习 ⊃ 深度学习 ⊃ 生成式 AI
监督学习	从有标签的输入—输出对中学习 x→y 的映射
分类 Classification	监督学习中输出为离散类别的任务

回归 Regression	监督学习中输出为连续实数的任务
无监督学习	数据无标签，模型自行发现结构：聚类、降维、关联规则挖掘
强化学习	agent 与环境交互，通过奖励／惩罚学到最大化累积奖励的策略
半监督学习	少量有标签数据 + 大量无标签数据结合使用
自监督学习	从数据本身构造学习目标，无需人工标注；基础模型的主流训练方式

数学基础与线性代数

正面（术语）	背面（定义）
四大数学板块	线性代数（表示）／微积分（求梯度）／概率统计（不确定性）／优化（更新参数）
Tutorial 聚焦范围	微积分 + 概率；线性代数与优化只作课程背景
向量／矩阵／张量	一维／二维／更高维；一条样本 = 向量，一批数据 = 矩阵
点积 Dot product	$x^Ty = \Sigma_i x_i y_i$，结果是标量，衡量两向量的对齐程度
矩阵乘法	$(AB)_{ij} = \Sigma_k A_{ik} B_{kj}$；A 的第 i 行 · B 的第 j 列
矩阵乘法维度规则	$(m\times n)(n\times p) \to (m\times p)$；A 的列数必须等于 B 的行数
矩阵乘法交换律	不成立，$AB \neq BA$
转置 Transpose	$(A^T)_{ij} = A_{ji}$，行列互换
逆矩阵 Inverse	$AA^{-1} = A^{-1}A = I$，仅当存在时；需方阵且满秩
L2 范数	$\|x\|_2 = \sqrt{(\Sigma x_i^2)}$，即向量的欧氏长度
线性层公式	$z = Wx + b$；W 权重矩阵，b 偏置向量
特征值与特征向量	PCA 降维的数学基础
前向传播的本质	forward pass = matrix multiply，一次矩阵乘法
张量运算的意义	可高效扩展，是 GPU 加速深度学习的原因

微积分

正面（术语）	背面（定义）
幂法则	$d(x^n)/dx = n \cdot x^{n-1}$
链式法则	$d[f(g(x))]/dx = f'(g(x)) \cdot g'(x)$；外层导数 × 内层导数
梯度 Gradient	各偏导数组成的向量 $\nabla f = [\partial f/\partial x_1, \cdots, \partial f/\partial x_d]^T$，指向上升最快方向
偏导数	多变量函数中对某一变量求导，其他变量当常数
指数导数	$d(e^x)/dx = e^x$
对数导数	$d(\ln x)/dx = 1/x$
梯度消失	sigmoid 等激活在两端导数趋近 0，误差信号传不回去，参数学不动

概率与统计

正面（术语）	背面（定义）
贝叶斯定理	$P(A\|B) = P(B\|A) \cdot P(A) / P(B)$
先验 prior	P(A)：还没看到证据前的概率
后验 posterior	P(A|B)：看到证据 B 之后更新的概率
似然 likelihood	P(B|A)：如果 A 成立，观察到 B 的概率

离散期望	$E[X] = \Sigma\, x \cdot P(X=x)$，即加权平均
方差公式	$Var(X) = E[X^2] - (E[X])^2$，「平方的期望减期望的平方」
正态标准化	$Z = (X - \mu)/\sigma$，表示 X 距均值几个标准差
全概率公式	$P(A) = \Sigma_i\, P(A\|B_i)P(B_i)$，常用于算贝叶斯分母
$\Phi(1)$ / $\Phi(1.96)$ / $\Phi(2)$	0.8413 / 0.9750 / 0.9772
标准正态对称性	$\Phi(-z) = 1 - \Phi(z)$；$P(Z>z) = 1 - \Phi(z)$
基础率谬误	低患病率下，即使检测很准，阳性结果的可信度也很低
全期望定律	$E[X] = E[E[X\|Y]]$
全方差定律	$Var(X) = E[Var(X\|Y)] + Var(E[X\|Y])$；组内平均 ＋ 组间波动
贝叶斯解题口诀	$P(A\|B)$ 中竖线后面的 B 就是分母

优化与损失函数

正面（术语）	背面（定义）
梯度下降更新式	$\theta \leftarrow \theta - \eta \nabla L(\theta)$；减号来自「梯度指向上升方向」
学习率 η 过大／过小	过大：震荡甚至发散；过小：收敛极慢
凸函数	只有一个最小值，局部最小 = 全局最小；线性／逻辑回归损失是凸的
非凸	存在多个局部最小值和鞍点；神经网络损失是非凸的
MSE	$(1/n)\Sigma(y_i - \hat{y}_i)^2$；用于回归，对离群点敏感
为什么 MSE 要平方	防止正负抵消、重罚大误差、处处可导
二元交叉熵	$L = -[y \log p + (1-y) \log(1-p)]$；用于二分类
交叉熵的本质	取模型分配给正确答案的那个概率，再取负对数
交叉熵的特性	重罚「自信地答错」；$p \to 0$ 时损失趋于无穷
sigmoid + 交叉熵梯度	$\partial L / \partial z = p - y$，形式极简洁
为什么分类不用 MSE	惩罚力度不对；且 sigmoid 两端梯度消失，学不动
正则化目标	$L_{reg} = L_{data} + \lambda R(\theta)$
L1 正则化	$R = \Sigma\|\theta\|$，产生稀疏解，权重被压到正好为 0
L2 正则化	$R = \Sigma\theta^2$，整体收缩权重但一般不归零
SGD	用小批量（mini-batch）估计梯度，快但带噪声
早停 early stopping	验证损失开始上升时停止训练，防止过拟合
Adam	为每个参数自适应调整步长

流水线、诊断与数据准备

正面（术语）	背面（定义）
ML 流水线五阶段	数据准备 → 训练 → 验证调参 → 最终测试（一次）→ 解释部署监控
欠拟合 Underfitting	训练和未见数据表现都差；别名高偏差 high bias
良好拟合 Good fit	两边都好且接近
过拟合 Overfitting	训练强、未见弱很多；别名高方差 high variance
过拟合的判据	看训练与验证的差距（gap），不是训练误差有多低
验证集 vs 测试集	验证集用来做决定；测试集用来交答卷，只用一次

数据准备的核心思想	数据准备是训练的一部分，不是分割前的中性编辑
数据准备七步	先分割 → 检查 → 填补 → 编码 → 缩放 → 复用 → 防泄漏
fit_transform vs transform	训练集上学＋用；验证／测试集上只用不学
三类数据泄漏	未来信息 / 目标衍生字段 / 测试集统计量
泄漏的典型症状	分数好得不真实
需要缩放的模型	SVM、k-means、DBSCAN、神经网络、KNN；决策树不需要
one-hot vs 序数编码	名义类别（无顺序）用 one-hot；真有顺序才用序数
Pipeline 的意义	让预处理留在交叉验证每一折内部，避免泄漏
ColumnTransformer	让不同列走不同的预处理

Practical 与模型对比

正面（术语）	背面（定义）
参数 vs 超参数	参数是学出来的（coef_、intercept_）；超参数是人设的（η、λ、max_depth、K）
R^2 决定系数	1 = 完美；0 = 与预测均值同样好；可为负数
内插 vs 外推	输入在训练范围内 = 内插；范围外 = 外推，不可靠
决策树深度方向	max_depth ↑ → 模型复杂度 ↑
KNN 的 K 方向	n_neighbors ↑ → 模型复杂度 ↓（方向相反）
决策树曲线形状	阶梯状：同一区间内返回同一预测值
KNN 曲线两端	变成水平线，因为最近邻居不再改变；无法自然外推
线性回归优缺点	优：简单可解释、能外推；缺：非线性时欠拟合、外推可能不切实际
决策树优缺点	优：捕捉非线性阈值、易可视化；缺：阶梯预测敏感、深树过拟合
KNN 优缺点	优：局部预测、不假设全局曲线；缺：对 K 和缩放敏感、大数据慢、不能外推
相关 ≠ 因果	系数为正只说明同向变化，可能存在未入模型的共同原因
sklearn 要二维 X	用双层方括号 [[ ]] 或 .reshape(-1, 1)
sklearn 尾部下划线	coef_、intercept_ 等属性只在 fit 之后才存在
estimator API	所有模型统一用 .fit(X, y) 和 .predict(X)
本次 practical 的斜率与截距	w = 6.78e−05，b = 3.749；每增 1 万美元约 +0.68 分
数据按 GDP 升序排列的陷阱	不能直接取前 80% 当训练集，否则训练全穷国、测试全富国