ARTI2001 机器学习

M1 T2 · 线性回归 Quizlet 题库

28 组 · 共 140 题 · 全部含答案与解析

讲义 27 页 + Tutorial 答案 + Practical 答案

使用说明与题组目录

> **建议用法：**先遮住 **答案** 框自测，选完再对照。答错的题回到知识点 PDF 对应页复看。
> 每题都附了 **提示**，卡住时先看提示再作答，效果比直接看答案好。

组号	主题	题数
1	第 4–5 页 回归的定位	5
2	第 6 页 记号与问题设定	5
3	第 7 页 一元线性回归模型	5
4	第 8 页 最佳拟合线	5
5	第 9 页 残差	5
6	第 10 页 代价函数	5
7	第 11 页 代价曲面	5
8	第 12 页 梯度下降的直觉	5
9	第 13 页 梯度下降算法	5
10	第 14 页 学习率	5
11	第 15 页 从一个特征到多个	5
12	第 16 页 正规方程	5
13	第 17 页 特征缩放	5
14	第 18 页 过拟合与欠拟合	5
15	第 19 页 模型评估	5
16	第 20 页 五个假设	5
17	第 21 页 总结	5
18	第 22 页 辅导课活动	5
19	第 23 页 准备似然论证	5
20	第 24 页 多项式设计矩阵	5
21	第 25 页 正规方程推导计划	5
22	第 26 页 实践活动	5
23	第 27 页 notebook 工作流	5
24	Tutorial Q1 高斯 MLE 与最小二乘	5
25	Tutorial Q2 多项式回归与正规方程	5
26	Practical Ex1 理解数据	5
27	Practical Ex2 基线模型	5
28	Practical Ex3 特征工程与对比	5

题库正文

第 1 组 · 第 4–5 页：回归的定位

1. 回归（Regression）与分类（Classification）最根本的区别是：

A. 回归用直线，分类用曲线
B. 回归输出连续实数，分类输出离散标签
C. 回归是监督学习，分类是无监督学习
D. 回归需要标签，分类不需要标签

提示：想想课件对比表里「Output」那一行写的是什么。

> **答案：B。**两者都是监督学习，都需要标签。唯一的分界线是 y 的类型：连续值 → 回归；离散类别 → 分类。

2. 下列哪一个任务是分类，而不是回归？

A. 根据学习时长预测考试分数（0–100）
B. 根据历史信号估计股票未来价值
C. 判断一封邮件是不是垃圾邮件
D. 预测明天的气温（°C）

提示：哪个选项的答案不能用小数表示？

> **答案：C。**垃圾邮件判断的输出是「是 / 否」这个标签，属于分类。其余三个输出都是连续实数，属于回归。

3. 某数据集里有一列「邮编」，值如 5005、5006。把它当作连续数值特征直接喂给模型，问题在于：

A. 数值太大，会让梯度爆炸
B. 邮编是标签，5006 并不是「比 5005 多一」，做算术没有意义
C. 邮编列缺失值太多，无法使用
D. 没有问题，数字就可以当连续特征用

提示：两个邮编求平均，得到的东西代表什么地方？

> **答案：B。**这是课件点名的常见错误：邮编、学号、电话号码、球衣号码都是「长得像数字的类别」。判断方法是问自己相减或求平均是否有意义。

4. 关于 house size vs. price 那张散点图，课件想让你注意的关键点是：

A. 存在明显上升趋势，但点不会精确落在任何一条直线上
B. 所有点恰好落在一条直线上，所以线性模型是完美的
C. 点完全随机分布，说明面积与价格无关
D. 数据点太少，无法建模

提示：课件说这个现象「就是这门课存在的理由」。

> **答案：A。**趋势存在，所以用直线拟合合理；但有噪声和未测量的因素，所以点不会完全共线。目标是抓住趋势，而不是追逐每一个点。

5. 课件指出，回归与分类共用同一条流水线。在这条流水线中，两者真正不同的是：

A. 是否需要训练数据
B. 是否需要优化器
C. 代价函数和输出的形式
D. 是否属于监督学习

提示：课件原话是：变的不是 philosophy。

> **答案：C。**流水线都是「数据 → 带参数的模型 → 代价函数 → 优化器 → 评估」。变的只是代价函数和输出形式，整体哲学不变。

第 2 组 · 第 6 页：记号与问题设定

1. 在本课的记号里，$x^{(2)}$ 表示什么？

A. x 的平方
B. 第二个训练样本的输入值
C. 第二个特征（第二列）
D. 第二次迭代时的参数值

提示：课件专门拿它和 x^2 做了对比。

> **答案：B。**上标是索引（index），不是指数。$x^{(2)}$ 指第二个训练样本；x 的平方写作 x^2（不加括号）。课件把这个误读列为开学头两周最常见的错误。

2. 记号 m 代表什么?

A. 特征（输入列）的数量
B. 模型参数的数量
C. 训练样本的数量，即表格的行数
D. 梯度下降的迭代次数

提示：一行 = 一栋房子 = 一个样本。

> **答案：C。**m = number of training examples，即表格的行数。列数（特征数）是 n。互换 m 和 n 是常见错误。

3. y 和 ŷ（y-hat）的区别是:

A. y 是真实观测值，ŷ 是模型预测值
B. y 是模型预测值，ŷ 是真实观测值
C. y 是训练集的值，ŷ 是测试集的值
D. 两者完全等价，只是书写习惯不同

提示：帽子（hat）戴在谁头上，谁就是猜的。

> **答案：A。**y 是真实观测到的值，ŷ 是模型预测的值。课件原话：整门课就是想办法让 ŷ 接近 y。

4. 根据课件表格（1.0/145、1.2/175、1.5/190、1.8/200、2.0/230 …），$x^{(4)}$ 和 $y^{(4)}$ 是什么?

A. $x^{(4)} = 1.5$，$y^{(4)} = 190$
B. $x^{(4)} = 1.8$，$y^{(4)} = 200$
C. $x^{(4)} = 1.0^4 = 1.0$，$y^{(4)} = 145$
D. $x^{(4)} = 2.0$，$y^{(4)} = 230$

提示：数到表格的第四行。

> **答案：B。**索引从 1 开始，第 4 行是 x = 1.8，y = 200。选项 A 是第 3 行，选项 C 把上标当成了平方。

5. 课件的房价例子中，m 等于多少?

A. m = 5，因为表格只列了 5 行
B. m = 2，因为有 x 和 y 两列
C. m = 10，对应散点图上的 10 个点
D. 无法确定，课件未给出

提示：数一下第 4 页散点图上有几个点。

> **答案：C。**幻灯片上只显示了前 5 行，但房价例子实际 m = 10，正好对应第 4 页散点图上的 10 个点。

第 3 组 · 第 7 页：一元线性回归模型

1. 模型 $f_{w,b}(x) = wx + b$ 与中学的 $y = mx + c$ 的对应关系是:

A. w 对应 c，b 对应 m
B. w 对应 m（斜率），b 对应 c（截距）
C. w 和 b 都对应 m，c 在 ML 里不存在
D. 两者是完全不同的数学形式，无法对应

提示：斜率和截距分别对应哪个字母?

> **答案：B。**w 对应斜率 m（weight / slope），b 对应截距 c（bias / intercept）。课件强调这就是中学的 y = mx + c 换了字母。

2. 下列关于 w、b 与学习率（learning rate）的描述，哪个正确?

A. 三者都是参数
B. 三者都是超参数
C. w、b 是参数（从数据学得），学习率是超参数（人为选定）
D. w、b 是超参数，学习率是参数

提示：问自己：谁是算法自己改的?

> **答案：C。**w 和 b 是参数（parameters，也叫 weights / coefficients），从数据中学得；学习率是超参数（hyperparameter），由我们自己选定，算法从不调整它。

3. 分别增大 w 和 b，直线会怎么变?

A. 增大 w 直线变陡；增大 b 直线向上平移
B. 增大 w 直线向上平移；增大 b 直线变陡
C. 两者都只会让直线平移
D. 两者都只会改变斜率

提示：一个管「陡不陡」，一个管「高不高」。

> **答案：A。**w 控制斜率，增大会让直线旋转变陡；b 控制高度，增大会让直线整体向上平移。两者是两个相互独立的旋钮。

4. 在房价例子里，b 表示「面积为 0 时的预测价格」，这在现实中没有意义。课件对此的态度是：

A. 说明模型错了，必须把 b 强制设为 0
B. 完全没关系；b 只是个垂直偏移量，不需要单独可解释
C. 说明数据采集有错，应重新收集
D. 说明应该改用分类模型

提示：课件对这件事的态度是「That is fine」。

> **答案：B。**课件明确指出：b 是 x = 0 时的预测值，它在物理上可能毫无意义（面积为零的房子不存在），但这完全没关系——它只是一个垂直偏移量，让直线坐在正确高度。

5. 按课件的说法，「训练模型」到底在做什么？

A. 修改训练数据，让它们落在直线上
B. 增加更多的特征列
C. 在所有可能的 (w, b) 组合中搜索出最好的一对
D. 选择一个合适的学习率

提示：课件说它「nothing more mysterious than…」

> **答案：C。**课件原话：训练模型不过就是在所有可能的 (w, b) 组合中搜索出最好的那一对。后面的代价函数和梯度下降只是定义「最好」和高效地搜。

第 4 组 · 第 8 页：最佳拟合线

1. 拟合线为 f(x) = 72x + 78。当 x = 2.6 时，模型预测值 ŷ 是多少？

A. 258.0
B. 265.2
C. 187.2
D. 243.6

提示：直接代入 f(x) = 72x + 78。

> **答案：B。**72 × 2.6 = 187.2，再加 78 = 265.2。注意实际值是 258，两者不相等。

2. 课件说：「每多 1000 平方英尺，价格增加约 7.2 万美元」——这句话在用词上必须注意什么？

A. 数字 72 应该四舍五入到 70
B. 应该说「减少」而不是「增加」
C. 应说「关联着（associated with）」而不是「导致（causes）」
D. 应该先把单位换成平方米

提示：课件叫它 Language discipline。

> **答案：C。**课件专门列出「Language discipline」：说 associated with，不说 causes。模型学到的只是观测数据里的模式，而观测模式混杂着大量未区分的因素。

3. 关于橙色拟合线与十个数据点的关系，下列哪项正确？

A. 它穿过了全部十个数据点
B. 没有直线能穿过全部十个点；它是同时靠近所有点的折中
C. 它只需要穿过首尾两个点
D. 它穿过了大多数点，剩下的是异常值，应删除

提示：回想第 4 页那句「抓趋势，不追点」。

> **答案：B。**课件明确说：没有任何直线能穿过全部十个点，也永远不会有。这条线是一个同时靠近所有点的折中（compromise）。

4. 图上青色点与橙色线之间的「垂直间隙」代表什么？

A. 误差（残差），即下一页要正式测量的东西
B. 学习率的大小
C. 直线的斜率 w
D. 样本数量 m

提示：课件说它们是「the errors we'll measure next」。

> **答案：A。**点与线之间的垂直间隙就是误差（残差），下一页会把它们正式定义为 residuals 并用来构造代价函数。

5. 数据表里没有面积为 2.5 的房子。模型能给出预测吗？

A. 不能，因为表格里没有 2.5 这一行
B. 不能，必须先重新训练模型
C. 能，直线在每个面积上都给预测，结果是 258
D. 能，但只能取相邻两行的平均值 242.5

提示：直线在每一个 x 上都有值。

> **答案：C。**直线在每一个面积值上都给出预测，包括从未观测过的面积。课件指出这正是模型有用的原因（泛化）。代入：72 × 2.5 + 78 = 258。

第 5 组 · 第 9 页：残差

1. 残差（residual）的定义是：

A. 预测值 − 实际值，即 $f(x^{(i)}) - y^{(i)}$

B. 实际值 − 预测值，即 $y^{(i)} - f(x^{(i)})$

C. 实际值与预测值的比值

D. 点到直线的垂足距离

提示：看课件的英文定义式：actual − predicted。

> **答案：B。**课件定义 residual = actual − predicted。顺序不能反，否则所有符号都会反。

2. i = 4 的残差是 −7.6。这个负号说明什么？

A. 模型高估了这栋房子的价格

B. 模型低估了这栋房子的价格

C. 这栋房子是异常值

D. 计算出错了，残差不能为负

提示：课件要你把符号的含义念出声。

> **答案：A。**预测 207.6，实际 200，残差 = 200 − 207.6 = −7.6。负号表示模型高估（over-predicted）了 7.6 千美元。

3. 采用平方误差时，错 10 被认为比错 5 糟糕多少倍？

A. 2 倍

B. 一样糟

C. 4 倍

D. 10 倍

提示：平方一下再比。

> **答案：C。**$10^2 / 5^2 = 100 / 25 = 4$。课件明确指出：错 10 被视为比错 5 糟 4 倍，而不是 2 倍。这就是「不成比例地惩罚大误差」。

4. 课件提到，用绝对值代替平方的主要问题是：

A. 绝对值无法防止正负抵消

B. 绝对值在 0 处有尖角，导数不存在，不利于用微积分优化

C. 绝对值会放大离群点的影响

D. 绝对值在数学上是错误的度量

提示：想想 |x| 的图像在原点长什么样。

> **答案：B。**课件指出：平方后的函数处处光滑可微，这才能用微积分优化；而绝对值在 0 处有尖角（kink），导数不存在。MAE 的优势恰恰是更抗离群点。

5. 为什么误差沿垂直（y）方向测量，而不是沿垂直于直线的方向？

A. 因为垂直距离总是更短，计算更快

B. 因为我们从 x 预测 y，x 视为已知，所有误差都在 y 方向

C. 因为垂直于直线的距离在数学上无法定义

D. 因为这样残差才不会为负

提示：我们在预测哪个变量？

> **答案：B。**因为我们从 x 预测 y，x 被当作已知给定，所有误差都在 y 方向。测量垂直于直线的距离是另一种方法，叫 total least squares，用在两个变量都带测量误差时。

第 6 组 · 第 10 页：代价函数

1. J(w,b) 公式里那个 1/2 的作用是：

A. 让代价值减半，从而得到更好的模型

B. 求导时抵消因子 2，公式更干净；不改变最优解位置

C. 防止代价函数为负

D. 使代价不依赖于样本数量

提示：对平方项求导会提出一个什么数？

> **答案：B。**课件括号里明说：1/2 是为了后面微积分方便，它会抵消求导时出现的因子 2。常数倍缩放不会移动最小值的位置。

2. 代价函数 J(w,b) 的自变量（可以调的旋钮）是什么？

A. 输入特征 x
B. 真实值 y
C. 参数 w 和 b
D. 样本数量 m

提示：课件把它写作 J(w,b) 而不是 J(x)。

> **答案：C。**数据 x 和 y 是固定给定的；J 是 w 和 b 的函数。学习的目标就是选择 w、b 使 J(w,b) 最小。

3. 若 m = 4，四个残差分别为 −2、+6、+2、−4，则 J(w,b) = ？

A. 15
B. 7.5
C. 60
D. 0

提示：先求平方和，再除以 2m。

> **答案：B。**平方和 = 4 + 36 + 4 + 16 = 60；J = 60 / (2×4) = 60/8 = 7.5。如果忘了那个 2，会得到 15。

4. 把 J 里的 $(f(x^{(i)}) - y^{(i)})$ 写成 $(y^{(i)} - f(x^{(i)}))$，会改变 J 的值吗？

A. 会，J 的符号会变反
B. 不会，因为外面有平方，$(a-b)^2 = (b-a)^2$
C. 会，J 会变成原来的两倍
D. 会，最优的 w 和 b 会变号

提示：想想 $(a-b)^2$ 与 $(b-a)^2$。

> **答案：B。**平方让顺序无关紧要。但在没有平方的场合（如梯度公式）顺序就很关键。

5. J 里除以 m（而不是只求和）的主要理由是：

A. 为了让 J 非负
B. 为了让 J 可微
C. 取平均，使代价不随样本数量膨胀，便于公平比较
D. 为了抵消求导时的因子 2

提示：想想 100 个样本与 10000 个样本的总和差多少。

> **答案：C。**除以 m 是取平均，使代价不随数据集大小膨胀，不同规模的数据集才能公平比较。

第 7 组 · 第 11 页：代价曲面

1. 线性回归的代价是凸二次函数，这带来的最重要推论是：

A. 代价函数有很多局部最小值，容易卡住
B. 每一个局部最小值都是全局最小值
C. 代价函数可能没有最小值
D. 最小值一定出现在 w = 0 处

提示：碗只有一个底。

> **答案：B。**课件原话：Every local minimum is global。这是凸二次代价的直接推论，也是线性回归比神经网络好训练的原因。

2. 课件表中 w = 1.5 和 w = 2.5 时 J 都等于 15。这反映了什么？

A. 巧合而已，没有特别含义
B. J 是 w 的二次函数，图像关于最低点 w = 2 对称
C. 说明有两个全局最小值
D. 说明数据里有错误

提示：看看这两个 w 到最低点的距离。

> **答案：B。**J 是 w 的二次函数（抛物线），图像关于最低点 w = 2 对称。w = 1.5 与 2.5 到对称轴距离相等，所以 J 相等。

3. 第 11 页的图与第 8 页拟合图的区别在于，本页图的坐标轴是：

A. 横轴 x（面积），纵轴 y（价格）
B. 横轴样本编号 i，纵轴残差
C. 横轴参数 w，纵轴代价 J
D. 横轴迭代次数，纵轴学习率

提示：这张图上找不到房子的面积。

> **答案：C。**本页画的是代价随参数的变化（参数空间），与第 8 页「面积 vs 价格」的数据空间图完全不同。

4. 代价曲面是凸的，是否就保证梯度下降一定能找到最小值?

A. 是，凸函数下梯度下降必定收敛
B. 不是，梯度下降只有在学习率合适时才收敛
C. 是，但需要无限多次迭代
D. 不是，因为凸函数没有最小值

提示：碗是凸的，不代表你一定能滚到底。

> **答案：B。**课件列出：Gradient descent converges only with an appropriate learning rate。凸性保证最优解存在且唯一地好，但学习率不当照样可能发散。

5. 课件说「唯一解需要足够的、独立的特征信息」。如果信息不足会怎样?

A. 代价函数不再是凸的
B. 代价函数会变成负值
C. 碗底可能变成一条平坦沟槽，最优解不唯一
D. 必须改用分类模型

提示：想象碗底被拉成一条平沟。

> **答案：C。**课件原话：A unique solution requires sufficient independent feature information。特征高度相关或信息不足时，碗底会变成平坦的沟槽，存在无穷多组同样好的解。

第 8 组 · 第 12 页：梯度下降的直觉

1. 在「雾中登山」的比喻里，你在山坡上的「位置」对应的数学量是：

A. 代价 J
B. 当前的参数 (w, b)
C. 梯度
D. 学习率

提示：你能调的东西就是你的位置。

> **答案：B。**课件的对应表：位置 = (w, b)，海拔 = 代价 J，脚下坡度 = 梯度，步子大小 = 学习率。

2. 同一个比喻里，「步子的大小」对应的是：

A. 样本数 m
B. 代价 J
C. 梯度
D. 学习率

提示：跨得多远，由谁决定?

> **答案：D。**步子的大小（stride）对应学习率。海拔是 J，坡度是梯度，位置是 (w, b)。

3. 第 3 步「Step downhill」具体是怎么做的?

A. 沿梯度方向迈一大步
B. 沿梯度方向迈一小步
C. 沿梯度的反方向迈一小步
D. 随机挑一个方向迈步

提示：梯度指向上升最陡的方向。

> **答案：C。**梯度是上升最陡的方向，所以要朝其反方向迈一小步才能下坡。这就是下一页公式里那个减号的来源。

4. 课件为什么说不能用穷举搜索来找最优参数?

A. 穷举搜索找到的解不够准确
B. 组合数量随维度爆炸，100 个特征就需要 10^{100} 种组合
C. 穷举搜索只能用于分类问题
D. 穷举搜索需要代价函数可微

提示：课件拿宇宙中的原子数做了对比。

> **答案：B。**课件给的数字：100 个特征、每个 10 个候选值，就需要 10^{100} 种组合，比可观测宇宙中的原子数还多。穷举搜索在现实维度下立刻失效。

5. 课件提到，在 practical 中你最可能使用的停止准则是：

A. 代价降到恰好等于 0
B. 残差全部变为正数
C. 跑固定的迭代次数，然后检查代价曲线是否变平
D. 学习率自动降到 0

提示：三个准则里哪个最好实现?

> **答案：C。**课件给了三个准则：代价不再明显下降、梯度约等于零、达到固定迭代次数。并指出 practical 中多半用固定次数，然后检查代价曲线是否变平。

第 9 组 · 第 13 页：梯度下降算法

1. 更新公式 w := w − α ∂J/∂w 中，α 是什么？

A. 梯度，指向上升最陡的方向
B. 学习率，控制每一步迈多大
C. 代价函数的值
D. 迭代次数

提示：回忆雾中登山里的「步子大小」。

> **答案：B。**α 是学习率（learning rate），控制每一步迈多大。它是超参数，由人选定，算法不会自己调它。

2. 为什么公式里是「减去」梯度而不是「加上」？

A. 为了让参数变成负数
B. 为了抵消 J 里的 1/2
C. 梯度指向上坡，减去它才能把参数推向下坡
D. 为了保证代价非负

提示：梯度指向 steepest ascent。

> **答案：C。**课件列出：梯度指向上坡（代价增加的方向），减去它就把参数推向下坡。

3. 先用公式更新 w，再用已经改过的新 w 去算 ∂J/∂b 并更新 b。这样做：

A. 没有问题，结果完全一样
B. 错误：b 的梯度用了新 w，不再是同一点上的最陡下坡方向
C. 错误：应该先更新 b 再更新 w
D. 没有问题，只是收敛更快

提示：∂J/∂b 的表达式里有没有 w？

> **答案：B。**必须同时更新：两个梯度都要用同一组旧参数计算。因为 ∂J/∂b 的计算里包含 w，先改 w 会导致 b 的梯度算在了另一个点上。这是手算和写代码时最常见的错误。

4. 若在某点梯度恰好为 0，根据更新公式会发生什么？

A. 参数会变成 0
B. 参数会发散
C. 参数保持不变，算法停在原地
D. 学习率会自动变大

提示：把 0 代入公式看看。

> **答案：C。**w := w − α · 0 = w，参数不变。这正是「梯度约等于 0」可作为停止准则的原因；对凸的线性回归而言这就是全局最优点。

5. 课件说「在光滑的最小值附近，梯度幅度通常会缩小」。这意味着：

A. 因此任何学习率都能保证收敛
B. 步子会自动变小，但收敛仍取决于合适的学习率
C. 因此必须手动把 α 调大
D. 说明代价函数不再凸

提示：课件在同一列里紧接着又提醒了一句。

> **答案：B。**课件同时列出两条：接近光滑最小值时梯度幅度往往缩小（步子自动变小）；但收敛仍取决于合适的学习率。自动减速不等于万无一失。

第 10 组 · 第 14 页：学习率

1. 你把 J 对迭代次数作图，发现代价在上升。这说明：

A. α 太小
B. α 太大
C. 样本数 m 太少
D. 代价函数不凸

提示：课件对这个症状用了 full stop 一词。

> **答案：B。**课件原话：如果代价曾经上升，就是 α 太大，full stop。步子跨过了谷底。

2. 学习率「刚好」时，代价曲线应该是什么形状？

A. 浅浅的、几乎笔直的下降线
B. 上下振荡但总体下降
C. 先陡降，然后变平
D. 一直水平不变

提示：课件说这就是你想看到的形状。

> **答案：C。**课件描述 just right 的形状是：先陡降然后变平（100→50→25→13→7）。浅而笔直是 α 太小，振荡或上升是 α 太大。

3. 代价先陡降后变平，但变平在一个仍然很高的值上。这是学习率问题吗？

A. 是，α 太大，应该调小
B. 是，α 太小，应该调大
C. 不是，优化已正常收敛；问题出在模型本身（欠拟合）
D. 不是，这说明代码写错了

提示：曲线形状本身是健康的吗？

> **答案：C。**曲线形状健康，说明梯度下降已正常收敛。高代价是模型本身的问题（欠拟合：特征不足或关系非线性），不是 α 的问题。考点：区分「优化问题」与「模型问题」。

4. 课件推荐的调 α 方法是：

A. 从 0.001 开始，每次加 0.001 微调
B. 在对数尺度上试 0.001、0.003、0.01、0.03、0.1，取仍能平滑下降的最大值
C. 让梯度下降自己学出最优 α
D. 固定用 0.5，这是标准值

提示：课件给了一串具体数字。

> **答案：B。**课件建议在对数尺度上搜索，并取仍然能平滑下降的最大值（大 = 快，但要保持平滑）。并补充：别指望第一次就猜对。

5. 训练时代价变成了 NaN 或无穷大。课件给出的可能原因是：

A. α 太小
B. 样本数 m 太大
C. α 大得离谱，或者特征没有做缩放
D. 学习率是参数而不是超参数

提示：课件列了两个可能原因。

> **答案：C。**课件指出：代价变成 NaN 或无穷大，说明 α 大得离谱，或者特征没有做缩放（unscaled）。

第 11 组 · 第 15 页：从一个特征到多个

1. 给定 w_1=3.1, w_2=8.5, w_3=−0.9, w_4=−2.2, b=45，特征值为 20、3、10、5。预测值是多少？

A. 127.5
B. 172.5
C. 217.5
D. 67.5

提示：逐项算：62、25.5、−9、−11，再加 b。

> **答案：B。**62 + 25.5 − 9 − 11 + 45 = 172.5，即 172,500 美元。注意负权重项要相减，最后别忘了加偏置 b = 45。

2. 有人说：「w_2 = 8.5 比 w_1 = 3.1 大，所以卧室数比面积更重要。」这个结论：

A. 正确，8.5 > 3.1
B. 正确，但需要更多数据验证
C. 错误，权重只有在特征共享同一尺度时才可比
D. 错误，因为权重为正就意味着不重要

提示：换个单位就能把权重变大变小。

> **答案：C。**课件明确警告：权重只有在特征共享同一尺度时才可比。面积以百平方英尺计、卧室以间计，尺度完全不同。这直接引出特征缩放。

3. 记号 $x_2^{(3)}$ 表示什么？

A. 第二栋房子的第三个特征
B. 第三栋房子的第二个特征（卧室数）
C. 第二个特征的三次方
D. 第二次迭代时第三个参数的值

提示：回忆第 6 页：上标一直是样本索引。

> **答案：B。**上标是样本编号，下标是特征编号。$x_2^{(3)}$ 就是第三栋房子的第二个特征，即卧室数。

4. 关于用 np.dot / @ 而不是 for 循环，课件的理由是：

A. 只是写法更简洁，速度完全一样
B. 循环更快，因为不需要建向量
C. 向量化点积快一到两个数量级，因为调用了编译版线性代数库
D. 两者结果不同，点积更精确

提示：课件说它「not merely cosmetic」。

> **答案：C。**课件指出：向量化的 NumPy 点积比等价的 Python 循环快一到两个数量级，因为它调用优化过的编译版线性代数库。

5. 有两个特征时，模型在几何上是什么？

A. 一条曲线；模型变成了非线性
B. 三维中的一个平面；模型仍然是线性的
C. 两条独立的直线
D. 一个球面

提示：课件说 It stays linear throughout。

> **答案：B。**一个特征是直线，两个是三维中的平面，更多就是超平面。全程仍然是线性的，只是可视化变难。

第 12 组 · 第 16 页：正规方程

1. 与梯度下降相比，正规方程的优势是：

A. 需要学习率 α
B. 需要反复迭代
C. 不需要学习率、不需要迭代、不需要特征缩放
D. 在特征数极大时比梯度下降更快

提示：对比表里叉最多的那一列的反面。

> **答案：C。**对比表：正规方程不需要学习率、不需要迭代、不需要特征缩放；但在特征数 n 很大时很慢（$O(n^3)$）。

2. 正规方程在特征数 n 很大时的复杂度是：

A. O(n)
B. $O(n^3)$
C. O(log n)
D. O(m)，只与样本数有关

提示：正规方程里最贵的操作是什么？

> **答案：B。**课件列出：Large # of features (n) — Slow: $O(n^3)$。因为要对 X^TX 求逆，n 翻倍时间变 8 倍。

3. 设计矩阵 X 的行和列分别代表什么？

A. 行 = 样本，列 = 特征
B. 行 = 特征，列 = 样本
C. 行 = 参数，列 = 迭代次数
D. 行和列都是特征

提示：一行 = 一个样本，和第 6 页的表格一致。

> **答案：A。**课件定义：X is the design matrix (rows = examples, columns = features)，y 是目标值向量。

4. 实践中应不应该直接写 np.linalg.inv(X.T @ X) @ X.T @ y？

A. 应该，这是标准做法
B. 应该，因为它比库函数快
C. 不应该，应优先用基于 QR、SVD 或伪逆的库求解器
D. 不应该，因为正规方程已被废弃

提示：课件点名了三种方法：QR、SVD、伪逆。

> **答案：C。**课件原话：对普通最小二乘，优先使用基于 QR、SVD 或伪逆的库求解器，而不是显式构造逆矩阵；数值软件通常使用更稳定的最小二乘求解器。

5. 正规方程 $\theta = (X^TX)^{-1}X^Ty$ 什么时候会失效？

A. 学习率选得太大
B. X^TX 不可逆，例如特征共线或样本数少于特征数
C. 代价函数不凸
D. 没有做特征缩放

提示：回想第 11 页那条关于唯一解的说法。

> **答案：B。**课件说公式仅在 X^TX 可逆时成立。特征共线或样本数少于特征数时它是奇异的，对应第 11 页「唯一解需要足够的、独立的特征信息」。

第 13 组 · 第 17 页：特征缩放

1. 为什么特征范围相差悬殊时梯度下降会变慢?

A. 代价函数变得不再凸
B. 等高线变成狭长椭圆，梯度多数时候横穿山谷而不指向最小值
C. 代价会变成负值
D. 模型从线性变成非线性

提示：等高线被拉成了什么形状?

> **答案：B。**范围差距大时代价曲面变成又长又窄的山谷，等高线是狭长椭圆。大多数点上梯度横穿山谷而不指向最小值，所以路径之字形摆动。

2. Z-score 标准化 $x' = (x - \mu) / \sigma$ 之后，特征会有什么性质?

A. 每个特征被缩放到 [0, 1]
B. 每个特征的最大值变成 1
C. 每个特征均值为 0、标准差为 1
D. 每个特征的权重变成 1

提示：看公式里减了什么、除了什么。

> **答案：C。**减均值、除以标准差，结果每个特征均值为 0、标准差为 1。缩放到 [0,1] 是 min-max 归一化。

3. 在划分训练/测试集之前，先对整个数据集计算 μ 和 σ 再做标准化。这会：

A. 没问题，这样统计量更准确
B. 造成数据泄漏，虚高性能并使评估失效
C. 会让代价函数不再凸
D. 会让学习率失效

提示：课件叫它 data leakage。

> **答案：B。**必须只在训练集上计算 μ 和 σ，然后把这些存下来的值应用到验证/测试集。先算后划分会造成数据泄漏，虚高性能并使评估失效。

4. 特征缩放会让模型本质上更强吗?

A. 会，缩放后模型能拟合非线性关系
B. 会，且正规方程也必须缩放
C. 不会，它只改变梯度下降到达答案的速度；正规方程不需要缩放
D. 不会，而且它对梯度下降也没有任何帮助

提示：缩放帮的是优化过程，不是模型本身。

> **答案：C。**课件明确：缩放不会让模型本质上更强，它改变的是梯度下降到达答案的速度；而正规方程不需要缩放，因为它不迭代。

5. 标准化之后，权重的含义发生了什么变化?

A. 权重全部变成 1
B. 权重表示该特征每变化一个标准差时 y 的变化量，因此可跨特征比较
C. 权重失去一切含义
D. 权重的含义完全不变

提示：这就是第 15 页那个伏笔的答案。

> **答案：B。**课件指出：标准化后一个权重表示该特征每变化一个标准差时 y 的变化量，而不是每个原始单位。这个版本的权重才能合法地跨特征比较。

第 14 组 · 第 18 页：过拟合与欠拟合

1. 怎么判断一个模型过拟合了?

A. 训练误差和留出误差都很高
B. 训练误差很低，但留出误差高得多
C. 训练误差很高，但留出误差很低
D. 只看训练误差就能判断

提示：课件说这一条 very examinable。

> **答案：B。**训练误差低而留出误差高得多 → 过拟合；两者都高 → 欠拟合。仅凭训练误差永远无法揭示过拟合。

2. 加入 x^2、x^3 等多项式特征后得到一条摇摆的曲线。这还是线性回归吗?

A. 不是，有了曲线就不再是线性回归
B. 不是，它变成了神经网络
C. 是，「线性」指对参数线性，而不是在 x 上画直线
D. 是，但必须换用别的代价函数

提示：线性是对谁而言的?

> **答案：C。**课件强调：「线性」指的是对参数线性，而不是在 x 上画出一条直线。把 x^2 当作额外一列加进去后，今天教的一切原封不动地适用。

3. 欠拟合对应的术语是：

A. 高偏差（high bias）
B. 高方差（high variance）
C. 数据泄漏
D. 学习率过大

提示：bias 对应哪一端?

> **答案：A。**欠拟合 = 高偏差（模型太简单，在训练数据上也系统性地错）；过拟合 = 高方差。

4. 欠拟合、拟合良好、过拟合三个模型中，在训练数据上误差最低的是：

A. 欠拟合的那个
B. 拟合良好的那个
C. 过拟合的那个
D. 三者一样

提示：哪条曲线贴得最近?

> **答案：C。**过拟合模型的训练误差几乎为零，因为它贴近了每一个点。但这恰恰说明训练误差最低 ≠ 模型最好。

5. 课件给出的应对「欠拟合」的办法是：

A. 使用更少的特征
B. 增加更有信息量的特征、加多项式项、或换更灵活的模型
C. 应用 ridge 或 lasso 正则化
D. 减少训练数据量

提示：欠拟合是模型太简单，该加还是该减?

> **答案：B。**课件对欠拟合的对策：增加更有信息量的特征、加多项式项、或换更灵活的模型。正则化和减少特征是对付过拟合的。

第 15 组 · 第 19 页：模型评估

1. MSE 与 RMSE 的关键区别是：

A. RMSE 总是比 MSE 小，所以模型看起来更好
B. MSE 的单位是 y^2，RMSE 回到 y 的原始单位，因此可直接解读
C. MSE 可以为负，RMSE 不能
D. RMSE 用于分类，MSE 用于回归

提示：看两者的单位分别是什么。

> **答案：B。**MSE 的单位是 y^2，本身不直观；RMSE = $\sqrt{}$MSE 回到 y 的原始单位（如美元），所以能直接解读为「平均偏离多少美元」。

2. R^2 能不能为负?

A. 不能，因为它是平方，永远非负
B. 不能，它最小只能是 0
C. 能，在未见数据上预测很差时 R^2 可以为负
D. 能，但只在训练集上

提示：课件在 R^2 的描述里专门加了一句。

> **答案：C。**课件明确指出 R^2 在未见数据上预测很差时可以为负。负值意味着模型比「永远预测目标均值」还差。R^2 并不是某个东西的平方。

3. R^2 是拿模型与什么基线作比较?

A. 一个随机猜测的模型
B. 永远预测目标均值的基线
C. 一个完美拟合训练集的模型
D. 上一次迭代的模型

提示：课件用了 improvement over … 这个说法。

> **答案：B。**R^2 衡量相对于「预测目标均值」这个基线的改进程度。$R^2 = 0$ 表示与直接预测均值一样好。

4. 为什么评估指标要在留出的测试数据上计算?

A. 因为测试数据更干净
B. 因为训练数据太少
C. 因为仅凭训练误差无法揭示过拟合
D. 因为训练数据上无法计算 MSE

提示：回想第 18 页那句 very examinable 的话。

> **答案：C。**课件说指标通常在留出测试数据上计算，因为（第 18 页）仅凭训练误差永远无法揭示过拟合。

5. 要向非技术客户汇报「模型平均错多少钱」，应该用哪个指标?

A. MSE = 42.3，因为它是优化目标
B. RMSE = 6.5，因为它与 y 同单位，可读作平均偏离约 6,500 美元
C. R^2 = 0.94，因为它最接近 1
D. 三个都一样直观

提示：哪个数字能直接说成「多少美元」?

> **答案：B。**RMSE 与 y 同单位，可直接读作「平均偏离约 6,500 美元」。MSE 单位是 y^2，本身无直观意义。

第 16 组 · 第 20 页：线性回归的五个假设

1. 这五个假设什么时候真正重要?

A. 任何情况下五条都必须严格满足，否则不能用线性回归
B. 纯预测时可以违反好几条仍得到有用模型；做推断时它们非常重要
C. 它们只在梯度下降时适用，正规方程不需要
D. 它们只是历史遗留，现代 ML 已不关心

提示：课件说这个区分就是本页的要点。

> **答案：B。**课件开宗明义：纯预测时可以违反其中好几条而仍然得到有用的模型；如果要做推断（置信区间、p 值、声称某特征真的重要），它们就很重要。

2. 残差对拟合值的图呈现锥形（越往右越散开）。这提示什么问题?

A. 非线性
B. 多重共线性
C. 异方差（违反同方差性）
D. 残差不服从正态分布

提示：弯曲对应非线性，那锥形呢?

> **答案：C。**锥形 / 喇叭形说明方差随预测值增长，即违反同方差性，在价格和收入数据上非常常见；常用对 log(y) 建模来修复。

3. 「数据必须服从正态分布才能用线性回归。」这句话：

A. 正确
B. 错误：要求的是残差近似正态，而且只在做推断时才需要
C. 错误：实际上要求特征服从均匀分布
D. 错误：正态性对拟合直线是必需的，对推断反而不是

提示：要求正态的到底是数据还是残差?

> **答案：B。**课件点名这个误解：不是数据要正态，而是残差近似正态；而且它只在置信区间和假设检验时需要，拟合直线本身不需要。

4. 多重共线性的主要后果是：

A. 整体预测一定变得很差
B. 代价函数不再凸
C. 单个系数变得不稳定、不可信，但整体预测可能仍然很好
D. 残差一定变成锥形

提示：它影响的是解释，不一定是预测。

> **答案：C。**课件：强相关特征使单个系数不稳定、不可信赖地解释，尽管整体预测可能仍然很好。可用相关矩阵或 VIF 检查。

5. 对同一条街上的房子、跨十年的售价建模。最危险的假设是：

A. 残差正态性
B. 独立性
C. 无多重共线性
D. 线性性

提示：时间序列会威胁哪个假设?

> **答案：B。**跨十年是时间序列，相邻年份相关；同一条街的房子又共享地段、学区等因素。课件指出时间序列和重复测量是独立性最常见的违反场景。

第 17 组 · 第 21 页：总结

1. 线性回归的一句话定义是：

A. 把一个离散类别预测为特征的乘积
B. 把一个连续值预测为特征的加权和加上一个偏置
C. 把数据分成若干个簇
D. 从环境反馈中学习策略

提示：回想第 15 页那个向量形式。

> **答案：B。**课件第一条结论：线性回归把一个连续值预测为特征的加权和加上一个偏置，即 $w \cdot x + b$。

2. 梯度下降与正规方程的关系是：

A. 两者目标不同：一个最小化 J，一个最大化 R^2
B. 正规方程也需要迭代，只是更快
C. 两者都在最小化 J；梯度下降迭代求解，正规方程直接求解
D. 梯度下降用于回归，正规方程用于分类

提示：两者的目标是否一致？

> **答案：C。**课件第三条：梯度下降迭代地更新 w 和 b 以最小化 J；正规方程直接求解出它们。两者目标相同，途径不同。

3. 特征缩放主要帮助了哪一个求解方法？

A. 正规方程，因为它要求逆
B. 梯度下降，因为它靠迭代向最小值移动
C. 两者受益相同
D. 两者都不受影响

提示：哪个方法会一步一步走？

> **答案：B。**缩放加快梯度下降的收敛（第 17 页），但正规方程不迭代，所以不需要缩放（第 16 页对比表）。

4. 课件预告接下来要学的是：

A. 聚类与降维
B. 强化学习
C. 分类：感知机与逻辑回归
D. 神经网络与反向传播

提示：第 5 页就预告了监督学习的另一半。

> **答案：C。**课件 Next Steps：接下来是分类 —— 感知机与逻辑回归。对应第 5 页：分类与回归共用同一条流水线。

5. 根据总结，MSE、RMSE、R^2 应该在哪里计算？

A. 在训练数据上
B. 在留出（held-out）数据上
C. 在全部数据上，不划分
D. 在每次迭代的中间结果上

提示：第 18 页和第 19 页都强调了同一件事。

> **答案：B。**课件第五条：在留出数据上用 MSE、RMSE 和 R^2 评估。因为仅凭训练误差无法揭示过拟合。

第 18 组 · 第 22 页：辅导课活动

1. 最大化高斯对数似然等价于最小化平方误差和，这个结论的关键前提是：

A. 特征必须服从正态分布
B. 误差是独立同分布的高斯噪声 $N(0, \sigma^2)$
C. 特征已经做过 Z-score 标准化
D. 学习率足够小

提示：Q1 的标题就是 Gaussian log-likelihood。

> **答案：B。**取对数后，常数项与参数无关，剩下的是负常数乘以平方误差和，所以最大化对数似然等价于最小化 SSE。前提是误差服从独立同分布的高斯分布。

2. 对数似然中的 $-(m/2) \cdot \ln(2\pi\sigma^2)$ 一项为什么可以忽略？

A. 它等于零
B. 它就是平方误差和
C. 它不含 w 和 b，对参数而言是常数，不影响最优解
D. 它等于学习率

提示：这一项里有没有参数？

> **答案：C。**该项不含 w 和 b，对参数而言是常数，所以在对 w、b 优化时可以直接丢弃。

3. d 次多项式回归、m 个样本时，X 是 m × (d+1)。那么 X^TX 的维度是：

A. m × m
B. (d+1) × (d+1)
C. m × (d+1)
D. (d+1) × 1

提示：$(a\times b)^T$ 乘 $(a\times b)$ 结果是多少？

> **答案：B。**X 是 m × (d+1)，所以 X^TX 是 (d+1) × (d+1) 的方阵。这正是课件要求「检查矩阵维度」的原因。

4. 逆形式解 $\theta = (X^TX)^{-1}X^Ty$ 有效的条件是：

A. 只要 m > 0 就成立
B. 只要特征做过缩放就成立
C. X^TX 可逆，即 X 列满秩 rank(X) = d+1
D. 学习率选得合适

提示：Q2 明确要求说明逆形式解何时成立。

> **答案：C。**逆形式解仅在 X^TX 可逆时有效，等价于 X 列满秩。样本数少于参数数、或 x 的不同取值个数不足，都会导致失效。

5. 设计矩阵的第一列全是 1，作用是：

A. 为了归一化特征
B. 为了把偏置 b（θ_0）吸收进矩阵乘法，不用单独处理
C. 为了使 X^TX 成为方阵
D. 为了防止过拟合

提示：θ_0 乘上什么才能保持不变？

> **答案：B。**全为 1 的那一列使偏置 b（即 θ_0）能写进同一个矩阵乘法里，不用单独处理。

第 19 组 · 第 23 页：准备似然论证

1. 课件给出的第一步是什么？

A. 把具体数值代入指数项
B. 取对数，把连乘变成连加，将各个观测分离开
C. 先对参数求导并令其为零
D. 先把特征做 Z-score 标准化

提示：课件把这一步叫 product → sum。

> **答案：B。**课件第一个步骤 product → sum：用对数把各个观测分离开。似然是 m 个概率的连乘，取对数后变成连加。

2. 在 simplify carefully 这一步，课件的要求是：

A. 尽快代入数值以简化计算
B. 直接写出最终答案，省略中间步骤
C. 不代入数值，保持符号形式地追踪指数项
D. 先把 σ 设为 1 再化简

提示：课件说 without substituting values。

> **答案：C。**课件：Track the exponent without substituting values。目标是把似然与平方残差联系起来，代入具体数字反而会遮蔽结构。

3. parameter check 这一步具体要做什么？

A. 检查学习率是否合适
B. 标出哪些项依赖于模型参数，哪些是常数
C. 检查矩阵维度是否匹配
D. 检查残差是否服从正态分布

提示：课件开头就说要「辨认哪些量是固定的」。

> **答案：B。**parameter check 要求标出哪些项依赖于模型参数。只有平方和那一项含 w、b；σ、π、m 都是常数。

4. objective link 这一步要求你做什么？

A. 给出 σ 的数值估计
B. 画出残差对拟合值的图
C. 把剩余表达式与平方残差作比较，并用自己的话解释两者在优化上的联系
D. 用梯度下降跑一遍验证

提示：课件用了 in your own words 这个说法。

> **答案：C。**课件：Explain the optimisation connection in your own words。即说清楚最大化对数似然等价于最小化平方误差和，光写公式不够。

5. 本页 Study check 要求你在课前能做到什么？

A. 算出工作表里每个具体数值
B. 说出所考概念、列出推理步骤、指出该展示哪些过程
C. 背下高斯密度函数的完整形式
D. 写出完整的 Python 代码

提示：课件说 without calculating the worksheet values。

> **答案：B。**Study check 问的是能否说出所考概念、列出推理步骤、指出该展示哪些过程 —— 而不必算出工作表里的数值。这类题的分数主要在过程上。

第 20 组 · 第 24 页：多项式设计矩阵

1. 课件对设计矩阵 X 给出的两条构造规则是：

A. 每个系数一行，每个观测一列
B. 每个观测一行，每个系数一列
C. 行列都对应观测
D. 行对应迭代次数，列对应特征

提示：课件用了两句 one … per …。

> **答案：B。**课件两条铁律：Use one row per observation，Use one column per coefficient。

2. 若 X 是 n × p、β 是 p × 1，那么 $\hat{Y} = X\beta$ 的维度是：

A. p × 1
B. n × p
C. n × 1
D. p × p

提示：内侧维度抵消，外侧维度保留。

> **答案：C。**(n × p) 乘 (p × 1) = n × 1，正好是 n 个预测值。课件要求在相乘之前先检查维度。

3. 课件说「弯曲的关系可以表示出来」，靠的是什么？

A. 改用非线性模型，放弃线性回归
B. 用变换后的输入特征（如 x^2）作为新的列，模型对参数仍是线性的
C. 把 y 取对数
D. 增大学习率

提示：回想第 18 页关于「线性」的定义。

> **答案：B。**课件开篇：A curved relationship can be represented using transformed input features。对参数仍然线性，所以仍是线性回归。

4. 一般特征向量形式 $\phi(x_i)$ 中的「基项（basis terms）」可以是：

A. 只能是 x 的幂次
B. 只能是常数项
C. 任意基项，包括幂次、log x、sin x、交互项等
D. 必须是标准化后的原始特征

提示：课件写的是泛指的 [basis terms]。

> **答案：C。**$\phi(x_i) = [\text{basis terms}]^T$ 是一般形式，基项不限于多项式，也可以是 log x、sin x、交互项等。

5. 课件把列写成 $[x_i^2, x_i, 1]$。关于列的顺序：

A. 必须升幂排列，否则无法求解
B. 顺序可以自定，但 β 中系数的顺序必须一一对应
C. 顺序不重要，β 会自动对齐
D. 必须把全 1 列放在第一列

提示：列与系数是一一配对的。

> **答案：B。**列的排列顺序可以自己定，但 β 里系数的顺序必须与之一一对应，否则乘出来的模型就错了。这是手算时最容易错的地方。

第 21 组 · 第 25 页：正规方程推导计划

1. 课件给出的推导四步顺序是：

A. 求导 → 定义目标 → 展开 → 令梯度为零
B. 定义目标 → 小心展开 → 求导 → 用一阶条件
C. 检查可逆性 → 求逆 → 代入 → 验证
D. 初始化 β → 计算梯度 → 更新 → 重复

提示：先有目标函数，才能求导。

> **答案：B。**课件的四步：Define the objective → Expand carefully → Differentiate → Use the first-order condition。

2. 第四步 Use the first-order condition 中，课件特别要求什么？

A. 先代入具体数值验证
B. 先选定学习率
C. 先陈述所需的矩阵条件（X^TX 可逆 / X 列满秩）
D. 先对特征做标准化

提示：课件用了 only after 这个说法。

> **答案：C。**课件原话：Solve only after stating the required matrix condition。必须先声明 X^TX 可逆，才能写出逆形式解。直接跳过会丢分。

3. 展开 $(Y-X\beta)^T(Y-X\beta)$ 时，为什么可以把两个交叉项合并成 $-2\beta^TX^TY$？

A. 因为矩阵乘法可交换
B. 因为两项都是 1×1 标量，标量的转置等于自身
C. 因为 X 是对称矩阵
D. 因为 Y 是零向量

提示：先看这两项各自是什么维度。

> **答案：B。**展开后的 $-Y^TX\beta$ 与 $-\beta^TX^TY$ 都是 1×1 标量，标量的转置等于自身，所以两项相等可合并。这正是课件要求检查维度与转置规则的原因。

4. 令梯度 $\nabla_\beta J = -2X^TY + 2X^TX\beta$ 等于零，直接得到的方程是：

A. $\beta = X^{-1}Y$
B. $X^TX\beta = X^TY$
C. $\beta = Y - X\beta$
D. $X\beta = 0$

提示：把梯度令零后整理。

> **答案：B。**令 $-2X^TY + 2X^TX\beta = 0$，得 $X^TX\beta = X^TY$，这就是正规方程。注意它本身不需要求逆就成立。

5. 第一步 Define the objective 要求写出什么？

A. X^TX 的逆矩阵
B. 梯度表达式
C. 残差向量和平方误差目标函数
D. 学习率和迭代次数

提示：课件第一条提示就写了两个东西。

> **答案：C。**第一步 Define the objective：写出残差向量 $r = Y - X\beta$ 和平方误差目标函数 $\|Y - X\beta\|^2$。

第 22 组 · 第 26 页：实践活动

1. 课件要求预处理（如标准化）怎么做？

A. 在全部数据上拟合，再划分
B. 只在训练数据上拟合，测试集只做 transform
C. 分别在训练集和测试集上各拟合一次
D. 只在测试集上拟合

提示：回想第 17 页的 data leakage。

> **答案：B。**课件要求：fit preprocessing only on training data。否则测试集信息会泄漏进训练，虚高性能。

2. 为什么要「保持测试集划分固定」？

A. 为了让代价函数保持凸
B. 为了加快训练速度
C. 为了让不同特征组合之间的比较公平
D. 为了避免需要标准化

提示：实验比较需要控制变量。

> **答案：C。**固定划分才能保证不同特征组合之间的比较公平；每次换随机划分就分不清性能变化是特征带来的还是运气带来的。

3. 课件对 practical 的评分导向是：

A. 只要报告最高的 R^2 分数即可
B. 检查中间输出，从证据出发得出结论，而不是从单一分数出发
C. 只要代码能跑通就行
D. 尽量多试几个随机种子，选最好的那个

提示：课件说 rather than from a single score。

> **答案：B。**课件：这个 practical 既强调正确的实验推理，也强调代码；要按顺序运行工作流、检查中间输出，并从证据出发得出结论。

4. Practical 的 Q1 要求做什么?

A. 解读列、单位和可能的预测变量
B. 拟合并评估线性回归基线
C. 制作关系图和原创可视化
D. 为一组特征辩护

提示：四个题号的顺序是递进的。

> **答案：A。**Q1 是解读列、单位和可能的预测变量；Q2 是拟合基线；Q3.1 是画图；Q3.2 是特征辩护。

5. 要避免用测试数据做开发决策，应该怎么做?

A. 每试一组特征就看一次测试集分数，选最高的
B. 把测试集也加进训练以增加数据量
C. 用训练集内部的验证集或交叉验证做决策，测试集留到最后只用一次
D. 每次重新随机划分一次测试集

提示：开发决策应该在哪一部分数据上做?

> **答案：C。**应用训练集内部的验证集或交叉验证来做开发决策，测试集留到最后只用一次。反复用测试集挑特征，等于把它变成了训练集的一部分。

第 23 组 · 第 27 页：notebook 工作流

1. 课件给出的 notebook 四步工作流顺序是：

A. 构造特征 → 拟合基线 → 理解数据 → 解读
B. 拟合基线 → 理解数据 → 构造特征 → 解读
C. 理解数据 → 拟合基线 → 谨慎解读 → 构造特征并比较
D. 谨慎解读 → 理解数据 → 拟合基线 → 构造特征

提示：先看懂数据，才能拟合。

> **答案：C。**课件四步：Understand the data → Fit a baseline → Interpret carefully → Engineer and compare。

2. 第 3 步 Interpret carefully 中，关于比较系数的要求是：

A. 直接比大小，数值大的特征就重要
B. 只有在考虑尺度的前提下才能比较系数
C. 只看系数的符号，忽略大小
D. 系数没有解释价值，可以忽略

提示：第 15 页那个卧室 vs 面积的陷阱。

> **答案：B。**课件：compare coefficients only with scale in mind。未缩放时权重大小不可比（第 15、17 页）。

3. 第 2 步 Fit a baseline 要求记录哪些指标?

A. 只记录 R^2
B. 只记录 MSE
C. MSE、RMSE 和 R^2 都要记录
D. 只记录训练误差

提示：课件把三个都列出来了。

> **答案：C。**课件：use one fixed split; record MSE, RMSE and R^2。三个指标各有用途（第 19 页）。

4. 第 4 步 Engineer and compare 要求用什么为新特征辩护?

A. 训练误差降低了就行
B. 用图表和未见数据上的表现
C. 特征越多越好，不需要理由
D. 只要系数绝对值大就保留

提示：训练误差降低不说明任何问题。

> **答案：B。**课件：justify features with plots and unseen-data performance。因为过拟合只有在留出数据上才现形（第 18 页）。

5. 课件说「利用提供好的代码」，目的是让你把精力放在哪里？

A. 从零开始手写梯度下降代码
B. 尽可能优化代码运行速度
C. 解读、公平比较和特征推理
D. 背下所有 sklearn 函数名

提示：课件说代码是 supplied 的。

> **答案：C。**课件开头：Use the supplied code to focus on interpretation, fair comparisons and feature reasoning。代码是给定的，重点在解读与推理。

第 24 组 · Tutorial Q1：高斯 MLE 与最小二乘

1. 化简对数似然时，答案主要用到的两个法则是：

A. 链式法则与幂法则
B. $\log(ab) = \log a + \log b$ 与 $\log(e^u) = u$
C. 贝叶斯定理与全概率公式
D. 矩阵转置规则 $(AB)^T = B^T A^T$

提示：乘积变和，指数落地。

> **答案：B。**答案明确写出：应用 $\log(ab) = \log a + \log b$ 和 $\log(e^u) = u$。前者拆开常数因子与指数项，后者让指数项直接落下来。

2. 为什么求和号内的 $-\frac{1}{2}\log(2\pi\sigma^2)$ 可以变成 $-\frac{N}{2}\log(2\pi\sigma^2)$？

A. 它与 SSE 合并了
B. 它被求导消去了
C. 它不含下标 i，求 N 次就是乘以 N
D. 它被当作零忽略了

提示：这一项里有没有下标 i？

> **答案：C。**$-\frac{1}{2}\log(2\pi\sigma^2)$ 不含下标 i，对 N 个样本求和就是乘以 N，得到 $-\frac{N}{2}\log(2\pi\sigma^2)$。

3. 「最大化对数似然 = 最小化 SSE」，这个结论成立的直接理由是：

A. SSE 前面的系数是正的
B. 第一项是常数，SSE 前面的系数 $-1/(2\sigma^2)$ 是负的
C. 两项都与参数有关
D. 因为 σ^2 也需要同时优化

提示：系数的符号决定了方向。

> **答案：B。**答案的论证：第一项对 w_0、w_1 是常数；SSE 前面的系数是负的，所以增大对数似然就必须减小 SSE。

4. 答案的 Interpretation 部分强调了什么？

A. 任何噪声假设下 OLS 都等于 MLE
B. OLS 与 MLE 永远无关
C. 只在独立、等方差高斯噪声下 OLS 才是 MLE；假设改变时可能需要其他损失或加权
D. 只要数据量足够大，两者就等价

提示：答案末尾那段 Interpretation。

> **答案：C。**答案原话：在独立、等方差的高斯噪声假设下，普通最小二乘同时也是最大似然估计量；如果噪声假设改变，另一种损失或加权方式可能更合适。

5. 答案在开始代数化简之前做的第一件事是：

A. 先对 w_0 求偏导
B. 先定义残差 $r_i = y_i - (w_0 + w_1 x_i)$，并声明独立等方差高斯假设
C. 先把 σ^2 设为 1
D. 先把数据标准化

提示：答案开头第一行就写了它。

> **答案：B。**答案的第一个动作就是令 $r_i = y_i - (w_0 + w_1 x_i)$，并声明模型假设独立高斯误差且共同方差 $\sigma^2 > 0$。

第 25 组 · Tutorial Q2：多项式回归与正规方程

1. 对模型 $Y = ax^2 + bx + c$、n 个观测，设计矩阵 X 的维度是：

A. $n \times 2$
B. $n \times 3$
C. $3 \times n$
D. $n \times n$

提示：列数 = 未知系数的个数。

> **答案：B。**n 个观测一行，三个未知系数 a、b、c 各一列，所以 $X \in \mathbb{R}^{n \times 3}$。

2. 关于 Y 与 Xβ 的关系，答案强调了什么？

A. $Y = X\beta$ 完全成立
B. Xβ 是残差向量
C. Xβ 是拟合值向量 $\hat{Y}$；一般 $Y \neq X\beta$，因为观测含有残差
D. Xβ 的维度是 3×1

提示：回想 y 与 ŷ 的区别。

> **答案：C。**答案明说：Xβ 给出的是拟合值向量 $\hat{Y}$；一般 $Y \neq X\beta$，因为观测中含有残差误差。

3. 答案用什么论证了这个驻点确实是最小值？

A. 因为梯度等于零就一定是最小值
B. 因为 Hessian = $2X^TX$ 半正定，S(β) 是凸二次函数；列满秩时正定且解唯一
C. 因为残差平方总是非负
D. 因为学习率选得足够小

提示：二阶导数决定驻点的性质。

> **答案：B。**答案：Hessian 是 $2X^TX$，半正定，所以 S(β) 是凸二次函数；列满秩时 Hessian 正定，解唯一。

4. 从正规方程走到 $\beta = (X^TX)^{-1}X^TY$，需要的条件是：

A. n 必须等于 3
B. 所有 x_i 必须为正
C. X 的三列线性无关（列满秩）
D. 残差必须服从正态分布

提示：答案在写出逆形式前加了一个 If 子句。

> **答案：C。**答案：如果 X 的三列线性无关，那么 X^TX 可逆，才能写出逆形式解。正规方程 $X^TX\beta = X^TY$ 本身无需这个条件。

5. 答案的 Practical note 说了什么？

A. 推导和代码都应该显式求逆
B. 逆公式对推导有用；数值软件则用 QR、SVD 或伪逆，更稳定也能处理秩亏
C. 逆公式是错的，不应该写入推导
D. 只有在 n 很小时才能用矩阵方法

提示：答案说逆公式是 useful for derivation。

> **答案：B。**Practical note：逆的公式对推导有用；数值软件通常用 QR 分解、SVD 或伪逆求解最小二乘系统，更稳定且能处理秩亏情形。

第 26 组 · Practical Ex1：理解数据

1. California Housing 数据集中，每一行代表什么？

A. 一栋房子
B. 一个家庭
C. 一个街区组（block group）
D. 一个城市

提示：列名里的 Med 和 Ave 是线索。

> **答案：C。**答案明确：每一行描述的是 1990 年人口普查中加州的一个街区组。所以列名里才会充满 Med（中位数）和 Ave（平均）。

2. 目标列 MedHouseVal 的值为 4.526，它表示多少钱？

A. 4.526 美元
B. 452,600 美元
C. 4,526 美元
D. 45,260 美元

提示：答案写的是 in units of $100,000。

> **答案：B。**MedHouseVal 的单位是 $100,000，所以 4.526 表示 452,600 美元。单位直接影响对 MSE 和系数的解读。

3. 答案为什么说「直方图不能证明一个特征能预测房价」？

A. 因为直方图的 bin 数选得不对
B. 因为数据量太大
C. 因为直方图只描述单个变量自身的分布，不展示它与目标的关系
D. 因为直方图只能用于分类问题

提示：直方图里有没有出现 y?

> **答案：C。**答案原话：直方图帮我们理解范围、偏度和异常值，但一个特征自己的直方图并不能证明它能预测房价；还需要关系图或模型证据。

4. df.info() 输出告诉我们什么?

A. 有大量缺失值需要填补
B. 20640 行、9 列，无缺失值，全部为 float64
C. 有多个列是字符串类型，需要编码
D. 行数与列数相等

提示：看 Non-Null Count 那一列。

> **答案：B。**df.info() 显示 20640 条记录、9 列，每列 Non-Null Count 都是 20640，且全部为 float64，说明没有缺失值。

5. 答案为什么认为 MedInc 是合理的预测变量?

A. 它代表位置
B. 它代表住房的物理特征
C. 它代表本地的购买力（经济条件）
D. 它代表开发历史

提示：每个特征都配了一个领域理由。

> **答案：C。**答案给的理由：Income represents local purchasing power。其他特征分别代表位置、住房特征和开发历史。

第 27 组 · Practical Ex2：基线模型

1. train_test_split 里的 random_state=42 起什么作用?

A. 它能提高模型的 R^2
B. 它固定了划分，使不同特征组合之间的比较公平
C. 它自动对特征做标准化
D. 它决定了学习率

提示：不固定的话，每次比较都换一批数据。

> **答案：B。**固定随机种子使每次运行、每个特征组合都用同一批训练/测试样本，这正是课件第 26 页「保持测试集划分固定」的要求。

2. MSE ≈ 0.53，目标单位是 10 万美元。怎么把它说成人能听懂的话?

A. 平均偏离约 53,000 美元
B. 平均偏离约 530,000 美元
C. RMSE ≈ 0.73，即平均偏离约 73,000 美元
D. 平均偏离约 0.53 美元

提示：先开根号，再乘单位。

> **答案：C。**$\sqrt{0.53} \approx 0.73$，单位是 10 万美元，所以平均偏离约 73,000 美元。MSE 本身单位是目标的平方，不直观。

3. 系数表中 AveBedrms 的系数（0.779）最大。能否据此说它是最重要的特征?

A. 成立，系数最大就是最重要
B. 不成立，因为各特征单位不同，原始系数大小不能当作重要性排序
C. 不成立，因为系数为正就说明不重要
D. 成立，但需要更多数据验证

提示：回想第 15 页卧室 vs 面积的陷阱。

> **答案：B。**答案：因为各特征使用不同单位，原始系数的大小不应被当作重要性的完美排序。AveBedrms 取值集中在 1 附近，系数自然被推得很大。

4. Actual vs Predicted 图上，真实值接近 5 处出现一条水平聚集带。原因是:

A. 模型发散了
B. 学习率选得太大
C. 数据集的目标值被截断封顶在 5 左右
D. 测试集划分不均匀

提示：真实房价被人为封顶了。

> **答案：C。**答案指出：目标值接近 5 处的水平聚集反映了数据集的上限截断（upper cap）。所有更贵的房子都被压到这个值，模型无法预测超过它。

5. 这段代码没有做特征缩放。这是瑕疵吗?

A. 是瑕疵，应该加上 StandardScaler 否则结果错误
B. 没问题，LinearRegression 用闭式最小二乘求解，不迭代，不需要缩放
C. 没问题，因为数据本来就已经标准化过了
D. 是瑕疵，会导致梯度下降发散

提示：第 16 页那张对比表里有这一行。

> **答案：B。**sklearn 的 LinearRegression 用最小二乘闭式求解器，不迭代，因此不需要特征缩放。但不缩放的代价就是系数不可直接比大小。

第 28 组 · Practical Ex3：特征工程与对比

1. 对比三组特征时，循环里一直用 random_state=42。这为什么重要?

A. 为了让代码跑得更快
B. 为了避免过拟合
C. 三个模型见到完全相同的测试样本，性能差异只能归因于特征集
D. 为了自动选出最优特征

提示：实验对比需要控制变量。

> **答案：C。**循环里种子保持不变，三个模型见到完全相同的测试样本，性能差异只能归因于特征集本身。这就是「公平比较」的技术实现。

2. Selected six 的 $R^2 = 0.595$，All eight 的 $R^2 = 0.596$。这说明什么?

A. 说明六特征模型过拟合了
B. 说明 Population 和 AveOccup 对这个线性模型贡献极小
C. 说明应该再多加几个特征
D. 说明测试集太小

提示：0.595 与 0.596 差在哪里?

> **答案：B。**两者几乎相同，说明被省略的 Population 和 AveOccup 对这个特定的线性模型贡献极小，六特征集是一个合理的平衡。

3. Latitude 与 Longitude 的单变量相关系数都接近 0，但它们在模型里很有用。为什么?

A. 它们确实没用，应该删除
B. 相关系数计算错了
C. 相关系数只能捕捉单变量的线性单调关系，而地理效应需要经纬度一起看
D. 因为它们与 MedInc 高度共线

提示：相关系数只看单变量。

> **答案：C。**纬度单独看与房价无单调关系（北有旧金山、南有洛杉矶、中间内陆便宜），必须经纬度合看。答案原话：没有任何单一的简单相关系数能捕捉每一个有用的效应，尤其是地理效应。

4. 画 AveBedrms 散点图前先截到 99 分位，目的是:

A. 删除异常值以提高模型性能
B. 仅为了让图可读，避免极端值把主体模式压成一坨；不用于建模
C. 避免数据泄漏
D. 进行特征缩放

提示：注意代码注释里的 display 一词。

> **答案：B。**代码注释写的是 Limit the display。截断只为显示，过滤后的数据并没有拿去训练模型。不要把「为了画图而过滤」变成「悄悄删了数据再建模」。

5. 答案在结论末尾加了一句限定语，它说的是:

A. Population 和 AveOccup 在任何模型中都没有价值
B. 应该永久删除这两列数据
C. 这并不证明被省略的特征对每一个模型或分析都无用
D. 六特征模型已经是最优模型

提示：结论只对这个特定模型成立。

> **答案：C。**答案末句：这并不证明被省略的特征对每一个模型或分析都无用。这是方法学上的谨慎，也是拿高分的关键。

答案速查表（140 题）

组	主题	1	2	3	4	5
1	第 4–5 页 回归的定位	B	C	B	A	C
2	第 6 页 记号	B	C	A	B	C
3	第 7 页 模型 wx+b	B	C	A	B	C
4	第 8 页 最佳拟合线	B	C	B	A	C
5	第 9 页 残差	B	A	C	B	B
6	第 10 页 代价函数	B	C	B	B	C
7	第 11 页 代价曲面	B	B	C	B	C
8	第 12 页 梯度下降直觉	B	D	C	B	C
9	第 13 页 梯度下降算法	B	C	B	C	B
10	第 14 页 学习率	B	C	C	B	C
11	第 15 页 多特征	B	C	B	C	B
12	第 16 页 正规方程	C	B	A	C	B
13	第 17 页 特征缩放	B	C	B	C	B
14	第 18 页 过拟合欠拟合	B	C	A	C	B
15	第 19 页 模型评估	B	C	B	C	B
16	第 20 页 五个假设	B	C	B	C	B
17	第 21 页 总结	B	C	B	C	B
18	第 22 页 辅导课活动	B	C	B	C	B
19	第 23 页 似然论证	B	C	B	C	B
20	第 24 页 设计矩阵	B	C	B	C	B
21	第 25 页 推导计划	B	C	B	B	C
22	第 26 页 实践活动	B	C	B	A	C
23	第 27 页 notebook 工作流	C	B	C	B	C
24	Tutorial Q1	B	C	B	C	B
25	Tutorial Q2	B	C	B	C	B
26	Practical Ex1	C	B	C	B	C
27	Practical Ex2	B	C	B	C	B
28	Practical Ex3	C	B	C	B	C