M1 T2 · 线性回归 四源合并知识点

ARTI2001 Machine Learning · 讲义 27 页 + 课程网页三篇 + Tutorial 答案 + Practical 答案

按主题重构,不按讲义页码排列。

导读 · 这次合并了什么

原来的知识点全集只覆盖了讲义幻灯片、Tutorial 与 Practical。新加进来的三篇 Canvas 课程网页补的正好是讲义**跳过**的那几块推导。

来源	它独有的内容	为什么重要
讲义 27 页	全流程骨架、直觉、评估、假设、诊断表	MCQ 主要来源
网页 A《Calculating linear regression coefficients》	一元最小二乘的**标量闭式解全推导**,得到 $m = S_{xy}/S_{xx}$、$b = \bar{y} - m\bar{x}$	讲义完全没有。这是「by hand」手算题唯一能用的公式
网页 B《A Probability Interpretation》	噪声模型 → 似然 → 对数似然 → SSE 的完整链条,并明确区分 ε(噪声) 与 e(残差)	Tutorial Q1 的官方版本,ERQ 高危
网页 C《General form and gradient descent》	多特征向量形式、多项式设计矩阵、**逐参数梯度公式**与矩阵梯度 $\nabla J = (2/N)X^\top(Xw - y)$	讲义只写了 ∂J/∂w 这个符号,没给展开式。手算一步梯度下降必须用它

> **合并带来的第一个风险:四份材料用了四套记号**
>
> 同一门课里,讲义的 m 是样本数,网页 A 的 m 是斜率;讲义的代价函数带 1/2m,网页 C 的带 1/N。先过 §0 的对照表再往下读,否则后面所有公式都会对不上。

目录

1. 记号与写法的四套版本
2. 模型:从问题到假设函数
3. 误差:残差与三种代价写法
4. 解法一 · 闭式解(标量版 + 矩阵版)
5. 解法二 · 梯度下降
6. 概率解释:为什么偏偏是平方误差
7. 特征缩放与数据泄漏
8. 过拟合、欠拟合与多项式次数
9. 模型评估
10. 线性回归的五个假设
11. Tutorial 标准答案
12. Practical 标准答案
13. 讨论区 Activity 答题要点
14. 附录 · 速查表与失分点清单

0 记号与写法的四套版本 合并新增

这一节是合并后新写的,不来自任何单一材料。考场上读题的第一个动作是**认符号**,不是套公式。

0.1 符号对照表

概念	讲义幻灯片	网页 A 系数计算	网页 B 概率解释	网页 C 一般形式
截距	b	b	w_0	w_0
斜率 / 权重	w	$\boldsymbol{m}$	w_1	$w_1 \dots w_n$
样本数	$\boldsymbol{m}$	n	N	N 或 n
特征数	n	—	—	n
目标 / 预测	y / $\hat{y}$	Y / $\hat{Y}$	y / $\hat{y}$	y / $\hat{y}$
目标函数	$J = (1/2m)\Sigma(\hat{y}-y)^2$	SSE = $\Sigma(Y-\hat{Y})^2$	SSE = $\Sigma[y-(w_0+w_1x)]^2$	$J = (1/N)\|Xw-y\|^2$ (= MSE)
参数打包	θ	(m, b)	(w_0, w_1)	**w** 向量
设计矩阵列序	$[x^2, x, 1]$ (Tutorial)	—	—	$[1, x, x^2]$

三条必须内化的规则

① ***m*** **的含义看上下文。**看到 m,先确认题目在用哪套记号:出现 $y = mx + b$ 就是斜率;出现 $\Sigma_{i=1..m}$ 就是样本数。

② **三种代价只差一个正常数,argmin 完全相同。**SSE、MSE = SSE/N、Half-MSE = SSE/(2N) 的最优参数是同一组。但**梯度的数值不同**,所以手算梯度下降必须先声明用的是哪一个。

③ **设计矩阵的列序无所谓,但参数向量必须与之一一对应。**Tutorial 用降幂 $[x^2, x, 1]$ 配 $\beta = [a, b, c]^\top$;网页 C 用升幂 $[1, x, x^2]$ 配 $\mathbf{w} = [w_0, w_1, w_2]^\top$。写哪种都行,写混就全错。

0.2 常数因子对照(手算梯度必查)

代价定义	对 w_j 的梯度	矩阵形式	出处
SSE = $\Sigma(y-\hat{y})^2$	$-2\Sigma(y_i-\hat{y}_i)x_{ij}$	$-2X^\top(y-X\mathbf{w})$	网页 A
MSE = $(1/N)\Sigma(\hat{y}-y)^2$	$(2/N)\Sigma(\hat{y}_i-y_i)x_{ij}$	$(2/N)X^\top(X\mathbf{w}-y)$	网页 C
$J = (1/2m)\Sigma(\hat{y}-y)^2$	$(1/m)\Sigma(\hat{y}_i-y_i)x_{ij}$	$(1/m)X^\top(X\mathbf{w}-y)$	讲义

三行的**零点完全一样**(令梯度为 0 得到的都是 $X^\top X\mathbf{w} = X^\top y$),差别只在乘一个正常数。所以:代价定义不影响闭式解,只影响梯度下降在给定 α 下的步长。

1 模型:从问题到假设函数

1.1 任务类型:回归还是分类 讲义 p4–5

监督学习的分界线只有一条 —— 要预测的 y 是什么类型。

	Regression 回归	Classification 分类
预测什么	连续值	离散类别
输出	一个实数	一个标签 / 类
例子	房价、气温、考试分数	垃圾邮件、猫/狗/鸟、及格与否

两者都是监督学习,整条流水线一模一样:**数据 → 带参数的模型 → 代价函数 → 优化器 → 评估**。变的只有代价函数和输出形式。学会线性回归这套流程,学分类时只是换零件。

> **「看起来是数字,其实是类别」**
>
> 邮编 5005 存成数字,但 5006 并不是「比 5005 多一」,求平均没有意义 → 它是类别。同样的坑:学号、电话号码、球衣号码。判断方法:**这两个数相减 / 求平均有意义吗?**
>
> 另一个方向:从照片预测年龄是**回归**(年龄连续);分成「儿童/青年/中年/老年」四档就是**分类**。任务类型取决于输出形式,不取决于输入。

1.2 记号地基 讲义 p6

记号	含义
x	输入特征
y	目标 / 真实观测值
$\hat{y}$	模型的预测值
$(x^{(i)}, y^{(i)})$	第 i 个训练样本
m / n	样本数(行) / 特征数(列)

> **三个坑**
>
> **上标是索引不是指数。**$x^{(2)}$ = 第二栋房子,x^2 = x 的平方。加括号就是为了区分。
>
> ***m* 数 examples(行),*n* 数 features(列)。**互换是常见失分点。
>
> **y 是真实值,$\hat{y}$ 是预测值。**整门课的工程就是让 $\hat{y}$ 靠近 y。

1.3 一元模型 讲义 p7 网页 A

$$f_{w,b}(x) = wx + b \quad \equiv \quad Y = mx + b \quad \equiv \quad y = w_0 + w_1 x$$

同一个模型的三种写法:讲义 / 网页 A / 网页 B

- ***w*(斜率)**:x 每变化一个单位,y 改变多少。
- ***b*(截距)**:$x = 0$ 时的预测值。**它常常在物理上没有意义**(面积为 0 的房子不存在),这完全没问题 —— b 只是一个垂直偏移量,让直线坐到正确高度上,本身不需要能被解释。

参数 vs 超参数(高频 MCQ)

	参数 Parameters	超参数 Hyperparameters
例子	w、b(weights / coefficients)	学习率 α、多项式次数
谁定的	从数据中学出来	我们自己选
算法会调吗	会	不会,算法从不碰它

「训练模型」= 在所有可能的 (w, b) 组合里搜索最好的那一对。没有更玄的东西。

1.4 多特征与向量形式 讲义 p15 网页 C

$$\hat{y} = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

网页 C 给出的紧凑写法比讲义的 $\mathbf{w}\cdot\mathbf{x} + b$ 更进一步 —— 它把偏置**吸收进向量**:

$$\hat{y} = \mathbf{w}^\top \mathbf{x} = w_0 + \Sigma_{j=1..n}\, w_j x_j$$

其中 $\mathbf{w} = [w_0, w_1, \ldots, w_n]$,$\mathbf{x} = [\mathbf{1}, x_1, \ldots, x_n]$

> **这个 1 是整份材料里最实用的一个技巧**
>
> 把特征向量的**第一位固定为 1**,截距就变成了「第 0 个特征的权重」。好处:$\mathbf{w}^\top\mathbf{x}$ 一个式子就写完了整个模型,不用再单独拖一个 $+ b$;正规方程、梯度公式、设计矩阵全都因此统一。设计矩阵那一列全 1,来源就是它。

权重解释的两条纪律(高频考点)

① **必须加「其他条件不变」(all else held equal)**。Age 权重 −0.9 → 房龄越大预测价格越低,*在其他特征保持不变时*。这个限定语本身就是多元回归系数的定义。

② **不能因为 8.5 > 3.1 就说卧室比面积更重要**。权重只有在特征共享同一尺度时才可比。把长度从米改成厘米,权重就变成 1/100,预测结果完全不变 —— 这直接证明了权重大小不能拿来排重要性。→ §6 特征缩放

1.5 多项式回归:曲线仍然是线性回归 讲义 p18/24 网页 C

$$\hat{y}_i = w_0 + w_1 x_i + w_2 x_i^2$$

网页 C 的原话最值得背:预测关于**输入 x 是非线性的**,但关于**参数 w_0, w_1, w_2 仍然是线性的**。因此同一套最小二乘和梯度下降方法原封不动地适用。

$$\varphi(x_i) = [1,\ x_i,\ x_i^2]^\top \quad \Longrightarrow \quad \hat{y}_i = \mathbf{w}^\top \varphi(x_i)$$

φ 叫基函数(basis function);基项不一定是多项式,也可以是 log x、sin x、交互项 $x_1 x_2$

一句话答案(ERQ 常考)

「线性」指的是**对参数线性**,不是「在 x 上画出一条直线」。多项式回归不需要任何新算法 —— 把 x 变换成 $[1, x, x^2]$ 之后,做的还是线性回归。代价是:多项式特征越多,过拟合风险越大。

> $x \longrightarrow [1, x, x^2] \longrightarrow$ 线性回归

几何直观

特征数	几何形状
1 个	一条直线
2 个	三维空间中的一个平面
更多	超平面(hyperplane)

2 误差:残差与三种代价写法

2.1 残差 讲义 p9 网页 A/B

$$\text{residual} = \text{actual} - \text{predicted} = y_i - \hat{y}_i = y_i - (mx_i + b)$$

残差符号	含义
负号	模型**高估**了(over-predicted)
正号	模型**低估**了(under-predicted)

顺序永远是**实际 − 预测**,整个计算过程保持一致。误差在 **y 方向上垂直测量**,不是垂直于直线 —— 因为我们从 x 预测 y,x 被当作已知给定,所有误差都住在 y 里面。(测量垂直距离的方法叫 total least squares,用在两个变量都带测量误差的场合。)

网页 B 补的一个精确区分:噪声 ε ≠ 残差 e

ε_i(epsilon)是模型设定里**不可观测的随机误差**,它是真实数据生成过程的一部分:$y_i = w_0 + w_1 x_i + \varepsilon_i$。

$e_i = y_i - \hat{y}_i$ 是**拟合之后才算得出来的、可观测的**差值,叫残差。

「我们对 ε 做高斯假设,然后用 e 去检验这个假设」—— 残差图诊断(§9)的合法性就建立在这个区分上。ERQ 里写对这两个词能拿区分度分。

2.2 为什么把残差平方 讲义 p9

1. **否则正负相互抵消**。一条烂线如果高估和低估的量差不多,残差直接相加接近 0,毫无用处。
2. **不成比例地惩罚大误差**。错 10 被视为比错 5 糟糕 4 倍(100/25),不是 2 倍。
3. **处处光滑可微**。这才让我们能用微积分优化。绝对值在 0 处有尖角,导数不存在。

	平方误差(MSE 系)	平均绝对误差(MAE)
可微性	处处可微 ✓	0 处不可微 ✗
闭式解	有漂亮的闭式解 ✓	没有 ✗
抗离群点	弱 ✗	强 ✓

平方是**设计选择,不是自然法则**。MAE 完全合法,只是不好优化。它有概率论上的正当理由 —— 见 §5。

2.3 三种代价写法 合并

$$\text{SSE} = \Sigma_{i=1..N}(y_i - \hat{y}_i)^2 \quad \text{网页 A/B}$$

$$J(\mathbf{w}) = (1/N)\,\Sigma(\hat{y}_i - y_i)^2 = (1/N)\|\mathrm{X}\mathbf{w} - y\|_2{}^2 \quad \text{网页 C}$$

$$J(w,b) = (1/2m)\,\Sigma(f(x^{(i)}) - y^{(i)})^2 \quad \text{讲义 Half-MSE}$$

网页 C 明确说明:求和写法与矩阵写法「是同一个计算的两种等价写法」。

那个 1/2 和那个 1/N 各自在干嘛

- **1/2**:纯粹为了求导时抵消冒出来的因子 2。**不改变最优解** —— 常数倍缩放不移动最小值的位置。
- **1/N**:求平均,使代价不依赖数据集大小。100 个样本和 10000 个样本的模型才能公平比较。
- 不除 N(SSE)在推导里最干净,因为常数少。三者 argmin 相同。

> **符号顺序**
>
> 残差定义是 $y - \hat{y}$,代价函数里常写成 $(\hat{y} - y)^2$。**有平方时顺序无所谓**($(a-b)^2 = (b-a)^2$),**没平方时(梯度公式)顺序决定正负号**。网页 C 的两条梯度写法差一个负号,就是因为一条用 $(\hat{y}-y)$ 一条用 $(y-\hat{y})$ —— 见 §4.3。

2.4 代价曲面与凸性 讲义 p11

固定 b 只对 w 作图 → 一条碗形、**凸**的抛物线,只有一个全局最小值,且关于最低点对称。加上 b 之后变成一个碗形**曲面**,碗底那一点就是最优的 (w, b)。

别搞混两张图:数据空间(横轴 x 面积,纵轴 y 价格)vs 参数空间(横轴 w,纵轴 J)。

> **四条考点**
>
> 1. 线性回归给出的是**凸二次代价**,形状被数学保证是碗形。
> 2. **每一个局部最小值都是全局最小值。**这是凸性最重要的推论,也是线性回归远比神经网络好训练的原因 —— 不可能卡在假低谷里。
> 3. **唯一解需要足够的、独立的特征信息。**两个特征高度相关(共线性)或样本数少于特征数时,碗底成为一条平坦沟槽,有无穷多组同样好的解。
> 4. **凸性不保证算法能找到它。**「有唯一最优解」和「梯度下降能到达它」是两回事,后者取决于 α。

3 解法一 · 闭式解

讲义只给了矩阵形式的正规方程。网页 A 补上了**一元情形的标量全推导**,这是手算题唯一能用的东西。两者是同一件事在不同维度下的样子 —— §3.4 会把它们接起来。

3.1 一元最小二乘:五步推导 网页 A 全文

Step 1 · 定义误差

$$\text{Error}_i = Y_i - \hat{Y}_i = Y_i - (mx_i + b)$$

Step 2 · 目标函数

$$\text{SSE} = \Sigma_{i=1..n}\,(Y_i - (mx_i + b))^2$$

Step 3 · 两个偏导,各自令零

$$\partial \mathrm{SSE}/\partial m = -2\,\Sigma\, x_i(Y_i - (mx_i + b)) = 0$$

$$\partial \mathrm{SSE}/\partial b = -2\,\Sigma\,(Y_i - (mx_i + b)) = 0$$

各自展开整理,得到两条**标量形式的正规方程**(normal equations):

$$① \;\Sigma\, x_i Y_i = m\,\Sigma\, x_i^2 + b\,\Sigma\, x_i$$

$$② \;\Sigma\, Y_i = m\,\Sigma\, x_i + nb$$

> **这两行值得单独记**
>
> 如果题目给的是求和量(Σx、Σy、Σxy、Σx^2)而不是原始数据表,**直接把数代进这两条方程解二元一次方程组**比走 §3.2 的离差公式更快。注意方程 ② 里的 n 是样本数。

Step 4 · 解出 b 与 m

从方程 ② 直接得 b:

$$b = (\Sigma Y_i - m\,\Sigma x_i)\,/\,n$$

代回方程 ① 并用均值 $\bar{x}$、$\bar{Y}$ 化简,得到斜率:

$$m = \Sigma(x_i - \bar{x})(Y_i - \bar{Y}) \,/\, \Sigma(x_i - \bar{x})^2$$

Step 5 · 最终公式(必背)

$$m = S_{xy} \,/\, S_{xx} = \Sigma(x_i - \bar{x})(y_i - \bar{y}) \,/\, \Sigma(x_i - \bar{x})^2 \qquad b = \bar{y} - m\bar{x}$$

$\bar{x} = (1/n)\Sigma x_i, \bar{y} = (1/n)\Sigma y_i$

> **$b = \bar{y} - m\bar{x}$ 的几何含义**
>
> 它等价于说:**最小二乘直线一定穿过点 $(\bar{x}, \bar{y})$**,即数据的重心。这一条既是记忆钩子,也是手算的自检 —— 把 $\bar{x}$ 代进拟合直线,结果必须等于 $\bar{y}$。

3.2 手算流程卡 合并新增

考试的 by-hand 题基本是 4–6 个点。固定按这张表走,不要跳步。

步	算什么	写在纸上的形式
1	Σx、$\Sigma y \to \bar{x}$、$\bar{y}$	先写均值,后面全靠它
2	列表:$x_i - \bar{x}$、$y_i - \bar{y}$	两列离差,**各自求和必须 = 0**(自检点)
3	两列相乘求和 $\to S_{xy}$	第三列
4	第一列平方求和 $\to S_{xx}$	第四列
5	$m = S_{xy}/S_{xx}$	保留 3–4 位小数
6	$b = \bar{y} - m\bar{x}$	不要用方程 ② 重算,慢
7	自检:把 $\bar{x}$ 代入,应得 $\bar{y}$	5 秒,值得
8	若还要 SSE/MSE/R^2:补一列 $\hat{y}_i$ 和残差	见 §8

例题 A(五点,整数,建议先做这道)

x	1	2	3	4	5	**Σ**
y	2	4	5	4	5	**20**
$x-\bar{x}$	−2	−1	0	1	2	**0** ✓
$y-\bar{y}$	−2	0	1	0	1	**0** ✓
乘积	4	0	0	0	2	S_{xy} **= 6**
$(x-\bar{x})^2$	4	1	0	1	4	S_{xx} **= 10**

$\bar{x} = 3, \bar{y} = 4 \to m = 6/10 = \mathbf{0.6}, b = 4 - 0.6\times3 = \mathbf{2.2}$,即 $\hat{y} = 0.6x + 2.2$。

自检:$0.6\times3 + 2.2 = 4 = \bar{y}$ ✓

续算评估量:$\hat{y} = 2.8, 3.4, 4.0, 4.6, 5.2$ → 残差 $-0.8, +0.6, +1.0, -0.6, -0.2$ → SSE = 2.40,MSE = 0.48,RMSE ≈ 0.693。$SS_{tot} = \Sigma(y-\bar{y})^2 = 6 \to R^2 = 1 - 2.4/6 = \mathbf{0.60}$。

例题 B(讲义的十点房价数据,验证讲义那条线)

$\bar{x} = 2.20, \bar{y} = 238.3, S_{xy} = 461.20, S_{xx} = 6.48$

$$m = 461.20 / 6.48 \approx \mathbf{71.17} \quad b = 238.3 - 71.17\times2.20 \approx \mathbf{81.72}$$

> **顺手澄清一个可能被出成 MCQ 的点**
>
> 讲义第 8 页画的那条线是 $f(x) = 72x + 78$。真正的最小二乘解是 $71.17x + 81.72$。**讲义那条是用来演示的近似线,不是 OLS 最优解。**如果题目问「讲义给的 (72, 78) 是最优参数吗」,答案是否 —— 它的 SSE 略高于最优值。这也顺带说明:**肉眼看着很好的线不等于最小二乘线**,这正是需要代价函数的理由。

3.3 矩阵版正规方程 讲义 p16/25 网页 C

设计矩阵

网页 C 给出的二次多项式版本(升幂,第一列全 1):

$$\mathrm{X} = [\,[1, x_1, x_1^2]\,;\,[1, x_2, x_2^2]\,;\,\cdots\,;\,[1, x_N, x_N^2]\,]$$

两条铁律:**每个观测一行,每个系数一列。**全 1 那一列吸收截距。

维度检查(课件明确要求写出来)

量	维度(N 个观测、p 个系数)
X	$N \times p$
$\mathbf{w}$ / β	$p \times 1$
y, $\hat{y}$	$N \times 1$
$\mathrm{X}^\top\mathrm{X}$	$p \times p$ ← 方阵,才谈得上求逆
$\mathrm{X}^\top y$	$p \times 1$

内侧维度 p 必须对上,外侧给出 $N \times 1$,正好是 N 个预测值。先查维度再动手算,能挡掉大部分错误。

四步推导

1. **定义目标**:$r = y - \mathrm{X}\mathbf{w}$, $S(\mathbf{w}) = \|y - \mathrm{X}\mathbf{w}\|^2 = (y - \mathrm{X}\mathbf{w})^\top(y - \mathrm{X}\mathbf{w})$
2. **小心展开**:$S = y^\top y - 2\mathbf{w}^\top\mathrm{X}^\top y + \mathbf{w}^\top\mathrm{X}^\top\mathrm{X}\mathbf{w}$
3. **求导**:$\nabla_{\mathbf{w}} S = -2\mathrm{X}^\top y + 2\mathrm{X}^\top\mathrm{X}\mathbf{w}$
4. **一阶条件**:令零 → $\mathbf{X^\top X w = X^\top y}$(正规方程),**先陈述可逆条件**再写 $\mathbf{w} = (\mathrm{X}^\top\mathrm{X})^{-1}\mathrm{X}^\top y$

> **第 2 步是最常错的地方**
>
> 展开会得到 $-y^\top\mathrm{X}\mathbf{w}$ 和 $-\mathbf{w}^\top\mathrm{X}^\top y$ 两项。它们都是 **1×1 的标量**,而标量的转置等于自身,所以可以合并成 $-2\mathbf{w}^\top\mathrm{X}^\top y$。答题时把这句理由写出来。用到的规则:$(\mathrm{AB})^\top = \mathrm{B}^\top\mathrm{A}^\top$。

为什么这是极小值而不只是驻点

- Hessian = $2X^\top X$
- 对任意向量 v:$v^\top(X^\top X)v = (Xv)^\top(Xv) = \|Xv\|^2 \geq 0$ → **半正定** → S 是凸二次函数
- 若 X **列满秩**,则 $Xv = 0$ 只有 $v = 0$,严格大于 0 → **正定** → 解唯一

这段呼应 §2.4:凸 → 每个局部最小都是全局最小;列满秩 → 碗底是一个点而非平沟。

3.4 标量版与矩阵版是同一个东西 合并新增

把一元情形写成矩阵:X 是 $n \times 2$,列为 $[1, x]$,$\mathbf{w} = [b, m]^\top$。此时

$$X^\top X = \begin{bmatrix} n & \Sigma x \\ \Sigma x & \Sigma x^2 \end{bmatrix} \qquad X^\top y = [\Sigma y, \Sigma xy]^\top$$

展开 $X^\top X\mathbf{w} = X^\top y$ 得到的两行,**逐字就是网页 A 的方程 ② 和方程 ①**。也就是说:

网页 A 的标量推导 = 讲义正规方程在 $p = 2$ 时的特例。$X^\top X$ 可逆的条件在这里退化成 $S_{xx} \neq 0$,即 x **不能全部取同一个值** —— 所有点竖直堆在一条线上时斜率无定义,几何上完全对应。

这是把四份材料串起来的关键一句,ERQ 里能作为「解析解的统一视角」拿分。

3.5 可逆性与数值实践 讲义 p16

失效情形:$m < p$(样本比系数少);x 互不相同的取值个数少于 p;各列高度相关(Vandermonde 矩阵在次数高时出了名的病态)。

推导写 $(X^\top X)^{-1}$,代码不要真求逆

数值软件用 QR 分解、SVD 或伪逆求解最小二乘,更稳定且能处理秩亏情形。Practical 里用 `np.linalg.lstsq` 或 `np.linalg.pinv`,**不要**写 `np.linalg.inv(X.T @ X) @ X.T @ y`。

4 解法二 · 梯度下降

4.1 直觉与比喻 讲义 p12

站在代价曲面上,四周浓雾,只能感觉到脚下的坡度。① 随便起步 → ② 感受坡度 → ③ 朝反方向迈一小步 → ④ 重复到不再明显下降。

雾中登山	数学量
你在山坡上的位置	当前的 (w, b)
你的海拔高度	代价 J
脚下的坡度	梯度
步子的大小	学习率 α

为什么不穷举?100 个特征、每个取 10 个候选值 → 10^{100} 种组合,比可观测宇宙的原子数还多。穷举在现实维度下立刻死掉,有引导的搜索不会。

网页 C 给的另一条动机(比讲义更直接)

解析解随着特征数和数据量增长变得**计算昂贵**,主要因为正规方程这类方法需要**对大矩阵求逆**。梯度下降绕开了求逆。ERQ 问「为什么需要梯度下降」时,这一句 + $O(n^3)$ 就是完整答案。

4.2 算法与同时更新 讲义 p13 网页 C

$$\text{repeat until convergence:}$$
$$w_j := w_j - \alpha \cdot \partial J/\partial w_j \quad \text{(对所有 } j \text{ 同时)}$$

网页 C 的四步版本:① **初始化权重**(随机或全 0)→ ② **计算梯度** → ③ **用 α 更新权重** → ④ **重复**,直到梯度很小或达到设定迭代次数。

为什么是减号(四条)

1. 梯度指向**上坡**,即代价增加的方向。
2. 减去它就把参数推向下坡。
3. 在光滑的最小值附近梯度大小会缩小 → **步子自动变小**,算法自然减速停车,不需手动调 α。

4. 但收敛**仍然**取决于合适的学习率。自动减速不保证万无一失。

最容易失分的一条:同时更新

所有参数必须从**同一组旧参数值**出发更新。

```
tmp_w = w - alpha * dJ_dw   # 用旧的 w, b 算
tmp_b = b - alpha * dJ_db   # 仍用旧的 w, b 算
w, b = tmp_w, tmp_b         # 最后一起覆盖
```

因为 $\partial J/\partial b$ 的计算里包含 w。先更新 w 再算 b 的梯度,算的就不是同一个点上的梯度,走出去的方向也不再是真正的最陡下坡方向。

4.3 梯度公式(讲义没给展开式,这里补全) 网页 C

网页 C 对二次模型逐个参数写出了导数,用的是 $J = (1/N)\Sigma(\hat{y}-y)^2$:

$$\partial J/\partial w_0 = (2/N)\ \Sigma(\hat{y}_i - y_i)$$
$$\partial J/\partial w_1 = (2/N)\ \Sigma(\hat{y}_i - y_i)x_i$$
$$\partial J/\partial w_2 = (2/N)\ \Sigma(\hat{y}_i - y_i)x_i^2$$

规律一眼可见:**每个梯度都是「误差 × 该参数对应的那个特征」的平均**。w_0 对应的特征是常数 1,所以第一行没有 x。一般式:

$$\partial J/\partial w_j = (2/N)\ \Sigma_i\ (\hat{y}_i - y_i)\ x_{ij} \quad = \quad -(2/N)\ \Sigma_i\ (y_i - \hat{y}_i)\ x_{ij}$$

x_{ij} 是第 i 个数据点的第 j 个特征;两种写法只差残差的书写顺序,值相同

矩阵形式(三个导数一次写完)

$$\nabla_{\mathbf{w}} J(\mathbf{w}) = (2/N)\ \mathrm{X}^{\top}(\mathrm{X}\mathbf{w} - y)$$

把 §3 和 §4 接起来的那句话

令这个梯度等于零:$(2/N)\ \mathrm{X}^{\top}(\mathrm{X}\mathbf{w} - y) = 0 \iff \mathbf{X^{\top}Xw = X^{\top}y}$。

正规方程和梯度下降在解同一个方程 —— 一个直接解,一个迭代逼近。这是 ERQ 里「比较两种方法」最有分量的开场句,比背对照表高一个层次。

4.4 手算一步梯度下降 合并新增

用例题 A 的五点数据,模型 $\hat{y} = w_0 + w_1 x$,初始 $w_0 = w_1 = 0$,$\alpha = 0.1$,代价用 MSE(网页 C 版本)。

1. 当前预测全为 0 → 误差 $(y - \hat{y}) = 2, 4, 5, 4, 5$
2. $\partial J/\partial w_0 = -(2/5)(2+4+5+4+5) = -(2/5)(20) = \mathbf{-8}$
3. $\partial J/\partial w_1 = -(2/5)(2\cdot1+4\cdot2+5\cdot3+4\cdot4+5\cdot5) = -(2/5)(66) = \mathbf{-26.4}$
4. $w_0 := 0 - 0.1(-8) = \mathbf{0.8}$; $w_1 := 0 - 0.1(-26.4) = \mathbf{2.64}$ (两者都用旧值算)

同一道题换个代价定义,答案就变

若改用讲义的 $J = (1/2m)\Sigma(\ldots)^2$,梯度变成 $(1/5)(-20) = -4$ 和 $(1/5)(-66) = -13.2$,同样 $\alpha = 0.1$ 下一步后 $w_0 = 0.4$、$w_1 = 1.32$ —— **正好是上面的一半**。

所以手算梯度下降题,**第一行先写出你采用的代价函数定义**。这既是拿过程分的地方,也是唯一能自证答案合理的方式。

4.5 学习率 讲义 p14

α 是超参数,选错是「代码明明写对了却看起来坏掉」的最常见原因。

代价曲线形状	诊断
上升 / 振荡	α 太大,没有别的可能
浅浅的、几乎笔直的下降	α 太小
先陡降后变平	α 刚好 ✓
变成 NaN / inf	α 大得离谱,或特征没缩放
陡降后变平,但停在很高的值	**不是 α 的问题** —— 模型欠拟合

唯一最重要的诊断工具:把 J 对迭代次数作图。调 α 要在对数尺度上搜索:0.001 → 0.003 → 0.01 → 0.03 → 0.1,取仍能平滑下降的最大值。

> 最后一行是最容易被出成 MCQ 的:曲线形状健康说明**优化没问题**,代价停在高位说明**模型有问题**。区分「优化问题」和「模型问题」是这一页的考点。

三个停止准则

1. 代价在相邻两次迭代间不再明显下降
2. 梯度约等于 0(此时 $w := w - \alpha \cdot 0 = w$,参数不动)
3. 达到固定迭代次数上限(Practical 里多用这种)

4.6 两种方法对照(必背) 讲义 p16

	Gradient Descent	Normal Equation
需要学习率 α	需要	不需要
迭代	是	否,闭式解
n 很大时	扩展性好	慢:$O(n^3)$
特征缩放	推荐	不需要
适用模型	几乎所有(含逻辑回归、神经网络)	仅有闭式解的模型

记忆逻辑:正规方程「省心」(没有 α、不用缩放、不用迭代),代价是特征一多就跑不动 —— 求逆是 $O(n^3)$,n 翻倍时间变 8 倍。**大问题用梯度法。**

逻辑回归和神经网络**没有闭式解**,只能用梯度法 —— 这就是整门课要花大力气讲梯度下降的原因,也是通向 T3 的桥。

4.7 随机梯度下降 网页 C · 明确标注 optional

网页 C 在正文后附了一段 SGD 的选修视频,并写明「**beyond the scope of this course**」。知道名字和一句话区别即可:批量梯度下降每步用全部样本算梯度,SGD 每步只用一个(或一小批)样本,更新更快更噪声。**不会考计算。**

5 概率解释:为什么偏偏是平方误差 网页 B 全文 + Tutorial Q1

这是三份新材料里 ERQ 权重最高的一块。网页 B 是官方版本,Tutorial Q1 是它的考试形态。

5.1 建模假设

$$y_i = w_0 + w_1 x_i + \varepsilon_i, \quad \varepsilon_i \sim \mathrm{N}(0, \sigma^2) \text{ 独立同分布}$$

答题时这两个词必须写出来:**independent(独立)** 和 **common variance σ^2(等方差)**。观测值 y_i 由「底层线性模型 + 随机噪声」生成。

5.2 单点似然

给定 x_i 和参数,观测到 y_i 的似然就是正态分布的概率密度函数:

$$p(y_i \mid x_i; w_0, w_1) = (2\pi\sigma^2)^{-1/2} \exp\left(-(y_i - (w_0 + w_1 x_i))^2 / 2\sigma^2 \right)$$

注意:高斯的中心是**模型预测值**,不是 0。噪声均值为 0,所以 y 的均值就是 $w_0 + w_1 x$。

5.3 从连乘到连加

$$L(w_0, w_1) = \Pi_{i=1..N}\, p(y_i \mid x_i; w_0, w_1)$$

连乘的合法性来自独立性假设 —— 这一步必须点名(呼应 §9 的假设 ②)。

取自然对数的两个理由:① 大量概率密度连乘在数值上不方便;② **对数是单调增函数**,所以最大化似然 ⟺ 最大化对数似然。第二条是逻辑上的关键,不能省。

5.4 化简对数似然(四步,过程分都在这里)

第 0 步:先设 $r_i = y_i - (w_0 + w_1 x_i)$。式子立刻短一半,这是拿分的第一个动作。

第 1 步 · 拆乘积,用 $\log(ab) = \log a + \log b$:

$$\log L = \Sigma \left[\log((2\pi\sigma^2)^{-1/2}) + \log \exp(-r_i^2/2\sigma^2) \right]$$

第 2 步 · 两个对数各自化简,用 $\log a^n = n \log a$ 和 $\log \exp(u) = u$:

$$\log L = \Sigma \left[-\tfrac{1}{2} \log(2\pi\sigma^2) - r_i^2/(2\sigma^2) \right]$$

第 3 步 · 提出与 i 无关的项(第一项不含 i,求 N 次就是乘 N):

$$\ell(w_0, w_1) = -(N/2) \log(2\pi\sigma^2) - (1/2\sigma^2) \Sigma [y_i - (w_0 + w_1 x_i)]^2$$

最后那个求和正好就是 SSE

第 4 步 · 三句话论证等价性(这一段才是给分点):

1. 第一项 $-(N/2)\log(2\pi\sigma^2)$ **不含 w_0、w_1**,在优化中是常数,与 argmax 无关。
2. SSE 前面的系数 $-1/(2\sigma^2)$ 是**负常数**(这里用到 $\sigma^2 > 0$ 且固定),所以要让 ℓ 增大,就必须让 SSE 减小。
3. 因此 **arg max ℓ = arg min SSE**。

> **Q1 最常丢的两处分**
>
> ① **只写公式不写结论。**题目要求「in your own words」解释这个优化上的联系,必须有一句明确的「最大化对数似然等价于最小化平方误差和」。
>
> ② **不说明符号。**如果不指出系数是负的、不指出第一项是常数,等价性就是没有论证的断言。

5.5 闭环:MLE 给出的就是网页 A 那两个公式

网页 B 接着对 SSE 求偏导并令零:

$$\partial \mathrm{SSE}/\partial w_0 = -2 \Sigma [y_i - (w_0 + w_1 x_i)] = 0$$
$$\partial \mathrm{SSE}/\partial w_1 = -2 \Sigma x_i [y_i - (w_0 + w_1 x_i)] = 0$$

解出:

$$\hat{w}_1 = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / \Sigma(x_i - \bar{x})^2 \qquad \hat{w}_0 = \bar{y} - \hat{w}_1 \bar{x}$$

> **三份材料在这里合上了**
>
> 网页 A 从**纯代数**(最小化 SSE)出发,网页 B 从**概率**(最大化似然)出发,两条路得到**逐字相同**的公式;讲义的正规方程是它们的矩阵推广。
>
> 一句话总结:**在独立同方差高斯噪声的假设下,普通最小二乘估计量同时就是最大似然估计量。**MSE 不是随手挑的,它有概率论上的正当理由。

5.6 假设变了会怎样(留口子的那句话)

网页 B 和 Tutorial 答案都特意加了一句:如果噪声假设改变,另一种损失或加权方式可能更合适。具体地:

- 噪声是**重尾**的 → MAE 或 Huber 损失更稳健
- 方差不等(**异方差**) → 加权最小二乘

ERQ 里补这一句,是从「答对」到「答满」的差别。

6 特征缩放与数据泄漏 讲义 p17

当特征跨越差别巨大的取值范围时,梯度下降会**之字形**缓慢爬向最小值。

	不缩放	缩放后
等高线	狭长、拉伸的椭圆	圆整、均匀
下降路径	缓慢的之字形	直接走向最小值

为什么之字形:面积跑 0–2000 而卧室跑 0–5,代价曲面就是一条又长又窄的山谷。在大多数点上,梯度并不指向最小值,而是横穿山谷。缩放后等高线接近圆形,梯度几乎笔直指向最小值。

两种做法

Z-score 标准化:$x' = (x - \mu) / \sigma$　　Min-max 归一化:线性重缩放到 [0, 1]

> **数据泄漏 —— 本节最重要的考点**
>
> 均值和标准差**只能在训练数据上计算**,然后把存下来的同一组数值应用到验证集和测试集。
>
> 如果在划分之前就对整个数据集算统计量,测试集的信息就泄漏进了训练过程,会**虚高报告的性能,使整个评估失效**。课件的形容:微妙、极其常见、且是严重的方法学错误。
>
> 正确顺序:**先划分 → 再拟合 scaler → 再 transform**。sklearn:训练集 `fit_transform`,测试集只 `transform`。

四条要点

1. 缩放**不会让模型本质上更强**,它改变的是梯度下降到达答案的速度。
2. 正规方程不需要缩放,因为它不迭代。
3. 它**改变权重的含义**:标准化后,一个权重表示「该特征每变化一个标准差时 y 的变化量」。这个版本的权重才可以合法地跨特征比较(补上 §1.4 的伏笔)。
4. 正则化是**真正必须**缩放的,因为它惩罚权重,未缩放的特征会被不公平地惩罚。(L1/L2 本身不在 M1 考纲内)

7 过拟合、欠拟合与多项式次数 讲义 p18 网页 C

	Underfitting	Good Fit	Overfitting
症状	模型太简单,错过趋势	抓住底层模式	模型太复杂,记住噪声
术语	高偏差 high bias	—	高方差 high variance
训练误差	高	低	几乎为 0
新数据误差	高	低	很高

诊断(very examinable)

训练误差	留出误差	诊断
低	高得多	过拟合
高	高	欠拟合

仅凭训练误差永远无法揭示过拟合。这正是评估必须坚持留出划分的原因。

> **最容易误解的一点**
>
> 那条扭来扭去的过拟合曲线**仍然是线性回归** —— 它来自添加多项式特征(x^2、x^3)。一个特征的直线几乎不可能过拟合,参数太少扭不起来。
>
> 网页 C 把这条讲得很直白:更高次的模型可以包含 x^3、x^4 这样的特征,**但添加更多多项式特征也增加过拟合风险**。所以「多项式次数」是一个典型的超参数 —— 我们选,不是学出来的。

对策

问题	怎么办
过拟合	收集更多数据;使用更少或更简单的特征;降低多项式次数;正则化
欠拟合	增加更有信息量的特征;加多项式项;换更灵活的模型

8 模型评估 讲义 p19

指标	单位	用途	可否为负
MSE	y^2	优化 / 内部比较	否
RMSE	y 的原始单位	向人汇报误差大小	否
R^2	无量纲	说明解释力,可跨数据集比较	**可以**

MSE 就是讲义代价函数去掉 1/2。单位是 y^2,数字本身没有直观意义,只能用来比较模型。

RMSE 开根号回到原始单位。RMSE = 6.5 可直接读作「平均而言预测偏离约 6,500 美元」。

R^2 衡量比「永远预测 y 的平均值」这个笨基线好多少:1 = 完美;0 = 和预测均值一样好,模型毫无价值;< 0 = 比预测均值还差。

> **R^2 可以为负**
>
> 很多人以为「平方了所以非负」,错 —— R^2 不是某个东西的平方,它是 $1 - SS_{res}/SS_{tot}$。在未见数据上预测很糟时,残差平方和可以超过总平方和。

9 线性回归的五个假设 讲义 p20

先搞清楚这一节为什么存在:纯预测时可以违反其中好几条,模型照样有用;做**推断**(置信区间、p 值、宣称某特征真的重要)时非常重要。这个区分本身就是考点。

1. **Linearity 线性性** —— 准确说是对参数线性。检查:残差 vs 拟合值有无弯曲。修复:变换特征(对数、多项式)。
2. **Independence 独立性** —— 观测及其误差彼此独立。常见违反:时间序列、对同一对象的重复测量。(§5.3 的连乘就依赖这一条)
3. **Homoscedasticity 同方差性** —— 残差在所有预测值上方差大致恒定。检查:残差图摊开成锥形说明方差随预测值增长,在价格和收入数据上非常常见。修复:对 $\log(y)$ 建模。
4. **Normality of residuals 残差正态性** —— **只在**置信区间和假设检验时需要,拟合直线本身不需要。检查:Q-Q 图。
5. **No multicollinearity 无多重共线性** —— 后果是单个系数不稳定、不可信,但整体预测可能依然很好。检查:相关矩阵或 VIF。

> **常见误解**
>
> 「数据必须服从正态分布才能用线性回归」—— **完全不对**。要求的是**残差**近似正态,而且只在做推断时才要求。

如果只记一个诊断工具:残差 vs 拟合值图

图上看到	违反了什么
弯曲(curvature)	线性性
锥形 / 喇叭形	同方差性(异方差)
明显的模式或连续同号的串	独立性

10 Tutorial 标准答案

两道题的完整推导已并入 §5(Q1)与 §3.3(Q2)。这里只留**答题结构**和**失分点**。

Q1 · 高斯 MLE → 最小二乘

答题骨架:设记号 r_i → 写明独立 + 等方差假设 → log 拆连乘为连加 → 两个对数各自化简 → 提出常数项 → 三句话论证等价 → 一句 interpretation

Q2 · 多项式回归的矩阵形式与最小二乘解

第一部分 · 矩阵形式:$Y = [y_1 \dots y_n]^\top (n\times 1); \beta = [a, b, c]^\top (3\times 1)$;X 的第 i 行为 $[x_i^2, x_i, 1] (n\times 3)$。**为什么是 3 列:因为有 3 个未知系数**。

验证:$[x_i^2, x_i, 1]\cdot[a, b, c]^\top = ax_i^2 + bx_i + c = \hat{y}_i$ ✓

注意:一般来说 $Y \neq X\beta$,因为观测里含残差。等号只对 $\hat{Y}$ 成立。

第二部分 · 推导:见 §3.3 的四步 + Hessian 凸性说明。

Tutorial 最容易丢的三处分

1. Q1 忘了说明第一项是常数、系数是负的(结论就没有论证)
2. Q2 直接跳到 $(X^\top X)^{-1}$ 而不提**列满秩**
3. Q2 只令梯度为零,不做 **Hessian 的凸性说明**(驻点 ≠ 极小值)

11 Practical 标准答案 · California Housing

Ex1 · 理解数据

每一行描述的是 1990 年人口普查中加州的一个「**街区组 block group**」—— **不是一栋房子**。这是最容易误解的地方,也解释了为什么列名充满 Med(中位数)和 Ave(平均)。

列名	含义
MedInc	该街区组的家庭收入中位数
HouseAge	房屋年龄中位数
AveRooms / AveBedrms	每户平均房间数 / 卧室数
Population / AveOccup	街区组人口 / 每户平均人数
Latitude / Longitude	南北 / 东西位置
MedHouseVal	**目标**:房价中位数,单位 $100,000

数据规模:20640 行、9 列(8 特征 + 1 目标),全 float64,无缺失值。目标值 4.526 表示 452,600 美元。

方法学提醒:直方图帮我们理解取值范围、偏度和异常值,但**一个特征自己的直方图并不能证明它能预测房价**。要看关系,得画散点图或看模型证据。

Ex2 · 基线模型

```
X = df.drop(columns=["MedHouseVal"]); y = df["MedHouseVal"]
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42)
model = LinearRegression().fit(X_train, y_train)
```

结果:MSE ≈ 0.53,R^2 ≈ 0.60,RMSE ≈ 0.73 即平均偏离约 73,000 美元。

- `random_state=42` 就是「保持测试集划分固定」的实现,让不同特征组合的比较公平。
- **这里没有做特征缩放,完全正确** —— sklearn 的 `LinearRegression` 用闭式解 / 最小二乘求解器,不迭代(§4.6 对照表)。
- Actual vs Predicted 图在目标值接近 5 处有一条水平聚集带 —— 数据集的**上限截断**,真实房价被人为封顶在 5.00001。

系数表里的陷阱

AveBedrms 系数 0.779(最大),Population 系数 −7.8e-07(几乎为 0)。这**不**说明卧室最重要、人口不重要:Population 取值动辄成千上万,系数必然极小;AveBedrms 取值大多在 1 附近、变化范围极小,系数自然被推得很大。

要合法比较,得先标准化,让系数变成「每变化一个标准差」。

Ex3 · 特征工程

特征集	MSE	R^2
Location only(经纬度)	0.987	0.248
Selected six	0.532	0.595
All eight	0.531	0.596

为什么只用经纬度这么差:经纬度与房价的真实关系高度非线性(不是「越往北越贵」,而是「离海岸越近越贵」)。一个 w_1·Longitude + w_2·Latitude 的平面装不下这种模式。

相关性条形图的教训

MedInc 与房价相关系数 0.688(遥遥领先),而 **Latitude(−0.144)和 Longitude(−0.046)的单变量相关系数都接近 0,但它们在模型里非常有用**。

因为经纬度必须**一起看**才有意义 —— 北边有贵的旧金山,南边有贵的洛杉矶,中间内陆便宜。相关系数只能捕捉单变量的线性单调关系,抓不住这种交互效应。答案原话:没有任何单一的简单相关系数能捕捉每一个有用的效应,尤其是地理效应。

> **Q3.2 的高分写法**
>
> 选定六特征集远优于只用位置,并与全特征模型表现几乎相同,是一个合理的平衡。**但要加限定语:**「这并不证明被省略的特征(Population、AveOccup)对每一个模型或分析都无用」—— 它们在线性模型里贡献极小,不代表在树模型或加了交互项之后也没用。

报告里最容易失分的三处

1. 拿原始系数排重要性(AveBedrms 那个坑)
2. 只报 R^2,不说 RMSE 对应多少钱
3. 结论写死,不加「对这个线性模型而言」的限定

另外:为画图而截断(`AveBedrms.quantile(0.99)`)只是**显示处理**,截断后的数据没有被拿去训练。不要把「为了画图而过滤」变成「悄悄删了数据再建模」。

12 讨论区 Activity 答题要点 网页 A/C

两篇网页末尾各挂了一个 Activity。它们不算分,但问的正是最可能出 ERQ 的两个开放问题,值得各准备三句话。

网页 A · Linear regression by hand

要求手算一遍回归系数。→ 直接用 §3.2 的流程卡。这是三个 by-hand 活动之一,性价比最高的练习。

网页 C · 特征数量与多项式回归

问题:特征是不是「the more, the merrier」?加大量特征有什么利弊?关系不是直线时,多项式回归是帮忙还是把事情复杂化?

角度	好处	代价
加更多特征	降低偏差,能表达更复杂的关系	过拟合风险↑;共线性使系数不可信;$X^\top X$ 可能奇异;$O(n^3)$ 求逆变慢
加多项式项	用同一套线性回归机器就能拟合曲线,无需新算法	次数是超参数,选高了记住噪声;Vandermonde 矩阵病态;外推行为极不稳定

三句话答案:不是越多越好 —— 特征增加降低偏差但提高方差;判断标准不是训练误差而是**留出集表现**;多项式回归确实能捕捉曲线且**仍然是线性回归**(对参数线性),但次数必须靠验证集来选,不能靠眼睛。

A 附录 · 速查与失分点

A.1 公式墙

场景	写什么
一元手算	$m = S_{xy}/S_{xx}$, $b = \bar{y} - m\bar{x}$
给的是求和量	$\Sigma xy = m\Sigma x^2 + b\Sigma x$; $\Sigma y = m\Sigma x + nb$
多元 / 多项式	$X^\top X\mathbf{w} = X^\top y \to \mathbf{w} = (X^\top X)^{-1}X^\top y$(需列满秩)
梯度(逐参数)	$\partial J/\partial w_j = (2/N)\Sigma(\hat{y}_i - y_i)x_{ij}$
梯度(矩阵)	$\nabla_{\mathbf{w}} J = (2/N)X^\top(X\mathbf{w} - y)$
更新	$w_j := w_j - \alpha \cdot \partial J/\partial w_j$(同时更新)
对数似然	$\ell = -(N/2)\log(2\pi\sigma^2) - (1/2\sigma^2)\cdot SSE$
评估	$RMSE = \sqrt{MSE}$; $R^2 = 1 - SS_{res}/SS_{tot}$

A.2 二十条最容易失分的点

1. 上标 $x^{(i)}$ 是索引不是指数;m 是样本数(行),n 是特征数(列)。
2. **但网页 A 里 m 是斜率、n 是样本数。**读题先认符号。
3. y 是真实值,$\hat{y}$ 是预测值;ε 是不可观测噪声,e 是拟合后的残差。

4. 参数是学出来的,超参数是人选的(α、多项式次数)。
5. 说 associated with,不说 causes。
6. 残差 = 实际 − 预测。负号 = 高估,正号 = 低估。
7. 平方的三个理由:防抵消、重罚大误差、处处可微。
8. SSE / MSE / Half-MSE 的 argmin 相同,但**梯度数值不同**。手算前先声明用哪个。
9. J 的自变量是 w 和 b,不是 x。
0. 梯度下降必须**同时更新**,两个梯度都用同一组旧参数计算。
1. 凸性保证最优解唯一地好,但不保证算法能找到它 —— 仍取决于 α。
2. 代价曲线陡降后变平但停在高位 → 是**模型欠拟合**,不是 α 的问题。
3. $b = \bar{y} - m\bar{x} \iff$ 回归线必过重心 $(\bar{x}, \bar{y})$。手算自检用它。
4. 正规方程和梯度下降解的是**同一个方程** $X^\top X\mathbf{w} = X^\top y$。
5. 写 $(X^\top X)^{-1}$ 前必须先陈述**列满秩 / 可逆**条件;只令梯度为零不够,还要 Hessian 半正定说明是极小。
6. MLE 与 OLS 等价的前提是**独立 + 等方差高斯噪声**,且论证要点名「常数项无关」和「系数为负」。
7. 权重只有在特征共享同一尺度时才可比;标准化后才能按「每变化一个标准差」比较。
8. scaler 只在训练集上 fit,否则是数据泄漏,评估失效。
9. 「线性」指对参数线性。加了 x^2 仍是线性回归,但过拟合风险上升。
0. 仅凭训练误差永远无法揭示过拟合;R^2 可以为负;正规方程失效于共线或 $m < n$。

A.3 一分钟总复习

数据 → 模型 $\hat{y} = \mathbf{w}^\top\mathbf{x}$(第一位固定为 1 吸收截距)

→ 残差 $y - \hat{y}$ → 平方求和 → SSE / MSE / Half-MSE(只差正常数)

→ 最小化。两条路,同一个一阶条件 $\mathbf{X^\top X w = X^\top y}$:

- **闭式解** —— 一元用 $m = S_{xy}/S_{xx}$、$b = \bar{y} - m\bar{x}$;多元用正规方程(需可逆)
- **梯度下降** —— $\mathbf{w} := \mathbf{w} - \alpha(2/N)X^\top(X\mathbf{w} - y)$,同时更新,需调 α 与缩放

→ 为什么是平方:独立同方差高斯噪声下,**最小二乘 = 最大似然**

→ 在留出集上用 MSE / RMSE / R^2 评估 → 残差 vs 拟合值图检查五个假设 → 谨慎解读系数

合并自:M1 T2 讲义 27 页 · Calculating linear regression coefficients · Linear Regression: A Probability Interpretation · General form and gradient descent · Tutorial 答案 · Practical 答案(California Housing)。带 绿色标记 的段落来自本次新加入的课程网页或合并时新写的内容。