ARTI2001 机器学习

M1 T2 · 线性回归 完整知识点

讲义 27 页 | Tutorial 答案 | Practical 答案

Linear Regression — Fitting Lines, Minimizing Error, and Making Predictions

目录

- **第一部分 · 讲义 27 页**
- 第 1–3 页 封面 / 致辞 / Agenda
- 第 4 页 为什么要预测一个数字
- 第 5 页 回归在机器学习版图中的位置
- 第 6 页 问题的建立与记号
- 第 7 页 一元线性回归模型
- 第 8 页 最佳拟合线
- 第 9 页 残差
- 第 10 页 代价函数
- 第 11 页 代价曲面
- 第 12 页 梯度下降的直觉
- 第 13 页 梯度下降算法
- 第 14 页 学习率
- 第 15 页 从一个特征到多个
- 第 16 页 正规方程
- 第 17 页 特征缩放
- 第 18 页 过拟合与欠拟合
- 第 19 页 模型评估
- 第 20 页 线性回归的五个假设
- 第 21 页 总结与下一步
- 第 22–25 页 Tutorial 活动与解题指南
- 第 26–27 页 Practical 活动与工作流
- **第二部分 · Tutorial 标准答案**（Q1 高斯 MLE / Q2 正规方程）
- **第三部分 · Practical 标准答案**（California Housing，Ex1–Ex3）
- **附录 · 高频考点速查表**

第一部分 · 讲义 27 页

第 1–3 页 · 封面、致辞与 Agenda

第 1 页 封面

Linear Regression — Fitting Lines, Minimizing Error, and Making Predictions

副标题就是整个主题的三步骨架：

1. **Fitting Lines** — 用一条直线去拟合数据
2. **Minimizing Error** — 定义「误差」并把它最小化
3. **Making Predictions** — 用学到的直线去预测新数据

> *线性回归把「数值预测」和「线性函数」连起来，用残差（residuals）和平方误差衡量偏差，再通过优化（梯度下降）或闭式解（正规方程）学出参数。*

第 2 页 Acknowledgement of Country

向 Kaurna、Boandik、Barngarla 等原住民族群及其长者致敬。与技术内容无关，考试不考。

第 3 页 Agenda（六个模块）

#	模块	内容
1	Why Linear Regression?	动机，它在 ML 里的位置
2	The Model	一元线性回归 y = wx + b
3	Measuring Error	残差与代价函数
4	Gradient Descent	机器怎么找到最佳拟合线
5	Beyond One Feature	多元回归与正规方程
6	Tutorial & Practical	手算推导 + 代码实现

> **提醒：**后面的计算全部建立在前面的定义和记号之上。第 6 页的记号那一页千万别跳。

第 4 页 · Why Predict a Number?（为什么要预测一个数字）

核心：很多真实问题要预测的是一个**连续量（continuous quantity）**，而不是一个类别。

四个例子：**Housing prices**（从面积、位置、房龄预测售价）、**Stock trends**（从历史信号估计未来价值）、**Weather**（预测明天气温）、**Student outcomes**（从学习时长预测考试分数）。

贯穿全篇的房价数据（house size vs. price）

Size (1000 sqft)	1.0	1.2	1.5	1.8	2.0	2.3	2.6	2.9	3.2	3.5
Price ($1000s)	145	175	190	200	230	255	258	290	315	325

> **散点图要看两件事：**
> 1. **有明显的上升趋势** — 面积越大价格越高，所以用直线拟合是合理的。
> 2. **点不会完全落在任何一条直线上** — 这就是整门课存在的理由。真实数据有噪声和没测到的因素，目标是**抓住趋势，而不是追逐每一个点**。完美穿过所有点不是目标，那叫过拟合。

名字来源："regression" 来自 Galton 19 世纪研究身高的工作 —— 高个父母的孩子会「回归」到平均值。纯属历史遗留，与方法本身无关。

> **Study check：**从照片预测一个人的年龄 —— 回归还是分类？
> **答：**回归。年龄是连续数值。但若任务是分成「儿童/青年/中年/老年」四档，就变成分类了。**任务类型取决于输出的形式，不取决于输入。**

第 5 页 · Regression in the ML Landscape（回归在机器学习版图中的位置）

核心：监督学习分成两大家族，分界线只有一条 —— **你要预测的 y 是什么类型**。

	Regression（回归）	Classification（分类）
预测什么	连续值（continuous value）	离散类别（discrete category）
输出	一个实数（real number）	一个标签/类（label / class）
例子	房价（$）、气温（°C）、考试分数	垃圾邮件与否、猫/狗/鸟、及格与否

1. 两者都是监督学习

共同点是训练时我们**已经握有正确答案**。整条流水线也完全一样：

> 数据 → 带参数的模型 → 代价函数 → 优化器 → 评估

变的只是**代价函数**和**输出的形式**，底层哲学没变。学会线性回归这套流程，学分类时只是换零件。

2. 「看起来是数字，其实是类别」的陷阱

邮编 5005 存成数字，但它是个**标签**。5006 并不是「比 5005 多一」，把邮编求平均没有意义。同样的坑：学号、电话号码、球衣号码。
判断方法：问自己「这两个数相减 / 求平均有意义吗？」没有意义 → 它是类别。

第 6 页 · Setting Up the Problem（问题的建立与记号）

这一页是全学期的地基。这套记号会用一整个学期，现在马虎，之后每个主题都会混乱。

五个记号

记号	含义
x	输入特征（input feature），例如房屋面积
y	目标 / 输出值（target / output），例如价格
$(x^{(i)}, y^{(i)})$	第 i 个训练样本
m	训练样本的数量（number of training examples）
$\hat{y}$（y-hat）	模型的**预测**值（predicted value）

三个必须记牢的坑

坑 1：上标是索引，不是指数。
这是开学头两周最常见的记号误读，而且会悄无声息地毁掉代数推导。
- $x^{(2)}$ = 数据集里的**第二栋房子**
- x^2 = **x 的平方**

写的时候上标加括号 $x^{(2)}$，就是为了跟平方区分。

坑 2：m 和 n 别搞反。
- **m = 样本数** = 表格的**行数**（有几栋房子）
- **n = 特征数** = 输入的**列数**（第 5 模块才登场）

记忆法：m 数 exa**m**ples。互换是常见失分点。

坑 3：y 和 $\hat{y}$ 是两个东西。
- **y** = 真实观测到的值（true, observed value）
- $\hat{y}$ = 模型**猜**出来的值（predicted value）

整门课的全部工程，就是想办法让 $\hat{y}$ 尽量接近 y。

表格的每一行 = 一个训练样本 = 一栋房子。幻灯片只显示前 5 行，房价例子实际 **m = 10**，对应散点图上的 10 个点。

Study check： $x^{(3)}$ 和 $y^{(3)}$ 分别是什么？
答： 第 3 行：$x^{(3)} = 1.5$（千平方英尺），$y^{(3)} = 190$（千美元）。索引从 1 开始数。

第 7 页 · The Simple Linear Regression Model（一元线性回归模型）

$$f_{w,b}(x) = wx + b \quad （也写作 \hat{y} = wx + b）$$

1. 先卸下心理负担

这就是中学学过的 y = mx + c，只是换了字母。

中学	机器学习
m（斜率）	**w**（weight / slope，权重、斜率）
c（截距）	**b**（bias / intercept，偏置、截距）

没有任何新东西。真正新的是「**怎么自动找到最好的 w 和 b**」。

2. w 和 b 各自是什么

w — weight / slope： y 每随 x 变化一个单位而改变多少。在房价例子里回答：每多 1000 平方英尺，预测价格增加多少？

b — bias / intercept： x = 0 时的预测值。

b 常常在物理上没有意义。面积为 0 的房子不存在，也没有价格。但这**完全没问题** —— b 只是一个垂直偏移量，让直线坐到正确的高度上，它本身不需要能被解释。

3. 关键术语区分：参数 vs 超参数（考试常考）

	参数（Parameters）	超参数（Hyperparameters）
例子	w、b（也叫 weights、coefficients）	学习率（learning rate）
谁定的	**从数据中学出来的**	**我们自己选的**
算法会调吗	会	**不会，算法从不碰它**

一句话：参数是学出来的，超参数是我们挑的。

4. 「训练模型」到底是什么意思

> *训练 = 在所有可能的 (w, b) 组合里搜索，找出最好的那一对。*

没有更玄的东西。第 3、4 模块只是在回答「什么叫最好」和「怎么高效地搜」。

5. 单位检查的好习惯

x 单位是千平方英尺，y 单位是千美元 → **w 的单位 = 千美元 / 千平方英尺**。检查单位能抓出很多计算错误。

Study check： 增大 w 会让直线怎么变？增大 b 呢？
答： 增大 w → 直线**旋转变陡**（steeper）；增大 b → 直线**整体向上平移**。它们是两个互相独立的旋钮。

第 8 页 · Visualizing the Best-Fit Line（可视化最佳拟合线）

$$f(x) = 72x + 78 \quad （即\ w = 72\ ,\ b = 78）$$

怎么读这张图

图上元素	含义
青色点（teal dots）	实际观测到的房价
橙色线（orange line）	模型在每一个面积值上的预测
点与线之间的竖直间隙	误差 —— 下一页要正式测量的东西

Size x	1.0	1.2	1.5	1.8	2.0	2.3	2.6	2.9	3.2	3.5
Actual y	145	175	190	200	230	255	258	290	315	325
Pred. ŷ	150.0	164.4	186.0	207.6	222.0	243.6	265.2	286.8	308.4	330.0

三个重点

1. **直线在「没见过的面积」上也能给出预测**，这才是模型有用的原因。数据表里没有 2.5，但 72×2.5+78 = 258。这叫**泛化（generalisation）**。
2. **没有任何一条直线能穿过全部 10 个点，永远不会有。**这条线是一个**折中（compromise）** —— 同时靠近所有点。
3. 大白话解释：每多 1000 平方英尺，**关联着**大约多 7.2 万美元，在 7.8 万美元的基准偏移之上。

语言纪律（Language discipline）

> **说「associated with（关联）」，不要说「causes（导致）」。**
> 把房子扩建 1000 平方英尺，并不会可靠地给它加上 7.2 万美元的价值。模型学到的只是**观测数据里的一个模式**，混杂着大量未被区分的因素（confounding factors）—— 大房子可能本来就在好地段、房龄更新、装修更好。这是相关 ≠ 因果在本课的第一次出现。

这一页的教学意图：这条线看上去很好，于是逼出下一页的问题 —— **「好」到底按什么精确定义来衡量?**

第 9 页 · Quantifying Error: Residuals（量化误差：残差）

定义

$$\text{residual} = \text{actual} - \text{predicted} = y^{(i)} - f_{w,b}(x^{(i)})$$

残差是单个样本上的误差 —— 一个点一个残差。

i	x	y (actual)	ŷ (pred.)	residual
1	1.0	145	150.0	**−5.0**
2	1.2	175	164.4	**+10.6**
3	1.5	190	186.0	**+4.0**
4	1.8	200	207.6	**−7.6**

符号的含义

残差符号	含义
负号	模型**高估**了（over-predicted）。例：i=1 残差 −5，模型猜高了 5 千美元。
正号	模型**低估**了（under-predicted）。例：i=2 残差 +10.6，模型猜低了。

> **顺序不能反：**永远是 **实际 − 预测**。整个计算过程保持一致，否则后面所有符号都会反。

为什么误差是「垂直」量的，不是「垂直于直线」量的?

因为我们是**从 x 预测 y**。x 被当作已知、给定的；**所有误差都住在 y 里面**。所以误差只在 y 方向上测量。

补充：测量垂直于直线的距离是另一种真实存在的方法，叫 **total least squares（总体最小二乘）**，用在**两个变量都带测量误差**的场合。

为什么要把残差平方? 三个理由（重点考点）

1. 否则正负会相互抵消。一条烂线，如果高估的量和低估的量差不多，残差直接相加会接近 0。所以「直接求和」作为质量指标毫无用处。

2. 平方会不成比例地惩罚大误差。错 10 被视为比错 5 糟糕 **4 倍**（$10^2/5^2 = 100/25$），而不是 2 倍。

3. 结果处处光滑可微（smooth and differentiable）。这才让我们能用微积分优化。显而易见的替代品 —— 绝对值 —— 在 0 处有一个尖角（kink），导数在那里**不存在**。

平方是设计选择，不是自然法则

	平方误差（MSE 系）	平均绝对误差（MAE）
可微性	处处可微 ✓	0 处不可微 ✗
闭式解	有漂亮的闭式解 ✓	没有 ✗
抗离群点	**弱** —— 单个极端离群点就能主导总和 ✗	**强**（more robust）✓

MAE 完全合法，只是不好优化。

Study check：算出 x = 1.5 时的残差。
答：预测 72×1.5 + 78 = 186；实际 190；残差 = 190 − 186 = **+4.0**。正号 → 模型**低估**了。

第 10 页 · The Cost Function（代价函数）

$$J(w,b) = (1 / 2m)\ \Sigma_{i=1..m}\ (\ f_{w,b}(x^{(i)}) - y^{(i)}\ )^2$$

课件叫它 **Half-MSE Cost（半均方误差代价，为微积分而缩放）**，即「均方残差的一半」。

逐块拆解

部件	作用
$f(x^{(i)}) - y^{(i)}$	第 i 个样本的残差
$(\ \cdot\ )^2$	平方 —— 结果**永远非负**
Σ	对全部 m 个样本的平方误差求和
1/2m	求平均，再取一半（为方便）

符号细节：这里写的是 $f(x^{(i)}) - y^{(i)}$（预测 − 实际），而第 9 页残差定义是 $y^{(i)} - f(x^{(i)})$（实际 − 预测）。**顺序反了没关系**，因为外面有平方，$(a-b)^2 = (b-a)^2$。但在**没有平方**的场合（如梯度公式）顺序至关重要。

那个 1/2 是干嘛的?

1/2 是为了后面做微积分方便 —— 它会抵消求导时冒出来的因子 2。
它不改变最优解。常数倍缩放不会移动最小值的位置 —— 使 J 最小的 (w,b) 和使 MSE 最小的 (w,b) 是同一对。所以 1/2 纯粹是**书写便利**。

名称	公式
MSE（均方误差）	$(1/m)\ \Sigma(\ldots)^2$
本课的 J（Half-MSE）	$(1/\mathbf{2}m)\ \Sigma(\ldots)^2$

为什么要除以 m（求平均）?

这样代价**不依赖数据集大小**。100 个样本和 10000 个样本的模型才能公平比较；否则样本越多总和越大，看起来越差。

落脚点

学习的目标：选择 w、b 使 $J(w,b)$ 最小化　$\min_{w,b} J(w,b)$

完整链条：**模型 f(x)=wx+b → 残差 → 平方 → 求和平均 → J(w,b) → 最小化 J**

> J 的自变量是 **w 和 b，不是 x**。数据是固定给定的；旋钮上能拧的只有 w 和 b。

动手算一次（用前 4 个残差，假装 m = 4）

残差：−5.0、+10.6、+4.0、−7.6
平方和：25 + 112.36 + 16 + 57.76 = **211.12**
J = 211.12 / (2×4) = **26.39**

第 11 页 · Visualizing the Cost Surface（可视化代价曲面）

一维版本

固定 b，只把 J 对 w 作图 → 得到一条**碗形（bowl-shaped）、凸（convex）**的曲线，只有**一个全局最小值**。

w	−1	0	1	1.5	**2**	2.5	3	4	5
J(w)	190	90	30	15	**10 ← 最小**	15	30	90	190

它是**对称**的：w=1.5 与 2.5 都给 15；w=1 与 3 都给 30。因为 **J 是 w 的二次函数**（抛物线），最低点在 w = 2。

> **别搞混两张图：**
> · 第 8 页：横轴 x（面积），纵轴 y（价格）→ **数据空间**
> · 第 11 页：横轴 w（参数），纵轴 J（代价）→ **参数空间**

加上 b 之后

有了 w 和 b 两个参数，曲线变成一个**碗形的曲面**。两个水平轴是 w 和 b，竖直轴是 J。碗底那一点就是最优的 (w, b)。

Why this matters —— 四条考点

1. 线性回归给出的是凸二次代价（convex quadratic cost）。形状被数学保证是碗形。

2. 每一个局部最小值都是全局最小值（Every local minimum is global）。这是凸性最重要的推论，也是线性回归远比神经网络好训练的原因：你不可能卡在一个假的低谷里。

3. 唯一解需要足够的、独立的特征信息。碗可能是「扁的」—— 两个特征高度相关（共线性），或样本数比特征数还少，碗底就成了一条**平坦的沟槽**，有无穷多组 (w,b) 同样好，解不唯一。

4. 梯度下降只有在学习率合适时才收敛。碗是凸的，并不保证你一定能滚到底。**「有唯一最优解」和「算法能找到它」是两回事。**

第 12 页 · Gradient Descent: The Intuition（梯度下降的直觉）

场景：想象你站在代价曲面上，四周浓雾，什么都看不见 —— 只能感觉到脚下的坡度。

#	步骤	具体做什么
1	Start somewhere	给 w 和 b 一个初始猜测（**常取 0**）
2	Feel the slope	计算**梯度** —— 上升最陡的方向
3	Step downhill	朝梯度的**反方向**迈一小步
4	Repeat until settled	一直走，直到代价不再明显下降

> *梯度下降就是反复进行局部的下坡踏步。它从来看不到整个曲面，只能感受到当前所站位置的坡度。*

把比喻翻译成数学（考「解释梯度下降」的标准答案骨架）

雾中登山	数学量
你在山坡上的**位置**	当前的 (w, b)
你的**海拔高度**	代价 J
脚下的**坡度**	**梯度**（gradient）
你**步子的大小**	**学习率**（learning rate）

为什么不用穷举搜索?

> **100 个特征，每个只取 10 个候选值 → 需要 10^{100} 种组合，比可观测宇宙中的原子数还多。**
> 穷举搜索在现实维度下立刻死掉；有引导的搜索不会。

三个实用停止准则

1. 代价在相邻两次迭代间不再明显下降
2. 梯度约等于 0
3. **达到固定的迭代次数上限**（practical 里多半用这一种，跑固定次数后检查代价曲线是否变平）

> **Study check：**在浓雾里迈很大的步子会出什么问题?
> **答：会冲过头（overshoot）** —— 一步跨过谷底，落到对面山坡上，甚至比出发时更高。反复如此就会在碗壁间**振荡**甚至**发散**。这就是学习率过大的后果。

第 13 页 • Gradient Descent: The Algorithm（梯度下降算法）

$$\text{repeat until convergence}:$$
$$w := w - \alpha \cdot \partial J(w,b)/\partial w$$
$$b := b - \alpha \cdot \partial J(w,b)/\partial b$$
（同时更新 w 和 b，都使用它们的旧值）

三个符号

符号	含义
α（alpha）	**学习率** —— 控制每一步迈多大
∂J/∂w	**梯度** —— 指向**上升最陡**的方向
:=	**赋值**：重新计算并覆盖原值

> `:=` 不是数学等号。`w := w − …` 作为方程读是荒谬的，但作为**赋值语句**完全正常，就像代码里的 `w = w - lr * grad`。

Why subtract the gradient?（为什么是减号）—— 四条

1. **梯度指向上坡**，即代价增加的方向。
2. **减去它就把参数推向下坡。**
3. **在光滑的最小值附近，梯度的大小通常会缩小** → 步子自动变小，算法自然减速停车，不需手动调 α。
4. **收敛仍然取决于合适的学习率。**自动减速不保证万无一失，α 太大照样发散。

最容易失分的一条：同时更新（simultaneous update）

> **所有参数都必须从「同一组旧参数值」出发更新。**

正确做法：

```
tmp_w = w - alpha * dJ_dw   # 用旧的 w, b 算
tmp_b = b - alpha * dJ_db   # 仍用旧的 w, b 算
w = tmp_w                   # 最后一起覆盖
b = tmp_b
```

错误做法：

```
w = w - alpha * dJ_dw       # w 先被改了
b = b - alpha * dJ_db       # 这里的梯度用了新 w，错！
```

因为 ∂J/∂b 的计算里**包含 w**。先更新 w 再算 b 的梯度，算的就不是「同一个点上的梯度」，走出去的方向也不再是真正的最陡下坡方向。这是**手算和写代码时最常见的错误**。

连回比喻

公式部件	雾中登山
∂J/∂w、∂J/∂b	感受脚下的坡度
减号	转身朝下坡
α	迈多大一步
repeat	一直走

Study check：如果某点梯度为 0，参数会怎样？
答：w := w − α · 0 = w，**参数不变**，算法停在原地。这正是「梯度约等于 0」可作为停止准则的原因。对凸的线性回归，梯度为 0 的点就是全局最优。

第 14 页 · The Learning Rate（学习率）

α 是我们选的，不是从数据里学来的。**它是超参数。**选错 α，是「代码明明写对了却看起来坏掉」的最常见原因。

三种情形

① α 太小 —— 收敛，但慢得要命

迭代	1	3	5	7	10
Cost	100	91	86	83	80

特征形状：一条浅浅的、几乎笔直的下降线，永远不见变平。

② α 刚好 —— 平滑高效地收敛

迭代	1	3	5	7	10
Cost	100	50	25	13	7

特征形状：先陡降，后变平。这就是你想看到的形状。

③ α 太大 —— 冲过头，代价振荡或爆炸

迭代	1	2	3	4	5	6	8	10
Cost	100	150	90	200	120	300	400	500

上上下下，整体还在变大。步子跨过了谷底，落到对面更高的地方。

唯一最重要的诊断工具

永远把 J 对迭代次数作图（plot J against iteration number）。这一张图几乎能诊断一切。

你看到的	诊断
代价**上升**	α **太大**，没有别的可能（full stop）
几乎笔直的浅浅下降	α **太小**
变成 **NaN 或 inf**	α 大得离谱，或者**特征没有做缩放**

怎么调 α?

在对数尺度上搜索，而不是一点点微调：试 **0.001 → 0.003 → 0.01 → 0.03 → 0.1**，然后**取仍然能平滑下降的最大值**。别指望第一次就猜对，没有人能做到。

> **Study check**：代价下降得很漂亮，然后在一个仍然很高的值上变平了。这是学习率的问题吗？
> **答：不是。**曲线形状是健康的（陡降后变平），说明梯度下降正常，已收敛。问题出在**模型本身**：欠拟合 —— 特征不足或关系根本不是线性的。解决办法是改进模型或增加特征，**不是**调 α。考点是：**区分「优化问题」和「模型问题」**。

第 15 页 · From One Feature to Many（从一个特征到多个）

$$f_{w,b}(x) = w_1x_1 + w_2x_2 + \ldots + w_nx_n + b$$

向量形式： $f_{w,b}(x) = \mathbf{w} \cdot \mathbf{x} + b$

> **概念上什么都没变。**每个特征配一个权重，模型仍然是「加权和 + 一个偏移」。

例子（房价，4 个特征）

特征	值	权重
Size (sqft/100)	20	$w_1 = 3.1$
Bedrooms	3	$w_2 = 8.5$
Age (years)	10	$w_3 = -0.9$
Distance (mi)	5	$w_4 = -2.2$

$b = 45$（基础价格）

预测 = 3.1(20) + 8.5(3) + (−0.9)(10) + (−2.2)(5) + 45 = 62 + 25.5 − 9 − 11 + 45 = **172.5**（即 172,500 美元）

新记号

- **n** 现在是**特征的数量**（m 是样本数量）
- 每个样本 $\mathbf{x^{(i)}}$ **现在是一个向量**，不再是一个数
- $\mathbf{x^{(i)}_j}$ **= 第 i 个样本的第 j 个特征**

> 双下标/上标是真正的绊脚石，用具体例子记：$\mathbf{x_2^{(3)}}$ **= 第三栋房子的卧室数**。

点积不只是好看

- **数学上：**w · x 就是 $\Sigma_j w_j x_j$ 的紧凑写法。
- **计算上：**向量化的 NumPy 点积比等价的 Python 循环**快一到两个数量级**，因为它调用优化过的编译版线性代数库。

> practical 里请用 `np.dot` 或 `@` 运算符，不要对特征写 for 循环。

权重怎么解释（两个高频考点）

> **1. 必须加「其他条件不变（all else held equal）」**
> Age 权重 −0.9 → 房龄越大预测价格越低，**在其他条件不变时。**这个限定语必不可少，因为这正是多元回归中一个系数的含义。

> **2. 不能因为 8.5 > 3.1 就说卧室比面积更重要。**
> **权重只有在特征共享同一尺度时才可比。**这里显然不共享：面积以「百平方英尺」计，卧室以「间」计。改变单位就能任意改变权重大小。这直接引出下一页的特征缩放。

几何直观

特征数	几何形状
1 个	一条**直线**（line）
2 个	三维中的一个**平面**（plane）
更多	**超平面**（hyperplane）

全程都还是「线性」的，只是可视化变难了。

> **Study check：**加一间卧室、其他都不变，预测会怎么变？
> **答：**增加 w_2 = **8.5**（8,500 美元），从 172.5 变成 181.0。因为模型是加权和，每个特征的贡献独立可加。

第 16 页 · Closed-Form Solution: The Normal Equation（正规方程）

$$\theta = (X^T X)^{-1} X^T y$$

不用迭代、不用学习率，一步直接算出最优参数。

符号	含义
X	**设计矩阵（design matrix）—— 行 = 样本，列 = 特征**
y	目标值组成的**向量**
θ	全部参数（w 和 b 打包在一起）

> 记住 X 的方向：**行是样本（m 行），列是特征（n 列）**。搞反了整个式子就没意义。

两种方法的对比表（必背）

	Gradient Descent	Normal Equation
需要学习率 α	**需要**	**不需要**
迭代过程	**是**，迭代	**否** —— 闭式解
特征数 n 很大	**扩展性好**	**慢：$O(n^3)$**
需要特征缩放	**推荐**	**不需要**

记忆逻辑：正规方程「省心」（没有 α、不用缩放、不用迭代），代价是**特征一多就跑不动** —— 矩阵求逆复杂度 $O(n^3)$，n 翻倍时间变 8 倍。**一句话：大问题用梯度法。**

两个重要限制

> **1. 需要 X^TX 可逆（invertible）。**特征共线或样本数少于特征数时，X^TX 是奇异的，逆不存在，碗底是一条平沟。（呼应第 11 页「唯一解需要足够的、独立的特征信息」）

> **2. 实践中不要真的去算那个逆矩阵。**数值软件通常使用更稳定的最小二乘求解器。对普通最小二乘，优先使用基于 **QR、SVD 或伪逆（pseudoinverse）**的库求解器。
> practical 里用 `np.linalg.lstsq` 或 `np.linalg.pinv`，**不要**用 `np.linalg.inv(X.T @ X) @ X.T @ y`。

怎么选？

情况	选谁
特征少（n < 10000）、只做普通最小二乘	正规方程 / 库求解器
特征极多、数据极大、或模型非线性（神经网络）	梯度下降

正规方程只对线性回归这类有闭式解的模型存在。逻辑回归、神经网络都没有闭式解，只能用梯度法 —— 这也是为什么整门课要花大力气讲梯度下降。

第 17 页 · Feature Scaling（特征缩放）

当特征跨越差别巨大的取值范围时，梯度下降会**之字形（zig-zag）**缓慢地爬向最小值。缩放能解决这个问题。

	不缩放	缩放后
特征	x_1 = 面积 (0–2000)，x_2 = 卧室 (0–5)	都重缩放到大约 [−1, 1]
等高线	**狭长、拉伸的椭圆**	**圆整、均匀**
下降路径	缓慢的**之字形**	**直接**走向最小值

为什么会之字形？如果面积跑 0–2000 而卧室跑 0–5，代价曲面就变成一条**又长又窄的山谷**。在大多数点上，梯度**并不指向最小值，而是横穿山谷**。于是路径来回摆动。缩放后等高线接近圆形，梯度几乎笔直指向最小值。

怎么做

$$\text{① Z-score 标准化：}\ x' = (x - \mu) / \sigma$$

减均值、除以标准差。每个特征之后**均值为 0，标准差为 1**。

② **Min-max 归一化：**线性重缩放到 [0, 1]。

两种都可以，保持一致即可。

数据泄漏（Data Leakage）—— 本页最重要的考点

均值和标准差只能在「训练数据」上计算，然后把这些存下来的同一组数值应用到验证集和测试集。

如果在**划分数据之前**就对整个数据集算统计量，测试集的信息就**泄漏**进了训练过程，会**虚高**报告的性能，**使整个评估失效**。课件形容它：微妙、极其常见、且是严重的方法学错误。
正确顺序：先划分 → 再拟合 scaler → 再 transform。（sklearn：训练集 `fit`，测试集只 `transform`）

四条要点

1. **缩放不会让模型本质上更强。**它改变的是梯度下降**到达答案的速度**。
2. **正规方程不需要缩放**，因为它不迭代。
3. **它会改变权重的含义：**标准化之后，一个权重表示「该特征**每变化一个标准差**时 y 的变化量」。**这个版本的权重才可以合法地跨特征比较**—— 补上了第 15 页的伏笔。
4. **正则化（regularisation）是真正必须缩放的**，因为它惩罚权重，未缩放的特征会被不公平地惩罚。

Study check：把长度从米改成厘米，那个特征的权重会怎样？
答：数值**变成原来的 1/100**。特征值放大了 100 倍，要让预测不变，权重必须缩小 100 倍。**预测结果完全不变** —— 这正说明权重大小不能直接用来判断重要性。

第 18 页 · Overfitting & Underfitting（过拟合与欠拟合）

模型复杂度是一场平衡：**太简单会错过模式，太复杂会记住噪声。**

	Underfitting（欠拟合）	Good Fit	Overfitting（过拟合）
症状	模型太简单，**错过趋势**	抓住底层模式，泛化良好	模型太复杂，**记住噪声**
术语	**高偏差（high bias）**	—	**高方差（high variance）**
训练误差	**高**	低	**几乎为 0**
新数据误差	**高**	低	**很高**

- **欠拟合：**用直线拟合本来就弯曲的数据。它是**系统性地错**，而且**在训练数据上也错**。
- **过拟合：**曲线扭来扭去贴近每一个点。训练误差几乎为零，但换一栋新房子可能错得离谱 —— 它**把噪声当成信号学进去了**。

最容易误解的一点：第三张图仍然是线性回归

一个特征的直线几乎不可能过拟合 —— 参数太少，扭不起来。那条摇摆的曲线来自**添加多项式特征**（x^2、x^3 等）。

关键：那仍然是线性回归。
「线性」指的是「对参数是线性的」，不是指「在 x 上画出一条直线」。

一旦把 x^2 作为数据的额外一列加进去，今天教的**所有内容都原封不动地适用**（同样的 J、同样的梯度下降、同样的正规方程）。

怎么诊断（very examinable）

训练误差	留出误差	诊断
低	**高得多**	**过拟合**
高	**高**	**欠拟合**

仅凭训练误差永远无法揭示过拟合。这正是评估必须坚持留出划分（held-out split）的原因。

对策

问题	怎么办
过拟合	收集更多数据；使用更少或更简单的特征；**正则化**（ridge / lasso）
欠拟合	增加更有信息量的特征；加多项式项；换更灵活的模型

Study check：三个模型中，哪个在训练数据上误差最低？
答：过拟合的那个，训练误差几乎为 0。陷阱正是：**训练误差最低 ≠ 最好的模型**。

第 19 页 · Evaluating the Model（模型评估）

训练完成后，我们需要**指标**来判断模型表现如何 —— **通常在留出的测试数据上**。

指标	示例值	含义
MSE	42.3	**均方误差** —— 平均的平方残差；单位是 **y^2**
RMSE	6.5	$\sqrt{}$**MSE** —— 回到 y 的**原始单位**（例如美元）
R^2	0.94	相对于「直接预测目标均值」的**改进程度**；在未见数据上表现很差时**可以为负**

① MSE

$$\mathrm{MSE} = (1/m)\ \Sigma\ (\hat{y}^{(i)} - y^{(i)})^2$$

就是第 10 页的代价函数**去掉那个 1/2**。**单位是 y^2** —— 房价以千美元计，MSE 单位就是「千美元的平方」，这个数字本身没有直观意义，只能用来比较模型。

② RMSE

开根号，**回到 y 的原始单位**。RMSE = 6.5 可直接读作：**平均而言预测偏离约 6,500 美元**。这是它比 MSE 更适合汇报给人看的原因。

③ R^2（决定系数）

衡量**你的模型比「永远预测 y 的平均值」这个笨基线好多少**。

R^2 值	含义
1	完美预测
0.94	好模型（示例值）
0	和直接预测均值一样好，模型毫无价值
< 0	**比直接预测均值还差**

R^2 可以为负。很多人以为「平方了所以非负」，错 —— R^2 不是某个东西的平方，它是 $1 - (SS_{res} / SS_{tot})$。在**未见数据**上预测很糟时，残差平方和可以超过总平方和。

怎么选用

场合	用哪个
优化 / 内部比较	MSE
向人汇报误差大小	**RMSE**（有单位，可解释）
说明模型解释力	**R^2**（无量纲，可跨数据集比较）

第 20 页 · Assumptions Behind Linear Regression（五个假设）

先搞清楚这一页为什么存在

你的目标	假设重要吗
纯预测（prediction）	可以违反其中好几条，模型照样有用
推断（inference） —— 置信区间、p 值、宣称某特征真的重要	**非常重要**

这个区分就是本页的要点。

五个假设 + 怎么检查 + 怎么修

① Linearity（线性性）
特征与目标的关系近似线性 —— 准确说是**对参数线性**。
检查：画残差 vs 拟合值，看有没有**弯曲（curvature）**。修复：变换特征（对数项、多项式项）。

② Independence（独立性）
观测（及其误差）彼此独立。
常见违反：**时间序列**（相邻点相关）、对同一对象的**重复测量**。

③ Homoscedasticity（同方差性）
残差在所有预测值上有大致**恒定的方差**。
检查：残差图若**摊开成锥形（fans out into a cone）**，说明方差随预测值增长 —— 在**价格和收入**数据上非常常见。修复：常用做法是**对 log(y) 建模**。

④ Normality of residuals（残差正态性）
只在**置信区间和假设检验**时需要，**拟合直线本身不需要**。检查：Q-Q 图。

常见误解：「数据必须服从正态分布才能用线性回归」—— **完全不对**。要求的是**残差**近似正态，而且只在做推断时才要求。

⑤ No multicollinearity（无多重共线性）
特征之间不高度相关（多元回归才涉及）。
后果：单个系数变得**不稳定、不可信**，但**整体预测可能依然很好**。检查：相关矩阵，或**方差膨胀因子（VIF）**。

如果只记一个诊断工具，记这个

画残差对拟合值的图（residuals vs fitted values）。

图上看到	违反了什么
弯曲	非线性
锥形 / 喇叭形	异方差（heteroscedasticity）
明显的模式或连续同号的串	不独立

Study check：对同一条街上的房子、跨十年的售价建模。哪个假设最危险？
答：Independence（独立性），双重违反：① 时间维度 —— 跨十年是时间序列，相邻年份高度相关；② 空间维度 —— 同一条街的房子共享地段、学区、噪音。（同方差性也有风险，因为价格数据常呈锥形。）

第 21 页 · Summary & Next Steps（总结与下一步）

Key Takeaways（五条核心结论）

1. **线性回归把一个连续值预测为「特征的加权和 + 一个偏置」。**
2. **代价函数 J(w,b)** —— 均方误差 —— **衡量这条线拟合得多好。**
3. **梯度下降**迭代地更新 w 和 b 以最小化 J；**正规方程**直接求解出它们。
4. **特征缩放加快收敛；小心过拟合/欠拟合。**
5. **在留出数据上用 MSE、RMSE 和 R^2 评估。**

把它们连成一条线

数据 → 模型（wx+b）→ 残差 → 平方并平均得到 J → 用梯度下降或正规方程最小化 J → 在留出集上用 MSE/RMSE/R^2 检查

沿途的三个「注意事项」挂在不同环节：

- **特征缩放** 挂在「梯度下降」这一步（加速，正规方程不需要）
- **过拟合/欠拟合** 挂在「模型复杂度」这一步
- **五个假设** 挂在「解释系数」这一步（预测 vs 推断）

Next Steps

Practical：探索 California Housing 数据集的变量和单位；用**固定的 train–test 划分**拟合线性回归**基线；谨慎地**解读 MSE、RMSE、R^2、诊断图和系数；用**视觉证据和领域推理**提出新特征。

Coming next：分类 —— 感知机（perceptron）与逻辑回归（logistic regression）。回想第 5 页：分类和回归共用同一条流水线，只是代价函数和输出形式不同。

第 22 页 · Tutorial Activity（辅导课活动）

两道相互关联的题目，深化线性回归的数学基础。

- **Q1：**化简**高斯对数似然**，并解释为什么**最大化它等价于最小化平方误差和**。
- **Q2：**用**设计矩阵**表示**多项式回归**，推导**正规方程**，并说明**逆形式解何时有效**。

> 课件的要求：**展示每一步代数变换，并检查矩阵维度。**

Q1 思路概览：为什么最小二乘 = 最大似然

建模假设：$y^{(i)} = w \cdot x^{(i)} + b + \varepsilon^{(i)}$，噪声 $\varepsilon^{(i)} \sim$ 独立同分布的 $N(0, \sigma^2)$。

1. **单点似然：**$p(y|x) = (2\pi\sigma^2)^{-1/2} \exp(-(y - f(x))^2 / (2\sigma^2))$
2. **独立 → 连乘：**$L = \Pi_{i=1..m}\, p(y^{(i)} \mid x^{(i)})$（用到第 20 页的独立性假设）
3. **取对数，连乘变连加：**$\ln L = -(m/2)\ln(2\pi\sigma^2) - (1/2\sigma^2)\, \Sigma(y^{(i)} - f(x^{(i)}))^2$
4. **观察结构：**第一项不含 w、b，是常数；第二项 = 负常数 × 平方误差和

$$\max_{w,b} \ln L \iff \min_{w,b} \Sigma(y^{(i)} - f(x^{(i)}))^2$$

> **结论：MSE 不是随便挑的。在「误差是独立同分布高斯噪声」的假设下，最小二乘就是最大似然估计。**

Q2 思路概览：多项式回归的正规方程

设计矩阵：d 次多项式 $f(x) = \theta_0 + \theta_1 x + \cdots + \theta_d x^d$，X 的第一列全是 1（吸收偏置 b），这个矩阵叫 **Vandermonde 矩阵**。

> 呼应第 18 页：**这仍然是线性回归**，因为对参数 θ 是线性的。

维度检查（课件明确要求）：

量	维度
X	m × (d+1)
θ	(d+1) × 1
y	m × 1
X^TX	**(d+1) × (d+1)** ← 方阵，才谈得上求逆
X^Ty	(d+1) × 1

推导： $J(\theta) = \frac{1}{2} \| X\theta - y \|^2$，求导 → $\nabla_\theta J = X^T(X\theta - y) = 0$ → $\mathbf{X^TX\theta = X^Ty}$

逆形式何时有效： 只有当 X^TX 可逆（X 列满秩，rank(X) = d+1）时。失效情形：m < d+1；x 的取值互不相同的个数少于 d+1；各列高度相关（Vandermonde 矩阵在 d 大时出了名的病态）。否则用伪逆或 QR/SVD 求最小范数解。

第 23 页 · Prepare the Likelihood Argument（准备似然论证）

这是 **Q1 的解题指南**，只给方法框架，不给具体计算和答案。

> *复习高斯噪声假设，并辨认哪些量是固定的。从工作表给出的似然出发。在化简之前先给每一项贴标签。*

四个步骤

步骤	要求
① **product → sum**	**用对数把各个观测分离开。**似然是 m 个概率的连乘，取对数后变连加 —— 这是整道题最关键的第一个动作。
② **simplify carefully**	**追踪指数项，不要代入数值。**目标：把似然与平方残差联系起来。保持符号形式。
③ **parameter check**	**标出哪些项依赖于模型参数。**σ、π、m 都与 w、b 无关，是常数；只有平方和那一项含参数。
④ **objective link**	**把剩下的表达式与平方残差作比较，用你自己的话解释这个优化上的联系。**

「in your own words」是评分点 —— 光写出公式不够，要说清楚：最大化对数似然 = 最小化平方误差和，因为二者只差一个负常数因子和一个与参数无关的常数项。

应试提醒

Study check 问的是：上课前能不能**说出这题在考什么概念、列出推理步骤、指出该展示哪些过程** —— **而不必算出工作表里的数值**。这类题的分数主要在**过程**上：

- 有没有明确写出高斯噪声假设
- 有没有正确地从连乘取对数变成连加
- 有没有区分「常数项」与「含参数项」
- 有没有明确地下结论说明二者等价

第 24 页 · Prepare the Polynomial Design Matrix（准备多项式设计矩阵）

> *一个弯曲的关系，可以用「变换后的输入特征」来表示。*

这正是第 18 页那句话的操作版本：**曲线不代表非线性模型** —— 我们只是把 x^2、x 这些当作**新的列**塞进设计矩阵，模型对参数仍然是线性的。

设计矩阵 X 的结构（以二次多项式为例）

x_i^2	x_i	1
x_1^2	x_1	1
x_2^2	x_2	1
⋮	⋮	⋮
x_n^2	x_n	1

两条铁律：
每个观测一行（one row per observation）
每个系数一列（one column per coefficient）
最后那一列全是 1，用来吸收常数项（截距）。

课件这里的列顺序是 **[x^2, x, 1]**（降幂）。**顺序无所谓，但 β 里系数的排列必须与之对应** —— 手算时最容易错的地方。

一般的特征向量形式

$$\varphi(x_i) = [\text{basis terms}]^T \implies \hat{y}_i = \varphi(x_i)^T\beta$$

- **φ（phi）叫基函数（basis function）**，把原始的 x 映射成一组「基项」
- 基项不一定是多项式，也可以是 log x、sin x、交互项 x_1x_2 等
- **β 收集所有未知系数**

整个模型的矩阵形式：$\hat{Y} = X\beta$

符号	名称
X	设计矩阵
β	参数向量（parameter vector）
Y	响应向量（response vector）

维度检查（n 个观测、p 个系数）

量	维度
X	$n \times p$
β	$p \times 1$
$\hat{Y} = X\beta$	**$n \times 1$** ✓

内侧维度 p 必须对上，外侧给出 $n \times 1$，正好是 n 个预测值。**先查维度再动手算**，能挡掉大部分错误。

第 25 页 · Plan the Normal-Equation Derivation（正规方程推导计划）

> *为每一步代数变换给出理由，并在最后陈述所需的矩阵条件。*

#	步骤	具体要做什么
1	**Define the objective**	写出**残差向量**和**平方误差目标函数**
2	**Expand carefully**	**检查维度和转置规则**
3	**Differentiate**	**辨认出关于 β 的梯度**
4	**Use the first-order condition**	**只有在陈述了所需矩阵条件之后才求解**

逐步展开

① **定义目标：**残差向量 $r = Y - X\beta$（$n \times 1$）

$$J(\beta) = \|Y - X\beta\|^2 = (Y - X\beta)^T(Y - X\beta)$$

用**向量范数的平方**写，而不是 Σ 号 —— 这样才能用矩阵微积分。

② 小心展开：

$$J(\beta) = Y^TY - 2\beta^TX^TY + \beta^TX^TX\beta$$

展开会得到 $-Y^TX\beta$ 和 $-\beta^TX^TY$ 两项，它们都是 **1×1 的标量**，而标量的转置等于自身，所以可以合并成 $-2\beta^TX^TY$。**这一步是最常错的地方。**
常用规则：$(AB)^T = B^TA^T$。

③ 求导：

$$\nabla_\beta J = -2X^TY + 2X^TX\beta$$

（用到 $\nabla(\beta^TA\beta) = 2A\beta$，$A = X^TX$ 对称；以及 $\nabla(\beta^Tc) = c$）

④ 一阶条件：令梯度为 0：

$$X^TX\beta = X^TY \quad \text{（正规方程）}$$

只有在陈述了所需的矩阵条件之后才写出解。必须先说明：**当且仅当 X^TX 可逆（X 列满秩）时**，才可以写 $\beta = (X^TX)^{-1}X^TY$。
答题时如果直接跳到最后这个式子而不提可逆性，就会丢分。

一句话记住：定义 → 展开 → 求导 → 令零（并先说可逆条件）。

第 26 页 · M1 T2 Practical Activity（实践活动）

用 **California Housing 数据集**，把回归理论与一个真实的预测任务连接起来。

题号	要做什么
Q1	解读**列、单位和可能的预测变量**
Q2	**拟合并评估一个线性回归基线**；解读**指标和系数**
Q3.1	制作要求的**关系图**，外加**一张原创可视化**
Q3.2	用**领域推理、图表和测试集表现**为一组特征辩护

两条操作纪律

按顺序运行提供的脚手架（scaffold）。
保持测试集划分固定，并且只在训练数据上拟合预处理。

- **「只在训练数据上拟合预处理」** = 第 17 页的数据泄漏问题。sklearn 里：训练集 `fit_transform`，测试集只 `transform`。
- **「保持测试集划分固定」** 是为了让不同特征组合之间的比较**公平** —— 如果每次实验换一个随机划分，就分不清性能变化是特征带来的还是划分运气带来的。

评分导向

> *这个 practical 既强调正确的实验推理，也强调代码。按顺序运行工作流，检查中间输出，并且从证据出发得出结论，而不是从单一分数出发。*

只报告一个 R^2 数字是不够的，要用图、系数、诊断输出组成的证据链来支持结论。

Study check：你会用哪个输出、图或对比作为证据？你要如何避免用测试数据来做开发决策？

证据可以有：特征与目标的散点图 / 相关矩阵；残差 vs 拟合值图（第 20 页）；训练误差 vs 留出误差的对比（第 18 页）；系数的符号和大小是否符合领域常识。

避免用测试数据做决策：从训练集里再切出一个**验证集**，或用**交叉验证**来做特征选择和调参；**测试集只在最后碰一次**。反复用测试集挑特征，等于把测试集变成了训练集的一部分 —— 这是另一种形式的数据泄漏。

第 27 页 · How to Work Through the Regression Notebook

> *利用提供好的代码，把精力放在「解读、公平比较和特征推理」上。*

代码是给你的，分数在思考上。

#	步骤	具体做什么
1	**Understand the data**	辨认**行、特征、目标和单位**
2	**Fit a baseline**	用**一个固定划分**；记录 **MSE、RMSE 和 R^2**
3	**Interpret carefully**	读**诊断图**；比较系数时**务必考虑尺度**
4	**Engineer and compare**	用**图表**和**未见数据上的表现**为特征辩护

每一步挂钩的前面知识点

- ① **理解数据** → 第 6 页（m 是行、n 是列、x 与 y）+ 第 7 页（单位检查）
- ② **拟合基线** → 第 19 页（三个指标）+ 第 26 页（固定划分）。三个指标都要记录：MSE 比较、RMSE 汇报、R^2 说明解释力。
- ③ **谨慎解读** → 第 20 页（残差 vs 拟合值一张图诊断一切）+ 第 15、17 页（尺度不同权重不可比）。别忘第 8 页：说 **associated with**，不说 causes。
- ④ **构造并比较** → 第 18 页（过拟合只有在留出数据上才现形）。「unseen-data performance」= 必须用模型没见过的数据验证新特征是否真有帮助。

第二部分 · Tutorial 标准答案

Learning goals：① 把高斯噪声下的最大似然与平方误差和连接起来；② 用设计矩阵表达多项式回归；③ 推导并解读最小二乘的正规方程。

> *使用说明：一次跟一步代数变换，并检查每个矩阵的维度。重点在「为什么一个优化问题会变成最小二乘」和「解析解需要什么假设」。*

Question 1 · 高斯 MLE → 最小二乘（完整推导）

题目：化简下面的对数似然，并解释为什么最大化它等价于最小化 SSE。

$$\log L(w_0, w_1) = \Sigma_{i=1..N} \log \left[(2\pi\sigma^2)^{-1/2} \cdot \exp\left(-(y_i - (w_0 + w_1 x_i))^2 / (2\sigma^2) \right) \right]$$

第 0 步：设记号（答案的第一个动作）

$$r_i = y_i - (w_0 + w_1 x_i)$$

> **先定义残差再动手**，式子立刻短一半。这是拿过程分的第一步。
> **模型假设：**误差是**独立的高斯误差、共同方差 $\sigma^2 > 0$**。这两个词（independent、common variance）答题时必须写出来。

第 1 步：拆开乘积 —— 用 log(ab) = log a + log b

$$\log L = \Sigma_{i=1..N} \left[\log((2\pi\sigma^2)^{-1/2}) + \log \exp(-r_i^2/(2\sigma^2)) \right]$$

注意 $1/\sqrt{(2\pi\sigma^2)}$ 被写成 $(2\pi\sigma^2)^{-1/2}$，下一步好处理。

第 2 步：两个对数各自化简

- $\log((2\pi\sigma^2)^{-1/2}) = -\tfrac{1}{2} \log(2\pi\sigma^2)$（用 $\log a^n = n \log a$）
- $\log \exp(u) = u$ → 指数项**直接落下来**

$$\log L = \Sigma_{i=1..N} \left[-\tfrac{1}{2} \log(2\pi\sigma^2) - r_i^2/(2\sigma^2) \right]$$

第 3 步：把与 i 无关的项提出求和号

第一项**不含 i**，所以求 N 次就是乘 N：

$$\begin{aligned} \log L &= -(N/2) \log(2\pi\sigma^2) - (1/(2\sigma^2)) \Sigma_{i=1..N} r_i^2 \\ &= -(N/2) \log(2\pi\sigma^2) - (1/(2\sigma^2)) \Sigma (y_i - (w_0 + w_1 x_i))^2 \end{aligned}$$

最后那个求和正好就是 SSE。

第 4 步：解释等价性（拿分的关键段落）

$$\log L = \underbrace{-(N/2)\log(2\pi\sigma^2)}_{\text{[对 } w_0,w_1 \text{ 是常数]}} - \underbrace{(1/(2\sigma^2)) \cdot \mathrm{SSE}(w_0,w_1)}_{\text{[正常数]}}$$

答案给的三句话论证：

1. **第一项在 w_0、w_1 变化时不改变** → 与优化无关
2. **SSE 前面的系数是负的** → 要让对数似然**增大**，就必须让 SSE **减小**
3. 因此 **$\arg\max_{w0,w1} \log L = \arg\min_{w0,w1} \mathrm{SSE}$**

> 因为 $-1/(2\sigma^2)$ 是**负数**，「最大化 logL」和「最小化 SSE」才是同一件事。**$\sigma^2 > 0$ 这个条件在这里是必需的**，否则符号翻转。

第 5 步：Interpretation（答案专门写了一段）

> **在「独立、等方差的高斯噪声」假设下，普通最小二乘同时也是最大似然估计量。**
> **如果噪声假设改变，另一种损失或加权方式可能更合适。**

这回答了整门课一个大问题：**MSE 不是随手挑的**，它有概率论上的正当理由。同时也留了口子 —— 噪声是重尾的，MAE 或 Huber 损失更合适；方差不等（异方差），就该用加权最小二乘。

Question 2 · 多项式回归的矩阵形式与最小二乘解

题目：给定数据 $(x_1,y_1), \cdots, (x_n,y_n)$，拟合模型 $Y = ax^2 + bx + c$。要求：(1) 写出矩阵形式；(2) 用最小二乘推导出 $\beta = (X^TX)^{-1}X^TY$。

第 1 部分 · Matrix formulation

$Y = [y_1, y_2, \cdots, y_n]^T$； $\beta = [a, b, c]^T$； X 的第 i 行为 $[x_i^2, x_i, 1]$

量	维度
Y	$n \times 1$
X	**$n \times 3$**
β	3×1

为什么是 3 列? 因为有 **3 个未知系数** a、b、c —— 呼应第 24 页「每个系数一列」。

验证第 i 行乘以 β： $[x_i^2 \quad x_i \quad 1] \cdot [a, b, c]^T = ax_i^2 + bx_i + c = \hat{y}_i$ ✓

所以**拟合值向量**是 **$\hat{Y} = X\beta$**。

> **一般来说 $Y \neq X\beta$**，因为观测里含有残差。等号只对 **$\hat{Y}$** 成立，对 **Y** 不成立。（第 6 页 y vs ŷ 在矩阵版里同样重要）

第 2 部分 · Least-squares derivation

① 残差向量与目标函数： $r = Y - X\beta$

$$S(\beta) = \|Y - X\beta\|_2^2 = (Y - X\beta)^T(Y - X\beta)$$

② 展开：

$$S(\beta) = Y^TY - 2\beta^TX^TY + \beta^TX^TX\beta$$

③ 对参数向量求导：

$$\nabla_\beta S(\beta) = -2X^TY + 2X^TX\beta$$

④ 令梯度为零：

$$-2X^TY + 2X^TX\beta = 0 \iff X^TX\beta = X^TY \quad \text{（正规方程）}$$

⑤ 加条件才能求逆：如果 X 的三列线性无关，那么 X^TX 可逆，于是

$$\beta = (X^TX)^{-1}X^TY$$

β 的三个分量就是估计值 â、b̂、ĉ。

Why this is a minimum（为什么这是极小值）

求导令零只能保证是**驻点**。答案补上了严格论证：

- **Hessian（二阶导矩阵）= $2X^TX$**
- $2X^TX$ 是**半正定（positive semidefinite）**的 → 所以 **S(β) 是凸二次函数**
- 若 X **列满秩（full column rank）**，Hessian 就是**正定（positive definite）** → **解唯一**

为什么 X^TX 一定半正定？对任意向量 v：$v^T(X^TX)v = (Xv)^T(Xv) = \|Xv\|^2 \geqslant 0$。当 X 列满秩时，Xv = 0 只有 v = 0，于是严格大于 0，即正定。

这段呼应第 11 页：凸 → 每个局部最小都是全局最小；列满秩 → 碗底是一个点而非平沟。

Practical note

> *逆的公式对推导有用。数值软件通常用 QR 分解、SVD 或伪逆来求解最小二乘系统，这样更稳定，而且能处理秩亏（rank-deficient）的情形。*

注意措辞：「**对推导有用**」—— 考试推导时该写 $(X^TX)^{-1}$，但写代码时别真去求逆。

Tutorial 答题时最容易丢的三处分

1. Q1 忘了说明第一项是常数、系数是负的（结论就没有论证）
2. Q2 直接跳到 $(X^TX)^{-1}$ 而不提列满秩
3. Q2 只令梯度为零，不做 Hessian 的凸性说明

第三部分 • Practical 标准答案（California Housing）

Exercise 1 • Understand data（理解数据）

代码 Cell 1 — 导入与加载

```
import numpy as np
import pandas as pd
from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt

data = fetch_california_housing(as_frame=True)
df = data.frame
```

导入	对应课件的哪一步
`fetch_california_housing`	理解数据
`train_test_split`	**固定划分**（第 26 页纪律）
`LinearRegression`	拟合基线
`mean_squared_error, r2_score`	评估指标（第 19 页）

`as_frame=True` 让返回值是 **pandas DataFrame**，`data.frame` 里**特征和目标已经拼在一起**。

代码 Cell 2 — 先看数据

```
print(df.head())
print(df.info())
df.hist(bins=50, figsize=(12,8))
plt.show()
```

输出的关键信息：20640 行（m = 20640）；**9 列**（8 个特征 + 1 个目标）；**全部 float64，没有缺失值**。

> `df.info()` 的第一件事永远是查**缺失值和数据类型**。

Question 1 参考答案 • 列的含义

> 每一行描述的是 **1990 年人口普查中加州的一个「街区组（block group）」** —— **不是一栋房子**。这是最容易误解的地方，也解释了为什么列名充满 Med（中位数）和 Ave（平均）。

列名	含义
MedInc	该街区组的**家庭收入中位数**
HouseAge	房屋年龄中位数
AveRooms	每户平均房间数
AveBedrms	每户平均卧室数
Population	街区组人口
AveOccup	每户平均人数
Latitude	南北位置
Longitude	东西位置
MedHouseVal	**目标**：房价中位数，单位 **$100,000**

> **单位是 10 万美元** —— 目标值 4.526 表示 452,600 美元。这直接影响后面对 MSE 和系数的解读。

可能的预测变量：MedInc、Latitude、Longitude、AveRooms、AveBedrms、HouseAge。理由：收入代表**本地购买力**；经纬度代表**位置**；房间/卧室描述**住房特征**；房龄反映**开发历史**。

答案里最重要的方法学提醒

> **直方图帮我们理解取值范围、偏度和异常值，但一个特征自己的直方图并不能证明它能预测房价。我们还需要关系图或模型证据。**
> 直方图只描述**单个变量自身的分布**，完全没有涉及它与 y 的**关系**。要看关系，得画散点图或看模型系数。

Exercise 2 · Train a linear regression model（训练基线模型）

代码逐步拆解

```
X = df.drop(columns=["MedHouseVal"])   # 8 个特征
y = df["MedHouseVal"]                  # 目标

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42)

model = LinearRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

mse = mean_squared_error(y_test, y_pred)
r2  = r2_score(y_test, y_pred)
```

> `random_state=42` 就是第 26 页「**保持测试集划分固定**」的实现。有了它，每次运行、每个特征组合用的都是**同一批测试样本**，比较才公平。
> 30% 测试 → 训练 14448 条，测试 6192 条。

> `fit` **只在训练集上调用**（第 17 页数据泄漏）。而且这里**没有做特征缩放** —— 完全正确，因为 sklearn 的 `LinearRegression` 用的是**闭式解 / 最小二乘求解器**，不迭代（第 16 页对比表：正规方程不需要缩放）。

结果：MSE ≈ 0.53，R^2 ≈ 0.60

- **R^2 = 0.60**：这个线性模型解释了房价中位数**约 60% 的变异**。
- **MSE = 0.53 的单位**：目标单位是 10 万美元，MSE 单位是**目标的平方**。开根号得 **RMSE ≈ 0.73**，即**平均偏离约 73,000 美元**。

Actual vs Predicted 散点图

- 有**明显的向上趋势** ✓
- 但点**没有紧贴对角线**，模型仍有相当大的误差
- **在两端表现更差**

> **目标值接近 5 处出现一条水平聚集带** —— 这反映数据集的**上限截断（upper cap）**。真实房价被人为封顶在 5.00001（即 50 万美元），所有更贵的房子都被压到这个值。模型无法预测超过它的值，于是形成一条竖线。

系数表里的陷阱

Feature	Coefficient
AveBedrms	**7.786e-01 ← 最大**
MedInc	4.458e-01
HouseAge	9.682e-03
Population	−7.757e-07 ← 几乎为 0
AveOccup	−3.370e-03
AveRooms	−1.221e-01
Latitude	−4.185e-01
Longitude	−4.337e-01

> **系数描述的是「其他特征保持不变时，该特征变化一个单位」带来的方向和幅度。因为各特征使用不同的单位，原始系数的大小不应被当作重要性的完美排序。**

- **Population** 取值动辄成千上万，系数必然极小（−7.8e-07）—— 这**不代表**人口不重要，只是单位造成的。
- **AveBedrms** 取值大多在 1 附近、变化范围极小，系数自然被推得很大。

- 要合法比较，得先做**标准化**，让系数变成「每变化一个标准差」（第 17 页）。

答案最终的判断（结合探索性证据）：**MedInc 和位置变量（Latitude、Longitude）特别有用。**住房类变量（AveRooms、AveBedrms、HouseAge）在与收入和位置结合时能提供额外信息。

> 注意「Taken together with the exploratory evidence」这个措辞 —— 这就是第 26 页「**从证据链得出结论，而不是从单一分数**」。

Exercise 3 · Feature Engineering（特征工程）

一、示范：只用经纬度

```
X = df[["Longitude", "Latitude"]]
# 同样的 split(test_size=0.3, random_state=42)、fit、predict
```

结果：MSE = 0.99，R^2 = 0.25。对比 8 特征基线（0.53 / 0.60），**性能掉了一半以上。**

> *可视化突出了房价的地理分布，让我们看到位置如何影响房价。但模型捕捉到的只是空间趋势，预测精度有限，因为收入、人口密度等其他因素没有被包含进来。*

那张 **Longitude × Latitude 按房价着色**的散点图（`c=y, cmap="jet"`）实际上把**加州地图**画了出来 —— 沿海（旧金山湾区、洛杉矶）明显偏红（高价），内陆偏蓝。

> **线性模型的根本局限：**经纬度与房价的真实关系**高度非线性**（不是「越往北越贵」，而是「离海岸越近越贵」）。一个 w_1 · Longitude + w_2 · Latitude 的平面根本装不下这种模式。所以 R^2 只有 0.25。

二、三组特征的公平对比

```
feature_sets = {
    "Location only": ["Longitude", "Latitude"],
    "Selected six": ["MedInc","Latitude","Longitude","AveRooms","AveBedrms","HouseAge"],
    "All eight":    [c for c in df.columns if c != "MedHouseVal"],
}

for label, features in feature_sets.items():
    X_features = df[features]
    X_train, X_test, y_train, y_test = train_test_split(
        X_features, y, test_size=0.3, random_state=42)   # 同一个种子
    ...
```

> `random_state=42` 在循环里保持不变 —— 这就是「**公平比较**」的技术实现。三个模型见到的是**完全相同的**测试样本，性能差异**只能**归因于特征集本身。

特征集	MSE	R^2
Location only	0.987	0.248
Selected six	**0.532**	**0.595**
All eight	0.531	0.596

三、Question 3.1 的三张图

图 1 — MedInc vs MedHouseVal：清晰的**正向关系**。

图 2 — AveBedrms vs MedHouseVal：

```
bedroom_limit = df["AveBedrms"].quantile(0.99)
bedroom_plot = df[df["AveBedrms"] <= bedroom_limit]
```

> **先截到 99 分位再画图。**因为 AveBedrms 有少数极端值（有的街区组平均卧室数高达 30+），不截断的话所有正常点会被挤成左边一坨。

> 这**只是为了显示**，`bedroom_plot` 没有被拿去训练模型。**不要**把「为了画图而过滤」变成「悄悄删了数据再建模」。

图 3 — 原创可视化：相关性条形图

```
target_correlations = df.corr(numeric_only=True)["MedHouseVal"] \
    .drop("MedHouseVal").sort_values()
```

特征	与房价的相关系数
MedInc	**0.688 ← 遥遥领先**
AveRooms	0.152
HouseAge	0.106
AveOccup	−0.024
Population	−0.025
Longitude	−0.046
AveBedrms	−0.047
Latitude	**−0.144**

这张表最重要的教训：Latitude 和 Longitude 的单变量相关系数都**接近 0**，但它们在模型里**非常有用**。

为什么？因为**经纬度必须一起看才有意义** —— 单独看纬度和房价没有单调关系（北边有贵的旧金山，南边有贵的洛杉矶，中间的内陆便宜）。相关系数只能捕捉**单变量的线性单调关系**，抓不住这种交互效应。

答案原话：**没有任何单一的简单相关系数能捕捉每一个有用的效应，尤其是地理效应。**

四、Question 3.2 参考答案

特征	理由
MedInc	代表本地经济状况，**与房价的单变量关系最清晰**
Latitude + Longitude	代表位置，**必须一起考虑才最有意义**
AveRooms、AveBedrms	描述住房特征
HouseAge	反映本地住房存量的年龄与开发历史

> *选定的六特征集远优于只用位置，并且与全特征模型表现几乎相同。因此它是一个合理的平衡：兼顾了经济、地理和住房信息，同时省略了 Population 和 AveOccup —— 这两个特征对这个特定的线性模型贡献极小。*

这并不证明被省略的特征对每一个模型或分析都无用。
这是方法学上的谨慎（第 26 页的「cautiously」）。Population 在线性模型里没用，不代表它在树模型或加了交互项之后也没用。答题时加上这种限定语，是拿高分的关键。

Practical 最容易在报告里失分的三处

1. 拿原始系数排重要性（AveBedrms 那个坑）
2. 只报 R^2，不说 RMSE 对应多少钱
3. 结论写死，不加「对这个线性模型而言」的限定

附录 • 高频考点速查表

A. 必背对照表

参数 vs 超参数

	参数	超参数
例子	w、b	学习率 α
来源	从数据学出来	我们自己选
算法会调吗	会	不会

梯度下降 vs 正规方程

	Gradient Descent	Normal Equation
学习率 α	需要	不需要
迭代	是	否（闭式解）
n 很大	扩展性好	慢：$O(n^3)$
特征缩放	推荐	不需要

过拟合 vs 欠拟合诊断

训练误差	留出误差	诊断	术语
低	高得多	过拟合	高方差
高	高	欠拟合	高偏差

三个评估指标

指标	单位	用途	可否为负
MSE	y^2	优化 / 内部比较	否
RMSE	y 的原始单位	向人汇报	否
R^2	无量纲	说明解释力	**可以**

学习率诊断表

代价曲线形状	诊断
上升 / 振荡	α 太大（full stop）
浅浅的、几乎笔直的下降	α 太小
先陡降后变平	α 刚好 ✓
变成 NaN / inf	α 大得离谱，或特征没缩放
陡降后变平，但停在高位	**不是 α 的问题** —— 模型欠拟合

残差 vs 拟合值图诊断表

图上看到	违反的假设
弯曲（curvature）	线性性
锥形 / 喇叭形	同方差性（异方差）
明显的模式或连续同号的串	独立性

B. 十五条最容易失分的知识点

1. **上标 $x^{(i)}$ 是索引，不是指数。**m 是样本数（行），n 是特征数（列）。
2. **y 是真实值，$\hat{y}$ 是预测值。**整门课就是让 $\hat{y}$ 接近 y。
3. **参数是学出来的，超参数是人选的。**α 是超参数，算法从不碰它。
4. **说 associated with，不说 causes。**相关 ≠ 因果。
5. **残差 = 实际 − 预测。**负号 = 高估，正号 = 低估。
6. **平方的三个理由：**防抵消、重罚大误差、处处可微（绝对值在 0 处不可微）。
7. **J 里的 1/2 只为求导方便，不改变最优解。**
8. **J 的自变量是 w 和 b，不是 x。**
9. **梯度下降必须同时更新**：两个梯度都用同一组旧参数计算。
10. **凸性保证最优解存在且唯一地好，但不保证算法能找到它** —— 仍取决于 α。
11. **权重只有在特征共享同一尺度时才可比。**标准化后才能按「每变化一个标准差」比较。
12. **scaler 只在训练集上 fit**，否则是数据泄漏，评估失效。
13. **「线性」指对参数线性**，不是在 x 上画直线。加了 x^2 仍是线性回归。
14. **仅凭训练误差永远无法揭示过拟合。**必须看留出集。
15. **R^2 可以为负**（比直接预测均值还差）；**正规方程失效于 X^TX 不可逆**（共线或 m < n）。

C. 一分钟总复习

数据 → 模型 $f(x) = w \cdot x + b$ → 残差 $(y - \hat{y})$ → 平方并平均 → $J(w,b)$
→ 最小化 J【梯度下降（迭代，需 α 与缩放）／正规方程（一步，需可逆）】
→ 在**留出集**上用 MSE / RMSE / R^2 评估 → 用残差图检查假设 → 谨慎解读系数