ARTI2001 · M1 T3 分类 Quizlet 全集（167 题）

覆盖 28 页课件 + Tutorial 三题 + Practical 全部内容。每题含四个选项、正确答案与解析。
建议用法：遮住绿色答案栏自测，答错的题回去看知识点文件对应章节。

A · 课件部分（第 4–28 页，125 题）

第 4 页：回归 vs 分类（4 题）

1. 回归与分类最根本的区别是什么？

A. 回归是监督学习，分类是无监督学习
B. 预测的目标变量类型不同：连续值 vs 离散类别
C. 回归用线性模型，分类必须用神经网络
D. 回归需要标签，分类不需要标签

> **答案 B** — 两者都是监督学习、都用带标签数据、流水线相同。唯一的根本差别是目标 y 的类型：连续数值 → 回归；离散类别 → 分类。损失函数的不同是由此引起的结果，不是原因。

2. "根据历史数据预测明天的最高气温"属于哪类任务？

A. 分类，因为要预测天气
B. 回归，因为输出是连续数值
C. 无监督学习中的聚类
D. 强化学习

> **答案 B** — 气温是实数，输出连续 → 回归。判断标准永远看输出的类型，不看题目描述的领域。如果问的是"明天会不会下雨（是/否）"，那才是分类。

3. 课件提到的回归常用损失函数是：

A. 均方误差（mean squared error）
B. 二元交叉熵（binary cross-entropy）
C. 感知机更新规则
D. 准确率（accuracy）

> **答案 A** — MSE 衡量预测值与目标值之差的平方，是回归的典型目标函数。二元交叉熵是分类用的。准确率是评估指标，不是损失函数——它不可导，没法做梯度下降。

4. 关于分类模型的输出，下列说法正确的是：

A. 分类模型只能输出类别标签，不能输出数值
B. 分类模型可以直接输出标签，也可以先估计类别概率
C. 分类模型的输出一定在 0 到 1 之间
D. 分类模型输出的就是线性得分 z 本身

> **答案 B** — 课件写的是 "a classifier may output a class label directly or first estimate a class probability"。感知机直接给标签，逻辑回归先给概率 p 再用阈值 0.5 转成标签。这正是两个模型的分界点。z 本身可以是任意实数，不是概率。

第 5 页：特征表示与记号（4 题）

5. 按课件的定义 x = [开心词数量, 难过词数量]，句子 "The weather is great" 的特征向量是：

A. [0, 0]
B. [4, 0]，因为句子有 4 个词
C. [1, 0]
D. [0, 1]

> **答案 C** — 开心词：great（一个）；难过词：无。所以 x = [1, 0]。词袋表示只数词，不管语序、也不管 the、is 这类不在词典里的词。对比 "I love sunny days" 有 love、sunny 两个开心词，所以是 [2, 0]。

6. 记号 m 表示什么？

A. 特征的个数（向量维度）
B. 训练样本的数量
C. 类别的数量
D. 模型参数的数量

> **答案 B** — m = number of training examples，即样本数量（表格的行数）。特征的个数是维度 d（词袋例子里 d = 2）。别把 m 和 d 搞反，写求和式时一旦搞反整个公式就错了。

7. y 与 ŷ 的区别是：

A. y 是模型的预测，ŷ 是真实标签
B. 两者完全等价，只是书写习惯不同
C. y 是已知的真实标签，ŷ 是模型预测的类别
D. y 是特征向量，ŷ 是标签

> **答案 C** — y 是数据集给定的真实标签（ground truth），ŷ 是模型输出的预测。两者的差距就是学习信号的来源；后面逻辑回归的梯度 p − y 就是这个思路的具体化。帽子（hat）总是戴在"估计值"头上。

8. 关于标签约定，课件的说法是：

A. 感知机用 −1/+1，逻辑回归用 0/1
B. 感知机用 0/1，逻辑回归用 −1/+1
C. 两者都只能用 0/1
D. 标签约定可以随意选，对计算没有任何影响

> **答案 A** — 感知机计算通常用 −1 和 +1（更新规则靠标签的符号决定推动方向）；逻辑回归通常用 0 和 1（输出是概率，落在 [0,1]）。考试做计算题时，中途换约定是最常见的错。

第 6 页：线性得分 $z = w^Tx + b$（5 题）

9. 偏置 b 对决策边界的作用是：

A. 旋转决策边界
B. 平移决策边界，但不改变它的方向
C. 把得分 z 压缩到 0 到 1 之间
D. 决定哪些特征重要

> **答案 B** — 课件原话：bias shifts the boundary without changing its orientation。把 $z = 0$ 写成直线方程 $w_1x_1 + w_2x_2 + b = 0$ 就很清楚：w 决定斜率（方向），b 决定截距（位置）。旋转是 w 的事。

10. 设 $w = [1, -2]$，$b = -0.5$，$x = [3, 1]$。得分 $z = ?$

A. 1.0
B. 5.5
C. 0.5
D. −0.5

> **答案 C** — $z = w_1x_1 + w_2x_2 + b = (1)(3) + (-2)(1) + (-0.5) = 3 - 2 - 0.5 = 0.5$。$z > 0$ 落在正类一侧（但 0.5 离 0 很近，说明离边界不远，把握不大）。常见失误：漏加偏置 b。

11. 决策边界（decision boundary）由什么定义?

A. $z = 1$
B. $z = 0.5$
C. $x = 0$
D. $z = 0$，即 $w^Tx + b = 0$

> **答案 D** — 边界就是 $w^Tx + b = 0$ 这组点的集合，是"不正不负"的位置，也是模型最没把握的点。后面会看到 $z = 0$ 对应 sigmoid 输出 $p = 0.5$，刚好是阈值。

12. 线性得分 z 本身是概率吗?

A. 是，z 就是样本属于正类的概率
B. 不是，z 可以是任意实数，需要再套 sigmoid 才能得到概率
C. 是，只要 w 和 b 训练得好，z 自然落在 0 到 1
D. 不是，因为 z 只能取 −1 或 +1

> **答案 B** — z 的取值范围是整个实数轴，可以是 −7.3 也可以是 +150，根本不满足概率的要求。逻辑回归靠 sigmoid 把 z 压到 (0,1) 才得到概率；感知机则不做这一步，直接看符号出标签。

13. 某个特征的权重是负数，这意味着：

A. 该特征对模型没有影响
B. 该特征值越大，z 越大
C. 该特征值越大，z 越小，把样本推向负类一侧
D. 该特征必须在预处理时删掉

> **答案 C** — 权重为负意味着该特征值越大 z 越小，就把样本往负类推。在情感例子里，"难过词数量"这个特征的权重就应该是负的。权重接近 0 才是"被忽略"，负权重反而是强信号。

第 7 页：决策边界的几何（4 题）

14. 图中那条决策边界线上的每一个点都满足：

A. $z = 1$
B. $z = 0$
C. z 取最大值
D. $x_1 = x_2$

> **答案 B** — 边界上的点满足 $z = w^Tx + b = 0$。一侧 $z > 0$，另一侧 $z < 0$，模型给这两个区域分配不同类别。注意边界上的点并不是"两类都属于"，而是模型完全无法区分、把握为零的点。

15. 关于 |z| 与"点到边界的距离"，正确的说法是：

A. |z| 就是点到边界的几何距离
B. |z| 就是预测概率
C. |z| 是"得分距离"，真正的垂直距离是 $|z| / \|w\|$
D. |z| 与距离完全无关

> **答案 C** — 课件明说：|z| is a score distance rather than an ordinary geometric distance；真正的垂直距离是 $|z| / \|w\|$。因为把 w 和 b 同时放大 10 倍，边界不变但所有 z 变 10 倍，除以 $\|w\|$ 正好抵消这个缩放。

16. 某个点的得分 z = 10，模型的 w = [3, 4]。这个点到决策边界的垂直距离是：

A. 10
B. 2
C. 5
D. 10/7

> **答案 B** — 先算模长：‖w‖ = $\sqrt{(3^2 + 4^2)} = \sqrt{25} = 5$。然后距离 = |z| / ‖w‖ = 10 / 5 = 2。典型陷阱是直接拿 10 当答案，或者把 ‖w‖ 算成 3 + 4 = 7。

17. 在这张图上，w 和 b 分别控制什么？

A. w 控制线的方向，b 控制线的位置
B. w 控制线的位置，b 控制线的方向
C. w 和 b 都只能平移这条线
D. 只有 b 会影响分类结果

> **答案 A** — w 控制方向（orientation），b 控制位置（position）。改 w 线会旋转，改 b 它会平行地挪动。两者都能改变分类结果，但改变的方式不同。

第 8 页：感知机的符号预测（5 题）

18. 感知机如何从得分 s 得到预测类别？

A. 先对 s 应用 sigmoid，再看是否大于 0.5
B. 取 s 的绝对值
C. 取 s 的符号，ŷ = sign(s)
D. 取 s 与阈值 0.5 比较

> **答案 C** — 感知机直接取得分的符号：ŷ = sign(s)。s > 0 → +1，s < 0 → −1。它不做任何概率转换，这正是它与逻辑回归的关键区别。

19. 某样本的得分 s = −2.5，真实标签 y = −1。y · s 是多少？要不要更新？

A. y · s = −2.5，需要更新
B. y · s = +2.5，不需要更新
C. y · s = +2.5，但仍需要更新
D. y · s = −2.5，不需要更新

> **答案 B** — y · s = (−1)(−2.5) = +2.5 > 0，说明预测与真实标签同号，分对了，不更新。常见错误是看到 s 是负数就以为错了——判断依据是乘积 y · s 的符号，不是 s 自己的符号。

20. 本课程规定，感知机在什么条件下触发更新？

A. y · s < 0
B. y · s ⩽ 0
C. y · s > 0
D. s < 0

> **答案 B** — 课件明确写：In this course, y · s ⩽ 0 triggers an update。y · s = 0 意味着样本正好落在决策边界上，算"平局"，模型并没有真正把它分对，所以也要更新。这是本课特定的约定，考试按这个来。

21. 为什么感知机要用 −1/+1 而不是 0/1 作标签？

A. 因为 −1/+1 计算起来更快
B. 因为概率必须落在 −1 到 +1 之间
C. 因为乘积 y · s 的符号能直接表示对错；用 0/1 的话 y = 0 会把乘积变成 0
D. 没有原因，只是习惯

> **答案 C** — −1/+1 能让乘法 y · s 的符号直接编码"对与错"：同号为正（对），异号为负（错）。如果用 0/1，y = 0 会把乘积压成 0，不论 s 多少都一样，这个判断机制就失效了。

22. 样本的 s = −0.1，y = +1。根据本课规则：

A. 不更新，因为误差很小
B. 不更新，因为 y 是正的
C. 不更新，因为点就在边界上
D. 更新，因为 y · s = −0.1 ⩽ 0

> **答案 D** — y · s = (+1)(−0.1) = −0.1 < 0，分错了，需要更新。虽然 |s| 很小、点离边界很近，但感知机不看"错得多严重"，只看符号：只要在错的一侧，就要更新。

第 9 页：感知机损失 max(0, −y · s)（5 题）

23. 设 y = +1，s = 2.0。损失 L = max(0, −y · s) = ?

A. 2.0
B. 0
C. −2.0
D. 1.0

> **答案 B** — y · s = (+1)(2.0) = 2.0，所以 −y · s = −2.0，L = max(0, −2.0) = 0。分对的点损失恒为零，不论它离边界多远——这就是 max(0, ·) 干的事。

24. 设 $y = -1$，$s = 1.5$。损失 $L = ?$

A. 0
B. −1.5
C. 1.5
D. 2.25

> **答案 C** — $y \cdot s = (-1)(1.5) = -1.5$（分错了），$-y \cdot s = +1.5$，$L = \max(0, 1.5) = 1.5$。对分错的点，损失就等于 $|s|$，错得越远损失越大，而且是线性增长。

25. 当 $y \cdot s = 0$（样本正好在边界上）时：

A. 损失为 0，且不更新
B. 损失为 0，但按本课约定仍要更新
C. 损失为正数，需要更新
D. 损失无定义

> **答案 B** — $L = \max(0, -0) = 0$，损失确实是 0；但课件的更新规则是 $y \cdot s \leqslant 0$，所以仍然要更新。损失函数和更新规则在这一点上不一致，考试以更新规则为准。

26. 公式里的 max(0, ·) 起什么作用?

A. 为了把损失压缩到 0 到 1 之间
B. 为了让损失可导
C. 防止损失为负，使分对的样本对损失零贡献
D. 为了把得分转成概率

> **答案 C** — 课件写的是 max(0, ·) prevents negative loss。没有它的话，分得越对的点损失越负，模型会忙着把已经分对的点推得更远以"刷低"总损失，而不是去修正错的点。加了 max 后，分对的样本对损失零贡献，感知机只关心犯错的样本。

27. 感知机损失 L_i 的取值范围是：

A. [0, 1]
B. [0, +∞)
C. (−∞, +∞)
D. [−1, +1]

> **答案 B** — max 保证损失不小于 0（且 0 可以取到）；分错时损失等于 $|s|$，而 s 可以任意大，所以上不封顶。另外它是线性增长，不是平方增长。

第 10 页：感知机的顺序训练（5 题）

28. 感知机的更新规则是：

A. $w \leftarrow w + \eta y_i x_i$，$b \leftarrow b + \eta y_i$
B. $w \leftarrow w - \eta y_i x_i$，$b \leftarrow b - \eta y_i$
C. $w \leftarrow w + \eta x_i$，$b \leftarrow b + \eta x_i$
D. $w \leftarrow w + \eta y_i x_i$，$b \leftarrow b + \eta y_i x_i$

> **答案 A** — 课件给的是 $w \leftarrow w + \eta y_i x_i$，$b \leftarrow b + \eta y_i$。注意是加号不是减号，且 b 的更新不乘 x——相当于把 x 换成了常数 1。

29. 初始 $w = [0, 0]$，$b = 0$，$\eta = 1$。第一个样本 $x = [2, 1]$，$y = +1$。处理完后的参数是：

A. 不更新，w 仍为 [0, 0]，b 仍为 0
B. $w = [2, 1]$，$b = 0$
C. $w = [2, 1]$，$b = 1$
D. $w = [-2, -1]$，$b = -1$

> **答案 C** — $s = (0)(2) + (0)(1) + 0 = 0$；$y \cdot s = 0 \leqslant 0$，触发更新（平局也要更新）。$w = [0,0] + 1 \times (+1) \times [2,1] = [2,1]$；$b = 0 + 1 \times (+1) = 1$。验证：新得分 $= 2 \times 2 + 1 \times 1 + 1 = 6 > 0$，确实被推向了正类。

30. step（步）与 epoch（轮）的区别是：

A. step 是处理完所有样本，epoch 是处理一个样本
B. step 是对一个样本的一次更新机会，epoch 是把每个样本都处理一遍
C. 两者是同一个意思
D. step 是一次真正发生的参数改变，epoch 是一次初始化

> **答案 B** — 课件定义：one update opportunity for one example is a step；processing every example once is an epoch。注意 step 是"更新机会"，即使该样本分对了、参数没变，也算一步。

31. 改变训练样本的先后顺序，会怎么样?

A. 没有影响，因为所有梯度最后会加在一起
B. 没有影响，因为每个样本都用初始参数
C. 会影响中间参数值和学习路径
D. 会导致算法无法运行

> **答案 C** — 因为算法是顺序的，每个样本用的都是前一个样本刚产生的参数，所以换个顺序，中间的参数值和整条学习路径都会不同。做题时绝不能拿旧参数去算下一个样本。

32. 某样本 y = +1 但被分错了，执行一次更新后：

A. 该样本的得分 s 会变小
B. 该样本的得分 s 会变大，向正类方向修正
C. 该样本的得分 s 不变
D. 只有 b 会变，s 不受影响

> **答案 B** — 更新后新得分 = 旧得分 + η(‖x‖² + 1)，而 ‖x‖² + 1 恒为正，所以 y = +1 时得分一定变大，向正类方向修正。注意一次更新不一定能把它推过边界（取决于 η 和 x），但方向肯定是对的。

第 11 页：感知机更新手算（5 题）

33. w = [−0.5, 0.2]，b = 0，x = [2, 0]。初始得分 s = ?

A. −0.8
B. −0.5
C. −1
D. 1.5

> **答案 C** — s = (−0.5)(2) + (0.2)(0) + 0 = −1。第二项因为 $x_2 = 0$ 而归零，b = 0 也不贡献。y · s = −1 ⩽ 0，所以需要更新。

34. η = 0.5，y = +1，x = [2, 0]。更新后的 w 是：

A. [1.5, 0.2]
B. [0.5, 0.2]
C. [0.5, 0.7]
D. [−2.5, 0.2]

> **答案 B** — w ← [−0.5, 0.2] + 0.5(+1)[2, 0] = [−0.5 + 1, 0.2 + 0] = [0.5, 0.2]。第二维没变，因为更新量 η · y · x_2 = 0.5×1×0 = 0。

35. 若某个特征的值 $x_j = 0$，则更新时对应的权重 w_j：

A. 会变成 0
B. 会增加 ηy
C. 保持不变
D. 整个样本会被跳过，不做更新

> **答案 C** — 更新量是 η · y · x_j，当 $x_j = 0$ 时整项为零，所以 w_j 不变。直觉上也合理：这个特征在当前样本上根本没参与得分计算，自然不应为这次错误负责。

36. 用更新后的 w = [0.5, 0.2]、b = 0.5 重算同一个样本 x = [2, 0]，新得分是：

A. 1.5
B. 1.0
C. 0.5
D. −1

> **答案 A** — s_new = (0.5)(2) + (0.2)(0) + 0.5 = 1 + 0 + 0.5 = 1.5。得分从 −1 变成 +1.5，样本从错误一侧跨到了正确一侧。注意新的 b = 0.5 也贡献了一部分，别漏掉。

37. 关于 η 与 y · x 在更新中的角色：

A. η 决定方向，y · x 决定幅度
B. η 决定修正的幅度，y · x 决定更新的方向
C. 两者都只影响幅度
D. η 只影响 b，y · x 只影响 w

> **答案 B** — 课件明确：η controls the size of the correction，y · x determines the update direction。η 太小可能一次推不过边界，太大则可能矫枉过正、把原本分对的样本弄错。

第 12 页：感知机的保证与局限（5 题）

38. 感知机收敛定理成立的前提条件是：

A. 学习率足够小
B. 训练数据是线性可分的
C. 样本数量足够多
D. 标签用 0/1 约定

> **答案 B** — 定理的前提是数据 linearly separable：存在某条线性边界能把每一个训练样本都分对。满足这个条件时，算法只会犯有限次错误。学习率大小、样本多少都不是保证条件。

39. 某样本的得分 s = 9，能否说"模型有 90% 的概率判定它是正类"?

A. 可以，大致相当于 90% 的把握
B. 可以，只要先除以 10
C. 不可以，它只说明在正类一侧，不是校准的概率
D. 不可以，因为得分永远小于 1

> **答案 C** — 课件警告：大的正得分只说明在正类一侧，不能直接解释为"90% 概率"。因为 s 的尺度取决于 w 的大小——把 w 和 b 同乘 10，边界不变但所有得分变 10 倍。感知机输出的是硬标签，不是校准过的概率。

40. 当两类数据重叠、不线性可分时，感知机会：

A. 自动停在最优解
B. 更新可能持续不断，参数在几组值之间循环
C. 报错无法运行
D. 自动切换成非线性边界

> **答案 B** — 类别重叠意味着不存在完美的线性分隔器，所以总有样本被分错，更新就会一直触发，参数可能在几组值之间循环（cycle）。实践中必须人为设定停止条件，比如固定的 epoch 数。

41. "线性可分时，感知机会找到最好的那条分隔线"——这句话：

A. 正确，它会找到间隔最大的那条线
B. 错误，它只保证找到某一条能分开的线，不保证最优
C. 正确，因为损失最终会降到 0
D. 错误，它根本不保证能分开数据

> **答案 B** — 定理保证的是"错误次数有限"并能找到一条分隔边界，但不保证这条线是最优的。可行的线可能有无穷多条，感知机只是碰到哪条算哪条。追求最大间隔的是 SVM。

42. 调整学习率 η 能让感知机输出概率吗?

A. 能，只要 η 足够小
B. 能，η 越小输出越接近概率
C. 不能，学习率只缩放修正幅度，不会产生概率
D. 不能，因为感知机没有学习率

> **答案 C** — 课件写得很明确：学习率 scales each correction but does not create probabilities。概率需要另一个机制——sigmoid 函数，那是逻辑回归的事。学习率只控制每次修正走多远。

第 13 页：sigmoid 把得分变概率（5 题）

43. 当 z = 0 时，p = σ(0) = ?

A. 0
B. 0.5
C. 1
D. 无定义

> **答案 B** — $\sigma(0) = 1/(1 + e^{0}) = 1/(1+1) = 0.5$。这是最重要的锚点：决策边界 z = 0 对应概率恰好 0.5，也就是模型完全没把握的位置。

44. 加上 sigmoid 后，决策边界会变成曲线吗?

A. 会，边界变成 S 形曲线
B. 会，边界变成非线性，所以能解决 XOR
C. 不会，边界仍然是线性的（z = 0）
D. 不会，因为 sigmoid 是线性函数

> **答案 C** — 课件原话：the sigmoid changes scores into probabilities; it does not change the linear boundary family。因为 p > 0.5 等价于 z > 0，边界依然是直线 z = 0。所以逻辑回归同样解决不了 XOR 这类非线性可分的问题。

45. 已知 σ(4) = 0.982，那么 σ(−4) = ?

A. −0.982
B. 0.018
C. 0.982
D. 0.5

> **答案 B** — 利用对称性 $\sigma(-z) = 1 - \sigma(z)$：$\sigma(-4) = 1 - 0.982 = 0.018$，与课件表格一致。记住这个对称性可以少背一半的值。

46. sigmoid 输出 p 的取值范围是：

A. [0, 1]，且 0 和 1 都可以取到
B. (0, 1)，永远取不到 0 和 1
C. (−1, 1)
D. [0, +∞)

> **答案 B** — 因为 e^{-z} 恒大于 0，分母 $1 + e^{-z}$ 恒大于 1，所以 p 永远小于 1；同理也永远大于 0。z 趋于 ±∞ 时只是无限接近 1 和 0。这个性质很重要：它保证了后面交叉熵损失里的 log(p) 不会变成无穷大。

47. 若某样本的 z = 2.5，则：

A. p < 0.5
B. p = 0.5
C. p > 0.5
D. p 可能大于也可能小于 0.5

> **答案 C** — 因为 sigmoid 是单调递增的，且 σ(0) = 0.5，所以 $z > 0 \leftrightarrow p > 0.5$。这意味着"看 z 的符号"和"看 p 是否超过 0.5"得到完全相同的分类结果——两个模型边界相同的原因就在这里。

第 14 页：阶跃 vs. Sigmoid（5 题）

48. sigmoid 的"平滑"为什么对学习至关重要?

A. 因为它让输出更好看
B. 因为它把决策边界变成了曲线
C. 因为参数微小变化会引起概率和损失的渐变，使基于梯度的优化成为可能
D. 因为它让训练速度变快

> **答案 C** — 阶跃函数除边界外导数恒为 0、边界处不可导，梯度提供不了任何"往哪调"的信息。sigmoid 处处可导，参数微调会带来概率和损失的渐变，所以能用基于梯度的优化。

49. 按课件的标准阈值，若算出 p = 0.5，应该：

A. 预测类别 0
B. 预测类别 1
C. 无法预测，需要重新训练
D. 随机选一个类别

> **答案 B** — 课件写的是 predict class 1 when $p \geqslant 0.5$，所以恰好等于 0.5 时归正类（类别 1）。考试里这种边界情况很爱考，看清楚等号在哪一边。

50. 阈值化（thresholding）发生在哪一步?

A. 在计算 z 之前
B. 在算出概率 p 之后
C. 与计算概率同时进行
D. 在训练时就固定在模型内部，不可更改

> **答案 B** — 课件强调：the thresholding step is performed after the probability has been calculated。完整链条是 $z \to p \to$ 阈值 $\to$ 标签。因为阈值是最后一步，它才可以自由调整（比如医疗筛查调到 0.2）而不用重新训练模型。

51. 关于阶跃函数与 sigmoid，正确的是：

A. 两者的得分公式不同
B. 阶跃用 w，sigmoid 用 b
C. 两者用同一个得分 z，但阶跃突变给硬标签、sigmoid 平滑给概率
D. 阶跃函数的输出也是概率，只是取值只有两个

> **答案 C** — 两者用的是同一个得分 z，但表达方式不同：阶跃在边界处突变，直接给硬标签；sigmoid 随 z 平滑变化，所以相近的得分会得到相近的概率估计。

52. 某样本 $z = -1$，根据课件表格，p 是多少？预测哪一类?

A. $p = 0.269$，预测类别 0
B. $p = 0.269$，预测类别 1
C. $p = 0.731$，预测类别 1
D. $p = -1$，无法解释

> **答案 A** — 查表：$\sigma(-1) = 0.269 < 0.5$，所以按 0.5 的阈值预测类别 0。也可以不查表直接判断：$z = -1 < 0 \Rightarrow p < 0.5$。但 0.269 并不接近 0，说明模型对这个判断并不十分确定——这正是概率输出比硬标签有价值的地方。

第 15 页：p = 0.5 处的线性边界（5 题）

53. 条件 $p = 0.5$ 等价于：

A. $z = 0.5$
B. $z = 0$
C. $z = 1$
D. $w = 0$

> **答案 B** — 因为 $\sigma(0) = 0.5$，且 sigmoid 严格单调递增（因而可逆），所以 $p = 0.5$ 与 $z = 0$ 是等价的。把 $z = w^T x + b$ 代入，边界就是一个线性方程。

54. 设 $w = [2, 4]$，$b = -8$。决策边界的斜截式是：

A. $x_2 = 0.5x_1 + 2$
B. $x_2 = -0.5x_1 + 2$
C. $x_2 = -0.5x_1 - 2$
D. $x_2 = -2x_1 + 8$

> **答案 B** — 斜率 $= -w_1/w_2 = -(2)/(4) = -0.5$；纵截距 $= -b/w_2 = -(-8)/4 = 2$。所以边界是 $x_2 = -0.5x_1 + 2$。注意两处都有负号，b 本身又是负数，负负得正。

55. 把边界化成斜截式 $x_2 = -(w_1/w_2)x_1 - b/w_2$ 的前提是：

A. $w_1 \neq 0$
B. $b \neq 0$
C. $w_2 \neq 0$
D. 没有任何前提，总能化成斜截式

> **答案 C** — 化斜截式需要除以 w_2，所以必须 $w_2 \neq 0$。若 $w_2 = 0$，方程变成 $w_1 x_1 + b = 0$，即 $x_1 = -b/w_1$，这是一条垂直线，斜率无穷大，斜截式表示不了。

56. 画出边界线后，要判断一个新点属于哪一类，最简便的做法是：

A. 必须先算出 sigmoid 的值才能判断
B. 算 z 的符号：正则类别 1，负则类别 0
C. 比较该点到线的欧氏距离与 0.5 的大小
D. 看 x_2 是否大于 0

> **答案 B** — 课件的做法：画出线后，对任意测试点算 z，$z > 0$ 则 $p > 0.5$（类别 1），$z < 0$ 则 $p < 0.5$（类别 0）。符号就足以确定点在线的哪一侧，不必真的去算 sigmoid。

57. 为什么说"sigmoid 是非线性的，但逻辑回归的边界是线性的"?

A. 因为 sigmoid 其实是线性函数
B. 因为参数 w 和 b 是线性的，输出也一定是线性的
C. 因为判定条件 $p \geqslant 0.5$ 等价于 $z \geqslant 0$，而 $z = 0$ 是线性方程
D. 因为阈值正好取在 0.5，换个阈值边界就变成曲线了

> **答案 C** — sigmoid 确实是非线性函数，但它只作用在输出上。判定条件 $p \geqslant 0.5$ 等价于 $z \geqslant 0$，而 $z = 0$ 是一个线性方程，所以边界仍是直线。非线性体现在"概率随 z 怎么变"上，不在"边界长什么样"上。（换个阈值只是把线平移，仍是直线。）

第 16 页：二元交叉熵（5 题）

58. 当 $y = 1$ 时，二元交叉熵简化为：

A. $L = -\log(1-p)$
B. $L = -\log(p)$
C. $L = \log(p)$
D. $L = -[\log(p) + \log(1-p)]$

> **答案 B** — $y = 1$ 时 $(1-y) = 0$，第二项整项消失，只剩 $-\log(p)$。所以做题时先看 y 是 0 还是 1，直接套对应的那半个公式就行。

59. 某样本 $y = 0$，模型预测 $p = 0.98$。损失如何计算，大致多大?

A. 用 $-\log(p)$，损失很小
B. 用 $-\log(1-p)$，损失很小
C. 用 $-\log(1-p)$，损失很大
D. 损失为 0，因为 $y = 0$

> **答案 C** — $y = 0$，所以 $L = -\log(1-p) = -\log(0.02) \approx 3.91$。这是典型的"自信地错了"：真实是负类，模型却报了 98% 的正类概率，损失很大。如果模型只报 $p = 0.5$，损失反而只有 0.69。

60. "惩罚自信的错误"具体指的是：

A. 它对所有错误的惩罚都相同
B. 越自信的错误惩罚越大，$p \to 0$ 时损失趋于无穷
C. 它只惩罚分类错误，不看概率大小
D. 它对错误的惩罚是线性增长的

> **答案 B** — 因为 $p \to 0$ 时 $-\log(p) \to +\infty$，惩罚是爆炸式增长的。相比之下感知机损失只是线性增长。这个设计逼着模型不敢乱说满话，从而产生校准的概率。

61. 训练时最小化的是：

A. 单个样本的损失
B. 所有样本损失的平均值
C. 损失最大的那个样本
D. 权重的范数

> **答案 B** — 课件：training minimizes the average loss over all examples，即 $(1/m) \cdot \Sigma L_i$。写目标函数时别漏掉那个 1/m。（用总和还是平均不会改变最优解的位置，但会改变梯度的尺度，从而影响学习率的选择。）

62. 课件说交叉熵是 smooth 且 probabilistic，这两个性质分别带来什么好处?

A. 平滑让边界变成曲线；概率化让训练变快
B. 平滑让损失永远为正；概率化让标签变成 −1/+1
C. 两者都只是为了让公式好看
D. 平滑支持梯度下降；概率化奖励校准的置信度

> **答案 D** — 平滑使得损失处处可导，梯度下降才能用；概率化使得模型不仅要"猜对类别"，还要"概率报得准"（calibrated confidence）——后者正是感知机做不到的。

第 17 页：梯度 p − y（5 题）

63. 对逻辑回归 + 二元交叉熵，$\partial L_i / \partial z_i = ?$

A. $y_i - p_i$
B. $p_i - y_i$
C. $p_i(1 - p_i)$
D. $-\log(p_i)$

> **答案 B** — sigmoid 与交叉熵组合后求导，复杂的项全部约掉，只剩 $\partial L_i / \partial z_i = p_i - y_i$，叫做带符号的概率误差。这个简洁性正是两者搭配使用的重要原因。

64. 某样本 $y = 1$，$p = 0.2$。$p - y$ 是多少？应该怎么调?

A. $p - y = +0.8$，应降低得分
B. $p - y = -0.8$，应降低得分
C. $p - y = -0.8$，应提高得分
D. $p - y = 0.2$，不需要调整

> **答案 C** — $p - y = 0.2 - 1 = -0.8 < 0$，说明概率低于目标，梯度下降会把参数往"提高得分"的方向推。记忆方式：负误差 = 报低了 = 要抬高。

65. 设 x = [2, 0]，y = 0，p = 0.7。对权重的梯度贡献 (p−y)x = ?

A. [0.7, 0.7]
B. [1.4, 0]
C. [1.4, 0.7]
D. [−1.4, 0]

> **答案 B** — p − y = 0.7 − 0 = 0.7；梯度 = (p−y)x = 0.7 × [2, 0] = [1.4, 0]。第二维为 0，因为 $x_2 = 0$——特征值为零时对该权重没有直接贡献。

66. 偏置 b 的梯度是：

A. (p − y)x，与权重相同
B. 恒为 0，b 不会被更新
C. p − y，不乘特征，所以即使特征全为 0 也会更新
D. −log(p)

> **答案 C** — $\partial L/\partial b = p - y$，不乘任何特征。所以即使所有特征都是 0（此时所有权重梯度都为零），偏置 b 依然会被更新。可以把 b 看作一个恒等于 1 的虚拟特征的权重。

67. 与感知机相比，逻辑回归更新量的一个重要差别是：

A. 感知机的更新量与误差成正比，逻辑回归固定
B. 感知机错了就固定量更新，逻辑回归按误差 (p−y) 按比例调整
C. 两者完全相同
D. 感知机的边界是线性的，逻辑回归的是非线性的

> **答案 B** — 感知机只看对错，错了就固定加 ηyx，不区分错得多严重；逻辑回归的梯度含有 (p−y) 这个因子，误差大则调得猛，接近正确时自动放缓。注意两者的边界形状都是线性的，这不是区别。

第 18 页：批量 vs. 随机更新（5 题）

68. 批量与随机梯度下降的根本区别是：

A. 使用不同的损失函数
B. 一个沿正梯度、一个沿负梯度
C. 在更新参数之前，有多少个样本参与进来
D. 一个用于分类，一个用于回归

> **答案 C** — 课件原话：the difference is how many examples contribute before parameters are updated。单样本的梯度贡献公式 $(p_i - y_i)x_i$ 完全相同，三者也都沿负梯度方向走。

69. 关于两种方式的优化路径：

A. 批量更嘈杂，随机更平滑
B. 批量更平滑，随机更嘈杂
C. 两者的路径完全一样
D. 两者都是确定性的，没有噪声

> **答案 B** — 批量对所有 m 个样本的贡献取平均后再更新，梯度平滑且确定，但每次都要跑完整个数据集；随机只用一个样本就更新，快但路径嘈杂。

70. 数据是一条一条实时到达的在线学习场景，更适合用：

A. 批量梯度下降
B. 随机梯度下降
C. 两者都不适合
D. 只能用感知机

> **答案 B** — 课件列的适用场景是 online / large data。随机梯度下降处理完一个样本就更新，所以数据一条条到达时就能一条条学，不必等整个数据集。

71. 小批量（mini-batch）梯度下降被广泛使用，因为：

A. 它不需要计算梯度
B. 它能把非线性边界变成线性
C. 它在梯度估计的稳定性与计算效率之间取得平衡
D. 它保证一定能找到全局最优解

> **答案 C** — 小批量对一小组样本取平均，既比单样本稳定，又比全量高效，所以被广泛使用。它仍然是沿负梯度方向走，不是另一套原理。

72. 批量、小批量、随机三种方式的共同点是：

A. 都只需要一个样本
B. 都沿负梯度方向更新，用的是同一个单样本贡献公式
C. 都不需要学习率
D. 都保证在一个 epoch 内收敛

> **答案 B** — 课件：both follow the negative gradient。三者优化的是同一个目标、沿的是同一个方向，只是梯度估计得多准不同。它们的单样本贡献公式也完全一样。

第 19 页：两个模型的正面对比（5 题）

73. 感知机与逻辑回归的共同点是：

A. 使用相同的标签约定
B. 都用 $z = w^Tx + b$，且都以 $z = 0$ 为线性边界
C. 都输出概率
D. 都只在犯错时更新

> **答案 B** — 两者都从 $z = w^Tx + b$ 出发，都用 $z = 0$ 作为标准边界，所以属于同一个线性边界族。它们能画出的边界形状完全一样，区别在输出与学习信号上。

74. 关于两者的更新时机：

A. 两者都只在分错时更新
B. 感知机每次都更新，逻辑回归只在分错时更新
C. 感知机只在分错或平局时更新，逻辑回归只要梯度非零就更新
D. 两者都在每个样本上产生相同大小的更新

> **答案 C** — 感知机只在 $y \cdot z \leqslant 0$ 时更新，分对就完全不动；逻辑回归只要梯度非零就更新，而 p 永远取不到 0 和 1，所以每个样本总在贡献梯度（只是分得越对贡献越小）。

75. 两个模型的学习信号分别是：

A. 感知机用 $p - y$，逻辑回归用 $y \cdot z$
B. 感知机用 $y \cdot z$，逻辑回归用 $p - y$
C. 两者都用 $p - y$
D. 两者都用 $y \cdot z$

> **答案 B** — 感知机的信号是带符号得分 $y \cdot z$，只关心符号（对/错）；逻辑回归的信号是概率误差 $p - y$，是连续量，既带方向又带大小。

76. 你要把"最可能是欺诈"的 100 笔交易排序挑出来人工审核。应该选：

A. 感知机，因为它更快
B. 感知机，因为它的得分可以直接当概率用
C. 逻辑回归，因为它提供可用于排序的概率估计
D. 都可以，两者输出完全等价

> **答案 C** — 排序需要可比较的置信度，而感知机只给硬标签、没有概率估计。逻辑回归在阈值化之前概率是可用的，所以能排序、能调阈值、能把置信度传给下游。注意：两者边界能力相同，选择不是因为"边界更复杂"。

77. 逻辑回归能不能给出硬标签？

A. 不能，它只能输出概率
B. 能，通过阈值化；且概率在阈值化之前仍然可用
C. 能，但一旦阈值化就拿不到概率了
D. 不能，必须换成感知机

> **答案 B** — 课件写的是 probability before thresholding：逻辑回归可以通过阈值化得到硬标签，但概率在阈值化之前一直是可用的。换句话说，它能做感知机能做的一切，还多给你一个概率。

第 20 页：五个量的检查点（5 题）

78. 五个量的正确顺序是：

A. 得分 → 表示 → 概率 → 类别 → 学习信号
B. 表示 → 得分 → 概率 → 类别 → 学习信号
C. 表示 → 概率 → 得分 → 学习信号 → 类别
D. 学习信号 → 表示 → 得分 → 概率 → 类别

> **答案 B** — 顺序是：表示 x → 线性得分 z → 概率 p（仅逻辑回归）→ 预测类别 → 学习信号。学习信号在最后，因为它需要先有预测才能与真实标签比较。

79. 感知机会跳过五个量中的哪一个？

A. 表示
B. 线性得分
C. 概率
D. 学习信号

> **答案 C** — 感知机直接从 z 跳到 $\text{sign}(z)$，不经过概率这一步。这也是第 12 页说它"没有概率估计"的原因。

80. 某同学算出 $z = 3.2$，说"模型有 3.2 的概率判定为正类"。这：

A. 正确，320% 的把握
B. 错误，z 不是概率，必须先算 $\sigma(3.2) \approx 0.96$
C. 错误，应该直接除以 10 得到 0.32
D. 正确，只要 z 大于 0 就是概率

> **答案 B** — $z = 3.2$ 只是线性得分，不是概率。必须先过 sigmoid：$\sigma(3.2) \approx 0.96$。这正是课件点名的高频错误 "treating z as a probability"。注意概率不可能大于 1，看到 3.2 就应该警觉。

81. 能不能把 $y = -1$ 代入交叉熵公式 $-[y \log p + (1-y) \log(1-p)]$？

A. 可以，两套标签可以互换
B. 可以，只要最后取绝对值
C. 不可以，交叉熵必须用 0/1 标签
D. 不可以，因为交叉熵只能用于回归

> **答案 C** — 交叉熵假定 $y \in \{0, 1\}$。把 $y = -1$ 代进去会得到 $-[-\log p + 2\log(1-p)]$，毫无意义。这是课件点名的另一个高频错误：在逻辑回归公式里用感知机的标签。

82. "感知机用 sign(z)，逻辑回归把 p 在 0.5 处阈值化"描述的是哪一个量?

A. 线性得分
B. 预测类别
C. 学习信号
D. 表示

> **答案 B** — "预测类别"对应链条的第四步。两者在这一步做法不同，但结果等价（因为 $z \geqslant 0 \leftrightarrow p \geqslant 0.5$）。

第 21 页：第一部分总结（5 题）

83. 按课件的 tutorial 自检要求，写逻辑回归的梯度时：

A. 只需要权重梯度
B. 只需要偏置梯度
C. 两者完全相同，算一个就行
D. 权重梯度 $(p-y)x$ 和偏置梯度 $p-y$ 都要写

> **答案 D** — 课件明确要求 form both weight and bias gradients。权重梯度是 $(p-y)x$，偏置梯度是 $p-y$（不乘特征）。只算 w 忘了 b 是常见失分点。

84. 自检项"顺序地使用更新后的参数"指的是：

A. 所有样本都用初始参数，最后一次性更新
B. 每个样本都要用前一个样本更新后的参数
C. 样本顺序无关紧要
D. 只需记录最终参数，不必写中间值

> **答案 B** — 回到第 10 页：感知机是顺序的，每个样本必须用前一个样本刚产生的参数。拿旧参数算下一个样本是最常见的错。

85. 要画出决策边界，应该：

A. 令 $p = 0$
B. 令 $z = 0.5$
C. 令 $z = 0$，即 $w^Tx + b = 0$
D. 令 $w = 0$

> **答案 C** — 课件：obtain a decision boundary by setting $z = 0$。令 $w^Tx + b = 0$，两特征时化为斜截式 $x_2 = -(w_1/w_2)x_1 - b/w_2$ 就能画出来。不需要令 $p = 0$ 或 $z = 0.5$。

86. 本节总结中，感知机与逻辑回归共用的是：

A. 相同的损失函数
B. 线性得分 $z = w^Tx + b$
C. 相同的标签约定
D. 相同的学习信号

> **答案 B** — 五条要点里明确写着两者共用 $z = w^Tx + b$。它们的差别在 z 之后：输出变换、损失函数、学习信号。标签约定不同，损失也不同。

87. 用两个样本做一次批量更新，正确做法是：

A. 把两个贡献相乘
B. 只用第一个样本的贡献
C. 把两个贡献取平均再更新
D. 把两个贡献相减

> **答案 C** — 自检项 "average contributions before a batch update"：批量更新时要先把各样本的梯度贡献取平均再更新，呼应第 16 页"最小化平均损失"。Tutorial 第 2 题就是考这个。

第 22 页：Tutorial 活动概览（5 题）

88. Tutorial 三道题串起的主线是：

A. 数据清洗 → 训练 → 部署
B. 得分 → 学习 → 决策边界
C. 回归 → 分类 → 聚类
D. 概率 → 损失 → 准确率

> **答案 B** — 课件原话：three core questions connect score → learning → decision boundary。Q1 考得分与感知机学习，Q2 考梯度学习，Q3 考边界。

89. Tutorial 第 2 题考的是：

A. 顺序的感知机更新
B. 画决策边界
C. 对两个逻辑回归梯度贡献取平均
D. 计算准确率与混淆矩阵

> **答案 C** — 课件写的是 Question 2 averages two logistic-gradient contributions：先算两个样本各自的 $(p-y)x$，再取平均。这就是"批量更新前先取平均"那条自检项的具体考法。

90. 课件对答题格式的要求是：

A. 只写最终答案就行
B. 要写出中间值，不能只给最终答案
C. 只需要画图，不需要计算
D. 只需要写公式，不需要代数字

> **答案 B** — 课件两次强调 show intermediate values, not only final answers。比如 Q1 要列出每个样本的 s、y・s、是否更新、更新后的参数；Q2 要列出 z、p、p−y、(p−y)x 再取平均。

91. Q3 要把 z = 0 变成边界与类别区域，完整答案应当出现：

A. 交叉熵的数值
B. 每个样本的 y・s
C. 学习率的选择依据
D. 斜率 $-w_1/w_2$、截距 $-b/w_2$，以及用测试点验证哪侧是类别 1

> **答案 D** — Q3 要把 z = 0 变成画出来的边界和类别区域，对应第 15 页：斜率 $-w_1/w_2$、截距 $-b/w_2$，再用测试点的 z 符号确定哪一侧是类别 1。

92. "confidence extension（置信度扩展题）"的定位是：

A. 必做，且最重要
B. 时间允许才做的扩展题
C. 考试的主体部分
D. 取代第三题的备选题

> **答案 B** — 课件说 complete the confidence extension only if time permits，它是选做的扩展题，优先保证三道核心题做完。

第 23 页：Q1 的四步工作流（5 题）

93. 课件说 Q1 考的核心是什么？

A. sigmoid 的计算
B. 交叉熵损失
C. 状态的传递：上一个样本的输出参数是下一个的输入参数
D. 如何选择最优学习率

> **答案 C** — 课件：Question 1 is about state。上一个样本的输出参数就是下一个样本的输入参数，所以每一行都要记录当前的 w 和 b。

94. Q1 的四步流程顺序是：

A. 检查 $y_i s_i$ → 算得分 → 更新 → 带着走
B. 算得分 → 检查 $y_i s_i$ → 需要则更新 → 带着走
C. 更新 → 算得分 → 检查 → 带着走
D. 算得分 → 算概率 → 算损失 → 更新

> **答案 B** — 四步是：算得分 → 检查 $y_i s_i$ → 需要则更新 → 写出新参数并带到下一个样本。注意"带着走"是独立的一步，课件把它单列出来就是因为学生常在这里出错。

95. 课件建议的更新后快速自检是：

A. 检查学习率是否选得太大
B. 用新参数重算该样本的得分，看它是否朝正确一侧移动
C. 检查概率是否在 0 到 1 之间
D. 重新初始化参数重做一遍

> **答案 B** — 课件：recompute the score after an update and explain whether the update moved the example toward the correct side。如果重算后得分反而往错的方向走，说明你把更新的符号写反了。

96. 若某行算出 $y_i s_i > 0$，应该：

A. 仍然要更新，只是幅度变小
B. 保持参数不变，且这一行可以不写
C. 保持参数不变，但仍要写出 s_i、$y_i s_i$ 和"不更新"的判断
D. 跳过这个样本，直接看下一个

> **答案 C** — $y_i s_i > 0$ 表示分对了，保持 w 和 b 不变。但这一行仍然要写在工作表里（s_i、$y_i s_i$、"不更新"），因为这也是一个 step，且需要展示判断过程。

97. 课件为什么要求把中间量都标注出来？

A. 为了让答案看起来更长
B. 为了能定位并修正算术错误或约定错误
C. 为了凑够字数要求
D. 因为最终答案不计分

> **答案 B** — 课件：keep intermediate quantities labelled so that an arithmetic or convention error can be located and corrected。只写最终答案的话，错了无法定位是哪一步出问题，也拿不到过程分。

第 24 页：Q2 的梯度四步（5 题）

98. Q2 中处理第二个样本时，应该用哪组参数?

A. 用样本 1 更新后的参数，和 Q1 一样
B. 用与样本 1 相同的初始参数
C. 用随机初始化的新参数
D. 用平均后的参数

> **答案 B** — 课件：after both examples have been processed using the same starting parameters。Q2 是批量思路：两个样本共用同一组初始参数，算完取平均后才更新一次。而 Q1（感知机）是顺序的。两道题思路相反，很容易搞混。

99. Q2 最后的更新式是：

A. $w \leftarrow w + \eta\, \partial J / \partial w$
B. $w \leftarrow w + \eta(p-y)x$
C. $w \leftarrow w - \eta\, \partial J / \partial w$
D. $w \leftarrow -\eta\, \partial J / \partial w$

> **答案 C** — 梯度下降是 $w \leftarrow w - \eta\, \partial J / \partial w$，用减号。因为梯度指向损失上升最快的方向，要降低损失就得往反方向走。感知机的 $w \leftarrow w + \eta y x$ 用加号是因为 y 本身已经带了方向，不要两者混用。

100. 形成两个梯度贡献时，差别在于：

A. 两者都乘 x_i
B. 权重贡献乘 x_i，偏置贡献不乘（乘 1）
C. 权重贡献不乘，偏置贡献乘 x_i
D. 两者都乘 $\sigma(z_i)$

> **答案 B** — 因为 $z = w^T x + b$，所以 $\partial z / \partial w = x$（乘特征），$\partial z / \partial b = 1$（不乘）。同一个误差 $p-y$ 驱动两个梯度，只是乘的东西不同。

101. 两个样本：$p_1 = 0.8, y_1 = 1$；$p_2 = 0.3, y_2 = 0$。平均的偏置梯度 $\partial J / \partial b$ = ?

A. 0.55
B. 0.05
C. 0.1
D. −0.25

> **答案 B** — 平均偏置梯度 $= \frac{1}{2}[(p_1 - y_1) + (p_2 - y_2)] = \frac{1}{2}[(0.8-1) + (0.3-0)] = \frac{1}{2}[-0.2 + 0.3] = \frac{1}{2}(0.1) = 0.05$。注意两个误差符号相反，部分抵消了——这正是批量平均会发生的事。

102. 课件对计算精度的建议是：

A. 算出 p 后立刻四舍五入到一位小数
B. 只保留整数
C. 中间保留足够小数位，到最后一行再四舍五入
D. 精度不影响结果，随意即可

> **答案 C** — 课件：keep sufficient decimal precision until the final line。sigmoid 算出的 p 往往是 0.6225 这种数，中间就四舍五入的话，误差会被 ×x、取平均、×η 一路放大。

第 25 页：Q3 把方程变成图（5 题）

103. 画边界的第一步是：

A. 令 $\sigma(z) = 0$
B. 令 $z = 0$
C. 令 $x_2 = 0$
D. 令 $w_1 = w_2$

> **答案 B** — 因为 $p = 0.5 \Leftrightarrow z = 0$，所以边界就是令 $z = 0$，即 $w_1 x_1 + w_2 x_2 + b = 0$。自检方法课件也给了：看看是否真有点满足它。

104. 课件要求"选两个点并验证它们都满足 z = 0"，这一步的作用是：

A. 为了计算学习率
B. 为了找到支持向量
C. 两点就能确定直线，同时能验证斜截式的符号没写错
D. 为了计算平均梯度

> **答案 C** — 两点确定一条直线，同时把点代回 z 能验证你的斜截式没有把符号弄错——对应自检栏那句 check both signs。

105. 按置信度的判断标准，p = 0.9 与 p = 0.1 相比：

A. p = 0.9 更有把握
B. 两者把握相同，都离 0.5 有 0.4，只是方向相反
C. p = 0.1 更有把握
D. 无法比较

> **答案 B** — 置信度比的是离 0.5 的距离：$|0.9 - 0.5| = |0.1 - 0.5| = 0.4$，所以两者把握相同，只是一个自信地判正类、一个自信地判负类。而 p = 0.55 才是真正没把握的预测。

106. 课件要求的顺序是：

A. 先分类所有点，再画线
B. 先画线，再分类给定的点
C. 两者同时进行，顺序无关
D. 只需分类，不用画线

> **答案 B** — 课件：plot the line before classifying the given points。有了线，点在哪一侧一眼就能看出来，还能反过来验证你算的 z 符号对不对。

107. 设 $w_1 = -3$，$w_2 = 2$，$b = 6$。边界的斜截式是：

A. $x_2 = -1.5x_1 - 3$
B. $x_2 = 1.5x_1 + 3$
C. $x_2 = 1.5x_1 - 3$
D. $x_2 = -1.5x_1 + 3$

> **答案 C** — $m = -w_1/w_2 = -(-3)/2 = 1.5$；$c = -b/w_2 = -(6)/2 = -3$。所以 $x_2 = 1.5x_1 - 3$。验证一下：取 $x_1 = 2 \to x_2 = 0$，$z = -3(2) + 2(0) + 6 = 0$ ✓。这就是"选两个点验证"那一步在做的事。

第 26 页：Practical 概览（5 题）

108. 一张 28 × 28 的图像会变成多少个特征?

A. 28
B. 56
C. 784
D. 2

> **答案 C** — $28 \times 28 = 784$。把二维图像摊平成一维向量，每个像素就是一个特征。注意公式 $z = w^T x + b$ 完全不变，只是 w 也变成 784 维。

109. 在"5 vs 非 5"任务里，为什么不能只看准确率?

A. 因为准确率无法计算
B. 因为类别不平衡，一个永远预测"非 5"的模型也能得 90%
C. 因为特征太多
D. 因为感知机不能做二分类

> **答案 B** — "5"大约只占 10%，所以一个永远预测"非 5"的模型也能拿到 90% 准确率，但它一个 5 也找不出来。这就是 Q1 要先检查类别平衡的原因，也是课件说"不能只看一个分数"的原因。

110. one-vs-rest 的做法是：

A. 只训练一个能直接输出多个类别的模型
B. 把数据集分成多份，每份训一个模型
C. 为每个类别训练一个二分类器，预测时取得分最高的
D. 把所有类别合并成两类

> **答案 C** — one-vs-rest 为每个类别训练一个二分类器（是不是 2？是不是 4？是不是 6？），预测时取得分最高的那个。这是把二分类器扩展到多分类的标准做法。

111. 为什么不能用测试集来做开发决策（调参、选模型）?

A. 没关系，只要最后重新训练就行
B. 测试集被污染，报出的性能会偏乐观，不再反映真实泛化能力
C. 模型会无法收敛
D. 会导致特征数量变化

> **答案 B** — 一旦用测试集的表现来挑模型或调参，测试集就被污染了，报出来的性能会偏乐观，不再代表真实的泛化能力。开发决策要只用训练集/验证集。

112. Q4（比较硬得分与逻辑回归概率）呼应的是课件哪一页?

A. 第 5 页的特征表示
B. 第 11 页的手算更新
C. 第 19 页感知机与逻辑回归的对比
D. 第 24 页的平均梯度

> **答案 C** — Q4 比较硬得分与概率，正是第 19 页对比表的代码版：感知机只给硬标签，逻辑回归给出可用于排序、调阈值、衡量置信度的概率。

第 27 页：从像素到决策（5 题）

113. notebook 四个阶段的顺序是：

A. 概率 → 表示 → 多分类 → 二分类
B. 表示 → 二分类感知机 → one-vs-rest → 加入概率
C. 二分类 → 表示 → 概率 → 多分类
D. one-vs-rest → 表示 → 二分类 → 概率

> **答案 B** — 四阶段是：表示（784 特征）→ 二分类感知机（5 vs 非 5）→ one-vs-rest 多分类 → 加入概率（逻辑回归）。每一步只增加一个新东西，便于定位问题。

114. 课件笔记的核心一句是：

A. 分类需要完全不同的得分公式
B. 分类不需要线性得分
C. 分类复用回归的线性得分，只是把它解释为类别判定或概率
D. 分类只能用于图像数据

> **答案 C** — 课件原话：classification reuses the linear score from regression but interprets it as a class decision or probability。公式 $z = w^T x + b$ 从回归一路用到分类，变的只是对 z 的解读方式。

115. 课件说两个模型主要差在哪三个方面?

A. 特征表示、数据量、边界形状
B. 输出变换、损失函数、更新信号
C. 学习率、批量大小、初始化
D. 特征维度、样本数量、训练时间

> **答案 B** — 课件：differ mainly in their output transformation, loss, and update signal。具体就是：sign 对 σ；max(0,−ys) 对交叉熵；y · s 对 p−y。它们的特征表示和边界形状都相同。

116. 把这两个模型用在手写数字上，一个重要局限是：

A. 它们无法处理 784 维的数据
B. 它们都不需要标签
C. 它们只能画线性边界，而真实数据未必线性可分
D. 它们无法用于图像

> **答案 C** — 两个模型都只能画线性边界（第 13、15 页反复强调 sigmoid 不改变边界族）。另外把图像摊平后丢失了空间信息，也是一个重要局限。

117. 第四阶段"Add probabilities"用的是哪个模型，目的是什么?

A. 感知机，解释硬标签
B. 逻辑回归，解释置信度
C. 感知机，解释置信度
D. 两者都用，解释准确率

> **答案 B** — "Add probabilities"阶段用逻辑回归，并 interpret confidence——解释置信度，比如看概率离 0.5 有多远。感知机做不到这一点。

第 28 页：如何完成 notebook（5 题）

118. 为什么要从顶部开始按顺序运行每个 cell?

A. 只是为了美观
B. cell 共享内存状态，跳着运行会用到未定义或过时的变量，结果不可复现
C. 因为每个 cell 只能运行一次，运行后就锁定
D. 因为数据集会自动重新下载

> **答案 B** — notebook 的 cell 共享同一个内存状态。跳着跑会导致变量未定义或用到旧值，错误难以定位且结果不可复现。遇到怪错就 Restart Kernel + Run All。

119. 课件说 practical 看重的是：

A. 代码跑通就够了
B. 只看最终准确率
C. 代码与正确的实验推理同等重要
D. 只看代码风格是否规范

> **答案 C** — 课件：the practical emphasises correct experimental reasoning as well as code。代码跑通只是及格线，还要能比较模型、检查错误、解释原因。

120. 扩展题（extensions）应该：

A. 最先做，因为它最难
B. 最后做，先完成 TODO 和 one-vs-rest 挑战
C. 与 TODO 同时进行
D. 完全不用做

> **答案 B** — 课件：extensions last。先完成 TODO 和 one-vs-rest 编程挑战这些核心要求，有余力再做扩展。

121. "诊断结果"这一步具体要做什么?

A. 只报告最高的准确率
B. 只需要贴出代码
C. 比较模型、检查错分的样本、并解释原因
D. 用测试集反复调参直到分最高

> **答案 C** — 课件两次强调 justify conclusions from evidence rather than from a single score。具体到"诊断"这一步，就是比较模型、检查错分样本、并给出解释。

122. notebook 四步工作法的顺序是：

A. 补全代码 → 按顺序运行 → 反思 → 诊断
B. 诊断 → 补全代码 → 运行 → 反思
C. 反思 → 运行 → 诊断 → 补全代码
D. 按顺序运行 → 补全代码 → 诊断结果 → 反思与扩展

> **答案 D** — 四步是：按顺序运行 → 补全代码（TODO + one-vs-rest 挑战）→ 诊断结果 → 反思与扩展。先跑通，再补全，再分析，最后总结。

B · Tutorial 部分（15 题）

Tutorial Q1：感知机顺序更新（5 题）

123. $w = [1, -1]$，$b = 0$，$x_1 = [2, 3]$，$y_1 = +1$。s_1 和 $y_1 s_1$ 分别是？

A. $s_1 = 5$，$y_1 s_1 = 5$，不更新
B. $s_1 = -1$，$y_1 s_1 = 1$，不更新
C. $s_1 = -1$，$y_1 s_1 = -1$，需要更新
D. $s_1 = 1$，$y_1 s_1 = 1$，不更新

> **答案 C** — $s_1 = (1)(2) + (-1)(3) + 0 = 2 - 3 = -1$。$y_1 s_1 = (+1)(-1) = -1 \leqslant 0$，真实是正类但得分为负，确实分错了，需要更新。

124. 更新后的参数是：

A. $w = [3, 2]$，$b = 0$
B. $w = [3, 2]$，$b = 1$
C. $w = [-1, -4]$，$b = -1$
D. $w = [2, 3]$，$b = 1$

> **答案 B** — $w \leftarrow [1, -1] + (1)(+1)[2, 3] = [3, 2]$；$b \leftarrow 0 + (1)(+1) = 1$。注意 b 也要更新，只改 w 忘了 b 是常见失分点。

125. 处理第二个样本时，应该用哪组参数？

A. 初始的 $w = [1, -1]$，$b = 0$
B. 更新后的 $w = [3, 2]$，$b = 1$
C. 两组参数的平均
D. 重新初始化为零

> **答案 B** — 感知机是顺序的，必须用样本 1 更新后的 $w = [3, 2]$、$b = 1$。如果错用初始参数，会算出 $s_2 = 1$、$y_2 s_2 = -1$，得出"要更新"的错误结论，整道题就错了。

126. 用 $w = [3, 2]$、$b = 1$ 处理 $x_2 = [-1, -2]$，$y_2 = -1$：

A. $s_2 = -6$，$y_2 s_2 = -6$，需要更新
B. $s_2 = 6$，$y_2 s_2 = -6$，需要更新
C. $s_2 = -6$，$y_2 s_2 = +6$，不更新
D. $s_2 = 1$，$y_2 s_2 = -1$，需要更新

> **答案 C** — $s_2 = (3)(-1) + (2)(-2) + 1 = -3 - 4 + 1 = -6$。$y_2 s_2 = (-1)(-6) = +6 > 0$，分对了，不更新。别因为 s_2 是负数就以为错了——真实标签也是负的。

127. 更新后重算样本 1 的得分，结果是：

A. 仍为 −1，没有变化
B. 从 −1 升到 13，移到了正类一侧
C. 从 −1 降到 −13
D. 从 −1 升到 1

> **答案 B** — 新得分 = (3)(2) + (2)(3) + 1 = 6 + 6 + 1 = 13。从 −1 升到 13，样本被推到了边界的正确一侧——这就是题目要求的那句解释，也是第 23 页说的 quick check。

Tutorial Q2：平均梯度与更新（5 题）

128. Q2 中处理两个样本时，应该：

A. 用样本 1 更新后的参数
B. 两个样本都用初始的 $w = 1$、$b = 0$
C. 每个样本用自己的随机初始值
D. 用上一轮的平均参数

> **答案 B** — 这是批量（平均）梯度，两个样本都用 $w = 1$、$b = 0$，算完取平均后才更新一次。这与 Q1 感知机的顺序更新正好相反，是两道题之间最大的陷阱。

129. 样本 1：$x_1 = 0.5$，$y_1 = 1$。$p_1 \approx 0.622459$，那么 $p_1 - y_1 = ?$

A. +0.622459
B. +0.377541
C. −0.377541
D. −0.622459

> **答案 C** — $z_1 = (1)(0.5) + 0 = 0.5$，$p_1 = \sigma(0.5) \approx 0.622459$，$p_1 - y_1 = 0.622459 - 1 = -0.377541$。负误差说明概率报低了（真实是 1），需要把得分抬高。

130. 样本 2：$p_2 - y_2 = +0.425557$，$x_2 = -0.3$。$(p_2 - y_2)x_2 = ?$

A. +0.127667
B. −0.127667
C. +0.425557
D. −0.425557

> **答案 B** — $(p_2 - y_2)x_2 = (+0.425557)(-0.3) = -0.127667$。误差是正的，但 x_2 是负的，乘完变成负。这是本题最容易算错符号的一步。

131. 两个误差分别是 −0.377541 和 +0.425557。平均偏置梯度 $\partial J/\partial b$ = ?

A. −0.401549
B. 0.048016
C. 0.024008
D. −0.158219

> **答案 C** — ½(−0.377541 + 0.425557) = ½(0.048016) ≈ 0.024008。两个误差符号相反，大部分抵消了，所以平均偏置梯度很小——这就是批量平均的效果。

132. $\partial J/\partial w \approx -0.158219$，$\eta = 0.1$，$w = 1$。更新后的 w 是：

A. ≈ 0.984178
B. ≈ 1.015822
C. ≈ 0.841781
D. ≈ 1.158219

> **答案 B** — $w \leftarrow 1 - 0.1(-0.158219) = 1 + 0.0158219 \approx 1.015822$。梯度是负的，减去一个负数等于加上正数，所以 w 变大。写成 $w - \eta\,\partial J/\partial w$ 时特别要小心这个双重负号。

Tutorial Q3：边界、分类与置信度（5 题）

133. 题目要求解释"为什么边界是 z = 0"，正确的理由是：

A. 因为 z = 0 时模型没有参数
B. 因为所有样本的 z 都等于 0
C. 因为 σ(0) = 0.5 且 sigmoid 单调递增，所以 $p \geqslant 0.5$ 等价于 $z \geqslant 0$
D. 因为阈值可以任意选择

> **答案 C** — 因为 σ(0) = 0.5，且 sigmoid 严格单调递增（因而可逆），所以 $p \geqslant 0.5$ 恰好等价于 $z \geqslant 0$。"单调"这个条件不能漏——它保证了等价关系是双向的。

134. B = [1, 5]，$z = 2x_1 - x_2 - 3$。z_B 和预测类别分别是：

A. z = 4，类别 1
B. z = −6，类别 0
C. z = −6，类别 1
D. z = 6，类别 1

> **答案 B** — $z_B = 2(1) - 5 - 3 = 2 - 5 - 3 = -6 < 0$，所以预测类别 0。注意不需要算 sigmoid——判类只看 z 的符号就够了。

135. 类别 1 在直线的哪一侧？为什么？

A. 直线上方，因为 x_2 越大 z 越大
B. 直线下方，因为 $w_2 = -1$，x_2 越大 z 越小
C. 直线左侧
D. 无法确定，需要更多信息

> **答案 B** — $z > 0$ 即 $2x_1 - x_2 - 3 > 0$，移项得 $x_2 < 2x_1 - 3$，所以类别 1 在直线下方。根本原因是 $w_2 = -1$ 为负：x_2 越大反而 z 越小。拿 C = [3,1]（z = +2，在线下方）一验就知道了。

136. 扩展题：$P_A \approx 0.269$，$P_B \approx 0.00247$，$P_C \approx 0.881$。哪个预测最有把握？

A. A，因为它离边界最近
B. C，因为它的概率最大
C. B，因为它的概率离 0.5 最远
D. 三者置信度相同

> **答案 C** — B 的概率 $P \approx 0.00247$，离 0.5 有 0.498，是三个点中最远的（A 离 0.231，C 离 0.381）。它以约 99.75% 的把握预测类别 0。也可以直接比 |z|：|−6| 最大。

137. A 和 B 的预测类别都是 0。如果换成感知机：

A. 感知机会把 A 判为 1、B 判为 0
B. 感知机对两者都只输出"类别 0"，无法表达 B 比 A 可靠得多
C. 感知机会给出相同的概率估计
D. 感知机无法处理这两个点

> **答案 B** — 感知机只输出硬标签，A 和 B 都是类别 0，完全无法区分；逻辑回归告诉你 B（99.75%）比 A（73.1%）可靠得多。这正是第 19 页对比表里"probability"那一行的实际意义。

C · Practical 部分（30 题）

Practical Setup 与 Q1（5 题）

138. 代码里 X = ... / 255.0 的作用是：

A. 为了把像素值变成概率
B. 为了减少特征数量
C. 特征缩放：把 0–255 的像素值归一化到 [0,1]，使训练更稳定
D. 为了把图像变成黑白两色

> **答案 C** — 像素原本是 0–255，除以 255 缩放到 [0,1]。否则特征值过大会让 $w \leftarrow w + \eta yx$ 一次推得太远，训练不稳定。注意这不是标准化（减均值除标准差），而是固定除法缩放，因为 0–255 的范围是天然已知的。

139. 为什么用 X[:60000] / X[60000:] 切分，而不用 train_test_split?

A. 因为 train_test_split 会导致数据泄漏
B. 因为 MNIST 有官方标准划分（前 60000 训练、后 10000 测试），保证结果可比
C. 因为数据太大，train_test_split 跑不动
D. 因为感知机不支持随机划分

> **答案 B** — MNIST 有人人都用的官方划分，用它能让所有人的结果可比较，而且 MNIST 已经打乱过了，不用担心顺序偏差。notebook 的 good habits 也强调"保持官方训练/测试集分离"。

140. 要选出所有标签为 5 的样本，应该写：

A. y_train == 5
B. y_train.equals(5)
C. y_train == "5"，因为标签是字符串
D. y_train.astype(int) 后才能比较

> **答案 C** — setup 里写了 y = np.asarray(y_raw).astype(str)，标签是字符串。所以必须写 y_train == "5"（带引号）。写成 == 5 会得到全 False 的数组，不报错但结果全错——这种错最难找。

141. np.flatnonzero(y_train == str(digit)) 返回的是：

A. 该数字样本的像素值
B. 标签等于该数字的所有样本的下标
C. 该数字的样本总数
D. 非零像素的个数

> **答案 B** — y_train == str(digit) 产生一个布尔数组，np.flatnonzero 把它变成"所有 True 位置的下标"数组。这样就能用 digit_indices[0]、digit_indices[1] 取前两个样本。

142. 784 个特征中的一个代表什么?

A. 整张图的平均亮度
B. 该图像属于某个数字的概率
C. 图上某个固定位置的单个像素的归一化亮度
D. 笔画的粗细

> **答案 C** — 参考答案：one feature is the normalised intensity of one pixel at a fixed location。"固定位置"是关键（对应第 5 页"特征顺序必须一致"）。这也直接导致了局限：图像平移几个像素，所有特征值都变了，但模型不知道这只是同一个数字挪了位置。

Practical Q2：二分类感知机（5 题）

143. 多数类基线 0.9108 的含义是：

A. 随机猜的准确率，约 0.5
B. 永远预测多数类（"不是 5"）能拿到的准确率
C. 感知机的最低可能准确率
D. 训练集上的准确率

> **答案 B** — 多数类基线 = 最大类别的占比。测试集中 5 占 8.92%，所以非 5 占 91.08%。一个永远预测"不是 5"的模型就能拿 0.9108。任何模型必须明显超过这个数字才算有价值。

144. predict 与 decision_function 的区别是：

A. predict 返回概率，decision_function 返回标签
B. 两者都返回概率，只是格式不同
C. predict 返回硬标签，decision_function 返回原始线性得分 z
D. predict 用训练集，decision_function 用测试集

> **答案 C** — predict 返回硬标签（True/False），相当于 sign(z)；decision_function 返回原始线性得分 $z = w^T x + b$。感知机没有 predict_proba 这个方法，因为它不产生概率。

145. 输出的前五个得分是 −213.39、−56.32 等。这些能当概率用吗?

A. 能，除以 1000 就是概率
B. 不能，概率必须在 0 到 1 之间，这些只是线性得分
C. 能，负号表示概率很低
D. 不能，因为它们都是负数

> **答案 B** — 概率必须在 (0,1) 区间内，而这些得分是 −213、−226 这种数。它们只是线性得分 z：符号告诉你在边界哪一侧，绝对值告诉你离边界多远（以得分为单位）。

146. 为什么说"准确率 0.9651"可能有误导性?

A. 因为准确率计算有误
B. 因为测试集太小
C. 因为 5 只占 8.92%，高准确率可以与"漏掉很多 5"同时存在
D. 因为感知机不能做二分类

> **答案 C** — 参考答案：only 8.92% of the test images are 5s，a high overall accuracy can coexist with many missed 5s。模型错 3.49%，若这些错全是漏掉的 5，就是 349/892 ≈ 39% 的 5 被漏掉了。准确率完全看不出这一点，所以 Q4 要加 precision 和 recall。

147. 得分的绝对值越大，按参考答案的措辞意味着：

A. 图像属于该类的概率越高
B. 图像离拟合出的边界越远（以得分为单位）
C. 图像的像素值越大
D. 模型对它的预测正确率越高

> **答案 B** — 参考答案：greater magnitude means the image lies farther from the fitted boundary in score units。"以得分为单位"这个限定呼应第 7 页：真正的几何距离需要除以 ‖w‖，而且得分的尺度取决于 w 的大小。

Practical Q3：one-vs-rest 四分类（5 题）

148. one-vs-rest 如何产生四类预测?

A. 把 4 个得分相加，看总和的符号
B. 只训练一个直接输出 4 类的模型
C. 为每个类学一个得分，预测时选得分最大的那个类
D. 依次判断是不是 2、是不是 4、是不是 6，第一个为真就停

> **答案 C** — 参考答案：learns one score per class and selects the class with the largest score。训练 4 组 (w_k, b_k)，预测时算出 4 个得分取 argmax。注意用的是得分大小而不是符号——即使 4 个得分全是负的，也选那个最不负的。

149. 混淆矩阵用 normalize="true"，则对角线上的数字是：

A. precision（精确率）
B. recall（召回率）
C. 原始计数
D. F1 分数

> **答案 B** — normalize="true" 按真实类别按行归一化，每行和为 1。对角线上的值就是"该类真实样本中被正确识别的比例"，也就是 recall。按列归一化才是 precision。

150. 哪一类 recall 最低？它最常被误判成什么?

A. 数字 4，主要被误判为 6
B. 数字 2，约 22.2% 被误判为 others
C. others，主要被误判为 2
D. 数字 6，主要被误判为 4

> **答案 B** — 数字 2 的 recall 只有约 0.750，是四类中最低的；其中约 22.2% 的真实 2 被预测成 others。原因可能是 others 里的 3、7、8 等与 2 笔画重叠，加上 others 样本量大得多。

151. 为什么 others 类的高 recall（0.958）需要小心解读?

A. 因为它的 recall 太低
B. 因为它只包含一种数字
C. 因为它包含 7 种视觉上完全不同的数字，高 recall 不代表它是一个连贯的视觉类别
D. 因为它在训练集里不存在

> **答案 C** — 参考答案：the others class is broad and contains seven visually different digits, so its high recall does not mean it is a coherent visual category。模型不是学会了 others 长什么样，而是把不像 2/4/6 的都往这里扔；加上它本身就是个大类（10 个数字里占 7 个）。

152. 从 Q2 的二分类到 Q3 的四分类，建模代码发生了什么变化?

A. 换成了一个专门的多分类模型
B. 没有变化，还是 Perceptron；sklearn 根据标签有 4 个值自动启用 one-vs-rest
C. 手动写了一个循环训练 4 个模型
D. 换成了逻辑回归

> **答案 B** — 代码里还是 Perceptron(random_state=...)，一个字没改。sklearn 检测到标签有 4 个不同值，就自动采用 one-vs-rest 在内部训练 4 个二分类器。真正变的只是标签的定义。

Practical Q4 Part A：四指标对比（5 题）

153. 对比表中，两个模型差距最大的分类指标揭示了什么问题?

A. 感知机的 precision 太低
B. 感知机 recall 只有 0.6839，漏掉了约 32% 的真 5
C. 感知机的准确率低于基线
D. 感知机把所有图都判为 5

> **答案 B** — 感知机 recall = 0.6839，意味着约 32% 的真 5 被漏掉了；逻辑回归 recall = 0.8150，找到了多得多。但感知机的准确率还有 0.9651，完全看不出这个问题——这就是 Q2 预告的"高准确率与漏掉很多 5 可以共存"。

154. 对感知机的得分套上 sigmoid 后，为什么仍然不是好概率?

A. 因为 sigmoid 会把值压到 0 到 1 之外
B. 因为感知机的得分都是负数
C. 因为感知机不是用逻辑损失训练的，得分尺度任意，所以得到的值未经校准
D. 因为感知机没有 decision_function 方法

> **答案 C** — 参考答案：it does not make them well-calibrated probabilities because the perceptron was not trained using logistic loss。训练目标决定了输出的含义；而且感知机得分的尺度是任意的（w、b 同乘 10 边界不变但得分变 10 倍），套上 sigmoid 后概率完全不同。

155. 输出"Largest |sigmoid(score) − predict_proba|: 0.0"证实了什么?

A. 两个模型的预测完全相同
B. 逻辑回归的 predict_proba 内部就是 σ(decision_function)，即 p = σ(z)
C. 模型没有学到任何东西
D. 测试集有重复样本

> **答案 B** — 差值为 0 说明对逻辑回归而言，predict_proba 内部做的就是 σ(decision_function)。这从代码层面验证了课件第 13 页的 p = σ(z)。

156. 为什么 log loss 的差距（0.8440 vs 0.0919）远大于准确率的差距?

A. 因为 log loss 的计算有误差
B. 因为逻辑回归用的训练数据更多
C. 因为 log loss 衡量概率报得准不准，感知机的伪概率充满"自信地错了"的预测，被重罚
D. 因为感知机的准确率也很低

> **答案 C** — log loss（即二元交叉熵）衡量的是概率报得准不准，而不只是类别猜得对不对。感知机的伪概率包含大量"自信地错了"的预测，被交叉熵重罚（第 16 页），所以差距远大于准确率的差距。

157. 关于两个模型的训练数据量:

A. 两个模型都用了全部 60000 张
B. 逻辑回归只用了 15000 张，但测试集相同，所以对比仍公平
C. 逻辑回归用了更多训练数据，所以对比不公平
D. 两个模型用了不同的测试集

> **答案 B** — 逻辑回归只用了 15000 张（感知机用了 60000），是为了课堂上运行时间可控；但测试集完全相同、未被动过，所以对比仍然公平。值得注意的是：用了四分之一的数据，它依然赢了。

Practical Q4 Part B：手动梯度更新（5 题）

158. 初始 w = [0, 0]、b = 0，所有样本的 p 是多少？初始损失是多少?

A. p = 0，损失无穷大
B. p = 0.5，损失 = −log(0.5) ≈ 0.6931
C. p = 1，损失 = 0
D. p 因样本而异，损失无法确定

> **答案 B** — w = [0,0]、b = 0 → 所有 z = 0 → 所有 p = σ(0) = 0.5。损失 = −log(0.5) = ln2 ≈ 0.6931。这是二分类的"随机猜"基准，任何有用的模型都应明显低于它。

159. 为什么偏置梯度恰好等于 0?

A. 因为代码写错了
B. 因为 b 本来就是 0
C. 因为四个误差 0.5、0.5、−0.5、−0.5 相加为零，正负类数量相等完全抵消
D. 因为偏置永远不参与梯度下降

> **答案 C** — $\partial J/\partial b = \text{mean}(p - y) = (0.5 + 0.5 - 0.5 - 0.5)/4 = 0$。两个正类、两个负类，初始误差完全对称地抵消。所以这一步 b 不会变，只有 w 在动。

160. gradient_w[0] = −0.75，learning_rate = 0.5，初始 w[0] = 0。更新后 w[0] = ?

A. −0.375
B. 0.375
C. −0.75
D. 0.75

> **答案 B** — $w[0] = 0 - 0.5 \times (-0.75) = 0 + 0.375 = 0.375$。梯度为负，减去负数等于加上正数，所以权重变大。同理 w[1] = 0.28125。

161. BCE 从 0.6931 降到 0.3538，这证明了:

A. 任何学习率下损失都一定下降
B. 梯度下降不适用于逻辑回归
C. 在所选的学习率下，减去梯度确实把参数推向了降低损失的方向
D. 模型已经收敛到最优解

> **答案 C** — 参考答案特地加了 "for the chosen learning rate"——步长太大时损失可能反而上升，所以不能无条件地说"一定下降"。这呼应 tutorial Q2 里 "sufficiently small step" 那个限定词。

162. 代码 x2_boundary = -(w[0]*x1_boundary + b) / w[1] 画的是什么?

A. 概率等于 1 的位置
B. 令 z = 0 解出 x_2，即 tutorial Q3 的斜截式（斜率 $-w_1/w_2$，截距 $-b/w_2$）
C. 损失函数的最小值位置
D. 梯度向量的方向

> **答案 B** — 把 $w[0]x_1 + w[1]x_2 + b = 0$ 解出 x_2 就得到这个式子，与 tutorial Q3 的斜截式完全一致。代入数字：斜率 = −0.375/0.28125 = −4/3，截距 = 0。

Practical 最终反思与总结（5 题）

163. 为什么测试准确率无法反映"数据偏移"的风险?

A. 因为测试集太小
B. 因为准确率计算方式有误
C. 因为测试集与训练集来自同一分布，只能衡量分布内表现
D. 因为模型没有用全部训练数据

> **答案 C** — 测试集与训练集都来自 MNIST 官方划分，同一分布。所以 0.9744 只衡量了"分布内"表现，对不同书写风格、扫描质量、设备条件下的新数据没有预测力。

164. 为什么准确率无法反映"错误代价不对等"?

A. 准确率只统计假阳性
B. 准确率把所有错误一视同仁，没有代价加权
C. 准确率只能用于二分类
D. 准确率不能在测试集上计算

> **答案 B** — 准确率把所有错误算作同等代价。但现实中"读错账号"远比"拒读一张不清晰的图、转人工审核"严重得多。它没有代价加权的概念。

165. 要设计一个"不确定就转人工审核"的机制，应该用哪个模型?

A. 感知机，因为它的得分范围更大
B. 两者都可以，效果相同
C. 逻辑回归，因为它的概率能识别出"没把握"的样本
D. 都不可以，必须换成神经网络

> **答案 C** — 有了概率就可以设"拒答（reject option）"区间：p 在 0.4–0.6 之间时不下判断，转人工。感知机只给硬标签，无法区分"很有把握"和"勉强"，做不到这件事。

166. 扩展题让你改变玩具数据的学习率。你会发现:

A. 任何学习率都会降低损失，只是快慢不同
B. 学习率太大会冲过头，损失可能反而上升——验证了"足够小的步长"这个前提
C. 学习率不影响损失
D. 学习率只影响偏置，不影响权重

> **答案 B** — 步长太大会"冲过头"，参数被推得极远，损失可能反而上升。这直接验证了 tutorial Q2 里 "sufficiently small step（足够小的步长）"那个限定词——只有小步才保证下降。

167. Practical 总结第 2 条"目标的定义决定了分类问题"指的是:

A. 特征的数量决定模型能不能学会
B. 只有换模型才能换问题
C. 同样的特征，只要重新定义标签，就变成了完全不同的分类问题
D. 标签必须一直保持原样

> **答案 C** — Q2、Q3 都没有改变任何特征，只是把标签从 10 类重新定义成"5/非 5"或"2/4/6/others"，就变成了完全不同的任务。建模前先想清楚"我要模型回答什么问题"非常重要。