支持向量机 SVM

Module 1 · Topic 4 — 题库与解析

ARTI2001 Machine Learning

共 26 组 · 130 道选择题

讲座与推导 16 组 · Tutorial 4 组 · Practical 6 组

配套文件：《M1T4 知识点整理》

> **使用方法：**每组 5 题，题目与选项在前，**答案与解析在该组末尾**。建议先遮住解析区独立作答，全组做完再核对。做错的题回到《知识点整理》对应章节复习。

第一部分 · 讲座（第 3–16 页）

第 1 组：SVM 路线图（第 3 页）

1. 感知机（Perceptron）和 SVM 在训练目标上的关键差别是什么？

A. 感知机用线性边界，SVM 只能用非线性边界
B. 感知机返回任意一个可行的分隔面，SVM 选择最大间隔的分隔面
C. 感知机需要标签，SVM 不需要标签
D. 感知机是回归模型，SVM 是分类模型

2. 路线图中，参数 C 的作用是平衡哪两样东西？

A. 训练速度与预测速度
B. 特征数量与样本数量
C. 间隔宽度与违反程度
D. 训练误差与测试误差

3. 「支持向量决定了解」是路线图中哪一阶段的核心结论？

A. Margin Geometry（间隔几何）
B. Kernel Trick（核技巧）
C. Perceptron → SVM
D. Dual View（对偶视角）

4. 核技巧在路线图中被描述为通过什么来实现非线性边界？

A. 相似度（similarity）
B. 增加训练轮数
C. 堆叠多层神经网络
D. 删除异常值

5. Margin Geometry 阶段列出的两个关键概念是：

A. 梯度下降与学习率
B. 有符号距离与规范化缩放
C. 交叉验证与网格搜索
D. 过拟合与欠拟合

答案与解析

1. B — 两者都用同一个线性打分函数 $f(x)=w^{T}x+b$，区别在训练目标：感知机只要能分对就停，任何可行分隔面都可能被返回；SVM 则在所有可行分隔面中挑出间隔最大的那一个。

2. C — 课件原话是 "C balances width and violations"。C 大时严厉惩罚违规、间隔变窄；C 小时容忍更多违规、间隔更宽、正则化更强。

3. D — 对偶视角揭示了只有少数训练点（具有非零对偶系数的支持向量）真正影响决策边界，其余点即使删掉边界也不变。

4. A — 课件写的是 "Non-linear boundaries through similarity"。核函数本质上是在衡量两个样本的相似度，等价于在某个变换空间里做点积，但不需要真把特征算出来。

5. B — 课件写的是 "Signed distance and canonical scaling"。有符号距离 $f(x)/\|w\|$ 保留了点在边界哪一侧的信息；规范化缩放则约定 $y\cdot f(x)\geqslant 1$，从而把间隔宽度固定成 $2/\|w\|$。

第 2 组：感知机 vs SVM（第 4 页）

1. 感知机与 SVM 的共同点是：

A. 都使用核函数

B. 都最大化间隔

C. 都使用线性打分函数 $f(x)=w^Tx+b$

D. 都需要数据完美可分

2. 关于感知机返回的边界，下列哪项正确？

A. 它总是返回间隔最小的那一个

B. 任何一个有效分隔面都可能被返回，解不唯一

C. 它总是返回与 SVM 完全相同的边界

D. 它无法返回任何分隔面

3. 硬间隔 SVM（hard-margin SVM）选出最大规范间隔分隔面的前提条件是：

A. 数据必须含有噪声

B. 必须使用 RBF 核

C. C 必须设为 0

D. 数据必须是完美可分的

4. 课件对支持向量（support vectors）的定义是：

A. 具有非零对偶影响（nonzero dual influence）的训练观测

B. 距离边界最远的那些点

C. 所有被正确分类的点

D. 被删除的异常值

5. 为什么课件强调即使用了 SVM 也仍要依靠验证证据（validation evidence）？

A. 因为 SVM 训练速度太慢

B. 因为两种训练目标都不保证测试集上的稳健表现

C. 因为感知机不能处理标签

D. 因为最大间隔已经保证了最优泛化

答案与解析

1. C — 两个模型共享同一个线性打分函数，改变的只是训练目标（the training objective changes）。

2. B — 课件原话：Any valid separator may be returned。感知机没有显式的间隔目标，所以解不唯一，取决于初始值与样本顺序。

3. D — 硬间隔只在完美可分可行时才适用（when perfect separation is feasible）；数据不可分时需要转向软间隔。

4. A — 课件 notes 的定义是 Support vectors are the training observations with nonzero dual influence。注意违规的点也有非零对偶系数，同样是支持向量。

5. B — 最大间隔只是训练集上的一个几何标准，不是泛化的保证。泛化能力仍需靠验证证据判断。

第 3 组：间隔几何（第 5 页）

1. 要把原始分数 $f(x)=w^Tx+b$ 变成真正的几何距离，必须：

A. $f(x)$ 本身就是几何距离

B. $f(x)$ 乘以标签 y

C. $f(x)$ 除以 $\|w\|$

D. $f(x)$ 减去偏置 b

2. 若某个点满足 $0 < y_i f(x_i) < 1$，它的位置是：

A. 被错误分类

B. 分类正确，但落在间隔内部

C. 恰好落在决策边界上

D. 落在支持超平面之外，完全安全

3. 在规范化硬间隔约定下，一侧间隔和完整间隔宽度分别是：

A. 一侧 $2/\|w\|$，完整 $1/\|w\|$

B. 一侧 $\|w\|$，完整 $2\|w\|$

C. 一侧和完整都是 $1/\|w\|$

D. 一侧 $1/\|w\|$，完整 $2/\|w\|$

4. 对一个被误分类的观测，$f(x)/\|w\|$ 与 $y\,f(x)/\|w\|$ 可能符号相反，原因是：

A. 有符号距离只看点在哪一侧，带标签间隔还把真实标签乘进去了

B. 两者使用了不同的 $\|w\|$

C. 有符号距离总是非负的

D. 带标签间隔没有除以 $\|w\|$

5. 设 $w=[3,4]^T$，$b=-5$，$x=(2,1)$，真实标签 $y=-1$。则有符号距离和带标签几何间隔分别是：

A. 有符号距离 = 5，带标签间隔 = −5

B. 有符号距离 = −1，带标签间隔 = 1

C. 有符号距离 = 1，带标签间隔 = −1

D. 有符号距离 = 1，带标签间隔 = 1

答案与解析

1. C — 只有除以 $\|w\|$ 之后才是几何量。原始分数会随 (w,b) 缩放而变，不能当距离用。

2. B — 乘积为正说明分类正确，但小于 1 说明尚未达到支持超平面，落在间隔内部，属于违规。

3. D — 一侧间隔为 $1/\|w\|$，两侧加起来的完整宽度为 $2/\|w\|$。

4. A — 有符号距离与真实标签无关，只反映点在哪一侧；乘上 y 后得到的带标签间隔反映的是「分对没」。点在正侧但标签为 −1 时，两者符号相反。

5. C — $f(x)=3\times2+4\times1-5=5$，$\|w\|=\sqrt{(9+16)}=5$，所以有符号距离 = 1；$y=-1$ 时 $y\,f(x)=-5$，带标签间隔 = −1，说明该点被误分类。

第 4 组：SVM 工作流程（第 6 页）

1. 先对整个数据集做特征缩放、再划分训练集与测试集，会导致什么问题？

A. 训练变慢

B. 数据泄漏，因为缩放参数用到了测试集信息

C. 特征不再具有可比性

D. 标签变成连续值

2. 为什么特征缩放对 SVM（尤其是 RBF 核）特别重要？

A. 因为 SVM 不能处理负数

B. 因为缩放会自动删除异常值

C. 因为缩放能把非线性问题变成线性问题

D. 因为 SVM 依赖距离计算，尺度大的特征会主导结果

3. 工作流程的「选择基线」一步建议从什么开始？

A. 线性核 + 可复现的数据划分

B. RBF 核 + 随机划分

C. 高次多项式核 + 交叉验证

D. 直接在测试集上搜索最优核

4. 第 3 步「检查支持情况」具体要看哪两个指标？

A. 训练时长与内存占用

B. 特征的均值与方差

C. 间隔违反情况与支持向量个数

D. 测试集上的最终准确率

5. 为什么课件强调「测试集只用一次（test once）」？

A. 模型会无法收敛

B. 测试集实际上变成了验证集，性能估计会偏高

C. 支持向量数量会变为零

D. 特征缩放会失效

答案与解析

1. B — 缩放器的均值与标准差必须只从训练数据估计。先对全部数据缩放再划分，测试集信息会通过统计量泄漏给训练过程。

2. D — SVM 的间隔、距离以及 RBF 核 $\exp(-\gamma \| x-z \|^2)$ 都依赖距离。尺度大的特征会主导距离计算，把其他特征的作用淹没。

3. A — 课件建议 Start with a linear kernel and a reproducible split。线性核最简单、参数最少，作为对照基准；固定随机种子保证划分可复现。

4. C — 第 3 步 Inspect support 要求检查 margin violations 和 support-vector count。支持向量占比过高往往提示边界过于复杂、模型在硬啃噪声。

5. B — 反复用测试集比较模型、挑参数，等于把它变成了验证集，最终报告的分数会系统性偏高。

第 5 组：软间隔与超参数（第 7 页）

1. 当松弛变量 $\xi_i = 1$ 时，该点在哪里？

A. 在支持超平面之外，完全安全
B. 分类正确但在间隔内部
C. 恰好落在决策边界上
D. 被严重误分类，远离边界

2. $\xi_i > 1$ 表示该点：

A. 在支持超平面上
B. 被误分类
C. 分类正确且在间隔外
D. 分类正确但在间隔内

3. 在目标函数 $\frac{1}{2} \| w \|^2 + C\Sigma\xi$ 中，把 C 调小会怎样？

A. 间隔变窄，正则化变弱
B. 完全不允许任何违规
C. 核函数自动变为 RBF
D. 间隔变宽，正则化更强，允许更多违规

4. RBF 核中的 gamma 控制的是：

A. 单个样本的影响有多局部
B. 对违规的惩罚强度
C. 支持向量的上限个数
D. 多项式核的次数

5. SVC 的 decision_function 输出可以直接当作概率解释吗？

A. 可以，它已经归一化到 [0,1]
B. 可以，只要特征做过缩放
C. 不可以，除非经过校准（calibration）
D. 不可以，但取绝对值后就是概率

答案与解析

1. C — $\xi = 1$ 对应 $y\,f(x) = 0$，点恰好落在决策边界上。它不属于任何一侧，所以说它「在正确的一侧」并不准确。

2. B — $\xi > 1$ 对应 $y\,f(x) < 0$，即预测符号与真实标签相反，点被误分类。

3. D — 课件原话：small C favours a wider, more regularised margin。C 小时对违规的惩罚轻，模型愿意用更多违规换取更宽的间隔。

4. A — 课件写的是 Gamma controls how local an RBF influence becomes。γ 大时每个样本的影响范围很窄，边界变得更复杂；γ 小时影响范围宽，边界更平滑。

5. C — 课件明确：SVC scores are not probabilities unless calibrated。decision_function 返回带符号的实数 $f(x)$，不在 [0,1] 区间。

第 6 组：核函数选择（第 8 页）

1. RBF 核的公式是：

A. x^Tz

B. $\exp(-\gamma \| x-z \|^2)$

C. $(\gamma x^Tz + r)^d$

D. $½ \| w \|^2 + C\Sigma\xi$

2. 关于多项式核与 RBF 核产生的边界，课件的描述是：

A. 多项式核是局部的，RBF 是全局的

B. 两者都是全局的

C. 多项式核是全局的，RBF 是局部的

D. 两者都只能产生直线边界

3. 如果 RBF 的决策边界太不规则，应该调查对哪个参数做什么改动？

A. 增大 γ

B. 增大 C

C. 提高多项式次数 d

D. 减小 γ

4. 三个核中，需要调的参数最多的是：

A. 多项式核（C、d、γ、r）

B. 线性核（只有 C）

C. RBF 核（C、γ）

D. 三者参数数量相同

5. 为什么课件强调比较多项式或 RBF 模型之前必须先缩放特征？

A. 因为不缩放模型就无法训练

B. 因为否则尺度大的特征会主导核的计算

C. 因为缩放能减少支持向量的个数

D. 因为缩放能把核函数变成线性的

答案与解析

1. B — RBF 核通过距离衡量相似度：近的点相似度高，远的点相似度趋近于 0。

2. C — 课件把多项式核描述为 global curve，把 RBF 描述为 local curve。RBF 通过距离衡量相似度，每个样本的影响是局部的。

3. D — 课件写的是 RBF γ：small = smoother，large = more complex。边界太不规则时应减小 γ，并用验证证据支持这个改动。

4. A — 多项式核需要 C、d、γ、r 四个参数；RBF 需要 C 和 γ；线性核只需要 C。参数越多，调起来越麻烦。

5. B — 这两个核直接依赖 x^Tz 或 $\| x-z \|$，不缩放时尺度大的特征会主导整个核的计算，其他特征几乎失效。

第 7 组：概念检查点（第 9 页）

1. 有符号距离与点到边界距离的区别是：

A. 两者完全相同

B. 有符号距离总是非负，点距离可正可负

C. 有符号距离保留了点在哪一侧，点距离取绝对值后非负

D. 有符号距离不需要除以 $\| w \|$

2. 本页对支持向量的定义是：

A. 只有恰好落在支持超平面上的点

B. 具有非零对偶权重、定义边界的点

C. 所有距离边界小于 1 的点

D. 训练集中的全部点

3. 核技巧在公式层面具体做了什么替换？

A. 把 ‖ w ‖ 换成 K(w,b)

B. 把标签 y 换成 K(y)

C. 把松弛变量 ξ 换成 K

D. 把点积 $x_i^T x_j$ 换成 $K(x_i, x_j)$

4. 课件给出的计算顺序是：

A. 先算原始分数 → 再算距离 → 最后判断间隔条件

B. 先判断间隔条件 → 再算距离 → 最后算分数

C. 先算 ‖ w ‖ → 再选核函数 → 最后调 C

D. 先算支持向量个数 → 再算分数

5. 规范间隔条件（canonical margin condition）是：

A. $f(x_i) \geqslant 1$

B. $y_i f(x_i) \geqslant 1$

C. $|f(x_i)|/\|w\| \geqslant 1$

D. $y_i f(x_i) \geqslant 0$

答案与解析

1. C — 有符号距离 f(x)/‖ w ‖ 保留正负号，告诉你点在边界哪一侧；点到边界距离 |f(x)|/‖ w ‖ 取了绝对值，总是非负。

2. B — 课件的定义是 nonzero dual weight：具有非零对偶权重、定义边界的点。违规的点也有非零对偶系数，同样是支持向量。

3. D — 课件写的是 Replace $x_i^T x_j$ with $K(x_i,x_j)$。只有在对偶形式中数据才以点积形式出现，才能用核函数替换。

4. A — 课件 notes 明确：先算原始分数，再除以 ‖ w ‖ 得到距离，最后用 y f(x) 判断间隔条件。

5. B — 规范间隔条件是 $y_i f(x_i) \geqslant 1$。注意它用的是 y f(x)，不需要除以 ‖ w ‖，也不是单靠距离判断。

第 8 组：第一部分总结（第 10 页）

1. 为什么课件要求保持 ±1 标签约定的一致性？

A. 为了让训练速度更快

B. 为了让输出变成概率

C. 因为 y · f(x) 的判断规则依赖 ±1 标签，改用 {0,1} 会全部失效

D. 因为核函数只接受 ±1

2. 关于谁决定决策边界，本页的结论是：

A. 所有训练点都同等地影响边界

B. 只有支持向量决定边界

C. 只有被误分类的点决定边界

D. 边界由所有点的均值决定

3. 进 tutorial 前的注意事项中，要求明确区分哪两个量？

A. 支持向量与异常值

B. 训练集与测试集

C. 线性核与 RBF 核

D. 一侧间隔与完整间隔宽度

4. 若算出某点 y · f(x) = 0.6，完整的答案应该：

A. 还要解释它的含义：分类正确但落在间隔内部，属于间隔违反

B. 只需写出 0.6 即可

C. 需要把它转换成概率

D. 需要重新训练模型

5. 下列哪项**不是**本页列出的关键要点？

A. C 控制拟合与间隔的权衡

B. SVM 可以跳过特征预处理直接使用

C. 核函数使非线性边界成为可能

D. 间隔需要仔细区分分数与距离

答案与解析

1. C — SVM 的全部推导都建立在 $y \in \{+1, -1\}$ 上。若改用 {0,1}，$y \cdot f(x)$ 的符号判断规则全部失效。

2. B — 课件写的是 Support vectors—not every point—define the boundary。非支持向量的点删掉也不影响边界。

3. D — 课件要求 State one-sided versus full margin：一侧是 $1/\|w\|$，完整宽度是 $2/\|w\|$，相差一倍，必须标注清楚。

4. A — 课件要求 Interpret results, not only final numbers。算出数字后还要说明它在模型语境中的含义。

5. B — 第一条要点恰恰强调 SVM 仍然从数值特征开始，需要适当的特征处理与缩放。

第 9 组：Tutorial 活动介绍（第 11 页）

1. 课件说三道核心题串起了哪条主线？

A. 数据 → 模型 → 部署

B. 分数 → 间隔 → 核

C. 训练 → 验证 → 测试

D. 线性 → 多项式 → RBF

2. Tutorial 的 Q3 考的是：

A. 计算 f(x) 与有符号距离

B. 比较一侧与完整间隔宽度

C. 验证多项式核恒等式及其局限

D. 调优 C 与 gamma

3. 课件建议的做题节奏是：

A. 先独立做 → 组内比较方法 → 看完解答后修订

B. 先看解答 → 再自己做一遍

C. 直接小组分工，每人做一题

D. 只需写出最终答案，不用讨论

4. 为什么课件反复要求展示中间计算（show intermediate calculations）？

A. 为了让答案看起来更长

B. 为了避免使用计算器

C. 为了让小组成员抄作业

D. 为了在出错时能定位到具体哪一步

5. Tutorial 的可选扩展部分要求解释什么？

A. 特征缩放的具体方法

B. 对偶系数与 C 的解释

C. 神经网络的反向传播

D. 交叉验证的折数选择

答案与解析

1. B — 课件写的是 Three core questions connect score → margin → kernel，这正是第 4 到第 8 页的教学顺序。

2. C — Q3 要求验证一个多项式核恒等式及其局限，具体是展开 $\phi(x)^T\phi(y)$ 并证明它等于 $(x^Ty)^2$。

3. A — 课件 notes 给的节奏是：先独立尝试，再在组内比较方法，看过解答讨论后再修订自己的答案。

4. D — 一旦出现算术或约定错误，有标记的中间量能让你定位到具体哪一步出了问题。

5. B — 可选扩展要求解释对偶系数与 C（interprets dual coefficients and C），对应路线图中的 Dual View 阶段。

第 10 组：问题 1 四步法（第 12 页）

1. 课件给出的四步顺序是：

A. $y\,f(x) \to f(x) \to f(x)/\|w\| \to$ 判定

B. $\|w\| \to y\,f(x) \to f(x) \to$ 判定

C. $f(x) \to f(x)/\|w\| \to y\,f(x) \to$ 判定

D. $f(x)/\|w\| \to f(x) \to y\,f(x) \to$ 判定

2. 设 $w = [3, 4]^T$，$b = -1$，$x = (2, -1)$。第 1、2 步的结果是：

A. $f(x) = 1$，有符号距离 $= 1$

B. $f(x) = 1$，有符号距离 $= 0.2$

C. $f(x) = 2$，有符号距离 $= 0.4$

D. $f(x) = 1$，有符号距离 $= 5$

3. 接上题，若真实标签 $y = +1$，第 3、4 步的结论是：

A. 被误分类，$\xi > 1$

B. 在间隔内部，属于违规

C. 在决策边界上，$\xi = 1$

D. 恰好在支持超平面上，$\xi = 0$，无违规

4. 课件把这四步序列描述成什么？

A. 一个检查策略，有标签的中间量能定位错误

B. 一种能让模型训练更快的技巧

C. 一种避免使用核函数的方法

D. 一种自动完成特征缩放的流程

5. 本页 Study check 要求你能做到：

A. 只需写出最终的 $y\,f(x)$ 数值

B. 只需画出决策边界图

C. 不跳步地完成全部中间量，并解释结果在模型语境中的含义

D. 只需说出使用的是哪个核函数

答案与解析

1. C — 课件的四步流程是 Compute score → Signed distance → Margin score → Classify。

2. B — $f(x) = 3(2) + 4(-1) - 1 = 6 - 4 - 1 = 1$；$\|w\| = \sqrt{(9+16)} = 5$；所以有符号距离 $= 1/5 = 0.2$。

3. D — $y\,f(x) = (+1)(1) = 1$，恰好在支持超平面上，此时 $\xi = 1 - 1 = 0$，不算违规。

4. A — 课件 notes 称之为 checking strategy：保持中间量有标签，这样算术错误或约定错误才能被定位和纠正。

5. C — Study check 明确要求不跳过任何中间量地完成步骤，然后解释最终结果在模型语境中意味着什么。

第 11 组：间隔宽度与 C（第 13 页）

1. 若 $w = [6, 8]^T$，则一侧间隔和完整间隔宽度分别是：

A. 一侧 $= 10$，完整 $= 20$

B. 一侧 $= 0.1$，完整 $= 0.2$

C. 一侧 $= 0.2$，完整 $= 0.1$

D. 一侧 $= 0.5$，完整 $= 1$

2. 课件配套结论：更小的 $\|w\|$ 会：

A. 产生更窄的几何间隔

B. 使支持向量数量变为零

C. 对间隔宽度没有影响

D. 产生更宽的几何间隔

3. 当 C 取得很大时，目标函数 $\frac{1}{2}\|w\|^2 + C\sum\xi$ 中哪一项更重要，后果是什么？

A. $C\sum\xi$ 主导，模型优先减少违规，间隔变窄

B. $\frac{1}{2}\|w\|^2$ 主导，间隔变宽

C. 两项影响相同，间隔不变

D. 目标函数变为非凸的

4. 为什么课件这页没有给出具体的数值和最终答案？

A. 因为这些数值不重要

B. 因为这页已经在第 5 页讲过

C. 因为它们是有意省略的，要留给你自己完成

D. 因为这些内容不会考

5. 某模型的完整间隔宽度为 0.5，则它的一侧间隔是：

A. 0.5

B. 0.25

C. 1.0

D. 4

答案与解析

1. B — $\|w\| = \sqrt{(36+64)} = \sqrt{100} = 10$。一侧 = 1/10 = 0.1，完整宽度 = 2/10 = 0.2。

2. D — 课件写的是 A smaller $\|w\|$ produces a wider geometric margin。因为间隔宽度是 $2/\|w\|$，分母变小则商变大。

3. A — C 大时 $C\sum\xi$ 主导目标函数，模型优先减少训练违规，即使这意味着 $\|w\|$ 变大、间隔变窄。

4. C — 课件 notes 明确说工作表的数值、中间计算和最终结论是有意省略的（intentionally omitted），这页只提供组织你自己工作的概念和检查问题。

5. B — 完整宽度 = $2/\|w\| = 0.5$，所以 $\|w\| = 4$，一侧间隔 = 1/4 = 0.25，恰好是完整宽度的一半。

第 12 组：核恒等式验证（第 14 页）

1. 设 $\phi(x) = (x_1^2, \sqrt{2}\,x_1x_2, x_2^2)$。展开 $\phi(x)^T\phi(y)$ 得到：

A. $x_1^2y_1^2 + x_1x_2y_1y_2 + x_2^2y_2^2$

B. $x_1^2y_1^2 + \sqrt{2}\,x_1x_2y_1y_2 + x_2^2y_2^2$

C. $x_1^2y_1^2 + 2x_1x_2y_1y_2 + x_2^2y_2^2$

D. $x_1^2y_1^2 + x_2^2y_2^2$

2. 特征映射中的 $\sqrt{2}$ 为什么必须存在？

A. 为了让特征向量长度为 1

B. 为了让交叉项系数变成 2，与 $(x^Ty)^2$ 的展开式匹配

C. 为了避免负数

D. 为了降低计算复杂度

3. 核技巧避免了什么？

A. 避免了使用标签

B. 避免了交叉验证

C. 避免了计算 $\|w\|$

D. 避免了显式构造高维的特征向量

4. 第 4 步要求说明「什么并不保证便宜」，正确的回答是：

A. 核矩阵是 $n \times n$ 的，样本量大时存储和训练代价很高

B. 核函数无法处理二维数据

C. 核函数会破坏标签约定

D. 核函数必须手工构造 ϕ

5. 支持向量数量很多时，核 SVM 的预测会变慢吗？为什么？

A. 不会，预测代价与支持向量数量无关

B. 不会，因为预测只用 w^Tx

C. 会，因为需要对每个支持向量算一次核函数

D. 会，但只在线性核下成立

答案与解析

1. C — $\phi(x)^T\phi(y) = x_1^2y_1^2 + (\sqrt{2}\,x_1x_2)(\sqrt{2}\,y_1y_2) + x_2^2y_2^2$，中间项两个 $\sqrt{2}$ 相乘得到 2。

2. B — $(x^Ty)^2$ 展开后交叉项系数是 2。若写成 (x_1^2, x_1x_2, x_2^2)，交叉项系数只有 1，恒等式不成立。

3. D — 直接算 $(x^Ty)^2$ 只需 $O(d)$ 的点积加一次平方，而显式构造二次特征向量需要 $O(d^2)$ 的维度，次数更高时维度爆炸。

4. A — 核矩阵是 $n \times n$ 的，存储为 $O(n^2)$，训练时间通常在 $O(n^2)$ 到 $O(n^3)$ 之间。核技巧在特征维度上省钱，却在样本数量上花钱。

5. C — 核 SVM 预测时需要对每个支持向量算一次核：$f(x) = \Sigma\, \alpha_i y_i K(x_i, x) + b$；线性 SVM 只需一次 w^Tx。

第 13 组：Notebook 工作流程 + 综合复习（第 16 页）

1. Notebook 第 3 步「在验证集上调参」特别强调什么纪律？

A. 使用尽可能多的参数组合

B. 搜索过程不能碰触测试数据

C. 只搜索 C，不搜 gamma

D. 先在测试集上预热一次

2. 关于扩展内容（extensions），课件的建议是：

A. 最先做，因为它们最难

B. 与核心题同时进行

C. 完全跳过

D. 放到最后，核心题完成后再做

3. 综合题：$w = [1, 2]^T$，$b = 1$，$x = (3, -1)$，$y = -1$。下列哪项全对？

A. $f(x) = 2$，$y\,f(x) = 2$，分类正确且无违规

B. $f(x) = 4$，$y\,f(x) = -4$，在间隔内部

C. $f(x) = 2$，$y\,f(x) = -2$，被误分类

D. $f(x) = 2$，$y\,f(x) = -2$，在决策边界上

4. 核技巧的代价权衡可以总结为：

A. 在特征维度上省钱，在样本数量上花钱

B. 在样本数量上省钱，在特征维度上花钱

C. 两方面都省钱

D. 两方面都花钱

5. 若希望模型得到更宽的几何间隔，应该怎么做，代价是什么？

A. 增大 C，训练违规会减少

B. 减小 C，训练违规会增多

C. 增大 gamma，边界会变平滑

D. 换成多项式核，支持向量会减少

答案与解析

1. B — 课件写的是 search C and gamma without touching test data。所有参数搜索都在训练/验证数据上完成。

2. D — 课件写 extensions last：先把核心的五道题完整做完，有余力再做扩展。

3. C — $f(x) = 1(3) + 2(-1) + 1 = 2$；$\|w\| = \sqrt{5}$；$y\,f(x) = (-1)(2) = -2 < 0$，所以被误分类。

4. A — 核技巧避开了显式构造高维特征，所以在特征维度上便宜；但核矩阵是 $n \times n$ 的，样本量大时存储与训练代价很高。

5. B — 完整宽度 $= 2/\|w\|$，要让它变宽就要让 $\|w\|$ 变小，对应减小 C（对违规惩罚变轻，$\frac{1}{2}\|w\|^2$ 项相对更重要）。代价是训练违规会变多。

第 24 组：最大间隔推导与对偶形式

1. SVM 训练的原始目标可以写成 $\arg\max_{w,b}\{(1/\|w\|)\cdot\min_i[y_i(w\cdot x_i+b)]\}$，它的含义是：

A. 最小化训练误差
B. 最大化训练观测上最小的带标签几何间隔
C. 最大化支持向量的数量
D. 最小化核函数的求值次数

2. 引入规范形式（canonical form）后，支持向量满足 $y_i(w\cdot x_i+b)=1$。它们到决策边界的几何距离是：

A. 1
B. $\|w\|$
C. $1/\|w\|$
D. 2

3. 目标函数写成 $\tfrac{1}{2}\|w\|^2$ 而不是 $\|w\|$，主要原因是：

A. 因为 $\tfrac{1}{2}\|w\|^2$ 的最优解与 $\|w\|$ 不同
B. 因为平方能让间隔变宽
C. 因为 $\tfrac{1}{2}$ 和平方是为了简化后续计算（求导时抵消、去掉根号变成凸二次）
D. 因为核函数要求目标必须是二次的

4. 对拉格朗日函数关于 w 求偏导并令其为零，得到的结果是：

A. $w=\Sigma\,\alpha_i\,y_i\,x_i$
B. $\Sigma\,\alpha_i\,y_i=0$
C. $w=\|w\|/2$
D. $\alpha_i=C$

5. 为什么要转换到对偶形式？

A. 因为对偶形式的变量更少
B. 因为对偶形式中数据只以点积 $(x_i\cdot x_j)$ 出现，可以替换成核函数
C. 因为原始形式无解
D. 因为对偶形式不需要标签

答案与解析

1. B — 课程网页原话：SVM training aims to maximise the minimum labelled geometric margin over the training observations。即让边界离两侧最近的点尽可能远。

2. C — 规范形式固定的是**函数间隔**等于 1；对应的**几何距离是 $1/\|w\|$，不是 1**。这是最容易混淆的一点。

3. C — 课程网页说明 ½ 这个因子是为了简化后面计算中的数学（求导时与平方的 2 抵消）；取平方则去掉了根号，使目标成为光滑的凸二次函数。两者都不改变最优解位置。

4. A — $\partial\mathcal{L}/\partial w = w-\Sigma\,\alpha_i y_i x_i=0\Rightarrow w=\Sigma\,\alpha_i y_i x_i$。选项 B 是对 b 求偏导的结果。这说明 w 是训练样本的线性组合。

5. B — 对偶目标 $\max\Sigma\alpha_i-\tfrac{1}{2}\Sigma\Sigma\,\alpha_i\alpha_j y_i y_j(x_i\cdot x_j)$ 中数据只以点积出现，把点积换成 $K(x_i,x_j)$ 就得到核 SVM。原始形式里 w 是整体，无法直接替换。

第 25 组：核技巧与间隔手算（课程网页例题）

1. $w=(2,3)$，$b=-7$，$x_1=(3,2)$。则 $w^{\mathsf{T}}x_1+b$ 与 $\|w\|$ 分别是：

A. 5 和 $\sqrt{13}$
B. 5 和 13
C. -2 和 $\sqrt{13}$
D. 6 和 $\sqrt{5}$

2. 接上题，x_1 到决策边界的几何距离约为：

A. 5.000
B. 3.605
C. 1.387
D. 0.555

3. 两个观测中 $x_2 = (1,1)$ 的距离约 0.555，是这些样本的最小观测距离。可以直接把它称为 SVM 的一侧间隔吗？

A. 可以，最小距离就是间隔
B. 不可以，除非最近的观测在规范化缩放下确实是支持向量
C. 可以，只要数据被缩放过
D. 不可以，因为间隔必须大于 1

4. 取 $x_i = [1, 2]$，$x_j = [3, 4]$，用二次多项式核（$c = 0$）直接计算 $K(x_i, x_j)$ 等于：

A. 11
B. 121
C. 48
D. 25

5. 显式映射后 $\phi(x_i) = [1, 2\sqrt{2}, 4]$，$\phi(x_j) = [9, 12\sqrt{2}, 16]$，它们的点积是：

A. 9 + 24 + 64 = 97
B. 9 + 48 + 64 = 121
C. 9 + 96 + 64 = 169
D. 1 + 8 + 16 = 25

答案与解析

1. A — $w^T x_1 + b = (2 \cdot 3) + (3 \cdot 2) - 7 = 6 + 6 - 7 = 5$；$\|w\| = \sqrt{(2^2+3^2)} = \sqrt{13} \approx 3.605$。

2. C — $d(x_1) = |5| / \sqrt{13} = 5 / 3.605 \approx 1.387$。选项 B 是 $\|w\|$ 本身，选项 D 是另一个点 x_2 的距离。

3. B — 课程网页的「重要的间隔约定」：为单个点算出的是几何距离；几个示例点中的最小距离并不自动是 SVM 间隔，除非这些点是已拟合 SVM 的支持向量。

4. B — $K = (1 \cdot 3 + 2 \cdot 4)^2 = (3 + 8)^2 = 11^2 = 121$。选项 A 是尚未平方的中间值。

5. B — $(1 \cdot 9) + (2\sqrt{2} \cdot 12\sqrt{2}) + (4 \cdot 16) = 9 + (2 \cdot 12 \cdot 2) + 64 = 9 + 48 + 64 = 121$。与核直接计算的结果一致，但核没有显式构造这两个三维向量。

第 26 组：其他经典机器学习算法

1. 朴素贝叶斯中「朴素」一词指的是：

A. 算法实现简单
B. 在已知类别的条件下各特征条件独立的假设
C. 只能处理两个类别
D. 不需要训练数据

2. 已知 P(spam)=0.4、P(not spam)=0.6，P(offer|spam)=0.8、P(win|spam)=0.5、P(offer|not spam)=0.1、P(win|not spam)=0.05。对同时含 offer 和 win 的邮件，两类的未归一化分数分别是：

A. 0.16 和 0.003
B. 0.4 和 0.6
C. 0.8 和 0.1
D. 0.9816 和 0.0184

3. 接上题，归一化后 P(spam | offer, win) 约等于：

A. 0.16
B. 0.40
C. 0.9816
D. 0.50

4. 三个算法中，对特征缩放的需求分别是：

A. KNN 需要，决策树通常不需要，朴素贝叶斯有时需要
B. 三者都必须缩放
C. 三者都不需要缩放
D. 决策树必须缩放，KNN 不需要

5. KNN 的一个主要局限是：

A. 无法用于回归任务

B. 训练阶段非常慢

C. 只能表示线性边界

D. 训练集大时预测很慢，且高维下受维度灾难影响

答案与解析

1. B — 「朴素」指的是它的简化假设：一旦类别已知，各特征之间条件独立。这个假设常常不现实，但模型仍可能表现得出奇地好。

2. A — spam：$0.4 \times 0.8 \times 0.5 = 0.16$；not spam：$0.6 \times 0.1 \times 0.05 = 0.003$。这两个是**未归一化**分数。

3. C — $0.16 / (0.16 + 0.003) \approx 0.9816$。注意分母必须包含**两个类别**的分数，不能只除自己那一项。

4. A — 课程网页对比表：KNN「Yes」（依赖距离），决策树「Usually no」（只比较阈值），朴素贝叶斯「Sometimes」。作为对照，SVM 也依赖距离，因此必须缩放。

5. D — KNN 训练几乎不花时间（只存储样本），代价全在预测阶段；此外结果强烈依赖 K 与距离度量，高维空间中距离变得不具信息量。

第二部分 · Tutorial

第 14 组：Tutorial Q1 — 分数、距离与间隔

背景：$f(x) = x_1 + x_2 - 3$，$w = (1, 1)$，四点 (1,2,+1)、(2,3,+1)、(3,3,−1)、(1,1,−1)。

1. 本题中 $w = (1, 1)$，则 $\|w\|$ 等于：

A. 1

B. $\sqrt{2}$

C. 2

D. 3

2. 点 (3, 3) 带标签 $y = -1$，它的 $y\,f(x)$ 和判定是：

A. $y\,f = 3$，分类正确

B. $y\,f = -3$，在间隔内部

C. $y\,f = -3$，被误分类

D. $y\,f = 0$，在边界上

3. 点 (1, 1) 带标签 $y = -1$，答案纸对它的判定是：

A. 在边界上，属于违规

B. 被误分类

C. 分类正确但在间隔内部

D. 分类正确，恰好在支持超平面上

4. 点 (1, 2) 的 $y = +1$，为什么答案纸不说它「分类正确」？

A. 因为 $f(x) = 0$，点在边界上，没有严格的类别归属

B. 因为它的标签写错了

C. 因为它的距离是负的

D. 因为它不是支持向量

5. 四个点中，属于间隔违反（margin violation）的是哪些？

A. 只有 (3,3)

B. (1,2) 和 (3,3)

C. (1,2)、(3,3) 和 (1,1)

D. 四个点都违规

答案与解析

1. B — $\|w\| = \sqrt{(1^2 + 1^2)} = \sqrt{2}$。所有有符号距离都要除以它。

2. C — $f(3,3) = 3 + 3 - 3 = 3$，$y = -1$，所以 $yf = -3$。小于 0 说明被误分类，当然也是违规（$\xi = 4$）。

3. D — $f(1,1) = 1 + 1 - 3 = -1$，$y = -1$，所以 $yf = 1$，恰好等于规范间隔条件的下界，说明它就在支持超平面上，$\xi = 0$。

4. A — $f(1,2) = 1 + 2 - 3 = 0$，点恰好在决策边界上，不属于任何一侧；同时 $yf = 0 < 1$ 所以也是违规（$\xi = 1$）。

5. B — 四个点中 $yf < 1$ 的有 (1,2) 的 $yf = 0$ 与 (3,3) 的 $yf = -3$。另两点的 yf 分别为 2 和 1，都满足 $\geqslant 1$。

第 15 组：Tutorial Q2 — 间隔宽度与 C

1. $w = (3, 4)$ 时，一侧距离和完整间隔宽度分别是：

A. 0.4 和 0.8
B. 5 和 10
C. 0.2 和 0.4
D. 0.1 和 0.2

2. 模型 A 间隔更宽但有三个训练违规；模型 B 间隔更窄但无违规。相对较小的 C 会倾向于偏好哪个模型？

A. 模型 B，因为它没有违规
B. 模型 A，因为惩罚较轻时更宽的间隔更划算
C. 两者完全等价
D. 取决于核函数，与 C 无关

3. 相对较大的 C 会倾向于偏好哪个模型？

A. 模型 B，如果避免训练违规是可能的
B. 模型 A，因为间隔更宽
C. 模型 A，因为违规无关紧要
D. 两者都不选，需要重新训练

4. 答案纸认为更宽的间隔带来的好处是：

A. 它保证测试准确率更高
B. 它消除了所有噪声
C. 它使支持向量数量变为零
D. 它可以降低对小扰动的敏感性

5. 为什么更宽的间隔不保证更好的测试表现？答案纸提到泛化能力：

A. 只取决于训练集大小
B. 还取决于数据、缩放、核函数、噪声和所选超参数
C. 只取决于支持向量的个数
D. 只取决于 C 的大小

答案与解析

1. C — $\|w\| = \sqrt{(3^2+4^2)} = 5$，所以一侧距离 $= 1/5 = 0.2$，完整宽度 $= 2/5 = 0.4$。

2. B — 较小的 C 对违规惩罚较轻，所以愿意用三个违规换取更宽的间隔，倾向于偏好模型 A。

3. A — 较大的 C 把 $C\Sigma\xi$ 项放大，使避免违规变得更重要。答案纸还加了条件：如果避免训练违规是可能的。

4. D — 答案纸写的是：更宽的间隔可以降低对小扰动的敏感性，即提升稳健性。但这并不等于泛化保证。

5. B — 答案纸列出的因素是：数据、缩放、核函数、噪声以及所选的超参数。间隔只是训练数据上的一个几何量。

第 16 组：Tutorial Q3 — 核恒等式

1. $\phi(x_1, x_2) = (x_1^2, \sqrt{2}\, x_1 x_2, x_2^2)$。则 $\phi(1, 1) = ?$

A. (1, 1, 1)
B. $(1, \sqrt{2}, 1)$
C. (1, 2, 1)
D. $(2, \sqrt{2}, 2)$

2. 同一个映射下，$\phi(2, 2) = ?$

A. $(4, 2\sqrt{2}, 4)$

B. $(2, 4\sqrt{2}, 2)$

C. $(4, 4\sqrt{2}, 4)$

D. $(4, 8, 4)$

3. 展开 $\phi(x) \cdot \phi(y)$ 时，中间交叉项等于：

A. $2x_1x_2y_1y_2$

B. $\sqrt{2}\, x_1x_2y_1y_2$

C. $x_1x_2y_1y_2$

D. $4x_1x_2y_1y_2$

4. 答案纸认为核技巧避免了什么？

A. 避免了使用标签

B. 避免了特征缩放

C. 避免了计算点积

D. 避免了显式构造变换后的特征，直接计算它们的点积

5. 核技巧保证大数据集上的训练便宜吗？

A. 保证，因为避免了高维计算

B. 不保证，因为随数据集增长仍需大量成对核求值

C. 保证，只要使用线性核

D. 不保证，因为特征维度会爆炸

答案与解析

1. B — 代入 $x_1 = 1, x_2 = 1$：第一分量 $1^2 = 1$，第二分量 $\sqrt{2} \cdot 1 \cdot 1 = \sqrt{2}$，第三分量 $1^2 = 1$。

2. C — 代入 $x_1 = 2, x_2 = 2$：$2^2 = 4$，$\sqrt{2} \cdot 2 \cdot 2 = 4\sqrt{2}$，$2^2 = 4$。

3. A — $(\sqrt{2}\, x_1x_2)(\sqrt{2}\, y_1y_2) = 2x_1x_2y_1y_2$。这个系数 2 恰好匹配完全平方公式中的 2ab。

4. D — 答案纸写：核技巧避免了显式构造变换后的特征，直接计算它们的点积。这使得非常高维甚至无限维的特征映射变得可行。

5. B — 答案纸明确说不保证：随着数据集增长，核方法仍可能需要大量的成对核求值（many pairwise kernel evaluations）。

第 17 组：Tutorial 扩展 — 对偶系数与 C

1. 为什么 $\alpha_i > 0$ 的样本才是有影响力的支持向量？

A. 因为它们离边界最远

B. 因为它们的标签是 +1

C. 因为只有它们对决策函数 $\Sigma\alpha_i y_i K(x_i, x)+b$ 有贡献

D. 因为它们的 ξ 最大

2. 在软间隔对偶中，上界 C 的作用是：

A. 保证所有样本都成为支持向量

B. 限制单个样本能对解产生多强的影响

C. 保证核矩阵可逆

D. 使 $\|w\|$ 等于 C

3. 根据答案纸，增大 C 会：

A. 降低 α 的上限，允许更多违反

B. 对 α 无影响，只影响核函数

C. 降低 α 的上限，同时减少违反

D. 提高 α 的上限，并更严厉地惩罚违反

4. 根据答案纸，减小 C 会：

A. 允许更多违反，换取更强的正则化和可能更宽的间隔

B. 减少违反，间隔变窄

C. 使支持向量数量降为零

D. 只影响预测速度，不影响边界

5. 若某样本满足 $0 < \alpha_i < C$（严格小于上界），它在几何上的位置是：

A. 在间隔之外，不是支持向量

B. 被误分类，$\xi > 1$

C. 恰好在支持超平面上，$y f = 1$，$\xi = 0$

D. 在间隔内部，$\xi > 0$

答案与解析

1. C — 决策函数是 $f(x) = \Sigma\, \alpha_i y_i K(x_i, x) + b$。$\alpha_i = 0$ 的项直接变成 0，那个样本对输出没有任何贡献，删掉也不影响解。

2. B — 答案纸写：界 $\alpha_i \leqslant C$ 限制了单个样本能对解产生多强的影响。这让离群点无法无限制地扭曲边界。

3. D — 答案纸：增大 C 允许更大的乘子（α 的上限提高），并更严厉地惩罚违反。这与原始问题中 C 的角色一致。

4. A — 答案纸：减小 C 允许更多违反，换取更强的正则化和可能更宽的间隔。

5. C — $0 < \alpha_i < C$ 对应点恰好落在支持超平面上，称为 free / margin support vector。$\alpha = 0$ 的点在间隔外，$\alpha = C$ 的点违规。

第三部分 · Practical

第 18 组：Practical Setup — 数据与三重划分

1. 数据共 360 个点，经过两次划分后，训练 / 验证 / 测试集各有多少个点?

A. 270 / 18 / 72

B. 216 / 72 / 72

C. 288 / 36 / 36

D. 240 / 60 / 60

2. train_test_split 中的 stratify=y 起什么作用?

A. 保证数据被缩放到相同尺度

B. 保证每份数据量完全相等

C. 保证支持向量均匀分布

D. 保证每份数据中两类的比例与原始数据一致

3. make_moons 中的 noise=0.24 在教学上的作用是：

A. 制造类别重叠，使间隔违规和超参数的影响可见

B. 加快训练速度

C. 使数据变得线性可分

D. 替代特征缩放

4. 为什么要划分成三份（train / val / test）而不是两份?

A. 为了增加训练数据量

B. 为了让模型跑得更快

C. 为了把「选超参数」与「最终评估」分开，避免测试集被污染

D. 为了让缩放器有更多数据可 fit

5. 为什么验证准确率会出现 0.833333、0.916667 这种奇怪的小数?

A. 因为浮点数计算有误差

B. 因为验证集有 72 个点，准确率都是 x/72

C. 因为使用了分层抽样

D. 因为模型输出的是概率

答案与解析

1. B — 360 × 0.20 = 72 个测试点，剩 288 个 trainval；288 × 0.25 = 72 个验证点，剩 216 个训练点。第二次划分的比例是相对 288 而不是 360。

2. D — 分层抽样保证每份数据中两类的比例与原始数据一致，避免因随机划分导致某一类在验证集中偏多而使评估有偏。

3. A — noise=0.24 让两个月牙存在重叠，数据不可完美分开。否则任何非线性模型都能达到 100%，C 与 gamma 的影响就看不出来了。

4. C — 只有两份时，调参就必须看测试集，测试集立刻被污染。第三份验证集就是为了把「选超参数」和「最终无偏评估」彻底分开。

5. B — 验证集有 72 个点，所以所有验证准确率都是 x/72 的形式：0.833333 = 60/72，0.916667 = 66/72。

第 19 组：Practical Q1 — 公平比较三种核

1. 把 StandardScaler 放在 Pipeline 里而不是先单独缩放，关键好处是：

A. 它能自动选择最优核函数
B. 它能减少支持向量数量
C. 缩放器只在训练数据上 fit，避免信息泄漏
D. 它能把非线性数据变成线性可分

2. 三个核都用 C=1，为什么？

A. 因为 C=1 是最优值
B. 为了控制变量，使性能差异只能归因于核函数
C. 因为不同核不能使用不同的 C
D. 为了节省计算时间

3. 参考答案认为线性核在这个数据上出现了什么问题？

A. 过拟合，因为它支持向量太多
B. 正好拟合
C. 数据泄漏
D. 欠拟合，因为直线无法跟随弯曲的月牙结构

4. 多项式核的准确率（0.806）低于线性核（0.833），这说明了什么？

A. 更复杂的核不一定更好，多项式核反而比线性核准确率更低
B. 多项式核总是优于线性核
C. 多项式核没有支持向量
D. 多项式核无法处理二维数据

5. 参考答案为什么特意提到 RBF「并不需要比其他核更多的支持向量」？

A. 因为支持向量越多预测越准
B. 因为支持向量数量决定了准确率
C. 因为它说明 RBF 不是靠硬啃更多点取胜，两个指标一起看更有说服力
D. 因为支持向量数量必须相等才能比较

答案与解析

1. C — 把 StandardScaler 放在 Pipeline 里，fit 时缩放器只在 X_train 上估计均值与标准差，predict 时用这组统计量去 transform 验证集，避免泄漏。

2. B — C、缩放方式和数据划分全部固定，唯一变化的是核函数，这样性能差异才能归因于核。这就是「一次只改一个建模选择」。

3. D — 参考答案说线性核明显对弯曲的月牙结构欠拟合，这是模型容量不足。

4. A — 三次多项式核比线性核复杂，准确率反而更低。它产生的是全局曲线，与月牙的局部弯曲结构不匹配。

5. C — 支持向量多通常意味着模型在硬啃噪声。RBF 用更少的支持向量（71 < 73）拿到更高准确率，说明它真的匹配了数据结构。

第 20 组：Practical Q2 — 检查决策边界

1. plot_boundary 里的 meshgrid 网格是做什么用的？

A. 用来增广训练数据
B. 把每个格点交给模型预测，用填色把决策边界画出来
C. 用来重新拟合缩放器
D. 用来计算支持向量的个数

2. n_support_ 与 support_ 的区别是：

A. 两者完全相同

B. n_support_ 是索引，support_ 是个数

C. n_support_ 是坐标，support_ 是权重

D. n_support_ 是每类的个数，support_ 是支持向量的索引

3. 为什么代码用 support_ 索引回 X_train 取坐标，而不直接用 support_vectors_？

A. 因为 support_vectors_ 是缩放后的坐标，画在原始坐标系上会错位

B. 因为 support_vectors_ 不存在

C. 因为 support_vectors_ 只包含一个类别

D. 因为索引方式计算更快

4. 参考答案为什么说远离观测数据处的边界弯折不应被过度解读？

A. 弯折越多说明模型越好

B. 那些区域的预测一定是错的

C. 那里没有训练数据，模型只是在外推，视觉复杂不是泛化的证据

D. 那些区域的支持向量最多

5. 不同核函数得到的支持向量集合是否相同？

A. 相同，因为支持向量由数据本身决定

B. 不同，因为不同的核以不同方式表示相似度和几何

C. 相同，只要 C 一样

D. 不同，但只在未缩放时才不同

答案与解析

1. B — 决策边界没有现成的解析式，所以把特征空间铺成 240×240 的网格，把每个格点都交给模型预测，再根据预测类别填色，交界处就是边界。

2. D — n_support_ 返回每个类别的支持向量个数（所以要 .sum()）；support_ 返回支持向量在训练集中的索引。

3. A — support_vectors_ 保存的是经过 StandardScaler 变换后的坐标，直接画在原始特征坐标系上会错位。同理 model.predict 调用的是整个 pipeline。

4. C — 参考答案：远离观测数据处的弯折不应被过度解读，单凭视觉上的复杂并不是更好泛化的证据。那些区域模型只是在外推。

5. B — 参考答案：不同的核识别出不同的支持向量集合，因为它们以不同方式表示相似度和几何。支持向量是模型与数据共同决定的。

第 21 组：Practical Q3 — 调 C

1. 随着 C 从 0.1 增到 100，支持向量数量的变化模式是：

A. 单调上升

B. 先升后降

C. 单调下降（120 → 71 → 36）

D. 基本不变

2. 验证准确率随 C 的变化模式是：

A. 也是单调下降

B. 先升后降的倒 U 形

C. 单调上升

D. 完全随机

3. 参考答案选择的 C 是多少，依据是什么？

A. C = 0.1，因为支持向量最多

B. C = 100，因为支持向量最少

C. C = 100，因为 C 越大越好

D. C = 1，因为验证准确率最高

4. C = 0.1 时 216 个训练点中有 120 个是支持向量，这说明：

A. 间隔很宽，大量点落在间隔带内，正则化过强

B. 模型严重过拟合

C. 数据发生了泄漏

D. 核函数选错了

5. 为什么不能用测试集来选 C?

A. 因为测试集太小，算不准

B. 因为这会把评估信息泄漏到模型选择中，使最终估计偏高

C. 因为测试集没有标签

D. 因为测试集没有经过缩放

答案与解析

1. C — 支持向量从 120 降到 71 再降到 36，单调下降。C 小时允许大量违规，违规的点都是支持向量；C 大时只有少数点顶到边界。

2. B — 准确率是 0.861 → 0.917 → 0.903，先升后降。两端都不好：C 太小欠拟合，C 太大偏过拟合。

3. D — C=1 的验证准确率最高（0.917）。参考答案明确指出最大的 C 并没有给出最好的验证结果。

4. A — C=0.1 时惩罚很轻，模型选择很宽的间隔，大量训练点落在间隔带内成为支持向量，正则化过强、模型偏欠拟合。

5. B — 参考答案：反复使用测试集会把评估信息泄漏到模型选择中，使报告的估计偏高；测试集要保留给一次最终的无偏检查。

第 22 组：Practical Q4 — C 与 gamma 网格搜索

1. sort_values(["validation_accuracy", "support_vectors"], ascending=[False, True]) 的含义是：

A. 主键支持向量升序，次键准确率降序

B. 主键准确率降序，次键支持向量升序

C. 两个都降序

D. 两个都升序

2. 组合 C=0.1, gamma=10 得到 216 个支持向量，这意味着：

A. 模型完全没有拟合数据

B. 模型达到了最优

C. 支持向量个数计算错误

D. 全部 216 个训练点都成了支持向量，模型极其臃肿

3. 从三条 gamma 曲线的不同走向可以看出：

A. C 和 gamma 完全独立，可以分开调

B. gamma 对结果没有影响

C. C 的最优值取决于 gamma，两者存在交互

D. C 越大总是越好

4. 参考答案如何描述 gamma 取极端值的后果?

A. 非常大的值造成不必要的局部边界，非常小的值过于平滑

B. 非常大的值使边界过于平滑

C. 大小值效果相同

D. gamma 只影响训练速度

5. 参考答案指出这个搜索的两个局限是：

A. 数据太少，且没有缩放

B. 同一批验证观测被反复比较，且有限网格不保证普遍最优

C. 核函数选错，且 C 太小

D. 支持向量太多，且训练太慢

答案与解析

1. B — 主键是验证准确率降序（ascending=False），次键是支持向量升序（ascending=True），即只在准确率平局时才选支持向量更少的。

2. D — 216 正是训练集的全部点数。C 极小（容忍大量违规）加上 gamma 极大（影响极局部），使每个点都成了支持向量。

3. C — γ=0.1 时 C 越大越好，γ=1 时 C=1 最好，γ=10 时小 C 更好。若先固定 γ 单独调 C，会错过 (1, 1) 这个真正的最优组合。

4. A — 参考答案：非常大的值会造成不必要的局部边界，非常小的值会过于平滑。这是 gamma 控制局部性的直接后果。

5. B — 参考答案指出：同一批验证观测被反复比较（交叉验证会更稳定），以及任何有限网格都不保证是普遍最优设置。

第 23 组：Practical Q5 — 最终评估与总结

1. final_model.fit(X_trainval, y_trainval) 用的是多少数据?

A. 216 个训练点

B. 全部 360 个点

C. 288 个非测试点（训练 + 验证）

D. 72 个测试点

2. 把验证集合并进来重新训练，会造成数据泄漏吗?

A. 不会，参数已固定，验证集任务完成，合并回来可以用上更多数据

B. 会，验证集永远不能用于训练

C. 会，因为验证集包含测试信息

D. 不会，但会降低准确率

3. 反复从测试表现中挑选设置会造成什么后果?

A. 模型会无法收敛

B. 测试集变成了验证数据，报告的估计变得乐观

C. 支持向量数量会激增

D. 缩放器会失效

4. 验证准确率和测试准确率都是 0.958，应该怎么看待这两个数字?

A. 两者完全等价，可以互相替代

B. 验证准确率更可信

C. 两者都不可信

D. 验证准确率是多次比较的最大值天然偏乐观，测试准确率才是可信的泛化估计

5. 下列哪项**不是** notebook 总结列出的结论?

A. 核函数控制决策边界的形状

B. pipeline 防止预处理泄漏

C. 支持向量越多模型泛化能力越强

D. 结构化的验证搜索能暴露超参数之间的交互

答案与解析

1. C — 参数选定后验证集就完成使命，可以合并回来。用全部 288 个非测试点重新训练，数据更多、模型通常更好。

2. A — 验证集存在的目的就是选参数。参数固定后它不再有特殊作用，合并回来能让模型用上更多数据，不构成泄漏。

3. B — 参考答案：反复从测试表现中挑选设置会把测试集变成验证数据，使报告的估计变得乐观。测试集的价值在于它从未参与任何决策。

4. D — 验证准确率 0.958 是 12 次比较中的最大值，天然偏乐观；测试准确率是在完全未参与决策的数据上只评估一次的结果。两者相等属巧合（均为 69/72）。

5. C — 支持向量占比过高往往提示模型在硬啃噪声，与泛化能力强恰恰相反。总结的五条是：核控制边界形状；C 控制间隔—违规权衡；pipeline 防泄漏；验证选设置、测试估计泛化；结构化搜索暴露超参数交互。