Module 2 复习资料

无监督学习 · PCA / 聚类 / GMM — 总目录

ARTI2001 Machine Learning · 2026 Semester 2

7 册 • 约 115 页

四册**知识点整理** + 三册**题库与解析**（共 170 道选择题）

全部对照 **Canvas 官方讲义**编排，附 **Tutorial 完整解答**

每册都带**公式速查表**、**易错点清单**与**术语中英对照**

ARTI2001 · Module 2 测验：2026-10-12（周一）

目录

这一套包含什么

建议的使用顺序

★ 考前最后一小时：只看这几处

材料来源

这一套包含什么

文件	归属	页数
M2_评估与模型选择_知识点整理.pdf	跨三个主题	11 页
M2T1_PCA_知识点整理.pdf	Topic 1	18 页
M2T1_PCA_题库与解析.pdf	Topic 1 · 题库	13 页
M2T2_聚类_知识点整理.pdf	Topic 2	18 页
M2T2_聚类_题库与解析.pdf	Topic 2 · 题库	16 页
M2T3_GMM与EM_知识点整理.pdf	Topic 3	24 页
M2T3_GMM与EM_题库与解析.pdf	Topic 3 · 题库	15 页

合计 115 页。建议双面打印；题库可以单独抽出来做。

建议的使用顺序

顺序	做什么	为什么
①	先读《评估与模型选择》	它是**跨三个主题**的骨架，官方标为 CORE / ASSESSABLE；后面每个主题的论证都要用到那四格证据框架
②	按 T1 → T2 → T3 读知识点整理	每一册都按讲义页编号编排，和 Canvas 对得上
③	每读完一册，做对应题库	**每组 5 题，先遮住解析作答**，整组做完再核对
④	做错的题回到知识点整理的对应章节	组标题后面的括号就是讲义页编号
⑤	考前只看每册的附录 A/B	**公式速查 + 易错点清单**，是密度最高的两页

★ 考前最后一小时：只看这几处

主题	最该确认的东西
评估	**四部分证据框架**（拟合/稳定性/假设/领域有用性）；silhouette 的 a(i)、b(i) 定义；**「不要只看一个数」那张示范决策表**
PCA	中心化 → 散布/协方差 → 特征分解 → 解释方差比 → 投影 → **重构要加回均值**；**散布矩阵与协方差矩阵特征向量相同、解释方差比相同**
k-means	指派/更新两步**为什么不会增加 WCSS**；**全局最优 inertia 不随 k 上升，但实测值可能波动**；n_init 是重跑次数
DBSCAN	**邻域含点自己**；核心/边界/噪声的判据；**只有核心点能扩张簇**；**先标噪声的点可能变成边界点**
GMM	**责任度 = 先验 × 密度 ÷ 混合密度**；M 步**分母是 N_k、用新均值、除 N_k 不是 N_k−1**；**p = 3K − 1**；AIC/BIC 低者优且**不能互比**

⚠ 三条最容易丢分的「概念性」答法

- 凡是问「这个结果可信吗」，**必须答不止一类证据**，并以「这是有依据的判断，不是证明」收尾；
- 凡是涉及预测流程，**必须提一句「预处理与无监督变换只在训练集上拟合」**；
- 凡是问「簇/成分是不是真实分组」，**答案都是否** —— 它们是模型产出的摘要，需要领域证据支撑。

材料来源

来源	用在哪
Canvas 讲义 T1-00 ~ T3-06（8 份，约 12.4 万字）	知识点整理的主体，章节按讲义页编号编排
M2 T1/T2/T3 Tutorial_ans.pdf	三份 Tutorial 的**完整官方解答**，含扩展题
M2 T2 / T3 Prac solution.ipynb	Practical 的参考数字与讨论要点
numpy 复算	**全部 58 个数字逐个验算通过**（手算例题、Tutorial 答案、AIC/BIC）

⚠ Andrew Ng 的 CS229 讲了 GMM 与 EM（L13/L14），但**完全没讲 DBSCAN**，也基本没讲 BIC/AIC 选成分数。这两块只能看本套资料与学校讲义。