评估无监督学习

Module 2 · 跨三个主题 — 知识点完整整理

ARTI2001 Machine Learning · 2026 Semester 2

涵盖：**Canvas 讲义 T1-04**，官方标为 **CORE / ASSESSABLE**
这一页**横跨 PCA、聚类与 GMM**，所以单独成册
四部分证据框架 + **可复用的六步检查清单**
inertia 与 silhouette 的完整算法与手算例题
AIC / BIC 与「示范决策」表（大题的标准答法模板）
附录：公式速查 · 12 条易错点 · 术语中英对照

配套：《M2T1 PCA》《M2T2 聚类》《M2T3 GMM 与 EM》三册知识点整理

目录

1. 为什么无监督结果不能用准确率来判

2. ★★★ 四部分证据框架（整个 M2 的骨架）

3. 评估 PCA

4. 评估聚类（一）：inertia 与肘部法

   · inertia 怎么算

   · 手算例题 1

5. 评估聚类（二）：轮廓系数 silhouette

   · 三步算法与 b(i) 的三个误解

   · 手算例题 2

   · ★★★ silhouette 的系统性偏向

   · 稳定性四项检查

6. 评估高斯混合模型

   · AIC 与 BIC：平衡拟合与复杂度

7. ★★★ 示范决策：不要只看一个数

8. 可复用的评估检查清单（六步）

9. 四个 Study check（官方原题 + 参考答案）

附录 A · 公式速查表

附录 B · 高频易错点清单

附录 C · 术语中英对照

1. 为什么无监督结果不能用准确率来判

T1-04

★ 官方对这一页的定位（原文）

「核心且可考核的材料：你应当能够为一个无监督学习结果选择、解释并批判恰当的证据。」

「你不需要推导 silhouette、AIC 或 BIC 的公式。」

评估无监督模型和评估有监督预测器不同。**没有提供目标标签时，通常没有一个单一的准确率能告诉我们发现的结构是否正确。**取而代之的是：把几种形式的证据合起来，并结合问题、表示与建模假设去解释。

五条学习成果

1. 解释为什么无监督结果通常不能用准确率来判断；
2. 为 PCA、聚类与 GMM **选择合适的评估证据**；
3. 解释 inertia、silhouette、解释方差、AIC 与 BIC，**而不把任何单一数值当成自动的真理**；
4. 检查对**初始化、缩放与超参数**的稳定性与敏感性；
5. 判断发现的结构对这个应用是否有意义。

2. ★★★ 四部分证据框架（整个 M2 的骨架）

T1-04

证据	要问的问题	例子
拟合 / 内部结构	拟合出来的模型，是否表示了它被设计去找的那种结构?	解释方差、重构误差、inertia、silhouette、似然、AIC、BIC
稳定性	一个小的建模或抽样改动，会不会给出相似的结果?	跨随机种子、初始化、样本或邻近超参数重复
假设与表示	距离、尺度、形状与分布假设是否合理?	特征缩放、簇的几何、密度、协方差形式、噪声处理
领域有用性	这个结果是否回答了真实问题、是否支撑一个可辩护的解释?	有意义的投影、可行动的分组、合理的成分、专家审阅

★★★ 这一页的关键原则（一句话，建议背下来）

「一个有说服力的结果通常需要不止一个信号。一个高分本身不能证明某个嵌入、簇或成分对应真实世界的真相。」

⭐ 怎么把这个框架用在答题上

任何「请评估/论证这个无监督结果」的大题，都可以照这四格展开：**① 内部证据是多少 → ② 稳不稳 → ③ 假设合不合适 → ④ 对应用有没有用**，最后写一句**「这是有依据的判断，不是证明」**。

3. 评估 PCA

T1-04

证据	内容
解释方差比	每个保留成分所代表的总方差占比。**累计解释方差**帮助决定保留几个成分
重构质量	数据投影再重构之后丢了多少信息。**对压缩或去噪尤其相关**
任务有用性	降维后的表示是否支持了预期的可视化、解释或下游分析
对缩放与离群点的敏感性	**必须检查** —— 高数值方差可能只反映测量单位或极端观测，而不是有用信号

★★ PCA 评估的那句总结（原文的意思）

「高解释方差是有用的证据，但 PCA 保的是方差，不是意义。一个低方差方向仍可能对应用很重要；一个高方差方向可能代表的是干扰变异。」

4. 评估聚类（一）：inertia 与肘部法

T1-04

k-means 的 inertia 是簇内平方距离之和。inertia 越低意味着点离各自的质心越近。

★★★ 必须分清的两句话（讲义反复强调）

- **全局最优的 inertia 不会随簇数增加而上升**；
- **但不同次拟合可能落到不同的局部极小，所以「实测到的」inertia 不一定单调下降。**

肘部法找的是「再加簇、收益明显变小」的那个点。**有些数据集根本没有明显的肘部，所以这是一个诊断手段，不是自动规则。**

inertia 怎么算（等权重）

$$I = \sum_{r=1}^{K} \sum_{i \in C_r} \|x_i - \mu_r\|_2^2, \quad \mu_r = (1/|C_r|) \sum_{i \in C_r} x_i$$

$$\|x_i - \mu_r\|_2^2 = \sum_{q=1}^{p} (x_{iq} - \mu_{rq})^2$$

K 是簇数，C_r 是第 r 个簇的观测下标集合，$|C_r|$ 是它的大小，μ_r 是质心（均值），p 是特征数、用 q 索引。

⚠ 三条计算约定

- **先算每个点到它所属质心的平方距离，再把所有点加起来**；
- **它是「和」，不是「平均」**；
- **比较时必须用同一批观测、同一组特征、同一种缩放。**

手算例题 1 • inertia（讲义的一维小例）

一维两个簇 {1, 3} 与 {8, 10}。

① 质心

$$\mu_1 = (1+3)/2 = 2 \quad \mu_2 = (8+10)/2 = 9$$

② inertia

$$I = (1-2)^2 + (3-2)^2 + (8-9)^2 + (10-9)^2 = 1+1+1+1 = 4$$

5. 评估聚类（二）：轮廓系数 silhouette

T1-04

轮廓系数比较「一个观测离自己簇有多近」与「它离最近的另一个簇有多近」。取值在 −1 到 1 之间：

取值	含义
接近 1	这个点与它被指派的簇**匹配得好**
接近 0	**重叠或边界**上的点
负值	这个点**可能离另一个簇更近**

怎么算（三步）

$$a(i) = (1/(|C_r|-1)) \cdot \Sigma_{j \in C_\{r},\, j \neq i\}\, d(x_i, x_j)$$

a(i) 是到**同簇其它点**的平均距离 —— **排除点自己。**d 通常是欧氏距离，**不平方。**

$$b(i) = \min_{t \neq r} [\, (1/|C_t|) \cdot \Sigma_{j \in C_\{t\}}\, d(x_i, x_j)\,]$$

对每一个其它簇，算点 i 到该簇**所有点**的平均距离；这些平均值里**最小的**就是 b(i)。

⚠⚠ b(i) 的三个常见误解

- 用的是**「按点到点平均距离」最近的那个簇**，
- **不是最近的那个「单个点」**，
- **也不是最近的那个「质心」。**

$$s(i) = (b(i) - a(i)) \,/\, \max\{a(i), b(i)\}, \quad S = (1/n)\, \Sigma_{i=1}^{n}\, s(i)$$

s(i) 是该点的轮廓系数；S 是整体分数，对 n 个被评估的观测取平均。**a(i) 远小于 b(i) 时分数为正且接近 1；两个平均值接近时接近 0；a(i) 更大时为负。**

手算例题 2 • silhouette（接上例）

仍是 {1, 3} 与 {8, 10}，算**点 1** 的轮廓系数。

> **① a(1)**
> 同簇只剩点 3：
>
> $$a = |1 - 3| = 2$$

> **② b(1)**
> 到另一个簇**所有点**的平均距离：
>
> $$b = (|1 - 8| + |1 - 10|) / 2 = (7 + 9)/2 = 8$$

> **③ s(1)**
>
> $$s = (8 - 2) / \max\{2, 8\} = 6/8 = 0.75$$

> **④ 整体分数**
> 对其余各点同样算一遍，再取平均。

⚠⚠ 计算条件（容易被忽略，但很爱考）

- **整体分数要求簇数在 2 到 n−1 之间**；
- **独自成簇的点按约定记为 0**；两个距离平均值都为 0 时也记 0；
- **对 DBSCAN，评估时要排除噪声点（label = −1），报告被排除的比例**，并检查剩下的数据仍满足上述条件。

★★★ silhouette 的系统性偏向（高频简答题）

「平均轮廓系数更高，往往意味着簇更紧致、更分离。但是 silhouette 倾向于偏好「凸」的簇，当有用的分组是弯曲的、基于密度的或极不均衡时，它可能给出有误导性的排名。」

对 DBSCAN，还要同时看：簇的个数、被标为噪声的比例、以及对 eps 和 min_samples 的敏感性。

稳定性与意义（四条检查）

- **跨多个初始化或随机种子重复 k-means**；
- **检查邻近的 k、eps 或 min_samples 会不会引起突变**；
- **看图和簇的摘要，而不是只依赖一个分数**；
- **问这些分组在应用里是否有意义、有用。**

6. 评估高斯混合模型

T1-04

证据	内容
对数似然	度量拟合出的密度，但**它一般会随模型复杂度上升而改善，所以不能单独用它来选成分数**
AIC 与 BIC	在拟合与复杂度之间权衡。**对同一批数据拟合的模型，AIC 或 BIC 更低者更优**
责任度	显示软成员度里的不确定性。**大量模糊的责任度可能意味着成分之间重叠严重**
初始化与收敛	**EM 可能收敛到局部解。**要用多个初始化并比较拟合结果
分布假设	**低 BIC 不证明总体里有那么多自然分组**，也不证明高斯成分在科学上有意义

AIC 与 BIC：平衡拟合与复杂度

> $\mathrm{AIC} = 2k - 2\log(\hat{L})$　　$\mathrm{BIC} = k\cdot\log(n) - 2\log(\hat{L})$

k 是估计出的参数个数，n 是观测数，$\hat{L}$ 是最大似然。**一个更灵活的模型可能把训练数据拟合得更好，但也可能过拟合。**复杂度罚项鼓励「解释得好、又不含多余参数」的模型。

★★ 三条使用规则

- **对同一数据集拟合的模型，AIC 或 BIC 更低的那个更受偏好**；
- **BIC 的复杂度罚项比 AIC 更强**（尤其样本量增大时），所以**它常常选出更简单的模型**；
- **这两个准则支持「模型比较」，但不保证选中的模型在科学上或实践上恰当。**

⚠ 在 T3 的讲义里，同一组公式写成 AIC = −2 log L + 2p、BIC = −2 log L + p·log N —— **完全是同一个式子，只是把两项前后调换、并把参数个数记作 p。**不要被符号差异迷惑。

7. ★★★ 示范决策：不要只看一个数

T1-04

讲义给了一张非常典型的三行表，**几乎就是大题的标准答法模板**：

候选	内部证据	稳定性	应用证据
k-means, k = 2	silhouette 0.58；inertia 相对较高	**稳定**	把领域专家会区分的两个组**合并了**
k-means, k = 3	silhouette 0.55；inertia 明显下降	**稳定**	三个组有合理的解释
k-means, k = 4	silhouette **0.59（最高）**；inertia 略低	**不稳定**	有一个小组跨运行会变

★★★ 标准结论（照着这个结构写）

最大的 silhouette 属于 k = 4，但那个结果不稳定。

k = 2 的解稳定，但它合并了应用关心的分组。

⇒ 在这个例子里 k = 3 是最可辩护的选择，因为有好几种形式的证据支持它。

⚠ 收尾必须有这一句：这是一个有理据的判断，不是「恰好存在三个自然分组」的证明。

8. 可复用的评估检查清单（六步）

T1-04

1. **陈述实际问题**，以及「什么样的结果才算有用」；
2. **检查特征表示、缩放与相似性度量是否恰当**；
3. **使用一个方法专属的诊断量**，但要说明它度量什么、以及它**不能**确立什么；
4. **检查跨初始化、跨样本或跨邻近超参数的稳定性**；
5. **检视图形、摘要、不确定性与失败案例**；
6. **用领域证据解释结果，并报告局限。**

★ 数据泄漏提醒（三个主题通用，必考）

「如果 PCA 或聚类被用在后续的预测工作流里，预处理与无监督变换都只用「训练数据」拟合，然后把拟合好的变换应用到验证或测试数据。」

9. 四个 Study check（官方原题，附参考答案）

T1-04

Study check 与参考答法

① 为什么「k-means 的 inertia 更低」不足以支持更大的 k?

因为**全局最优的 inertia 不会随 k 增大而上升** —— 极端情况下每个点自成一簇时 inertia 为 0。所以「更低」几乎是必然的，**它不构成选择依据。**还必须看 silhouette、稳定性、以及分组在应用里是否可解释。

② 为什么即使 DBSCAN 还原了更有意义的弯曲分组，silhouette 仍可能偏向 k-means?

silhouette 倾向偏好「凸」的簇。它比较的是簇内平均距离与到另一簇的平均距离；**一条弯曲带上相距很远的两点会抬高簇内平均距离，哪怕它们属于同一个连通组。**于是这个度量偏好的几何，与应用要求的几何不一致。

③ 更低的 BIC 支持什么、不证明什么?

它**支持**：在这些候选模型里，这一个在「拟合 vs 复杂度」的权衡下更可取。它**不证明**：总体里存在那么多自然分组，也不证明高斯成分在科学上有意义。

④ 在接受一个无监督结果之前，能做哪两项稳定性或敏感性检查?

(a) 跨多个随机种子/初始化重复拟合，用**标签无关**的方式比较哪些观测仍在一起；**(b) 重采样观测（或改动邻近的超参数，如相邻的 k、eps、min_samples）**，看结构是否突变。前者查优化敏感性，后者查抽样稳定性。

附录 A • 公式速查表

名称	公式	备注
inertia / WCSS	$I = \Sigma_r \Sigma_{i \in C_r} \|\|x_i - \mu_r\|\|^2$	是**和**，不是平均
平方欧氏距离	$\|\|x_i - \mu_r\|\|^2 = \Sigma_q (x_{iq} - \mu_{rq})^2$	p 个特征逐个平方相加
silhouette a(i)	$(1/(\|C_r\|-1)) \Sigma_{j \in C_r, j \neq i} d(x_i, x_j)$	**排除自己**；d **不平方**
silhouette b(i)	$\min_{t \neq r} (1/\|C_t\|) \Sigma_{j \in C_t} d(x_i, x_j)$	**按平均距离**最近的那个簇
silhouette s(i)	$(b(i) - a(i)) / \max\{a(i), b(i)\}$	范围 −1 到 1
整体分数	$S = (1/n) \Sigma_i s(i)$	簇数须在 2 到 n−1 之间
解释方差比	$r_j = \lambda_j / \Sigma_l \lambda_l$	PCA
AIC	$2k - 2 \log \hat{L}$ （$= -2 \log L + 2p$）	低者优
BIC	$k \cdot \log(n) - 2 \log \hat{L}$ （$= -2 \log L + p \cdot \log N$）	罚得更重

附录 B • 高频易错点清单

#	易错点	正确做法
1	把 inertia 当平均	**是平方距离之和**
2	以为实测 inertia 必须单调下降	**只有全局最优才单调不增**；局部极小会让实测值波动
3	只靠肘部法定 k	**有些数据没有明显肘部**；它是诊断不是规则
4	算 a(i) 时把点自己算进去	**要排除自己**，分母是 $\|C_r\| - 1$
5	算 silhouette 时把距离平方了	**silhouette 用的是距离本身，不平方**
6	b(i) 取「最近的点」或「最近的质心」	取的是**按平均点到点距离最近的那个簇**
7	DBSCAN 算 silhouette 不排除噪声	**排除 label = −1**，并报告排除比例
8	只剩一个簇时还去要 silhouette	**无法计算（NaN）**；NaN ≠ 质量为 0
9	用对数似然选成分数	它随复杂度上升而改善；**要用 AIC/BIC**
10	拿 AIC 和 BIC 互相比较	**同类相比**，且须同数据同特征
11	由「分数最高」直接下结论	**要同时过稳定性与领域有用性两关**
12	在全量数据上拟合预处理再划分训练/测试	**只在训练集上拟合**，再 transform

附录 C • 术语中英对照

英文	中文	一句话
internal measure	内部度量	不用外部标签、只看数据本身的评价量
inertia / WCSS	惯性 / 簇内平方和	到各自质心的平方距离之和
elbow method	肘部法	找收益明显变小的拐点
silhouette coefficient	轮廓系数	(b−a)/max(a,b)
explained variance ratio	解释方差比	PCA 每个成分占的方差比例
reconstruction error	重构误差	投影再还原后丢了多少
log likelihood	对数似然	GMM 的拟合度，随复杂度上升
AIC / BIC	赤池 / 贝叶斯信息准则	拟合与复杂度的权衡，低者优
stability	稳定性	小改动下结果是否相似
sensitivity	敏感性	对初始化、缩放、超参数的反应
label-invariant comparison	标签无关比较	看哪些点仍在一起，而非比标签数字
domain usefulness	领域有用性	结果是否回答了真实问题
data leakage	数据泄漏	测试集信息混进了拟合过程
convex cluster	凸簇	silhouette 偏好的那种形状