主成分分析 PCA

Module 2 · Topic 1 — 知识点完整整理

ARTI2001 Machine Learning · 2026 Semester 2

涵盖：**Canvas 讲义 T1-02 ~ T1-09**（含标注 *** CORE MATH *** 的数学页）
Tutorial 三问 + 扩展的完整官方解答
两个完整手算例题（讲义 by-hand 例 + Tutorial 例）
Python 工作流：sklearn 属性与数学符号对照
附录：公式速查 · 12 条易错点 · 术语中英对照

配套：《M2T1 PCA 题库与解析》《M2 评估与模型选择》

目录

1. 路线图：这一周在干什么

2. 什么是无监督学习

- 本课深考的四个方法

3. 无监督学习的版图（了解即可）

4. 维度灾难与降维

- 降维的四种好处（都带前提）
- PCA 到底保留了什么
- PCA 不是线性回归

5. 概念：方向、得分、重构

6. ★ 核心数学：六个步骤

- Step 1–3 数据、中心化、协方差
- Step 4 为什么会冒出特征向量（要会推）
- Step 5–6 排序、选成分、投影与重构
- ★ 开算前必须核对的五条约定

7. 手算例题 A：讲义的 PCA by hand

8. 手算例题 B：Tutorial 三问全解

- Q1 准备步骤
- Q2 特征值与 PC1
- Q3 投影与重构
- 扩展两问

9. Python 工作流：数学符号对上 sklearn 属性

- 缩放为什么能改变 PCA
- 避免数据泄漏

附录 A · 公式速查表

附录 B · 高频易错点清单

附录 C · 术语中英对照

1. 路线图：这一周在干什么

T1-01

Module 2 整体从**有监督**转到**无监督**：训练数据里**不再给目标标签**。T1 这一周先把无监督学习定位清楚，再把 PCA 从概念讲到数学、再到 Python。

阶段	内容	这一讲的落点
① 什么是无监督学习	没有标签时，算法在找什么	聚类不是自动发现真类别，是**模型产出的摘要**
② 无监督版图	六大任务族各自回答什么问题	本课只深考四个方法；其余只作了解
③ 评估框架	没有准确率时拿什么当证据	**四部分证据框架**（核心考点，单独一册）
④ 维度灾难与降维	为什么要降维，降维换来什么	降维是**建模选择**，不是自动改进
⑤ PCA 概念	方向 / 得分 / 重构三个量	方差大 ≠ 重要
⑥ PCA 数学	中心化 → 协方差 → 特征分解 → 投影	**本周最核心的一页**
⑦ Python 与手算	sklearn 属性对上数学符号	缩放、泄漏、并列特征值

★ Module 2 的五条学习成果（考纲原文的中文意思）

1. 解释无监督学习的原理，区分主要任务族；
2. 应用 PCA，解释主方向与解释方差，并且**认识到保留方差不保证预测或领域重要性**；
3. 实现并比较 k-means 与 DBSCAN，包括各自的假设、参数敏感性与对噪声的处理；
4. 解释 GMM 的成分、参数与责任度，说明 E 步与 M 步，用 BIC/AIC 之类证据比较成分数；
5. 用内部度量、稳定性、假设、表示与领域有用性来评估结果，**不依赖单一分数**。

2. 什么是无监督学习

T1-02

给定 N 个观测 $\{x_1, \ldots, x_N\}$，**没有目标标签**，算法按自己的目标与假设去找一个有用的**表示**、**分组**或**概率模型**。

⚠ 最容易被想当然的一条

算法可能把无标签图片按颜色、形状或学到的视觉特征分组，这些组**也许**对应猫和狗，**但没有任何保证**：结果取决于所用的特征、缩放、距离或模型假设。

簇是模型产出的摘要，需要人去解释，不是自动发现的真实类别。

本课深考的四个方法

方法	任务	一句话
PCA	线性降维	找方差最大的正交方向
k-means	基于质心的**硬**聚类	每个点归给最近的质心
DBSCAN	基于密度的聚类 + 噪声识别	连通的稠密区域就是一个簇
GMM	概率密度建模 + **软**聚类	每个点对每个成分都有一个概率

关联规则挖掘、异常检测、层次聚类、非线性降维、自监督表示学习等只在「版图」页作背景介绍，**不直接考**。

3. 无监督学习的版图（了解即可）

T1-03

任务族	主要问题	例子
降维	能不能用更少的变量表示数据而保留有用结构?	PCA；t-SNE、UMAP 等非线性方法
聚类	有没有有用的相似观测分组?	k-means、DBSCAN、GMM、层次聚类
密度估计	概率质量在特征空间里怎么分布?	GMM、核密度估计
异常检测	哪些观测相对主模式很异常?	Isolation Forest、Local Outlier Factor
关联与模式发现	哪些项目/事件/行为倾向同时出现?	频繁项集、关联规则
表示与流形学习	能不能学到有用的底层表示或几何?	流形学习、自监督表示学习

★ 三条必须记住的告诫（讲义原文的三点）

- **没有标签不等于没有目标函数**——每个方法仍在优化某个准则，或依赖某个关于结构的定义。
- **相似性取决于表示**——特征选择、缩放和距离都能实质性地改变结果。
- **模式需要验证**——视觉上很有说服力的簇或嵌入，可能不稳定、有误导性，或与领域问题无关。

Study check

- 要压缩很多相关特征，该用哪个任务族?
- 为什么改变特征尺度会改变聚类结果?
- 为什么发现的簇不该被自动当成真实世界的类别?

4. 维度灾难与降维

T1-05

维度灾难指特征数增加时出现的那一堆困难：数据点变得稀疏、距离变得不那么有信息量、可视化更难，模型通常需要更多数据和算力才能学到可靠模式。

> ⚠ **高维本身不是毛病**
>
> 讲义的措辞是「High dimensionality is not automatically a problem」——它只是**要求我们去问：该保留哪些结构、这个降维后的表示要拿来干什么。**

降维可能带来的四种好处（都带前提）

好处	具体是什么	⚠ 前提
可视化与探索	投到 2–3 维就能看图	二维图**不保证**保住每一个重要关系
压缩与效率	变量更少，存储与计算更省	—
降噪与去冗余	丢掉的方向若主要是噪声或重复信息	**这个假设必须自己去验**
下游建模	紧凑表示可能帮到后续模型	也可能删掉有用信息；要**比对验证集表现**，不能假定更好

PCA 到底保留了什么

先把特征均值去掉，然后 PCA 找出一组**互相正交的主方向**（协方差矩阵的特征向量）。把观测投到这些方向上，得到**主成分得分。**第一个方向抓住输入数据里**方差最大**的方向；之后每个方向在**与前面所有方向正交**的前提下，抓住**剩余方差**里最大的那部分。

> ★★★ **这一讲最重要的一句话：PCA 保的是方差，不是意义**
>
> **PCA 不使用目标标签。**所以「输入方差高」和「对预测有用」是两回事。
>
> 一个高方差方向可能描述的是光照、测量单位或别的干扰因素；而一个低方差方向可能恰恰分开了两个类别。
>
> **PCA 可能提升、可能降低、也可能完全不改变下游预测表现。**

PCA 不是线性回归

	线性回归	PCA
用不用标签	**用**目标变量 y	**只用**输入特征
在最小化什么	在目标 y 上的**预测误差**	等价于最小化低维重构的**平方正交误差**
几何上量的是	沿 y 轴方向的竖直距离	**垂直于主方向**的距离

> ⚠ **这是选择题的常客**
>
> 两者画出来都是一条直线，但**误差的量法不同**：回归量竖直距离，PCA 量垂直（正交）距离。所以同一堆点，回归线和 PC1 一般**不是同一条线。**

5. 概念：方向、得分、重构

T1-06

PCA 构造出叫做**主成分**的新特征。每个成分都是原始特征的**线性组合**，并按它们捕获的变异量排序。

量	回答什么问题	含义
主方向 principal direction	该朝特征空间的哪个方向看?	协方差矩阵的**单位特征向量**；它的各个分量描述原始特征如何贡献于这个方向
得分 score	某一个观测在这个方向上处在哪儿?	把**中心化后**的观测投到该方向上得到的坐标
重构 reconstruction	保留的那些得分对应原特征空间里的什么近似?	把得分映射回特征空间，**再把均值加回去**

> ⭐ **一句话区分**
>
> **方向是一支箭（d 维，单位长），得分是一个数（这个观测在箭上的位置）。**一个数据集只有 d 个方向，但每个观测各有自己的一组得分。

> ★ **符号的正负无所谓**
>
> `components_` 里某一行取反，会让对应的所有得分取反，但它**代表同一条 PCA 轴、同一个重构。**考试里看到答案的符号和你算的相反，先别慌。

Study check

- 主方向和主成分得分有什么不同?
- 为什么主方向的**符号**不改变它代表的那条一维轴?
- 举一个低方差方向仍然重要的情形。

6. ★ 核心数学：六个步骤

T1-07

这一页讲义标着 *** CORE MATH ***，是 T1 最可能出大题的地方。

Step 1 • 从数据开始

数据集 X 有 n 个观测、d 个特征。**每一行是一个观测，每一列是一个特征。**

Step 2 • 中心化

$$\mu = (1/n)\,\Sigma_{i=1}^{n}\, x_i$$
$$X_c = X - 1_n\,\mu^T \qquad (1_n \text{ 是 } n\times 1 \text{ 的全 } 1 \text{ 向量})$$

中心化把数据中心搬到原点，于是方差描述的是**围绕特征均值的散布**，而不是到某个任意原点的距离。

> ⭐ **一个随手就能做的自检**
>
> **X_c 的每一列加起来必须等于 0**（允许极小的舍入误差）。手算时先验这一步，能挡掉大半的错。

Step 3 • 构造协方差矩阵

$$\Sigma = (1/(n-1)) \cdot X_c^{\,T}\, X_c$$

Σ 是对称的 d×d 矩阵。**对角元是某个特征自己的方差；非对角元表示两个特征怎样共同变化。**

Step 4 • 为什么会冒出特征向量（这一段要会推）

取任意**单位**方向 v（即 $v^Tv = 1$），把每个中心化观测投上去：

$$z = X_c\, v$$

这些一维得分的样本方差是：

$$\mathrm{Var}(z) = (1/(n-1))\; z^Tz = v^T\,\Sigma\, v$$

PCA 问的就是：**哪个单位方向能让这个量最大？**解这个带约束的最大化问题，得到特征值关系：

$$\Sigma\, v = \lambda\, v$$

> ★★★ **这一步的结论要能背出来**
>
> **一个特征向量给出的方向，其投影方差就等于它的特征值。**
>
> 所以**特征值最大的那个特征向量就是第一主方向**，因为它产生最大的投影方差。

> ⭐ **几何读法（答简答题时很好用）**
>
> 想象一根一维的轴穿过中心化后的点云转动，把每个点投上去。**PCA 挑的就是让这些投影坐标散得最开的那个角度。**协方差的特征问题，只是「不用一个个角度去试」的矩阵算法。

Step 5 • 分解并排序

- 求 Σ 的特征值 $\lambda_1 \dots \lambda_d$ 与对应的**单位**特征向量 $v_1 \dots v_d$；
- 按降序排 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$；
- 特征向量定义主方向，**每个方向上挂着的特征值就是对应得分的方差。**

主方向两两正交。对拟合用的这批数据，**成分得分是不相关的**——但这**不保证**所有非线性依赖或任务相关的信息都消失了。

Step 6 • 选成分、投影、重构

取前 k 个特征向量放进 d×k 的矩阵 W_k。成分 j 的**解释方差比**是：

> $r_j = \lambda_j \,/\, \Sigma_{l=1}^{d} \lambda_l$
> k 个成分的累计保留方差 $= \Sigma_{j=1}^{k} r_j$

> $Z = X_c\, W_k$　　（n×k 得分矩阵）
> $\hat{X} = Z\, W_k^{T} + 1_n\, \mu^{T}$　　（回到原特征空间的重构）

> ⚠ **重构时必须把均值加回去**
>
> `Z W^T` 只回到**中心化**的空间。漏掉 `+ μ` 是手算大题最常见的扣分点之一。

★ 开算之前必须核对的五条约定（讲义标为 exam-critical）

约定	内容
① 先中心化	构造散布矩阵或协方差矩阵**之前**，先把每个特征的均值减掉
② 散布 vs 协方差	$S = X_c^{T}X_c$ 和 $S/(n-1)$ 的**特征向量完全相同**；特征值差一个 $(n-1)$ 的因子，但**解释方差比一模一样**
③ 归一化	投影之前要用**单位**特征向量
④ 投的是中心化数据	$Z = X_cW$；均值**只在重构时**加回去
⑤ 该缩放时才缩放	特征单位或量程不可比时才标准化

⭐ **约定 ② 在考试里的用法**

题目给的是散布矩阵 S（不除 n−1）时，**直接对 S 做特征分解即可**——方向一样，比值一样，不用先除。这样能省掉分数运算，还不容易算错。

Study check

- 为什么 $v^T\Sigma v$ 度量的是沿方向 v 的方差?
- 如果协方差的一个特征对是 (λ, v)，λ 在 PCA 里是什么意思?
- 为什么散布矩阵和样本协方差矩阵给出相同的主方向?

7. 手算例题 A：讲义的 PCA by hand

T1-09

这个例子**刻意**造得两个主方向都有变异，所以保留一个成分只能留住大部分、留不住全部方差 ——比「所有点正好共线」的例子更能说明成分选择。

题：把下面四个二维观测投到一维

观测	x	y
1	−3	0
2	3	0
3	0	−1
4	0	1

第 1 步

均值与中心化矩阵。

$$\mu = (0, 0) \quad \Rightarrow X_c = X\text{（本来就已经居中）}$$

自检：两列各自加起来都是 0。✓

第 2 步

散布矩阵与样本协方差。

$$S = X_c^{T} X_c = [[18, 0], [0, 2]]$$
$$\mathrm{Cov} = S/(n-1) = S/3 = [[6, 0], [0, 2/3]]$$

因为是对角矩阵，特征值直接就在对角线上，不用解特征方程。

第 3 步

特征值与单位特征向量（按降序）。

$$\lambda_1 = 6, \quad v_1 = (1, 0)^{T}$$
$$\lambda_2 = 2/3, \; v_2 = (0, 1)^{T}$$

第 4 步

解释方差比。

$$r_1 = 6 \,/\, (6 + 2/3) = 6 \,/\, (20/3) = 0.9$$
$$r_2 = (2/3) \,/\, (20/3) = 0.1$$

一个成分就达到 90% 的保留方差目标。

第 5 步

投影到 PC1 并用一个成分重构。

$$z = X_c v_1 = (-3, 3, 0, 0)^T$$
$$\hat{X} = z\, v_1^T + \mu = [[-3,0], [3,0], [0,0], [0,0]]$$

第 6 步

谁丢了信息?

观测 3 和 4 在第二个特征上被重构到了均值（0），它们之间的差别彻底消失了。

$$\text{总平方重构误差} = (-1-0)^2 + (1-0)^2 = 2$$
$$\text{校验：被丢掉的特征值} \times (n-1) = (2/3) \times 3 = 2 \ \checkmark$$

★★ 这题真正要考的点

保留 90% 的方差，不等于保留了每个特征的 90%，也不等于保留了每一个与应用相关的信号。

这里第二个特征的变异在秩一重构里**完全消失**。如果应用恰好要区分观测 3 和 4，那么「90% 方差」这个目标就是不够的。

⭐ **一个能当校验用的恒等式（手算时很值钱）**

丢掉成分 j 造成的总平方重构误差 = $\lambda_j \times (n-1)$（λ 取自样本协方差矩阵）。或者更直接：**= 散布矩阵 S 的对应特征值**。这里 S 的第二个特征值就是 2。

8. 手算例题 B：Tutorial 三问全解

Tutorial

Tutorial • Q1 — 准备步骤

数据集 X = [[2,3], [3,5], [0,−1], [−1,−3]]。两个特征尺度已经可比，所以**只中心化、不标准化。**

① 均值与中心化矩阵

$$\mu = (1, 1)$$
$$X_c = [[1, 2], [2, 4], [-1, -2], [-2, -4]]$$

② 散布矩阵与样本协方差

$$S = X_c^T X_c = [[10, 20], [20, 40]]$$
$$\text{Cov}(X) = S/3 = [[10/3, 20/3], [20/3, 40/3]]$$

③ 中心化的快速自检
每一个中心化后的列加起来都等于 0。

另外：**把 S 乘以正常数 1/3 会改变它的特征值，但不改变它的特征向量。**

Tutorial • Q2 — 特征值与第一主成分

特征方程化简为 λ(λ − 50) = 0。

① 两个特征值

$$\lambda = 50 \text{ 与 } \lambda = 0$$

② 验证特征向量

$$S\,(1,2)^{T} = (50,100)^{T} = 50\cdot(1,2)^{T} \quad \checkmark$$
$$S\,(-2,1)^{T} = (0,0)^{T} = 0\cdot(-2,1)^{T} \quad \checkmark$$

③ 选出并归一化第一主成分

$$v_1 = (1/\sqrt{5})\,(1,2)^{T} \approx (0.4472, 0.8944)^{T}$$

选它是因为它对应最大的特征值，也就是方差最大的方向。

Tutorial • Q3 — 投影与重构

① 四个一维得分

$$z = X_c v_1 = (\sqrt{5}, 2\sqrt{5}, -\sqrt{5}, -2\sqrt{5})^{T} \approx (2.236, 4.472, -2.236, -4.472)^{T}$$

② 重构第一个观测

$$\hat{x}_{c,1} = z_1\, v_1^{T} = \sqrt{5}\cdot(1/\sqrt{5}, 2/\sqrt{5}) = (1,2)$$
加回均值 (1,1) ⇒ (2, 3)，**正好是原始点**。

③ 为什么一个成分就留住了 100% 的方差
每一个中心化后的行都是 (1,2) 的倍数，所以中心化矩阵的**秩是 1**。正交方向上没有任何变异，于是 PC1 保留 50/(50+0) = **100%** 的方差。

Tutorial • 扩展（两问）

(a) 若第一个特征以美元计、数值大上几千倍

因为 PCA 最大化方差，**大尺度的那个特征会主导协方差矩阵**，把 PC1 拽向它自己的坐标轴——哪怕这种主导只是**单位造成的。**

什么时候该标准化：特征单位或量程不同、而你希望比较的是「相对变异」时。**但它不是自动动作**：到底该用绝对方差还是标准化后的方差，由领域含义决定。

(b) PCA 放在有标签的预测任务之前

PCA **只用输入特征、不用目标标签。**所以高方差方向可能反映的是干扰变异，而较低方差的方向反而可能含有有用的预测信号。

怎么检验：比较**用 PCA 和不用 PCA 的下游验证表现**；并且**任何缩放器与 PCA 变换都只在训练数据上拟合**，再应用到验证/测试数据。

9. Python 工作流：把数学符号对上 sklearn 属性

T1-08

属性 / 输出	对应数学里的什么	说明
`pca.mean_`	μ	拟合时学到的特征均值，投影前会被减掉
`pca.components_`	W^T（**每一行**一个 v_j）	用原始特征坐标表示的主方向
`pca.explained_variance_`	λ_j	每个保留方向上的方差
`pca.explained_variance_ratio_`	r_j	该方向占总方差的比例
`fit_transform(X)`	$Z = X_c W$	一行一个观测，一列一个保留成分
`inverse_transform(Z)`	$\hat{X} = ZW^T + \mu$	重构，**均值已经帮你加回去了**

⚠ **`components_` 是按行存的**

数学里 W 是 d×k（列是方向），而 sklearn 的 `components_` 是 k×d（**行**是方向）。写代码或读答案时注意这个转置。

讲义里那个可验证的例子

用的正是第 7 节那四个点 X = [[−3,0], [3,0], [0,−1], [0,1]]：

输出	值
`mean_`	[0, 0]
`components_`	与两条特征轴对齐
`explained_variance_`	约 6 与 0.667
`explained_variance_ratio_`	0.9 与 0.1
得分矩阵形状	(4, 2)
只留 1 个成分时的保留方差	**90%**
总平方重构误差	**2**

缩放为什么能改变 PCA

把第二个特征乘以 100 之后：**没有标准化时，被放大的那个特征会主导 PC1**。标准化之后，两个特征方差相等、协方差为零，所以**两个解释方差比都是 0.5**。

⚠ 这是一个「特征值并列」的情形

两个特征值相等时，**第一主方向不唯一**，返回哪个朝向可能取决于数值细节。

这个例子说明的是「**缩放改变了 PCA 认为什么方差重要**」，**不能**被解读成「标准化会让 PC1 在两个特征上载荷相等」。

★ 不要无脑标准化

特征单位或量程**不可比**时才缩放。如果原始的方差差异**本身就有科学含义**，标准化反而会抹掉你本来想让 PCA 保住的信息。

避免数据泄漏

> train_scaler.fit_transform(X_train) → train_scaler.transform(X_test)
> train_pca.fit_transform(X_train_scaled) → train_pca.transform(X_test_scaled)

★ 泄漏规则（M2 三个主题通用）

若 PCA 或聚类被用在后续的预测流程里，预处理与无监督变换都只用训练数据拟合，再把拟合好的变换应用到验证或测试数据。

附录 A • 公式速查表

名称	公式	备注
均值向量	$\mu = (1/n)\,\Sigma_i\, x_i$	按列（按特征）算
中心化	$X_c = X - 1_n\mu^T$	**每列和必须为 0**
散布矩阵	$S = X_c^T X_c$	手算常用这个，省掉除法
样本协方差	$\Sigma = S/(n-1)$	与 S **同特征向量**
投影方差	$\mathrm{Var}(X_c v) = v^T \Sigma v$	v 必须是单位向量
特征关系	$\Sigma v = \lambda v$	λ 就是该方向的投影方差
解释方差比	$r_j = \lambda_j / \Sigma_l \lambda_l$	S 与 Σ 给出的 r 相同
累计保留方差	$\Sigma_{j=1}^{k}\, r_j$	选 k 的主要依据之一
得分	$Z = X_c W_k$	投的是**中心化**数据
重构	$\hat{X} = ZW_k^T + 1_n\mu^T$	**别忘了加回均值**
丢掉成分 j 的重构误差	$= \lambda_j(n-1) = S$ 的第 j 个特征值	手算的现成校验
2×2 特征方程	$\lambda^2 - \mathrm{tr}(A)\lambda + \det(A) = 0$	tr 是迹，det 是行列式

附录 B • 高频易错点清单

#	易错点	正确做法
1	忘了先中心化就去算协方差	**永远先减均值**；算完验「每列和为 0」
2	重构时忘了加回均值	$\hat{X} = ZW^T + \mu$
3	特征向量没归一化就投影	先除以它的长度，使 $\|\|v\|\| = 1$
4	纠结散布矩阵该不该除 $(n-1)$	**方向和比值都不变**，手算直接用 S
5	把「方差大」读成「重要」	PCA 不看标签；低方差方向可能才是关键
6	把 PCA 当成线性回归	PCA 最小化**正交**误差，回归最小化**竖直**误差
7	看到符号相反就以为算错	主方向取反代表**同一条轴**
8	无脑标准化	单位不可比时才标准化；否则可能抹掉真实信息
9	在全量数据上拟合 PCA 再切分训练/测试	**只在训练集上 fit**，测试集只 transform
10	把 `components_` 当成列向量矩阵	sklearn 里**每一行**才是一个方向
11	特征值并列时硬说 PC1 是哪个方向	并列时**第一主方向不唯一**
12	用「保留 90% 方差」来保证任务够用	方差目标**不保证**保住应用关心的那个信号

附录 C • 术语中英对照

英文	中文	一句话
unsupervised learning	无监督学习	训练时不提供目标标签
curse of dimensionality	维度灾难	特征变多带来的一系列困难
dimensionality reduction	降维	用更少的变量表示数据
principal direction / component	主方向 / 主成分	协方差矩阵的单位特征向量
score	得分	中心化观测在某主方向上的投影坐标
reconstruction	重构	把得分映回原特征空间的近似
scatter matrix	散布矩阵	$S = X_c^T X_c$，不除 $(n-1)$
covariance matrix	协方差矩阵	$\Sigma = S/(n-1)$
eigenvalue / eigenvector	特征值 / 特征向量	λ 是投影方差，v 是方向
explained variance ratio	解释方差比	$r_j = \lambda_j/\Sigma\lambda$
cumulative explained variance	累计解释方差	前 k 个 r 的和
orthogonal	正交	互相垂直，内积为 0
standardisation	标准化	减均值再除标准差
data leakage	数据泄漏	测试集信息混进了训练过程
SVD	奇异值分解	与 PCA 计算方式密切相关的矩阵分解
t-SNE	t-SNE	强调局部邻域的非线性可视化方法