主成分分析 PCA

Module 2 · Topic 1 — 题库与解析

ARTI2001 Machine Learning · 2026 Semester 2

共 10 组 • 50 道选择题

覆盖：无监督学习与版图 · 维度灾难 · PCA 保留什么

核心数学六步 · 两个手算例题 · Tutorial 三问 · Python 工作流

答案与解析紧跟每一组之后

配套：《M2T1 PCA 知识点整理》

目录

使用方法

第 1 组：无监督学习与版图（T1-02 / T1-03）

第 2 组：维度灾难与降维（T1-05）

第 3 组：PCA 保留什么（T1-05 / T1-06）

第 4 组：核心数学（一）中心化与协方差（T1-07）

第 5 组：核心数学（二）为什么是特征向量（T1-07）

第 6 组：选成分、投影与重构（T1-07）

第 7 组：讲义 by-hand 例题（T1-09）

第 8 组：Tutorial Q1–Q2（散布矩阵与特征对）

第 9 组：Tutorial Q3 与扩展（投影、重构、缩放）

第 10 组：Python 工作流（T1-08）

使用方法

每组 5 题，题目与选项在前，答案与解析在该组末尾。建议先遮住解析区独立作答，整组做完再核对。做错的题回到《M2T1 PCA 知识点整理》对应章节复习。

组标题后面括号里是对应的 Canvas 讲义页编号，方便回查。

第 1 组：无监督学习与版图（T1-02 / T1-03）

1. 无监督学习与有监督学习最根本的差别是什么？

A. 无监督学习只能用于图像数据
B. 训练时不向算法提供目标标签
C. 无监督学习不需要选择任何参数
D. 无监督学习总是比有监督学习更准确

2. 一个聚类算法把无标签图片分成了两组。下列说法正确的是：

A. 这两组一定对应猫和狗
B. 分组结果与所用特征和缩放无关
C. 这两组是模型产出的摘要，需要人去解释
D. 有了分组就不再需要领域知识

3. 要把很多相关特征压缩成更少的变量，属于哪个任务族？

A. 降维
B. 关联与模式发现
C. 异常检测
D. 密度估计

4. 下列哪一项不是本课程直接考核的四个核心方法之一？

A. DBSCAN
B. k-means
C. 高斯混合模型
D. 层次聚类

5. 「相似性取决于表示」这句告诫的直接后果是：

A. 距离度量可以任意选，不影响结果
B. 特征选择、缩放和距离会实质改变聚类结果
C. 只要数据相同，任何算法都给出相同分组
D. 标准化之后所有方法都等价

答案与解析

1. B —— 定义就是「数据没有提供目标标签」。⚠ 注意它仍然在优化某个准则，**没有标签不等于没有目标函数**。

2. C —— 讲义原文：簇是 model-produced summaries，需要解释。它们**可能**对应猫狗，但没有保证，结果取决于特征、缩放、距离或模型假设。

3. A —— 降维回答的问题是「能不能用更少的变量表示数据而保留有用结构」。PCA 是其中的线性方法。

4. D —— 深考的是 PCA、k-means、DBSCAN、GMM 四个。层次聚类、关联规则、异常检测、非线性降维、自监督表示学习都只在「版图」页作背景介绍。

5. B —— 三条告诫之一。同一批行，换特征、换缩放、换距离，拟合出的分组就可能完全不同。

第 2 组：维度灾难与降维（T1-05）

1. 「维度灾难」指的是什么?

A. 特征数太少，导致模型容量不足、只能学到过于简单的规律
B. 样本量太大，使得每一轮训练的计算时间线性增长
C. 特征数增加时数据变稀疏、距离变得不那么有信息量、可视化更难
D. 标签里的噪声会随着特征维数增加而按比例被放大

2. 关于「高维」，讲义的态度是:

A. 高维一定是问题，必须降维
B. 高维数据不能用无监督方法
C. 只要超过 10 个特征就必须用 PCA
D. 高维本身不自动是问题，但要求我们想清楚该保留哪些结构

3. 把降维用于「降噪」时，必须注意什么?

A. 丢弃方向主要含噪声或重复信息这个假设必须自己去验证
B. 低方差方向一定是噪声
C. 降噪效果与保留成分数无关
D. 只要保留 90% 方差就一定降了噪

4. 在预测流程里用了 PCA，应该怎样判断它有没有帮助?

A. 看 PCA 的解释方差是否超过 90%
B. 看成分数是否小于特征数的一半
C. 比较用与不用 PCA 的下游验证表现
D. 看重构误差是否接近 0

5. PCA 与线性回归在「误差」上的差别是:

A. PCA 最小化正交（垂直于主方向）的重构误差
B. PCA 最小化竖直方向的预测误差
C. 两者都最小化同一个平方误差
D. PCA 不涉及任何误差概念

答案与解析

1. C —— 讲义定义：data points become sparse, distances become less informative, visualisation becomes harder，而且通常需要更多数据和算力。

2. D —— 原文是 High dimensionality is not automatically a problem。它只是要求我们去问「该保留什么结构、降维后的表示拿来干什么」。

3. A —— 讲义措辞：this assumption must be checked。**低方差不自动等于噪声。**

4. C —— 紧凑表示可能帮到后续模型，也可能删掉有用信息。讲义要求 compare downstream validation performance rather than assuming an improvement。

5. A —— 线性回归用目标变量、最小化在 y 上的预测误差；PCA 只用输入特征，其低维重构最小化**平方正交重构误差**。所以同一堆点两条线一般不重合。

第 3 组：PCA 保留什么（T1-05 / T1-06）

1. 关于「高方差方向」，下列哪一项是正确的？

A. 它一定是对预测最有用的方向
B. 它的解释方差比一定大于 0.5
C. 它一定对应某个类别的分界
D. 它可能只是描述了光照、单位之类的干扰因素

2. 主成分是原始特征的什么？

A. 非线性组合
B. 线性组合
C. 随机子集
D. 离散化分箱

3. 「主方向」和「主成分得分」的区别是：

A. 主方向是一个标量数值，而主成分得分是一个 d 维的向量
B. 得分必须先做完重构、再从重构结果里反推出来才有定义
C. 两者其实是同一个量，只是在不同教材里叫法不同而已
D. 方向是协方差矩阵的单位特征向量，得分是某个观测在该方向上的投影坐标

4. `components_` 里某一行取反，会发生什么？

A. 重构结果完全改变
B. 解释方差比会变成负数
C. 代表同一条 PCA 轴，对应得分跟着取反
D. 该成分不再与其它成分正交

5. 保留较少的主方向会带来什么？

A. 保留这些方向代表的变异，并丢失被省略方向上的变异
B. 所有特征的信息按同样比例缩减
C. 重构结果与原始数据完全一致
D. 方差总量保持不变

答案与解析

1. D —— PCA 不使用目标标签，所以输入方差高 ≠ 预测有用。高方差方向可能是 nuisance factor；低方差方向反而可能分开类别。

2. B —— Each component is a LINEAR COMBINATION of the original features，并按捕获的变异量排序。

3. D —— 方向是一支 d 维单位箭（整个数据集只有 d 个）；得分是一个数（每个观测各有一组）。

4. C —— 符号可逆：The SIGN of a row may be reversed. 它反转对应得分，但代表**同一条轴、同一个重构**。

5. A —— 丢失在「重构后的观测与原观测的差异」上可见。⚠ 不是每个特征按同比例缩减 —— 某个特征的变异可能被**完全**抹掉。

第 4 组：核心数学（一）中心化与协方差（T1-07）

1. 为什么 PCA 之前要先中心化?

A. 为了把所有特征的方差拉成相等，使它们贡献一样大
B. 让方差描述围绕特征均值的散布，而不是到任意原点的距离
C. 为了避免协方差矩阵里出现负的元素，保证它非负
D. 为了让求出来的特征向量自动具有单位长度，省去归一化

2. 中心化做对了，最快的自检是什么?

A. 协方差矩阵的行列式为 0
B. 矩阵变成对称矩阵
C. 所有元素都变成非负
D. X_c 的每一列加起来等于 0（允许舍入误差）

3. 样本协方差矩阵 Σ = (1/(n−1)) X_c^T X_c 的对角元是什么?

A. 两个特征的协方差
B. 单个特征自己的方差
C. 特征均值
D. 特征的标准差

4. 散布矩阵 S = X_c^T X_c 与样本协方差 S/(n−1) 的关系是:

A. 两者在特征向量和特征值上都完全相同，可以互换使用
B. 两者的特征向量互不相同，但特征值恰好完全一样
C. 特征向量相同，特征值差一个 (n−1) 因子，解释方差比相同
D. 两者的解释方差比相差一个 (n−1) 的倍数，必须换算

5. 若协方差矩阵恰好是对角矩阵，特征值在哪里?

A. 直接就是对角线上的元素
B. 需要解特征方程才能得到
C. 等于矩阵的迹
D. 等于矩阵的行列式

答案与解析

1. B —— 中心化把数据中心搬到原点。⚠ 让方差相等是**标准化**做的事，不是中心化。

2. D —— 讲义特意给了这条 useful CHECK：every column of X_c sums to zero。手算时先验这步能挡掉大半错误。

3. B —— 对角元是某个特征的方差；非对角元表示两个特征怎样共同变化。Σ 是对称的 d×d 矩阵。

4. C —— 这是 exam-critical 的第 ② 条约定。所以手算时**直接对 S 做特征分解即可**，省掉分数运算。

5. A —— 对角矩阵的特征值就是对角元，特征向量就是坐标轴。讲义的 by-hand 例正是这种情形，所以能直接读出 6 和 2/3。

第 5 组：核心数学（二）为什么是特征向量（T1-07）

1. 把中心化数据投到单位方向 v 上，得分的样本方差等于什么？

A. v^T v
B. v^T Σ v
C. Σ v
D. ||Σv||

2. 解「在 v^T v = 1 约束下最大化 v^T Σ v」这个问题，得到的关系是：

A. v = Σ λ
B. Σ = v λ v^T
C. Σ v = λ v
D. λ = v^T v

3. 在 PCA 里，一个特征值 λ 的含义是什么？

A. 该方向上得分的方差
B. 该方向与坐标轴的夹角
C. 该方向上观测的个数
D. 重构误差的平方根

4. 主方向之间的关系是：

A. 互相平行
B. 没有固定关系
C. 互相成 45 度
D. 互相正交

5. 「几何读法」里，PCA 在做的事情是：

A. 把每个特征分别排序
B. 把点云压到最接近原点的位置
C. 找到让所有点距离之和最小的那个点
D. 转动一根一维轴，挑让投影坐标散得最开的那个角度

答案与解析

1. B —— z = X_c v，Var(z) = (1/(n−1)) z^T z = v^T Σ v。PCA 问的就是哪个单位 v 让它最大。

2. C —— 这正是特征值方程。于是「找方差最大方向」变成了「求协方差矩阵的特征对」。

3. A —— an eigenvector gives a direction whose PROJECTED VARIANCE IS ITS EIGENVALUE。所以最大特征值对应第一主方向。

4. D —— 对称矩阵的特征向量可取为两两正交。对拟合用的这批数据，成分得分也是不相关的 —— 但这不保证所有非线性依赖都消失了。

5. D —— 协方差的特征问题只是「不用一个个角度去试」的矩阵算法，本质就是这个转动-投影的过程。

第 6 组：选成分、投影与重构（T1-07）

1. 成分 j 的解释方差比怎么算?

A. λ_j / n
B. λ_j / λ_1
C. $\lambda_j / \Sigma_l \lambda_l$
D. $\lambda_j \times (n-1)$

2. 投影公式 $Z = X_c W_k$ 里，投的是什么数据?

A. 原始数据 X
B. 中心化后的数据 X_c
C. 标准化后的数据
D. 重构后的数据

3. 从得分重构回原特征空间的公式是:

A. $\hat{X} = Z W_k^T + 1_n \mu^T$
B. $\hat{X} = Z W_k^T$
C. $\hat{X} = Z W_k + \mu$
D. $\hat{X} = W_k Z^T$

4. 投影之前为什么要把特征向量归一化?

A. 否则求出来的特征值会整体变号，排序结果被颠倒
B. 否则得分会被特征向量的长度缩放，不再是几何投影坐标
C. 否则不同主方向之间不再保持正交，投影会相互干扰
D. 否则协方差矩阵会变成奇异矩阵，特征分解无法进行

5. 丢掉第 j 个成分造成的总平方重构误差，等于下列哪一项?

A. $\lambda_j \times (n-1)$，也就是散布矩阵 S 的对应特征值
B. 直接等于样本协方差矩阵的第 j 个特征值 λ_j 本身
C. 等于样本协方差的特征值再除以 $(n-1)$，即 $\lambda_j/(n-1)$
D. 等于该成分的解释方差比 r_j，是一个 0 到 1 之间的数

答案与解析

1. C —— $r_j = \lambda_j$ 除以所有特征值之和。前 k 个 r 相加就是累计保留方差。

2. B —— exam-critical 第 ④ 条：Project centred data；均值**只在重构时**加回去。

3. A —— ⚠ 漏掉 + μ 是手算大题最常见的扣分点：$Z W^T$ 只回到**中心化**的空间。

4. B —— exam-critical 第 ③ 条：use unit eigenvectors before projecting。

5. A —— 很好用的手算校验。讲义 by-hand 例：丢掉的协方差特征值是 2/3，(2/3)×3 = **2**，正是直接算出来的总平方重构误差。

第 7 组：讲义 by-hand 例题（T1-09）

1. 数据 X = [[−3,0],[3,0],[0,−1],[0,1]]，它的散布矩阵 S 是什么?

A. [[9, 0], [0, 1]]
B. [[6, 0], [0, 2/3]]
C. [[18, 0], [0, 2]]
D. [[18, 2], [2, 18]]

2. 这个例子的两个解释方差比是多少?

A. 1.0 与 0.0
B. 0.5 与 0.5
C. 0.75 与 0.25
D. 0.9 与 0.1

3. 只保留 PC1 时，观测 3 和 4 被重构成什么?

A. 原来的位置
B. 都落在第二个特征的均值上，彼此无法区分
C. 被删除
D. 被投到第一个特征的最大值处

4. 这个例子的总平方重构误差是多少?

A. 2
B. 1
C. 0
D. 4

5. 这个例子想说明的核心道理是:

A. 只要保留了 90% 的方差，任何下游应用的需求就都能满足
B. 做完中心化之后，所有特征的方差就会自动变得相同
C. 任何数据集的两个主成分，解释方差比一定是相等的
D. 保留 90% 方差不等于保留了每个特征或每个应用相关信号的 90%

答案与解析

1. C —— 均值是 (0,0)，所以 X_c = X。S = X_c^T X_c：第一列平方和 9+9 = 18，第二列 1+1 = 2，交叉项为 0。样本协方差才是 S/3 = [[6,0],[0,2/3]]。

2. D —— 6 / (6 + 2/3) = 6/(20/3) = 0.9，另一个是 0.1。所以**一个成分就达到 90% 的目标。**

3. B —— 它们只在第二个特征上有变异，而这个方向被丢掉了，所以在秩一重构里变成同一个点。

4. A —— $(-1-0)^2 + (1-0)^2 = 2$。也可以用校验式：丢掉的协方差特征值 $(2/3) \times (n-1) = (2/3)\times 3 = 2$。

5. D —— 第二个特征的变异在秩一重构里**完全消失。**若应用要区分观测 3 和 4，90% 的方差目标就不够。

第 8 组：Tutorial Q1–Q2（散布矩阵与特征对）

1. X = [[2,3],[3,5],[0,−1],[−1,−3]] 的特征均值向量是：

A. (0, 0)
B. (1, 2)
C. (1, 1)
D. (2, 3)

2. 这个数据集的散布矩阵 S 是：

A. [[20, 10], [10, 40]]
B. [[10/3, 20/3], [20/3, 40/3]]
C. [[5, 10], [10, 20]]
D. [[10, 20], [20, 40]]

3. 特征方程 λ(λ − 50) = 0 给出的两个特征值是：

A. 50 与 1
B. 25 与 25
C. 50 与 0
D. 10 与 40

4. 归一化后的第一主成分 v_1 是：

A. (1/√5)(2, 1)^T
B. (1/√5)(1, 2)^T
C. (1, 2)^T
D. (1/5)(1, 2)^T

5. (−2, 1)^T 对应哪个特征值?

A. 0
B. 50
C. 25
D. 它不是特征向量

答案与解析

1. C —— 第一列 (2+3+0−1)/4 = 1；第二列 (3+5−1−3)/4 = 1。于是 X_c = [[1,2],[2,4],[−1,−2],[−2,−4]]。

2. D —— S = X_c^T X_c。样本协方差是 S/3 = [[10/3, 20/3], [20/3, 40/3]]。两者**特征向量相同**。

3. C —— 直接读根即可。λ = 0 说明中心化矩阵是**秩一**的 —— 正交方向上没有任何变异。

4. B —— (1,2) 对应较大特征值 50（验证：S(1,2)^T = (50,100)^T = 50(1,2)^T）。它的长度是 √5，所以除以 √5。选它是因为它是方差最大的方向。

5. A —— S(−2,1)^T = (0,0)^T = 0·(−2,1)^T。这个方向上投影方差为 0，所以可以整个丢掉而不损失信息。

第 9 组：Tutorial Q3 与扩展（投影、重构、缩放）

1. 四个观测投到 v_1 上的得分 z 是：

A. (2, 4, −2, −4)^T
B. (1, 2, −1, −2)^T
C. (5, 10, −5, −10)^T
D. (√5, 2√5, −√5, −2√5)^T

2. 重构第一个观测时，$\hat{x}_{c,1} = z_1 v_1^T$ 得到 (1,2)，接下来要做什么？

A. 把结果再除以 √5，抵消掉归一化时乘进去的那个因子
B. 加回均值 (1,1)，得到 (2,3)
C. 把结果乘以 n−1，还原散布矩阵与协方差矩阵之间的比例
D. 对每个分量取绝对值，因为重构出来的坐标不应该为负

3. 为什么这个数据集里一个成分就保留了 100% 的方差？

A. 因为每个中心化行都是 (1,2) 的倍数，中心化矩阵秩为 1
B. 因为这个数据集只有四个观测，样本量不足以支撑第二个成分
C. 因为这两个特征事先已经做过标准化，方差被归一到了 1
D. 因为它的特征均值恰好是 (1,1)，中心化后抵消掉了一个方向

4. 若第一个特征改用美元计、数值大上几千倍，会发生什么？

A. PCA 结果完全不变
B. 解释方差比一定变成 0.5 和 0.5
C. 大尺度特征可能主导协方差矩阵，把 PC1 拽向它的坐标轴
D. 特征向量不再正交

5. PCA 放在有标签的预测任务之前，为什么「保留最大方差方向」不保证预测更好？

A. 因为主成分之间不正交
B. 因为 PCA 会丢掉所有线性信息
C. 因为 PCA 只用输入特征、不使用目标标签
D. 因为解释方差比总是小于 1

答案与解析

1. D —— $z = X_c v_1$。例如第一行 $(1,2)\cdot(1/\sqrt{5})(1,2) = (1+4)/\sqrt{5} = 5/\sqrt{5} = \sqrt{5} \approx 2.236$。

2. B —— 重构必须把均值加回去。加回之后正好还原成原始点 (2,3)。

3. A —— 秩一 ⇒ 正交方向上没有变异 ⇒ PC1 保留 50/(50+0) = 100%。这也是它比讲义 by-hand 例「更简单」的地方。

4. C —— 因为 PCA 最大化方差，而这种主导可能**只是单位造成的。**⚠ 标准化不是自动动作：该用绝对方差还是标准化方差，由领域含义决定。

5. C —— 高方差方向可能反映干扰变异，低方差方向反而可能含预测信号。**检验办法**：比较用与不用 PCA 的下游验证表现，并且缩放器与 PCA 只在训练集上拟合。

第 10 组：Python 工作流（T1-08）

1. `pca.components_` 的每一行代表什么？

A. 一个观测的得分
B. 一个主方向（用原始特征坐标表示）
C. 一个特征的均值
D. 一个特征值

2. `fit_transform(X)` 返回的矩阵形状是什么？

A. (特征数, 成分数)
B. (观测数, 特征数)
C. (成分数, 观测数)
D. (观测数, 成分数)

3. 只保留 1 个成分时，`explained_variance_ratio_.sum()` 为什么小于 1？

A. 因为被省略成分所代表的那部分方差没有被计入
B. 因为计算有舍入误差
C. 因为没有做标准化
D. 因为数据没有中心化

4. 把第二个特征乘以 100 后再做标准化，两个解释方差比变成 0.5 和 0.5。这说明：

A. 这是特征值并列的情形，第一主方向不唯一
B. 标准化会让 PC1 在两个特征上载荷相等
C. 标准化之后 PCA 失效
D. 两个特征变得完全相关

5. 在预测流程里，测试集应该怎么处理？

A. 对测试集单独 fit_transform
B. 把训练集和测试集合起来 fit
C. 只用训练集拟合的缩放器与 PCA 对它 transform
D. 测试集不需要任何变换

答案与解析

1. B —— ⚠ 数学里 W 是 d×k（列是方向），而 sklearn 存成 k×d（**行**是方向）。读答案时注意转置。

2. D —— 一行一个观测，一列一个保留成分。讲义例子里是 (4, 2)。

3. A —— 保留 1 个成分时这个和是 0.9，另外的 0.1 属于被丢掉的方向。

4. A —— ⚠ 讲义明确警告不要把它解读成「载荷相等」。并列时返回哪个朝向取决于数值细节。

5. C —— 这是通用的防泄漏规则：**fit 只在训练数据上做**，后续数据只 transform。