聚类：k-means 与 DBSCAN

Module 2 · Topic 2 — 知识点完整整理

ARTI2001 Machine Learning · 2026 Semester 2

涵盖：**Canvas 讲义 T2-01 ~ T2-06**（k-means 与 DBSCAN 两页均标为 CORE）
Tutorial 三问 + 扩展的完整官方解答
五个完整手算例题（k-means 两个、DBSCAN 两个、稳定性一个）
Practical 的参考数字：选 k、eps/MinPts 扫描、单位干预、双月形对照
附录：公式速查 · 12 条易错点 · 术语中英对照

配套：《M2T2 聚类 题库与解析》《M2 评估与模型选择》

目录

1. 路线图与这一周的考核重点

2. 什么是聚类：相似是建模选择
   - 四件事一改结果就可能变
   - 七步实用工作流

3. k-means：算法与目标函数
   - 欧氏距离与四步算法
   - ★★ 为什么两步单调不增
   - 手算例题 1：讲义一维四点
   - 手算例题 2：Tutorial Q1（含扩展第二轮）

4. 选 k：用证据，不是用答案键
   - ★★★ 关于 inertia 必须分清的那句话
   - k 大一点还是小一点

5. 初始化：k-means++ 与 n_init
   - 手算例题 3：标签 vs 成员

6. k-means 什么时候合适

7. DBSCAN：密度是局部定义的
   - 三类点与四步流程
   - 两个参数与四种偏差
   - 手算例题 4：讲义一维五点
   - 手算例题 5：Tutorial Q2（完整）
   - 形式化定义 6 条
   - 缩放怎样改变邻域

8. k-means 与 DBSCAN 的对照
   - ★★ Tutorial Q3 的标准答法

9. Python 工作流与 Practical 的关键数字
   - ★★★ 双月形：silhouette 和应用需求打架

附录 A · 公式速查表

附录 B · 高频易错点清单

附录 C · 术语中英对照

1. 路线图与这一周的考核重点 T2-01

聚类是无监督学习里用来**提出有用分组**的核心任务。结果取决于所选特征、缩放、算法与参数，所以一个拟合出来的划分应当被当作**基于模型的提案**，而不是自动就是数据里的「真实」分组。

算法	一句话定义	关键特点
k-means	把观测划分成**预先给定**的 k 个簇，最小化到各簇质心的**平方欧氏距离之和**	每个点都必须有标签；倾向紧致、凸的区域
DBSCAN	从**连通的稠密区域**构建簇，稀疏区域的点可被标为噪声	不需要预先给 k；能还原非球形；对缩放与 eps/min_samples 非常敏感

★ 讲义原文的考核重点（ASSESSMENT FOCUS）

你需要能够：计算并解释小例子、比较算法假设、用不止一种证据来论证结论。

你不需要记住软件的默认值。

八条学习成果

1. 把聚类解释为「在无标签数据中发现结构」；
2. 对一个小数据集执行 k-means 的**指派步**与**质心更新步**；
3. 解释 k-means 的目标函数，并评估一个 k 的选择；
4. 用 DBSCAN 的邻域规则识别**核心点、边界点、噪声点**；
5. 比较 k-means 与 DBSCAN 的假设与行为；
6. 解释特征缩放与参数选择如何影响聚类结果；
7. 在 Python 里拟合两者并解释主要输出；
8. 用内部证据、稳定性、假设与领域有用性来评估聚类结果。

2. 什么是聚类：相似是建模选择 T2-02

聚类按照所用的表示与建模选择，把观测分组成：**组内相对相似、组间相对不相似。**

★★ 和分类的根本差别

分类有**已知的类标签要去复现**；聚类没有。

但聚类也不是在自动搜索唯一正确的分组：分析者仍然要选择怎么表示观测、怎么度量相似、用哪个算法、参数怎么设。

四件事一改，结果就可能变

可变项	内容
特征 / 表示	用哪些信息来描述每个观测
特征缩放	量级大的特征会不会主导比较
距离或模型假设	这个方法能表示什么形状的组
算法与参数	例如 k-means 的 k，或 DBSCAN 的邻域设置

> ⭐ **讲义举的那个例子，很好用来答简答题**
>
> 两位顾客年度消费相同、但购买频率差别很大。
>
> 如果表示里**只有年度消费**，算法就用不上频率来区分他们。
>
> 如果消费以**美元**计（量级大），而频率只在 **1 到 20** 之间，**未缩放的欧氏距离会被消费主导**。
>
> **加入并适当缩放频率，就改变了「相似」的含义**，于是可能改变拟合出来的簇 —— 尽管这两位顾客本身一点没变。

七步实用工作流

1. **定义目的**：这个分组要支持什么决策或探索；
2. **选定观测单位**：比如一行一个顾客，而不是一行一笔交易；
3. **构建表示**：选特征、处理缺失与重复、必要时变换或缩放；
4. **检查几何**：看图或摘要，留意离群点、弯曲结构、密度不均、高维效应；
5. **拟合不止一种配置**：比较相邻的 k、多次初始化、几组 DBSCAN 邻域设置；
6. **评估多个信号**：内部分数 + 稳定性 + 模型假设 + 领域有用性；
7. **谨慎解释**：描述各组之间差在哪，不要把数字标签当成身份。

3. k-means：算法与目标函数

T2-03

前提：欧氏距离

$$d(x, y) = \sqrt{(x_1-y_1)^2 + (x_2-y_2)^2 + \ldots + (x_n-y_n)^2} = \sqrt{\Sigma_{i=1}^{n}(x_i-y_i)^2}$$

> ⭐ **手算时不用开根号**
>
> 指派步只是**比大小**，而平方根是单调的，所以**直接比平方距离**即可。Tutorial 的参考答案也是这么做的，还省掉了无理数。

四步算法

步骤	内容
① 初始化	选 k（靠领域知识或肘部法等）；初始化质心。实践中常用 **k-means++**，因为它把起始中心**拉开**。不同起点会收敛到不同局部解，所以要**多次初始化并保留 WCSS 最低的那次**
② 指派	对每个点算到每个质心的欧氏距离，**归给最近的那个质心**
③ 更新	每个簇的新质心是**所有被指派进来的点的均值**：$\mu_i = (1/m)\Sigma_{j=1}^{m} x_j$
④ 迭代	重复 ②③，直到：指派不再变化 / 质心稳定 / 达到最大迭代次数

★★ 为什么这两步有效：目标函数

> $\mathrm{WCSS} = \Sigma_{i=1}^{k} \Sigma_{x \in C_{\{i\}}} d(x, \mu_i)^2$　　（也叫 inertia / 惯性）

★★★ 两步为什么单调不增（大题常考）

- **指派步不会增加 WCSS**，因为每个观测都被指派给**当前**离它最近的质心；
- **更新步不会增加 WCSS**，因为在簇固定的前提下，**均值正是让平方距离之和最小的那个点。**

重复这两步会收敛到一个**局部**解，**不一定是全局最小。**

⚠ 不要从目标函数里读出它没说的东西

WCSS 低只意味着：**在所选特征、所选缩放和这个 k 下，观测离各自的质心近。**

它**不**显式地最大化簇间分离，也**不**证明拟合出来的组对应自然类别或有用的真实分组。

手算例题 1 • 讲义的一维四点（完整一轮）

四个一维观测 {1, 2, 8, 9}，k = 2，初始质心 $\mu_1 = 1$、$\mu_2 = 8$。

> **指派**
> 1 和 2 离 μ_1 近；8 和 9 离 μ_2 近 ⇒ **$C_1 = \{1,2\}$，$C_2 = \{8,9\}$**

> **更新**
>
> $$\mu_1' = (1+2)/2 = 1.5 \quad \mu_2' = (8+9)/2 = 8.5$$

> **算 WCSS**
>
> $$\mathrm{WCSS} = (1-1.5)^2 + (2-1.5)^2 + (8-8.5)^2 + (9-8.5)^2 = 0.25 \times 4 = 1$$

再指派
分组不变 ⇒ **这一轮已收敛。**

⚠ 这个计算说明了什么、没说明什么

它说明了**指派与均值更新为什么不会让 WCSS 上升。**

它**没有**证明 2 就是这个应用正确的分组数。

手算例题 2 • Tutorial Q1 — 完整一轮 k-means（二维八点）

A=(2,10) B=(2,5) C=(8,4) D=(5,8) E=(7,5) F=(6,4) G=(1,2) H=(4,9)；k = 2，初始质心取 **B=(2,5)** 与 **E=(7,5)**。可以直接比平方距离。

① 平方距离表

点	A	B	C	D	E	F	G	H
到 (2,5) 的 d^2	25	0	37	18	25	17	10	20
到 (7,5) 的 d^2	50	25	2	13	0	2	45	25

② 指派

$$C_1 = \{A, B, G, H\} \qquad C_2 = \{C, D, E, F\}$$

③ 更新质心

$$\mu_1 = ((2+2+1+4)/4, (10+5+2+9)/4) = (2.25, 6.5)$$
$$\mu_2 = ((8+5+7+6)/4, (4+8+5+4)/4) = (6.5, 5.25)$$

④ 这两步在减什么
指派步与更新步交替，是在减小「到各自所属质心的簇内平方距离之和」。

Tutorial • 扩展 — 第二轮（平局归 Cluster 1）

从 (2.25, 6.5) 与 (6.5, 5.25) 再走一轮。

关键点
点 D 正好打平，按题目约定归给 Cluster 1。

结果

$$C_1 = \{A, B, D, G, H\}, \quad \mu_1 = (2.8, 6.8)$$
$$C_2 = \{C, E, F\}, \quad \mu_2 = (7, 13/3) \approx (7, 4.33)$$

4. 选 k：用证据，不是用答案键

T2-03 / T2-06

> **★★★ 关于 inertia 的那句必须分清的话（讲义特意澄清过）**
>
> **全局最优的 inertia 不会随 k 增大而上升**（因为更多质心的解可以表示更少质心的解）。
>
> **但是：不同次拟合可能落到不同的局部极小，所以「实测到的」inertia 不一定单调下降。**
>
> ⇒ 所以要**多次初始化**，并把肘部、silhouette、稳定性、图形与应用含义合起来看。

讲义给的示例表

k	Inertia	Silhouette	解读
2	142	0.58	粗分组
3	76	0.64	**较强的暂定候选**
4	55	0.52	更细，但分离度更差

这里 **k = 3 是一个可辩护的暂定选择**：它 silhouette 最好，inertia 的下降也最有用。但仍应跨初始化或跨样本复核，并对照应用含义。

> **Study check**
>
> 为什么一个 inertia 更低的解，可能反而没有一个 inertia 更高的解有用?

k 大一点还是小一点

	更小的 k	更大的 k
分组粒度	更粗：更多观测被并进更少、更大的簇	更细：分成更多、更小的簇
代价	**值得区分的模式可能被合并**；簇内变异/inertia 通常更高	额外的细分可能**不稳定、难解释、或与应用无关**

> **⭐ 讲义的例子**
>
> 零售商做一次简单的营销活动，也许三个咖啡偏好簇就够；而产品设计任务可能需要更细的分组。
>
> **哪个值都不是自动正确的「真」答案；有用的粒度取决于要支持的决策。**

可辩护的选择要同时看五类证据

- inertia 与肘部形态；
- silhouette 或别的合适的内部度量；

- **跨初始化、跨样本、跨相邻 k 的稳定性**；
- 数据的几何形状与特征缩放是否适合 k-means；
- 得到的组在上下文里是否可解释、有用。

5. 初始化：k-means++ 与 n_init

T2-03

k-means++ 从数据里选第一个质心，之后**偏好离已选质心更远的点**作为后续质心。这把起始质心铺开在整个数据集上，通常比随意摆放给出更好的起点。

在 scikit-learn 里，`n_init` **指的是用不同种子完整跑几次 k-means，保留 inertia 最低的那次结果。** `n_init=10` 就是独立试十次初始化。

> ⚠ **两个常见误读**
>
> - `n_init` **不是迭代次数**，是「完整重跑几遍」；
> - 默认值会随 scikit-learn 版本和初始化方法而变，**要可复现就显式写出来。**

手算例题 3 • 稳定性：标签 vs 成员（讲义的四点例子）

A=(0,0) B=(0,2) C=(4,0) D=(4,2)，k = 2。不同起始质心得到三次收敛结果：

运行	A,B,C,D 的标签	分组	Inertia
1	0,0,1,1	{A,B}, {C,D}	4
2	1,1,0,0	{A,B}, {C,D}	4
3	0,1,0,1	{A,C}, {B,D}	16

> **运行 1 与 2**
> **成员完全相同**，只是标签号互换了。质心是 (0,1) 与 (4,1)，四个平方距离各为 1，合计 **4。**

> **运行 3**
> 质心是 (2,0) 与 (2,2)，四个平方距离各为 4，合计 **16。**这是一个**不同且更差的局部解** —— 尽管它在继续更新下也保持稳定。

> ★★ **这题的考点：比较必须是「标签无关」的**
>
> **单纯去数「标签数字不一样的点有几个」，会把运行 1 和 2 错判成不同。**
>
> 正确做法是比较**哪些观测仍然待在一起。**

> ⭐ **两种稳定性检查，查的不是同一件事**
>
> **重复随机种子**查的是**优化敏感性**；**重采样观测**查的是**抽样稳定性。**两者都不能单独确立领域有用性。

6. k-means 什么时候合适

T2-03

当**质心是一个有意义的摘要**、而且在所选特征空间里各组**相当紧致**时，k-means 最合适。它的平方距离目标带来五个必须考虑的点：

考虑点	内容
特征缩放	数值范围大得多的特征会主导欧氏距离。单位不可比时**标准化是有用的基线**，但缩放应当反映领域含义
几何形状	k-means 偏好**紧致、凸、以质心为中心**的区域，**会横切弯曲或非凸的组**
簇的大小与密度	大小、散布或密度差别很大的组，用一个质心表示会很差
离群点	极端观测会把均值质心**从主体拽走**
表示	换特征或换变换，就换了「最近」的含义，也就可能换掉整个划分

7. DBSCAN：密度是局部定义的

T2-04

DBSCAN（Density-Based Spatial Clustering of Applications with Noise）能发现**非质心形状**的稠密区域，并且可以把区域之外的观测**留着不指派**。它**不需要预先给出簇数**，但结果仍然取决于距离表示以及 eps 与 MinPts 两个参数。

> **★ 密度的定义是「局部」的**
>
> **当一个点的 eps-邻域里至少有 MinPts 个观测时，它就处在稠密区域。**
>
> 连通的核心点构成簇的骨架；附近的非核心点可以作为**边界点**加入；落在所有已发现稠密区域之外的观测，在当前设置下被标为**噪声**。

四步高层流程

1. **访问一个未处理的观测**：检查所有与它距离 ≤ eps 的观测，**包括它自己**；
2. **判定三类点**（见下表）；
3. **从核心点扩张**：递归地把通过相邻核心点可达的观测加进来。**边界点加入簇，但不扩张簇。**
4. **重复**：访问下一个未处理的观测，直到所有观测都被检查过。

类型	判据
核心点 Core	**它自己的邻域里至少有 MinPts 个观测**
边界点 Border	它**在某个核心点的邻域内**，但它自己不是核心点
噪声点 Noise	既不是核心点，也不在任何核心点的邻域内

> **⚠⚠ 三个最容易丢分的细节**
>
> - **邻域包含点自己。**scikit-learn 的 `min_samples` 也是**把该点算在内**的，和本课的约定一致；
> - **只有核心点才能继续密度可达链。**边界点进了簇就到此为止；
> - **先被标成噪声的点，可能后来变成边界点。**如果 A 在 B 之前被访问，A 可能被**临时**标为噪声；等 B 被认出是核心点、簇扩张过来，A 就成了边界点。

两个参数与四种偏差

参数	含义
eps（ε）	数据点周围邻域的**半径**
MinPts	成为核心点所需的**最少观测数**（sklearn 里是 `min_samples`，含该点自己）

设置偏差	后果
eps 太小	稠密区域可能**碎裂**，很多观测留着没被指派
eps 太大	本来不同的稠密区域可能**被合并**
MinPts 太小	微弱的局部模式也会被当成簇
MinPts 太大	真实的较小或较低密度的组会留着没被指派

> ⚠ **DBSCAN 的结构性弱点**
>
> **当真实的簇密度差别很大时，一组全局的 eps 与 MinPts 可能描述不好所有区域。**

手算例题 4 • 讲义的一维五点

A=0, B=0.5, C=1.0, D=3.0, E=3.4；**eps = 0.6，MinPts = 3**，邻域含点自己。

点	邻域	|N|	角色
A	{A, B}	2	**边界**
B	{A, B, C}	3	**核心**
C	{B, C}	2	**边界**
D	{D, E}	2	**噪声**
E	{D, E}	2	**噪声**

> **判定理由**
>
> B 的邻域有 3 个点，达到 MinPts ⇒ **核心**。A 和 C 各自落在核心点 B 的邻域里，但自己邻居不够，不能扩张簇 ⇒ **边界**。

> **结果**
>
> **发现的簇是 {A, B, C}；在这组设置下 D 和 E 是噪声。**

> **Study check**
>
> 若 eps 提高到 1.1、MinPts 仍为 3，会有什么变化？（提示：先重算每个点的邻域大小，注意 D 与 E 之间的距离是 0.4。）

手算例题 5 • Tutorial Q2 — 二维六点（完整）

A=(2,2) B=(3,3) C=(3,4) D=(4,3) E=(8,7) F=(9,8)；**ε = 2，MinPoints = 3**。用欧氏距离，邻域含点自己，**距离 ≤ ε 算在邻域内**。

① 列出每个点的 ε-邻域

点	ε-邻域	|N|	角色
A	{A, B}	2	边界
B	{A, B, C, D}	4	**核心**
C	{B, C, D}	3	**核心**
D	{B, C, D}	3	**核心**
E	{E, F}	2	噪声
F	{E, F}	2	噪声

② 三类点

B、C、D 是核心点。A 不是核心，但它落在核心点 B 的邻域里 ⇒ **边界点。E 与 F 是噪声。**

③ 最终结果

> $\text{Cluster } 1 = \{A, B, C, D\} \quad \text{noise} = \{E, F\}$

为什么先被标噪声的点能变成边界点：临时的噪声标签不是最终的 —— 当后来的某个核心点扩张出簇时，先前访问过的、落在该核心点邻域里的非核心点就成了边界点。

> ⭐ **手算小技巧：把要比的距离平方一下**
>
> ε = 2 ⇒ **ε² = 4**。于是只要比 $(\Delta x)^2 + (\Delta y)^2 \le 4$，不用开根号。比如 A 到 C：$1^2 + 2^2 = 5 > 4$ ⇒ 不在邻域内。

形式化定义（6 条）

#	名称	定义
1	ε-邻域	$N_\varepsilon(p) = \{ q \in D \mid \text{dist}(p,q) \le \varepsilon \}$
2	核心点	p 是核心点，当且仅当 $\lvert N_\varepsilon(p) \rvert \ge \text{MinPts}$
3	直接密度可达	q 在 $N_\varepsilon(p)$ 内**且 p 是核心点** ⇒ q 从 p 直接密度可达
4	密度可达	存在链 $p_1 \cdots p_n$，$p_1=p$，$p_n=q$，每个 p_{i+1} 从 p_i 直接密度可达
5	密度相连	存在 o，使 p 与 q 都从 o 密度可达
6	簇	非空子集 C 满足：**极大性**（$p \in C$ 且 q 从 p 密度可达 ⇒ $q \in C$）与**连通性**（C 中任意 p,q 密度相连）

⚠ **「噪声」是算法标签，不是事实判断**

讲义的原话很克制：对**固定的**数据、特征、缩放、距离度量、eps 与 MinPts，噪声就是「不属于任何已发现簇」的那些观测。

这是在那组设置下的算法性标注，不是「这些观测是测量错误或真实异常」的已验证陈述。

sklearn 的 **label −1** 只表示「在当前设置下未被指派到稠密区域」。

⚠ **边界点的归属可能不稳定**

一个边界点有时会落在**不止一个簇**的可达范围内。**它最终归谁，可能取决于遍历顺序**；而**核心点构成的连通集合要稳定得多**。⇒ 对孤立的边界点归属要谨慎解读。

缩放怎样改变邻域

DBSCAN 用距离，所以**特征单位直接决定哪些点落在 eps-邻域里**。如果一个特征在数千量级、另一个只在 0 到 10，大尺度那个会主导欧氏距离。

- 单位不可比时要缩放或变换；标准化是有用的基线，**强离群点扭曲均值与标准差时可考虑稳健缩放**；
- **缩放要先定、eps 后定** —— eps 的数值含义随表示而变；
- 若聚类属于某个训练/评估流程，**缩放器只在训练数据上拟合**，再复用到后续数据。

8. k-means 与 DBSCAN 的对照

T2-05

问题	k-means	DBSCAN
必须给的参数	簇数 k	eps 与 min_samples
典型几何	紧致、以质心为中心的区域	连通的稠密区域，**包括弯曲形状**
会不会有未指派的观测	**不会**，每个点都拿到标签	**会**，稀疏点可得 −1
主要敏感性	初始化、k、离群点、尺度	邻域参数、密度不均、尺度
簇数从哪来	你指定	由拟合出的密度结构决定
对离群点	会被拽动质心	可以直接标成噪声

★★ Tutorial Q3 的三个场景（直接照着答）

- **预期两个紧致、大小相近的顾客群，而且 k=2 有意义** ⇒ **k-means** 是自然起点；
- **GPS 观测构成不规则形状的路线，还含孤立传感器错误** ⇒ **DBSCAN**，因为它能生长密度相连的形状，并把稀疏观测标为噪声；
- **一个特征以米计、另一个以毫米计** ⇒ **两个算法都受影响**：都依赖距离，数值尺度大的特征会主导，**单位会扭曲相似性时就要缩放。**

★ 参数怎样改变结果（Tutorial Q3 第 4 问的标准答案）

- **增大 k** ⇒ 强制 k-means 分出更多簇；
- **增大 ε** ⇒ 纳入更多邻居，**可能合并** DBSCAN 的簇；**减小 ε** ⇒ 可能制造更多噪声；
- **增大 MinPoints** ⇒ 要求更稠密的区域才能形成核心点。

★★ Tutorial Q3 第 6 问（高分答法）

情形：k-means 结果 silhouette 很高，但跨初始化时成员变化很大，而且分组没有明确的应用含义。

不应该只凭分数接受这个结果。silhouette 是**内部几何证据**：高值支持「紧致且分离」的分组，但**不能证明分组稳定或有意义。**成员变化本身就是**不稳定的证据。**

该补的检查：跨种子/样本/相邻参数重复分析；检视簇的形状与摘要；检查分组是否回答了应用问题。**可辩护的结论要把分数与稳定性、假设、领域证据合起来。**

9. Python 工作流与 Practical 的关键数字


```
kmeans = KMeans(n_clusters=3, init="k-means++", n_init=10, random_state=42)
labels  = kmeans.fit_predict(X)     # kmeans.inertia_ / kmeans.cluster_centers_
dbscan  = DBSCAN(eps=0.35, min_samples=5).fit(X)
core_mask[dbscan.core_sample_indices_] = True
noise_mask  = dbscan.labels_ == -1
border_mask = (~core_mask) & (~noise_mask)
```

输出	含义 / 陷阱
`labels_`	**任意的簇标识符**，不是有序类别
`cluster_centers_`	质心，**在缩放后的特征空间里**
`inertia_`	拟合出的 WCSS；只能在**同一表示**下比较不同 k
`core_sample_indices_`	核心样本的下标；边界点要用 `(~core) & (~noise)` 推出来
簇数	`len(set(labels)) - (1 if -1 in labels else 0)`，**要把噪声那一类减掉**

Practical 跑出来的参考数字（很适合当论据背）

实验	结果
选 k	inertia 从 k=2 的 **288.735** 降到 k=3 的 **73.979**（降 214.756）；再到 k=4 只降 11.398。silhouette 在 k=3 达到 **0.714**（k=2 是 0.502，k=4 是 0.580）⇒ **选 k=3**
eps 扫描（min_samples=5）	eps=0.20 ⇒ 核心 195 / 边界 25 / 噪声 44；eps=0.32 ⇒ 240 / 15 / 9；eps=0.50 ⇒ 256 / 4 / 4
MinPts 扫描（eps=0.32）	min_samples 3 ⇒ 254/5/5；12 ⇒ 199/43/22。**两次都是 3 个簇**
单位干预	原表示：3 簇、9 个噪声 → 把特征 1 乘 100 不重缩放：**1 簇、258 个噪声** → 重新标准化：恢复 3 簇、9 噪声
双月形数据	DBSCAN eps=0.28 得到 2 条弯曲带、0 噪声（silhouette 0.3793）；k-means 得 2 组但横切（silhouette **0.4944，反而更高**）

★★★ 双月形那一组数字是现成的大题素材

silhouette 更偏向 k-means（0.4944 > 0.3793），但应用要的是「连通的弯曲带」，所以该选 DBSCAN。

原因：silhouette 比较的是**簇内平均距离**与**到另一簇的平均距离**。一条弯曲带上相距很远的两点会抬高簇内距离，**哪怕它们属于同一个连通组。**

⚠ 还有两个陷阱：eps=0.15 碎成 19 个簇、52/320 是噪声，它的 0.4835 **只算在 268 个非噪声点上**，和另外两个用全部 320 点算的分数**不是同一个评估总体**；**只剩一个簇时 silhouette 是 NaN**（没有可比的另一个簇），**NaN 不等于质量为零。**

⚠ 关于噪声标签的那一句，答题时最好照抄

「**记录本身的含义没有变，变的是距离表示。**噪声是在所选设置下的算法性标注，**不是记录有误的证明。**」

附录 A • 公式速查表

名称	公式	备注
欧氏距离	$d(x,y) = \sqrt{\Sigma_i (x_i - y_i)^2}$	比大小时**可以不开根号**
质心更新	$\mu_i = (1/m)\ \Sigma_{j=1}^{m}\ x_j$	簇内所有点的均值
WCSS / inertia	$\Sigma_{i=1}^{k}\ \Sigma_{x \in C_\{i\}}\ \|\|x - \mu_i\|\|^2$	是**和**，不是平均
inertia 展开	$\|\|x_i - \mu_r\|\|^2 = \Sigma_{q=1}^{p} (x_{iq} - \mu_{rq})^2$	p 是特征数
ε-邻域	$N_\varepsilon(p) = \{q \mid dist(p,q) \le \varepsilon\}$	**含 p 自己**
核心点	$\|N_\varepsilon(p)\| \ge MinPts$	sklearn 的 min_samples 同样含自己
簇数（含噪声时）	len(set(labels)) − (1 if −1 in labels else 0)	别把 −1 算成一个簇

附录 B • 高频易错点清单

#	易错点	正确做法
1	DBSCAN 邻域忘了把点自己算进去	**永远含自己**；|N| 至少是 1
2	以为边界点能继续扩张簇	**只有核心点能扩张**；边界点进簇即止
3	先被标噪声就当成最终结论	后来出现核心点时**可能转为边界点**
4	比较 k 时看到 inertia 没单调降就以为算错	**全局最优**才单调不增；**实测值**可能因局部极小而波动
5	只凭 inertia 最低选 k	k 越大 inertia 越低，极端时每点一簇为 0 —— 必须配合别的证据
6	用「标签数字不同」来判断两次结果不同	要做**标签无关**的比较：看哪些点仍在一起
7	把 n_init 当成迭代次数	是**完整重跑的次数**，保留 inertia 最低的一次
8	silhouette 高就下结论	它偏好**凸**簇；弯曲/密度型的有用分组会被它低估
9	DBSCAN 算 silhouette 时把噪声点算进去	**要排除 label = −1**，并报告被排除的比例
10	先定 eps 再决定缩放	**先定特征、变换、缩放与距离度量，最后才定 eps**
11	把 −1 解读成「这条记录有错」	它只是「当前设置下未归入稠密区域」
12	k-means 用在弯曲簇上还期待它跟着形状走	它偏好紧致凸区域，**会横切弯曲组**

附录 C • 术语中英对照

英文	中文	一句话
clustering	聚类	在无标签数据中提出分组
centroid	质心	簇内所有点的均值
WCSS / inertia	簇内平方和 / 惯性	到各自质心的平方距离之和
elbow method	肘部法	找「再加簇收益明显变小」的拐点
silhouette coefficient	轮廓系数	(b−a)/max(a,b)，范围 −1 到 1
k-means++	k-means++	把起始质心铺开的初始化方法
n_init	初始化次数	完整重跑几遍，取 inertia 最低
local minimum	局部极小	收敛了但不是全局最优
convex	凸	两点连线仍在区域内；k-means 偏好这种形状
DBSCAN	基于密度的带噪声空间聚类	Density-Based Spatial Clustering of Applications with Noise
eps / ε	邻域半径	多远算「邻居」
MinPts / min_samples	最少点数	成为核心点所需的邻居数（含自己）
core / border / noise point	核心点 / 边界点 / 噪声点	DBSCAN 的三类点
density-reachable	密度可达	能通过核心点链走到
density-connected	密度相连	存在一个点能同时可达两者
label −1	噪声标签	当前设置下未归入任何稠密区域