聚类：k-means 与 DBSCAN

Module 2 · Topic 2 — 题库与解析

ARTI2001 Machine Learning · 2026 Semester 2

共 **12 组 • 60 道选择题**

覆盖：聚类的本质 · k-means 算法与 WCSS · 选 k · 初始化与稳定性

DBSCAN 三类点 · 参数敏感性 · 形式定义 · 两算法对照

Tutorial 与 Practical 的具体数字都做成了题

答案与解析紧跟每一组之后

配套：《M2T2 聚类 知识点整理》

目录

使用方法

第 1 组：什么是聚类（T2-02）

第 2 组：k-means 算法（T2-03）

第 3 组：WCSS 与两步为什么有效（T2-03）

第 4 组：选 k（T2-03 / T2-06）

第 5 组：初始化与稳定性（T2-03）

第 6 组：k-means 的适用性（T2-03）

第 7 组：DBSCAN 的三类点（T2-04）

第 8 组：DBSCAN 参数与 Tutorial Q2（T2-04）

第 9 组：DBSCAN 的形式定义与噪声标签（T2-04）

第 10 组：k-means 与 DBSCAN 的对照（T2-05）

第 11 组：Practical 的证据（双月形与单位干预）

第 12 组：综合与评估（T2-05 / T1-04）

使用方法

每组 5 题，题目与选项在前，答案与解析在该组末尾。建议先遮住解析区独立作答，整组做完再核对。做错的题回到《M2T2 聚类 知识点整理》对应章节复习。

组标题后括号里是对应的 Canvas 讲义页编号，方便回查。

第 1 组：什么是聚类（T2-02）

1. 聚类与分类最根本的差别是什么？

A. 聚类只能处理数值特征，而分类可以处理类别特征
B. 聚类没有已知的类标签要去复现，分类有
C. 聚类不需要选择任何参数，分类需要调很多参数
D. 聚类一定比分类更快，因为不用计算损失函数

2. 「相似」在聚类里应当被理解成什么？

A. 数据本身固有的客观属性，与方法无关
B. 由欧氏距离唯一确定的数学量
C. 一个建模选择，取决于特征、缩放与距离假设
D. 只要特征相同，任何算法都得到相同的相似度

3. 两位顾客年度消费相同但购买频率差别很大，表示里只有「年度消费」。后果是：

A. 算法用不上频率来区分他们，两人会被当作相似
B. 算法会自动推断出频率这个特征并加以利用
C. 两人一定会被分到不同的簇里去
D. 需要增加簇数 k 才能把他们分开

4. 两位分析者从同一批行得到了不同的簇，最可能的解释不包括：

A. 他们选了不同的特征子集
B. 他们对特征做了不同的缩放
C. 他们用了不同的算法或参数设置
D. 数据行在两次分析之间被人为改动过了

5. 一个拟合出来的聚类划分，应当被当作什么？

A. 数据里客观存在的真实分组
B. 基于模型的提案，需要用多种证据去验证
C. 可以直接用作标签的监督学习训练集
D. 只要内部分数高就无需再解释的结论

答案与解析

1. B —— 分类有 known class labels to reproduce；聚类没有。⚠ 但聚类也不是在自动搜索唯一正确的分组 —— 分析者仍要选表示、相似度、算法与参数。

2. C —— Similarity is a MODELLING CHOICE rather than an inherent property of the data。

3. A —— 讲义的原例。而且若消费以美元计、频率只在 1 到 20 之间，**未缩放的欧氏距离会被消费主导** —— 加入并适当缩放频率就改变了「相似」的含义。

4. D —— 前三项正是讲义列出的建模选择。第四项属于数据问题，不是「同一批行」这个前提下的解释。

5. B —— 原文：a fitted partition should be treated as a model-based proposal rather than automatically as the 'true' groups。

第 2 组：k-means 算法（T2-03）

1. k-means 的指派步做的是什么？

A. 按密度把点分成核心点与边界点两类
B. 把每个质心移动到它所属点的均值位置上
C. 把每个点归给当前离它最近的那个质心
D. 随机重新打乱所有点的簇标签再重新计算

2. k-means 的更新步把新质心定在哪里？

A. 被指派进来的点里离中心最近的那个观测上
B. 上一轮质心与本轮点集的加权折中位置上
C. 被指派进来的点的中位数位置上
D. 所有被指派进来的点的均值位置上

3. 手算 k-means 的指派步时，为什么可以不开平方根？

A. 因为平方是单调变换，比大小的结果完全一样
B. 因为平方根运算在计算机里不精确，会引入误差
C. 因为欧氏距离的定义本来就不含平方根运算
D. 因为质心更新步会把平方根的影响抵消掉

4. k-means 的停止条件不包括下列哪一项？

A. 指派不再发生变化
B. 质心位置稳定下来
C. WCSS 下降到某个绝对阈值以下
D. 达到预设的最大迭代次数

5. 四个一维观测 {1, 2, 8, 9}，k=2，初始质心 1 和 8。一轮之后新质心是：

A. 1.5 和 8.5
B. 1 和 8（不变）
C. 2 和 8
D. 1.5 和 8

答案与解析

1. C —— 指派步算每个点到每个质心的欧氏距离，归给最近的。更新步才是把质心移到均值。

2. D —— $\mu_i = (1/m)\Sigma x_j$。⚠ 是**均值**不是中位数 —— 这也正是「均值最小化平方距离之和」的那条性质。

3. A —— 指派只是比大小，d 与 d^2 的排序一致。Tutorial 的参考答案也是直接比平方距离。

4. C —— 前三项是讲义列的三个停止条件。WCSS 的绝对值随数据尺度而变，没有通用阈值。

5. A —— 指派后 C1={1,2}、C2={8,9}；均值分别是 1.5 和 8.5。此时 WCSS = 0.25×4 = 1，再指派分组不变，已收敛。

第 3 组：WCSS 与两步为什么有效（T2-03）

1. WCSS（inertia）的定义是什么?

A. 各簇质心之间两两距离的平方和
B. 每个观测到最近的另一个簇质心的平方距离之和
C. 每个观测到全体数据均值的平方距离之和
D. 每个观测到其所属簇质心的平方距离之和

2. 为什么指派步不会增加 WCSS?

A. 因为质心在这一步保持不动，距离自然不变
B. 因为每个观测都被指派给当前离它最近的质心
C. 因为簇的数量 k 在整个过程中保持固定
D. 因为平方距离的和总是非负的

3. 为什么更新步不会增加 WCSS?

A. 因为每个簇的点数在更新步里保持不变
B. 因为更新步只移动质心，不改变任何点的归属
C. 因为新质心一定落在原质心和数据中心之间
D. 因为均值正是让簇内平方距离之和最小的那个点

4. 重复指派与更新，k-means 收敛到什么?

A. 全局最小值
B. 一个鞍点
C. 一个局部解，不一定是全局最小
D. 一个随 k 增大而单调改善的解

5. 「inertia 低」能说明什么?

A. 在所选特征、缩放和这个 k 下，观测离各自质心近
B. 拟合出的分组一定对应真实世界的自然类别
C. 各簇之间的分离程度一定很好
D. 这个 k 的取值一定比别的 k 更合适

答案与解析

1. D —— WCSS = $\Sigma_i \Sigma_{x \in C_i} d(x, \mu_i)^2$。它是**和**不是平均，而且只看「到自己簇的质心」。

2. B —— 每个点都换到（或留在）最近的质心上，它那一项只会变小或不变。

3. D —— THE MEAN IS THE POINT THAT MINIMISES the sum of squared distances within a fixed cluster。⚠ 「不改变归属」是事实但不构成理由。

4. C —— Repeating these steps converges to a LOCAL solution。这正是要多次初始化的原因。

5. A —— 目标函数只保证紧致性，**不显式最大化簇间分离**，也不证明分组有意义。

第 4 组：选 k（T2-03 / T2-06）

1. 关于 inertia 随 k 的变化，正确的说法是：

A. 实测的 inertia 一定随 k 增大而单调下降
B. 全局最优的 inertia 不会随 k 增大而上升，但实测值可能因局部极小而波动
C. inertia 与 k 之间没有任何系统性关系
D. inertia 随 k 增大而上升，所以要选小的 k

2. 为什么不能只用「inertia 最低」来选 k?

A. 因为 inertia 的计算复杂度太高，算不动大的 k
B. 因为 inertia 只在 k 为偶数时才有定义
C. 因为 inertia 的量纲与特征单位无关，不可比较
D. 因为 k 越大 inertia 越低，极端时每点一簇为 0

3. 肘部法应当被当作什么?

A. 一条能自动给出正确 k 的规则
B. 一个诊断手段，而且有些数据根本没有明显肘部
C. 只在 silhouette 不可用时才使用的替代品
D. 一种衡量簇间分离程度的内部度量

4. 讲义示例表里 k=2/3/4 的 silhouette 是 0.58/0.64/0.52，inertia 是 142/76/55。可辩护的选择是：

A. k=2，因为 inertia 最高说明分组最粗、最稳健
B. k=4，因为 inertia 最低说明拟合得最好
C. k=3，因为 silhouette 最好且 inertia 下降最有用
D. 三者都不可选，需要换用 DBSCAN 重做

5. 选更大的 k 可能带来的问题是：

A. 额外的细分可能不稳定、难解释或与应用无关
B. 簇内变异一定会上升，拟合变差
C. 必然导致某些簇变成空集
D. 会使 silhouette 必然下降到负值

答案与解析

1. B —— 讲义特意澄清过这两句的区别。所以要用多次初始化，再把肘部、silhouette、稳定性合起来看。

2. D —— 加质心给了模型更多自由。Practical 里的话：with one centroid per observation it reaches zero。

3. B —— Some datasets have no clear elbow, so this is a diagnostic rather than an automatic rule。

4. C —— 但讲义补了一句：**仍应跨初始化或跨样本复核，并对照应用含义。**

5. A —— 更小的 k 会把值得区分的模式合并；更大的 k 则可能细分出没用的组。**哪个值都不是自动正确的，有用的粒度取决于要支持的决策。**

第 5 组：初始化与稳定性（T2-03）

1. k-means++ 做的是什么?

A. 先用层次聚类求出一组起始质心再交给 k-means
B. 从数据里选第一个质心，之后偏好离已选质心更远的点
C. 把所有质心都初始化在数据的整体均值附近
D. 按特征的方差大小依次挑选最分散的那些观测

2. scikit-learn 里的 `n_init=10` 意思是:

A. 内部的指派/更新迭代最多做十轮就强制停止下来
B. 在每一次指派步里，最多只考察十个候选质心位置
C. 用不同种子完整跑十次 k-means，保留 inertia 最低的那次
D. 把数据随机切成十份，做一次十折交叉验证来选 k

3. A=(0,0) B=(0,2) C=(4,0) D=(4,2)，k=2。运行 1 标签是 0,0,1,1，运行 2 是 1,1,0,0。它们:

A. 成员完全相同，只是标签号互换了，inertia 都是 4
B. 是两个不同的局部解，inertia 也不同
C. 运行 2 比运行 1 更优，因为标签顺序更自然
D. 无法比较，因为标签编号不一致

4. 同一组四个点，运行 3 得到 {A,C} 与 {B,D}，inertia 是多少?

A. 4
B. 8
C. 32
D. 16

5. 「重复随机种子」与「重采样观测」这两种稳定性检查的区别是:

A. 两者都只能用于 DBSCAN，不适用于 k-means
B. 前者查抽样稳定性，后者查优化敏感性
C. 两者查的是同一件事，可以互相替代
D. 前者查优化敏感性，后者查抽样稳定性

答案与解析

1. B —— 这把起始质心铺开在整个数据集上，通常比随意摆放给出更好的起点。

2. C —— ⚠ 这是高频陷阱：**它不是迭代次数。**而且默认值随版本而变，要可复现就显式写出来。

3. A —— 质心都是 (0,1) 与 (4,1)，四个平方距离各为 1，合计 4。**⚠ 单纯数「标签不一样的点」会把它们错判成不同。**

4. D —— 质心是 (2,0) 与 (2,2)，每个点到质心的平方距离都是 4，合计 16。这是一个**不同且更差的局部解** —— 尽管它在继续更新下也保持稳定。

5. D —— Repeating seeds probes OPTIMISATION sensitivity, while resampling observations probes SAMPLING stability。**两者都不能单独确立领域有用性。**

第 6 组：k-means 的适用性（T2-03）

1. k-means 偏好什么形状的簇？

A. 任意形状，包括弯曲和环形的结构
B. 密度相同但形状可以任意的连通区域
C. 紧致、凸、以质心为中心的区域
D. 沿某个特征轴高度拉长的细条形区域

2. 离群点对 k-means 的影响是：

A. 会被自动标记为噪声而排除在外
B. 会把均值质心从簇的主体拽走
C. 只影响 inertia 的数值，不影响质心位置
D. 会使算法无法收敛，一直迭代下去

3. 一个特征的数值范围比另一个大得多时，会发生什么？

A. 大范围的特征会主导欧氏距离
B. 两个特征的贡献会被算法自动均衡掉
C. 小范围的特征会因为数值小而权重更大
D. 只要用 k-means++ 初始化就不受影响

4. 下列哪种情形最不适合 k-means？

A. 两个紧致、大小相近的点云，k=2 有明确含义
B. GPS 轨迹构成的不规则弯曲路线，并含孤立传感器错误
C. 特征已标准化、簇大致为球形的中等规模数据
D. 二维高斯生成的三个分离良好的簇

5. 「质心是一个有意义的摘要」这个前提失效的典型情形是：

A. 各组的大小、散布或密度差别很大
B. 簇内样本数量很大，统计量很稳定
C. 所有特征都已经做过标准化处理
D. 特征数远小于观测数，维度不高

答案与解析

1. C —— 它的平方距离目标决定了这一点，**会横切弯曲或非凸的组**。

2. B —— ⚠ 「自动标为噪声」是 DBSCAN 的能力，k-means **每个点都必须有标签**。

3. A —— 标准化是有用的基线，**但缩放应当反映领域含义**，不是无脑动作。

4. B —— 弯曲形状 + 孤立噪声正是 DBSCAN 的场景：它能生长密度相连的形状并把稀疏观测标为噪声。

5. A —— 大小/散布/密度差别大时，用一个质心表示每组会很差。

第 7 组：DBSCAN 的三类点（T2-04）

1. DBSCAN 里「核心点」的判据是什么？

A. 它到最近质心的距离小于 eps
B. 它的 eps-邻域里不含任何噪声点
C. 它自己的 eps-邻域里至少有 MinPts 个观测
D. 它是某个簇里密度最高的那一个观测

2. 「边界点」的定义是：

A. 它是簇里离质心最远的那个观测
B. 它位于两个簇的正中间位置上
C. 它的邻域里恰好有 MinPts − 1 个观测
D. 它在某个核心点的邻域内，但自己不是核心点

3. 关于簇的扩张，正确的说法是：

A. 核心点和边界点都可以继续扩张簇
B. 只有核心点能继续密度可达链，边界点进簇即止
C. 只有边界点能把簇扩张到稀疏区域
D. 扩张与点的类型无关，只取决于访问顺序

4. 一个点先被标成噪声，后来可能变成什么？

A. 可能变成边界点，当附近的核心点被发现并扩张过来
B. 永远保持噪声，标签一旦给出就不再改变
C. 可能变成核心点，当 eps 被自动调大之后
D. 会被算法从数据集中剔除掉

5. eps = 0.6、MinPts = 3，五个一维点 A=0, B=0.5, C=1.0, D=3.0, E=3.4。C 的角色是：

A. 核心点，因为它邻域里有 3 个点
B. 核心点，因为它位于簇的中间位置
C. 噪声点，因为它邻域里不足 MinPts
D. 边界点，因为它邻域只有 {B,C} 但落在核心点 B 的邻域内

答案与解析

1. C —— ⚠ 邻域**包含点自己**；sklearn 的 min_samples 也是把该点算在内的，和本课约定一致。

2. D —— ⚠ 选项 C 听起来对，但判据是「在核心点邻域内」，和自己邻域里差几个没有直接关系。

3. B —— BORDER POINTS JOIN THE CLUSTER BUT DO NOT EXPAND IT。这是必考点。

4. A —— A provisional noise label is not final。这解释了为什么访问顺序会影响中间状态。

5. D —— $|C-B| = 0.5 \le 0.6$ 而 $|C-A| = 1.0 > 0.6$，所以 $N(C) = \{B,C\}$，只有 2 个 < 3。但 B 是核心点且 C 在 B 的邻域内 ⇒ 边界点。

第 8 组：DBSCAN 参数与 Tutorial Q2（T2-04）

1. eps 设得太小会怎样?

A. 本来不同的稠密区域被合并成一个大簇
B. 所有点都变成核心点，不再有噪声
C. 稠密区域碎裂，很多观测留着没被指派
D. 算法的时间复杂度急剧上升到不可用

2. MinPts 设得太大会怎样?

A. 微弱的局部模式也会被当成簇
B. 簇的数量一定会增加
C. 边界点会全部升格成核心点
D. 真实的较小或较低密度的组会留着没被指派

3. Tutorial Q2：A=(2,2) B=(3,3) C=(3,4) D=(4,3) E=(8,7) F=(9,8)，ε=2，MinPoints=3。核心点是:

A. 只有 B
B. B 和 C 两个
C. B、C、D 三个
D. A、B、C、D 四个

4. 同一题里，A、E、F 的角色分别是:

A. A 核心，E 边界，F 边界
B. A 边界，E 噪声，F 噪声
C. A 噪声，E 边界，F 核心
D. A 边界，E 核心，F 边界

5. DBSCAN 在什么情况下会特别吃力?

A. 真实的簇之间密度差别很大
B. 观测数非常多，超过十万条
C. 特征数只有两个，无法可视化
D. 数据里没有任何离群点

答案与解析

1. C —— 反过来，eps 太大则会把本来不同的稠密区域合并。

2. D —— MinPts 太小才会把微弱的局部模式当成簇。

3. C —— N(B)={A,B,C,D} 有 4 个；N(C)={B,C,D} 和 N(D)={B,C,D} 各 3 个，都 ≥ 3。A 的邻域只有 {A,B} 共 2 个，所以 A 不是核心点。

4. B —— A 在核心点 B 的邻域内但自己不是核心 ⇒ 边界。E、F 互为邻居但只有 2 个，且不在任何核心点邻域内 ⇒ 噪声。最终：Cluster 1 = {A,B,C,D}，noise = {E,F}。

5. A —— 因为**一组全局的 eps 与 MinPts 可能描述不好所有区域**。这是它的结构性弱点。

第 9 组：DBSCAN 的形式定义与噪声标签（T2-04）

1.「q 从 p 直接密度可达」的完整条件是：

A. q 在 N_ε(p) 内即可
B. p 与 q 互相在对方的 ε-邻域内
C. p 在 N_ε(q) 内，并且 q 是核心点
D. q 在 N_ε(p) 内，并且 p 是核心点

2.「p 与 q 密度相连」的定义是：

A. p 与 q 互相直接密度可达
B. 存在一个点 o，使 p 与 q 都从 o 密度可达
C. p 与 q 之间的距离不超过 ε
D. p 与 q 属于同一个核心点的邻域

3. DBSCAN 的 label −1 应该被解读成什么？

A. 在当前设置下未被指派到任何稠密区域
B. 这条记录存在测量错误，应当删除
C. 这个观测是统计意义上的真实异常值
D. 这个观测离所有质心的距离都超过了阈值

4. 一个边界点落在不止一个簇的可达范围内时，会怎样？

A. 算法会报错，要求用户调整参数
B. 它会被自动改判为噪声点
C. 它最终归谁可能取决于遍历顺序
D. 它会同时属于两个簇，标签是一个列表

5. 决定 eps 的正确时机是：

A. 在选定特征与缩放之前先定好 eps
B. 与 MinPts 同时随机搜索，不依赖表示
C. 在决定特征、变换、缩放与距离度量之后
D. 在拟合完成、看到噪声比例之后再回头改

答案与解析

1. D —— ⚠ 只说「在邻域内」是不够的，**必须 p 是核心点**。这正是边界点不能扩张簇的形式化原因。

2. B —— 簇的「连通性」条件用的就是这个关系：簇内任意两点都密度相连。

3. A —— 原文很克制：这是在那组设置下的**算法性标注**，不是「观测有误或是真实异常」的已验证陈述。

4. C —— **而核心点构成的连通集合要稳定得多** ⇒ 对孤立的边界点归属要谨慎解读。

5. C —— Choose eps ONLY AFTER deciding the features, transformations, scaling and distance metric —— 因为 **eps 的数值含义随表示而变**。

第 10 组：k-means 与 DBSCAN 的对照（T2-05）

1. 两个算法必须给的参数分别是：

A. k-means 需要给邻域半径 eps，DBSCAN 需要给簇数 k
B. k-means 给 k，DBSCAN 给 eps 与 min_samples
C. 两者都只需要事先给定簇数 k，别的参数可用默认值
D. 两者都只需要给定邻域半径 eps，簇数会自动确定

2. 关于「未被指派的观测」，两者的差别是：

A. k-means 会留下未指派的点，DBSCAN 不会
B. 两者都强制每个点必须属于某个簇
C. 两者都会把稀疏点标为噪声
D. k-means 每个点都有标签，DBSCAN 可以留 −1

3. 一个特征以米计、另一个以毫米计，会影响哪个算法?

A. 两个算法都受影响，因为都依赖距离
B. 只影响 k-means，DBSCAN 用密度不受影响
C. 只影响 DBSCAN，k-means 的质心会自动归一
D. 两个都不受影响，只要簇数设置正确

4. 参数变化的后果，下列哪一项说错了?

A. 减小 ε 会让更多点升格为核心点，噪声减少
B. 增大 ε 会纳入更多邻居，可能合并 DBSCAN 的簇
C. 增大 MinPoints 要求更稠密的区域才能形成核心点
D. 增大 k 会强制 k-means 分出更多簇

5. DBSCAN 的主要敏感性来源是：

A. 初始化与随机种子
B. 簇数 k 的选择
C. 邻域参数、密度不均与尺度
D. 质心的初始位置

答案与解析

1. B —— DBSCAN 的簇数是由拟合出的密度结构决定的，不需要预先给。

2. D —— 这正是 Team A（必须指派每条记录）选 k-means、Team B（可以挑出异常人工复核）选 DBSCAN 的理由。

3. A —— Tutorial Q3 的标准答案：Both algorithms depend on distances，数值尺度大的特征会主导，**单位会扭曲相似性时就要缩放。**

4. A —— **减小 ε 恰恰会制造更多噪声**：邻域变小，够不上 MinPts 的点变多。

5. C —— 初始化敏感性是 k-means 的问题；DBSCAN 没有随机初始化这一步（但有遍历顺序影响边界点）。

第 11 组：Practical 的证据（双月形与单位干预）

1. 双月形数据上，k-means 的 silhouette 是 0.4944，DBSCAN(eps=0.28) 是 0.3793。应该选哪个?

A. k-means，因为 silhouette 更高
B. 取决于哪个运行时间更短
C. 两个都不选，应当换用 GMM
D. DBSCAN，因为应用要的是连通的弯曲带

2. 同一组实验里 eps=0.15 碎成 19 个簇、52/320 是噪声，它的 silhouette 0.4835 为什么不可直接比较?

A. 因为簇数太多导致 silhouette 失去定义
B. 因为它只算在 268 个非噪声观测上，评估总体不同
C. 因为噪声点的 silhouette 一律记为 −1
D. 因为 eps 太小时距离计算会溢出

3. eps=0.60 把两条带合并成一个簇，它的 silhouette 是 NaN，原因是:

A. 只剩一个簇，没有可比的另一个簇
B. 所有点都变成了噪声点
C. 簇内距离全部为零导致除零
D. 合并后的簇不是凸集

4. 把特征 1 乘以 100 而不重新缩放，DBSCAN(eps=0.32) 的结果从「3 簇 9 噪声」变成:

A. 3 簇 9 噪声（不变）
B. 5 簇 0 噪声
C. 1 簇 258 噪声
D. 0 簇 320 噪声

5. Practical 里选 k 的证据是：inertia 从 k=2 的 288.735 降到 k=3 的 73.979，再到 k=4 只降 11.398；silhouette 在 k=3 达 0.714。结论是:

A. 选 k=2，因为它最简单
B. 证据不足，无法做出任何选择
C. 选 k=4，因为 inertia 仍在下降
D. 选 k=3，肘部与 silhouette 一致指向它

答案与解析

1. D —— **silhouette 偏好凸簇**：弯曲带上相距很远的两点会抬高簇内平均距离，哪怕它们属于同一连通组。这个度量偏好的几何与应用要求不一致。

2. B —— Omitting difficult points can alter a score, so these are not identical evaluation populations。

3. A —— 整体分数要求簇数在 2 到 n−1 之间。⚠ **NaN 不等于质量为零。**

4. C —— 距离被那个坐标主导而 eps 没变。重新标准化后恢复成 3 簇 9 噪声。**记录本身的含义没变，变的是距离表示。**

5. D —— 两个诊断量加上「三个可见的点云」合起来支持这个选择。**但仍需重复初始化/重采样来确认稳定性。**

第 12 组：综合与评估（T2-05 / T1-04）

1. silhouette 很高，但跨初始化成员变化很大、分组没有应用含义。应该怎么办？

A. 接受这个结果，因为内部分数已经足够高
B. 不接受，成员变化是不稳定的证据，还需补稳定性与领域检查
C. 直接增大 k，直到成员不再变化为止
D. 换成 DBSCAN，因为它没有初始化问题

2. 比较两次聚类结果时，正确的做法是：

A. 逐个比较观测的数字标签是否相同
B. 比较两次的簇标签排序后的字典序
C. 做标签无关的比较，看哪些观测仍然待在一起
D. 只比较两次的 inertia 数值大小

3. 对 DBSCAN 结果算 silhouette 时，必须注意什么？

A. 把噪声点也算进去，否则样本不完整
B. 把 eps 调到不产生噪声为止再计算
C. 先把噪声点合并成一个额外的簇再计算
D. 排除噪声点（label = −1），并报告被排除的比例

4. 聚类结果用在后续预测流程里时，缩放器应该怎么拟合？

A. 在全部数据上拟合一次，训练和测试共用
B. 只在训练数据上拟合，再应用到后续数据
C. 分别在训练集和测试集上各拟合一次
D. 不需要拟合，直接用固定的经验参数

5. 一个有说服力的聚类结论，最少需要几类证据？

A. 不止一个信号：内部证据 + 稳定性 + 假设 + 领域有用性
B. 只要有一类证据、且那个分数足够高，就可以下结论
C. 必须把所有可用的内部度量全部算一遍并逐一报告
D. 只需要内部证据与算法运行时间这两类就已经足够

答案与解析

1. B —— Tutorial Q3 第 6 问的标准答法：silhouette 是**内部几何证据**，不能证明分组稳定或有意义。要跨种子/样本/相邻参数重复、检视形状与摘要、检查应用问题。

2. C —— A LABEL-INVARIANT comparison is needed —— 否则会把「只是标签号互换」的两次结果错判成不同。

3. D —— 还要检查剩下的数据仍满足「簇数在 2 到 n−1 之间」这个条件。

4. B —— 这是 M2 三个主题通用的防泄漏规则。

5. A —— A convincing result normally needs more than one signal。**一个高分本身不能证明簇对应真实世界的真相。**