高斯混合模型与 EM

Module 2 · Topic 3 — 知识点完整整理

ARTI2001 Machine Learning · 2026 Semester 2

涵盖：**Canvas 讲义 T3-01 ~ T3-06**（T3-04 被官方标为「最核心的一页」）
Tutorial 三问 + 扩展的完整官方解答
六个完整手算例题：责任度、简化 M 步、完整一轮 EM（含对数似然校验）…
AIC/BIC 模型选择：参数计数规则与讲义的完整对照表
Practical 参考数字：含「对称初始化卡死」这一经典诊断
附录：公式速查 · 16 条易错点 · 术语中英对照

配套：《M2T3 GMM 与 EM 题库与解析》《M2 评估与模型选择》

目录

1. 路线图与考核边界

2. 前置：概率 vs 密度

- 高斯的两个参数与记号陷阱
- ★★★ 概率是面积、密度是高度
- 混合权重：加的是高度
- 手算例题 1：2.5 kg 的包裹
- 加权平均与分数计数

3. ★ 模型与记号（最核心的一页）

- 混合模型与高斯密度
- ★ 隐变量 z 与责任度 r 的区别
- 协方差类型四选一

4. ★★★ EM 算法：两个更新步

- 要最大化的量与取对数的理由
- E 步：估计责任度
- M 步：有效计数与四条更新公式

5. 手算例题（讲义三个 + Tutorial 三题）

- 例 2 混合密度与责任度
- 例 3 简化的 M 步（五步）
- 例 4 完整一轮 EM（含似然校验）
- 例 5 Tutorial Q1&Q2
- 例 6 Tutorial Q3 诊断错误的 M 步
- 扩展：从 GMM 抽样

6. 选成分数：AIC 与 BIC

- ★★★ 参数计数规则 $p = 3K - 1$
- 讲义的完整对照表与验算

7. GMM 与 k-means 的对照

8. Python 工作流与 Practical 的关键数字

- ★★★ 对称初始化为什么会卡死

9. 四条收尾警告

附录 A · 公式速查表

附录 B · 16 条高频易错点

附录 C · 术语中英对照

1. 路线图与考核边界 T3-01

GMM 是一个概率密度模型：把数据分布表示成若干高斯成分的**加权混合**。因为每个观测对每个成分都有一个后验**责任度**，而不只是一个硬指派，所以它能支持**软聚类**。

> **★★ 开篇就要钉死的一句话**
>
> **GMM 不是「k-means 的高级版」**。两者优化的是**不同的目标**，做的是**不同的建模假设**。
>
> **而且拟合出来的成分也不自动就是自然的、有意义的簇**；它的解释要靠模型拟合、稳定性与领域证据来支撑。

> **★ 考核边界（讲义原文 ASSESSMENT FOCUS）**
>
> **要理解并应用 E 步与 M 步；但详细的收敛性证明不在考核范围内。**
>
> **把 BIC/AIC 和拟合出的成分当作「证据」，而不是「自然分组存在」的证明。**

六条学习成果

1. 把 GMM 解释为一个能支持软聚类的概率密度模型；
2. 解释混合权重、成分均值与协方差参数；
3. **计算并解释**某个数据点的成分责任度；
4. 解释 EM 算法的 E 步与 M 步；
5. 比较 GMM 的责任度与 k-means 的硬指派；
6. 拟合 GMM 并用 BIC/AIC 之类的证据比较成分数。

2. 前置：概率 vs 密度（这一节不过关，后面全乱） T3-02

高斯分布的两个参数

参数	作用	⚠ 注意
均值 μ	**中心**。增大均值，曲线整体右移	—
标准差 σ	**散布**。σ 越大，曲线**越宽、峰越矮**（因为总面积恒为 1）	方差是 σ^2，单位是平方的

$$f(x) = N(x \mid \mu, \sigma^2) = (1 / (\sigma\sqrt{(2\pi)})) \cdot \exp(-(x-\mu)^2 / (2\sigma^2)), \quad \sigma > 0$$

⚠⚠ **记号陷阱（讲义反复提醒，极易出选择题）**

- **N(x | μ, σ²) 的第二个参数是「方差」σ²，不是标准差**；
- **NumPy 的 `rng.normal(loc=…, scale=…)` 里的 `scale` 是「标准差」**；
- **sklearn 的 `gmm.covariances_` 装的是「方差」**（一维时）；
- 公式里 2π 的 π 是**圆周率常数**，和混合权重 π_k **完全是两码事。**

★★★ 概率是面积，密度是高度

	概率 probability	密度 density
是什么	某个**事件**发生的机会	曲线在某个值处的**高度**
取值范围	0 到 1	**可以大于 1**
怎么得到	对区间**求面积（积分）**	把 x 代进密度公式
单位	无单位	有单位（比如「每千克」）

$P(a \le X \le b) = \int_a^b f(x)dx$，$f(x) \ge 0$，$\int_{-\infty}^{+\infty} f(x)dx = 1$

$P(X = x) = 0$　　（连续模型下，单个精确值的概率是 0）

⭐ **讲义的包裹例子，数字很好记**

均值 2 kg、标准差 0.25 kg 的高斯：**峰值密度 ≈ 1.596 每千克。**

这是合法的密度，不是「160% 的概率」。

窄区间时 概率 ≈ 密度 × 区间宽度：2 kg 附近 0.01 kg 宽的区间，概率 ≈ 1.60 × 0.01 = **0.016。**

区间 1.75–2.25 kg 下的面积 ≈ **0.683**（68.3%）。

⚠ **「秤显示 2.00 kg」为什么又有正概率**

因为那个读数代表一个**舍入区间**（比如 1.995–2.005），区间有宽度，所以面积不为零。

混合权重：加的是「高度」，不是「观测」

两个成分：A 的均值 2 kg、标准差 0.25 kg；B 的均值 3 kg、标准差 0.40 kg。令 A 的混合权重 0.6、B 的 0.4。模型想象的是：**以 0.6 的概率选中 A、0.4 的概率选中 B，然后从被选中的那个高斯里抽一个重量。**

混合密度 $f(x) = 0.6 \cdot f_A(x) + 0.4 \cdot f_B(x)$

一般地：$f(x) = \Sigma_{k=1}^{K} \pi_k f_k(x)$，$\pi_k \ge 0$，$\Sigma_k \pi_k = 1$

⚠ 最常见的误解

我们是在同一个 x 处把曲线高度相加；**不是**把两个包裹的重量平均起来造出一个观测。

加权后的 A 曲线面积是 0.6，加权后的 B 曲线面积是 0.4，**混合曲线面积是 1。**

从先验到后验：责任度就是贝叶斯

$$r_k(x) = P(Z = k \mid X = x) = \pi_k f_k(x) / \Sigma_j \pi_j f_j(x) = \pi_k f_k(x) / f(x)$$

手算例题 1 • 一个 2.5 kg 的包裹

量	成分 A	成分 B
先验混合权重	0.6	0.4
2.5 kg 处的高斯密度	0.2160 每 kg	0.4566 每 kg
权重 × 密度	0.1296	0.1826

① 相加得混合密度

$$0.1296 + 0.1826 = 0.3122 \text{ 每 kg}$$

② 各自除以总和

$$r_A \approx 0.1296 / 0.3122 \approx 0.415$$
$$r_B \approx 0.1826 / 0.3122 \approx 0.585$$

★★ 这题的考点

B 的先验权重更小（0.4 < 0.6），但它的责任度反而更大。

因为**责任度 = 先验权重 × 成分密度，再归一化** —— B 在 2.5 kg 处的密度高得多，压过了它较小的先验。

责任度**没有单位**，而且**加起来等于 1。**

加权平均与「分数计数」

普通均值：$\bar{x} = (1/N) \Sigma_i x_i$

加权均值：$\bar{x}_w = \Sigma_i w_i x_i / \Sigma_i w_i$

★★★ M 步的全部思想就在这里

一个成分均值的分母，是「它自己的责任度之和」，不是自动等于观测个数。

例：两个包裹 2 kg 和 3 kg，对成分 A 的责任度是 0.8 和 0.2。

> $N_A = 0.8 + 0.2 = 1$，$\mu_A = (0.8\times 2 + 0.2\times 3) \,/\, 1 = 2.2\ \text{kg}$

结果更靠近 2 kg，因为那个观测贡献得更多。**每个观测贡献的是「一个计数的一部分」，没有哪个包裹被物理地切开。**

3. ★ 模型与记号（官方标为「最核心的一页」）

T3-04

符号	含义
N, i, x_i	共 N 个观测；i 标识一个观测，它的测量值/特征向量是 x_i
K, k	共 K 个高斯成分；k 标识一个成分
π_k	**混合权重**：成分 k 的**先验**概率，**所有观测共用**；各权重之和为 1
μ_k, σ_k^2, Σ_k	成分均值；单特征时的方差；多特征时的协方差矩阵
r_{ik}	**责任度**：在观测到 x_i 并给定当前模型的条件下，成分 k 生成它的概率。**对每个观测，各成分的责任度加起来是 1**
N_k	**有效计数**：把成分 k 的责任度在所有观测上相加。**这是一个分数，不一定是整数**

⚠ 四对必须分清的符号

- **N 是一个计数**，而花体 N 表示**高斯密度**；
- **2π 里的 π 是常数**，**π_k 是混合权重**；
- **对 i 求和 = 把「观测」合起来**；**对 k 求和 = 把「成分」合起来**；
- **π_k 是成分级的先验**，**r_{ik} 是观测级的后验** —— 这两个最容易混。

混合模型

$$p(x) = \Sigma_{k=1}^{K} \pi_k \cdot N(x \mid \mu_k, \Sigma_k)$$
$$N(x \mid \mu_k, \Sigma_k) = 1/((2\pi)^{d/2}|\Sigma_k|^{1/2}) \cdot \exp[\ -½\ (x-\mu_k)^T\ \Sigma_k^{-1}\ (x-\mu_k)\ ]$$

一维时就化简成：

$$N(x \mid \mu_k, \sigma_k^2) = 1/\sqrt{(2\pi\sigma_k^2)} \cdot \exp[\ -(x-\mu_k)^2\ /\ (2\sigma_k^2)\ ]$$

⭐ 怎么读这个公式（答简答题时照着说）

减均值 → 平方 → 除以两倍方差 → 取负指数；前面那个因子让总面积等于 1。

固定方差时，**离均值越近密度越高。**多特征时，**Σ_k 描述各特征的散布以及它们之间的关系**：行列式 $|\Sigma_k|$ 进入归一化因子，逆 Σ_k^{-1} 按成分的散布去缩放那个平方距离。

公式假设 **Σ_k 是正定的。**

★ 隐变量 z 与责任度 r 的区别

生成模型里，每个 x_i 都带着一个**未观测**的成分指示变量 z_i。在 1-of-K 表示下，z_i 是一个 K 维向量，**只有一个 1、其余是 0。**

K = 3 时：x_1 来自成分 1 ⇒ z_1 = [1, 0, 0]；x_2 来自成分 3 ⇒ z_2 = [0, 0, 1]。**在观测到 x_i 之前**，混合权重 π_k = $p(z_{ik} = 1)$ 就是成分 k 的先验概率。

★★★ 观测之后并不是「把隐变量换成已知标签」

我们算的是一个后验概率： $r_{ik} = p(z_{ik} = 1 \mid x_i)$

- **z_i 是生成模型里那个未观测的 one-hot 状态**；
- **r_{ik} 是观测之后我们得到的「软」后验成员度**，对每个观测 $\Sigma_k r_{ik} = 1$。

⚠ 「成分」不等于「簇」

数学上推断的是**隐藏的成分状态与后验责任度。把这些成分叫做「簇」是一个建模解释。**

由似然、BIC 或 AIC 选出的成分数，不证明总体里存在同样数目的自然分组。

协方差类型：四选一（在拟合之前就要定）

类型	大白话	二维形状与取舍
spherical	每个成分**一个方差**，所有特征共用，特征间协方差为 0。不同成分可以有不同方差	**圆**，大小可不同。简单，但表示不了拉长或倾斜的点云
diag	每个成分对**每个特征**各有一个方差；**不同特征之间的协方差固定为 0**	**与特征轴对齐的椭圆。**允许不同方向的散布不同，但表示不了成分内的相关性
tied	**所有成分共享同一个完整协方差矩阵**；均值与混合权重仍可不同	大小、形状、倾斜**完全相同**、只有中心不同的椭圆。比 full 省参数，但「同形状」假设可能不合适
full	每个成分有**自己的完整协方差矩阵**，含特征间协方差	每个椭圆可以有**自己的大小、拉伸与倾斜。**最灵活，但参数多、需要足够数据

★ 自检题（讲义自带，答案就是 full）

如果两个成分需要「不同的倾斜」，该选哪个协方差类型？ ⇒ full。

⚠ 注意：**每个选项都仍然给每个成分一个协方差矩阵。**spherical 和 diag 只是把某些元素约束住；tied 是跨成分共用同一个；full 才能自由不同。

⚠ 更灵活不等于更好

数据有限时，简单的协方差类型反而给出更稳定的估计；数据足够时 full 才可能抓到简单类型漏掉的真实模式。⇒ **用验证证据或 BIC/AIC 去比较，不要总是选最灵活的那个。**

⭐ **等密度轮廓是什么、不是什么**

等密度轮廓是围绕成分中心、密度相同的位置连成的线。二维时，**协方差决定它们的大小、拉长程度与倾斜，均值决定它们的中心在哪。**

⚠ **这些轮廓描述的是「一个成分的密度」，不是「各簇之间的分界线」。**

4. ★★★ EM 算法：两个更新步

T3-04

要最大化的量

$$\ell(\theta) = \Sigma_{i=1}^{N} \log[\, \Sigma_{k=1}^{K} \pi_k \, N(x_i \mid \mu_k, \Sigma_k) \,]$$

⭐ **为什么要取对数**

对独立观测，似然是各自混合密度的**连乘。取对数把连乘变成连加，而不改变「哪组参数让它最大」。**

内层的和是把「成分」合起来（对 k）；外层的和是把「观测」合起来（对 i）。

★★ 关于收敛，考试要的就这两句

精确的 EM 更新不会让这个似然下降。

但算法可能停在一个局部最优；「收敛了」和「可解释」是两件不同的事。

⚠ 详细的收敛性证明**不在考核范围内。**

第一次 E 步之前：要先选定 K 并初始化合法的权重、均值与协方差（例如用 k-means 的结果来初始化）。**没有起始参数就算不出责任度。**

E 步：估计责任度

$$r_{ik} = \pi_k \, N(x_i \mid \mu_k, \Sigma_k) \,/\, \Sigma_{j=1}^{K} \pi_j \, N(x_i \mid \mu_j, \Sigma_j)$$

1. 在**同一个观测** x_i 上，算**每一个**成分的高斯密度；
2. 各自乘上该成分**当前的**权重 π_k；
3. 把这些加权密度相加，得到分母 $p(x_i)$；
4. 每个加权密度除以这个**公共分母**。对每个观测重复一遍。

这就是**贝叶斯公式**：**后验成员度 = 先验权重 × 成分密度 ÷ 混合密度。**一个观测的各责任度加起来是 1。它们是**软后验指派，不是观测到的或固定的类标签。**

M 步：用加权统计量更新参数

★★★ 什么是「有效计数」（必考概念）

如果成员是已知的，每个观测对某成分的计数贡献要么是 1 要么是 0。

GMM 里成员是不确定的：责任度 0.9 就贡献 0.9 个计数。把这些分数贡献加起来，就得到 $N_k = \Sigma_i r_{ik}$，即成分 k 期望生成的观测数。

它不是「概率超过某阈值的点数」，也不意味着某个观测被物理地切开。

因为每个观测在所有成分上总共贡献 1，所以 $\Sigma_k N_k = N$。

⚠⚠ M 步内部的顺序不能乱

整个 M 步里都要保持 E 步算出的责任度不变。

先算有效计数 → 再算权重和均值 → 最后用「新均值」算协方差。

$$N_k = \Sigma_i r_{ik}$$
$$\pi_k = N_k / N$$
$$\mu_k = (1/N_k) \Sigma_i r_{ik} x_i$$
$$\Sigma_k = (1/N_k) \Sigma_i r_{ik} (x_i - \mu_k)(x_i - \mu_k)^T$$

用大白话说：**新权重是这个成分占数据集的份额；新均值是它的责任度加权平均；新协方差是围绕「那个新均值」的责任度加权散布。**均值和协方差的和要除以 N_k，因为 N_k 正是被平均的总权重。这些更新要求 $N_k > 0$。

⚠⚠⚠ 三个最高频的扣分点

- **分母是 N_k，不是 N**（这是加权平均，不是普通平均）；
- **协方差要用「刚更新完的新均值」**，不是旧均值；
- **除以 N_k，不是 $N_k - 1$** —— 这是**极大似然**更新，不是无偏样本方差公式。

⭐ 多特征时的唯一改动

把 $(x_i - \mu_k)^2$ 换成**外积** $(x_i - \mu_k)(x_i - \mu_k)^T$。其余一字不改。

⚠ 成分标签是任意的

交换两个拟合成分的编号，不改变混合密度。要通过它估计出的参数、以及它描述的那些观测来解释一个成分（通常按均值排序后再比较）。

5. 手算例题（讲义三个 + Tutorial 三题）

手算例题 2 · 混合密度与责任度（讲义 WORKED EXAMPLE 1）

一维两成分：$\pi_1=0.7$, $\mu_1=-1$, $\sigma_1^2=1$ ； $\pi_2=0.3$, $\mu_2=2$, $\sigma_2^2=1$。求 x = 0 处。

① 算两个高斯密度

两个方差都是 1，所以公共因子是 $1/\sqrt{(2\pi)} \approx 0.39894$。x=0 到两个均值的**平方**距离是 1 和 4：

$$N(0 \mid -1, 1) = 0.39894 \cdot \exp(-1/2) \approx 0.2420$$
$$N(0 \mid 2, 1) = 0.39894 \cdot \exp(-4/2) \approx 0.0540$$

② 乘混合权重

$$0.7 \times 0.2420 = 0.1694 \qquad 0.3 \times 0.0540 = 0.0162$$

③ 相加得混合密度

$$p(0) = 0.1694 + 0.0162 = 0.1856$$

④ 归一化得责任度

$$r_1(0) = 0.1694 / 0.1856 \approx 0.913 \qquad r_2(0) \approx 0.087$$

★ 为什么成分 1 的责任度大

它同时占了两个便宜：先验权重更大，而且在 x=0 处的密度也更高。

⚠ 这是**拟合模型下的后验成分概率**，不是已验证的真实世界类别归属概率。

手算例题 3 · 简化的 M 步（讲义 WORKED EXAMPLE 2，五个步骤）

N = 3：$x_1=-2$, $x_2=0$, $x_3=3$；K = 2。E 步给出的责任度：

x_i	r_{i1}	r_{i2}	行和
−2	0.9	0.1	1
0	0.6	0.4	1
3	0.1	0.9	1

① 按「列」相加得有效计数

$$N_1 = 0.9 + 0.6 + 0.1 = 1.6 \quad N_2 = 0.1 + 0.4 + 0.9 = 1.4$$

解读：成分 1 的总成员权重相当于 1.6 个被完全指派的观测。实际仍然只有三个观测：1.6 + 1.4 = 3。
⚠ 不要把这些计数取整，也不要把责任度换成硬标签。

② 有效计数除以 N 得新权重

$$\pi_1' = 1.6/3 \approx 0.5333 \quad \pi_2' = 1.4/3 \approx 0.4667$$

验一下两者相加是 1。**这是成分级的权重；在下一次 E 步之前，各个责任度本身不变。**

③ 用加权平均更新均值

$$\mu_1' = (0.9(-2) + 0.6(0) + 0.1(3)) \,/\, 1.6 = -1.5/1.6 = -0.9375$$
$$\mu_2' = (0.1(-2) + 0.4(0) + 0.9(3)) \,/\, 1.4 = 2.5/1.4 \approx 1.785714$$

⚠ 取值为 0 的那个观测对「分子」贡献 0，但它的责任度仍然计入「分母」。除以 3 是错的 —— 这是加权平均，不是普通平均。

④ 围绕「新均值」更新方差

$$(\sigma_k^2)' = \Sigma_i \, r_{ik}(x_i - \mu_k')^2 \,/\, N_k$$

成分 1 的三个差是 −1.0625、0.9375、3.9375：

$$0.9(-1.0625)^2 = 1.016015625$$
$$0.6(\,0.9375)^2 = 0.52734375$$
$$0.1(\,3.9375)^2 = 1.550390625$$
$$(\sigma_1^2)' = (1.016015625 + 0.52734375 + 1.550390625) \,/\, 1.6 = 1.93359375$$

成分 2 要用**未四舍五入的** 2.5/1.4，三个差约 −3.785714、−1.785714、1.214286：

$$(\sigma_2^2)' \approx (1.433163 + 1.275510 + 1.327041) \,/\, 1.4 \approx 2.882653$$

⑤ 方差与标准差别弄混

$$\sigma_1' = \sqrt{1.93359375} \approx 1.391 \quad \sigma_2' = \sqrt{2.882653} \approx 1.698$$

⚠ 保留精度

计算过程中保持完整精度，只在显示结果时才四舍五入。用四舍五入后的均值去算方差，会把误差放大。

手算例题 4 • 完整一轮 EM（讲义 WORKED EXAMPLE 3，含似然校验）

两个观测 $x_1 = -1$、$x_2 = 1$，两个成分。

① 初始化

$$\pi_1 = \pi_2 = 0.5\,,\ \mu_1 = -1\,,\ \mu_2 = 1\,,\ \sigma_1^2 = \sigma_2^2 = 1$$

② E 步

$$N(-1 \mid -1, 1) = 0.398942 \quad N(-1 \mid 1, 1) = 0.053991$$
$$r_{11} = 0.5(0.398942) \,/\, (0.5(0.398942) + 0.5(0.053991)) \approx 0.880797$$
$$r_{12} \approx 0.119203$$

$x_2 = 1$ 处由对称性把两个责任度反过来：

观测	成分 1	成分 2	行和
−1	0.880797	0.119203	1
1	0.119203	0.880797	1

③ M 步（责任度保持不变）

$$N_1 = 0.880797 + 0.119203 = 1\,,\ N_2 = 1 \ \Rightarrow\ \pi_1' = \pi_2' = 0.5$$
$$\mu_1' = (0.880797(-1) + 0.119203(1)) \,/\, 1 \approx -0.761594\,,\ \mu_2' \approx 0.761594$$
$$(\sigma_1^2)' = (0.880797(-1+0.761594)^2 + 0.119203(1+0.761594)^2) \,/\, 1 \approx 0.419974$$

均值向内移动，因为每个成分对另一个点也分了一些权重；**方差下降**，因为更新后的加权散布比初始的 1 小。

④ 校验：对数似然确实上升了

$$\ell(\theta) = \Sigma_i \log[\, \Sigma_k \pi_k N(x_i \mid \mu_k, \sigma_k^2)\,]$$
初始：每个观测的混合密度 $\approx 0.226467 \Rightarrow \ell_\text{old} = 2 \cdot \log(0.226467) \approx -2.9703$
更新后：$\ell_\text{new} \approx -2.4394$ ⇒ **上升了（负得更少）** ✓

⑤ 下一轮的责任度

用新参数重算：$x_1 = -1$ 处约为 **(0.974090, 0.025910)**，x_2 反过来。

⚠ 这些属于「下一次 E 步」，不要混进刚做完的这次更新里。

自检：为什么权重仍是 0.5，而责任度却变了？

数据和参数都是对称的，所以每个成分的总有效计数仍然是 1 —— 尽管每个单点的成员归属变得更确信了。

⚠ 讲义同时提醒的实践局限

只有两个点、两个不受约束的高斯时，**反复拟合可能让某个成分的方差塌缩到接近 0。**

手算例题 5 • Tutorial Q1 & Q2 — 密度、模糊度与责任度

两成分 GMM，$\pi_1 = 0.6$、$\pi_2 = 0.4$；两个观测处的成分密度已经给好：

	$N_1(x)$	$N_2(x)$
x_A	0.30	0.10
x_B	0.12	0.18

Q1-① 加权贡献与混合密度

$$x_A: 0.6(0.30) = 0.18\,,\ 0.4(0.10) = 0.04 \Rightarrow p(x_A) = 0.22$$
$$x_B: 0.6(0.12) = 0.072\,,\ 0.4(0.18) = 0.072 \Rightarrow p(x_B) = 0.144$$

Q1-② 哪个密度大、哪个更模糊

x_A 的总密度更大（0.22 > 0.144）。**x_B 更模糊**：它的两个加权贡献**完全相等**，哪个成分都不占优。

Q1-③ 为什么是密度不是概率

对连续变量，一个精确点的概率是 0。密度描述的是「每单位 x 的概率」，**必须在一个区间上积分才得到概率。**

Q2-① 两个观测的责任度

$$x_A: (\gamma_1, \gamma_2) = (0.18/0.22, 0.04/0.22) \approx (0.818, 0.182)$$
$$x_B: (\gamma_1, \gamma_2) = (0.072/0.144, 0.072/0.144) = (0.5, 0.5)$$

两对都加起来等于 1。**x_B 的 (0.5, 0.5) 表示在当前模型下两个成分完全无法区分。**

Q2-③ 把权重改成 0.2 / 0.8 之后

$$0.2(0.30) = 0.06\,,\ 0.8(0.10) = 0.08 \Rightarrow p(x_A) = 0.14$$
$$(\gamma_1, \gamma_2) = (0.06/0.14, 0.08/0.14) \approx (0.429, 0.571)$$

最有责任的成分换人了。因为**责任度把成分密度和它的先验权重结合在一起**：成分 2 更大的先验压过了它在 x_A 处更低的密度。

手算例题 6 • Tutorial Q3 — 诊断一个错误的 M 步

E 步给出四个观测的责任度：

x_i	−4	−1	2	5
r_{i1}	0.9	0.7	0.2	0.1
r_{i2}	0.1	0.3	0.8	0.9

① 错在哪
分析师提议用 $\mu_k = \Sigma_i r_{ik}x_i$ / **4。**

这个分母是错的。每个均值都是**某一个成分**的加权均值，它的分母必须是**该成分的有效计数** $N_k = \Sigma_i r_{ik}$，**不是观测总数。**

② 正确计算

$$N_1 = 0.9+0.7+0.2+0.1 = 1.9,\quad N_2 = 0.1+0.3+0.8+0.9 = 2.1$$
$$\pi_1' = 1.9/4 = 0.475,\qquad \pi_2' = 2.1/4 = 0.525$$
$$\mu_1' = (0.9(-4)+0.7(-1)+0.2(2)+0.1(5)) \,/\, 1.9 = -3.4/1.9 \approx -1.789$$
$$\mu_2' = (0.1(-4)+0.3(-1)+0.8(2)+0.9(5)) \,/\, 2.1 = 5.4/2.1 \approx 2.571$$

③ 这两个均值说明什么
更新后的均值把成分 1 定位到负值那一侧、成分 2 到正值那一侧。

E 步用当前参数算软成员度；**M 步**把这些责任度当作分数成员度来重估参数。反复迭代会**提高数据似然**，直到满足停止条件。

Tutorial • 扩展 — 从 GMM 里抽样

$\pi_1 = 0.7$, $N(-3, 1)$；$\pi_2 = 0.3$, $N(3, 2)$。抽到 $u = 0.85 \sim \text{Uniform}(0,1)$，$z = -0.5 \sim N(0,1)$。用 $x = \mu_k + \sigma_k z$。

① 选成分
u = 0.85 > 0.7 ⇒ 选成分 2。

② 算样本
成分 2 的方差是 2，所以标准差是 √2（⚠ 这里最容易直接拿 2 当 σ）：

$$x = 3 + \sqrt{2} \times (-0.5) \approx 2.293$$

③ 说明了什么
两阶段抽样：先用混合权重选一个成分，再从那个成分的高斯里抽一个值。

6. 选成分数：AIC 与 BIC

T3-04 / T3-05

只看训练似然，总会偏向更灵活的模型。AIC 与 BIC 给参数个数加一个罚项：

$$\mathrm{AIC} = -2\log \mathrm{L} + 2\mathrm{p}$$
$$\mathrm{BIC} = -2\log \mathrm{L} + \mathrm{p}\cdot\log \mathrm{N}$$

p 是**拟合参数的个数**，N 是观测数。**在候选模型里，取值更低的更好。**

★★★ 一维 K 成分 GMM 的参数计数规则（必背）

$$\mathrm{p} = (\mathrm{K}-1) + \mathrm{K} + \mathrm{K} = 3\mathrm{K} - 1$$

(K−1 个独立的混合权重) + (K 个均值) + (K 个方差)

⚠ 混合权重只有 **K−1** 个是自由的，因为它们必须加起来等于 1。

讲义的完整对照表（N = 300，BIC 用自然对数）

K	参数 p	总对数似然	AIC	BIC
1	2	−652.29	1308.58	1315.99
2	5	−516.30	**1042.60**	**1061.12**
3	8	−515.19	1046.39	1076.02
4	11	−511.73	1045.45	1086.19
5	14	−511.55	1051.10	1102.95

K = 2 时的验算（未四舍五入的总对数似然约 −516.29855）：

$$\mathrm{AIC} = -2\times(-516.29855) + 2\times 5 \approx 1042.60$$
$$\mathrm{BIC} = -2\times(-516.29855) + 5\times\ln(300) \approx 1061.12$$

★★ 为什么选 2（这段推理是标准答案）

两个准则都在 K = 2 取到最小值。

从 K=2 到 K=3，**对数似然只改善约 1.11，却多了 3 个参数。**AIC 的拟合项改善约 2.21，而罚项增加 6，**所以 AIC 反而变差。**BIC 的罚项更大。

⇒ **更多灵活性改善了这一次的训练拟合，但两个准则都认为不值得。**

⚠⚠ **三条使用规则**

- **AIC 只和 AIC 比，BIC 只和 BIC 比**，而且必须在**同一批观测、同一套特征表示**上。**绝对不要拿一个 AIC 值直接去比一个 BIC 值。**
- **BIC 的罚项更重**（尤其样本量变大时），所以它往往选出更简单的模型；两个准则在别的数据上可能**不一致**；
- **一个最小值只是「模型选择的证据」，不是「存在同样多个自然分组」的证明。**

⭐ **注意两个 p 不是一回事**

这里的 p 指「参数个数」，不是密度 p(x)。讲义特意提醒过这一点。

7. GMM 与 k-means 的对照

T3-03 / T3-06

方面	k-means	GMM
拟合什么	K 个质心	K 个高斯成分，各有均值、协方差与混合权重
拟合目标	**减小**到所属质心的平方距离之和	**增大**观测在混合密度下的**似然**
成员度	一个最近质心的标签	**每个成分一个责任度**；硬标签是可选的
形状信息	用到质心的欧氏距离；**不为每组拟合一个散布**	能学到不同的散布与朝向（取决于协方差类型）
对重叠的处理	强行二选一	**保留不确定性**

⚠ **GMM 不自动比 k-means 好**

它额外的灵活性需要估计更多参数，也需要假设成立。两个方法是用**不同的模型和目标**去回答相关但不同的问题。

一个合适的例子是：**重叠的、倾斜的椭圆区域** —— full 协方差的 GMM 可能比 k-means 更好地描述那个分布以及指派的不确定性。但结论仍要用 BIC、稳定性、可视化或领域证据，以及分析目的来检验。

★ **责任度怎么读（T3-03 的例子）**

[0.92, 0.08] ⇒ 在拟合模型下强烈支持成分 1。**[0.51, 0.49]** ⇒ 模型几乎无法决定。

⚠ **如果一定要硬标签，两者都会被判成成分 1 —— 但它们的不确定性天差地别。**`predict` 会丢掉这个信息，`predict_proba` 才保留。

⚠ **混合权重不是责任度**

权重 0.7 表示成分 1 占模型概率质量的 70%，不表示每个观测有 70% 的概率属于它 —— 成员度还取决于这个观测的取值。

8. Python 工作流与 Practical 的关键数字


```
gmm = GaussianMixture(n_components=2, covariance_type="full", n_init=10, random_state=42)
gmm.fit(X)   # weights_ / means_ / covariances_ / converged_ / n_iter_
gmm.predict_proba(probe)  # 责任度，每行和为 1
gmm.predict(X)        # 硬标签，丢掉不确定性
gmm.score_samples(X)    # 每个观测的「对数混合密度」
gmm.bic(X) , gmm.aic(X)
```

属性	含义 / 陷阱
`weights_`	混合权重，和为 1
`means_`	成分中心
`covariances_`	**一维时装的是方差**，要开根号才是标准差
`n_init=10`	**拟合十次初始化、保留最好的目标值 —— 不是十次 EM 迭代**
`converged_` / `n_iter_`	是否达到停止规则 / 实际迭代次数
`lower_bound_`	最终**每样本**的下界，用来判断收敛
成分编号	**任意的。**比较前先按均值排序

Practical 跑出来的参考数字

实验	结果
拟合两成分	左：权重 0.596、均值 −2.237、标准差 0.564；右：权重 0.404、均值 1.998、标准差 1.123
最不确定的点	x = −0.75 ⇒ 责任度约 **[0.6435, 0.3565]**；对比 x = −2.25 ⇒ [0.9997, 0.0003]
BIC 比较	K=1 约 1569.5；**K=2 约 1276.3**；K=3 约 1293.0 ⇒ **选 2**（比 3 好约 16.7）
手推一轮 EM	权重 [0.616960, 0.383040]；均值 [−2.115770, 2.033414]；标准差 [0.811798, 1.190269]
初始化 A（非对称）	对数似然 −745.050 → **−623.503**（改善约 121.547），结果接近 sklearn
初始化 B（完全对称）	对数似然 −1028.912 → −778.898 后**卡住不动**

★★★ 对称初始化为什么会卡死（极好的大题素材）

初始的权重、均值、散布完全相同 ⇒ 两个成分的加权密度在每个观测处都一样 ⇒ 每个观测对两个成分的责任度都恰好是 0.5。

于是两个均值都更新到**同一个总体均值**（约 −0.526），两个标准差都变成约 2.240，权重保持 0.5。

⇒ EM「似然不下降」的性质并不保证找到全局最优。这里的对称性产生了一个**更差的稳定配置。**

⚠ 用多个**非对称**起点有助于暴露敏感性，但**同样不能证明全局最优。**

9. 四条收尾警告（讲义原文的 FOUR CLOSING CAUTIONS)

T3-04

#	警告
①	**密度不是点概率**：对连续数据 p(x) 是密度值；恰好观测到某一个数值的概率是 0，概率要赋给区间或区域
②	**责任度是归一化过的**：成分 k 的软成员度正比于 $\pi_k N(x\|\mu_k,\Sigma_k)$，再除以对所有成分的和
③	**混合的方差有两个来源**：**每个成分内部的变异** + **各成分均值之间的变异。**⚠ 它**一般不等于**各成分方差的加权平均
④	**模型选择很要紧**：在参数约束相容时，增加成分不会降低可达到的最佳训练似然（大模型能表示小模型）。不同的 EM 运行可能到达不同局部最优，所以拟合似然**不一定单调改善。**要用验证证据或 BIC/AIC，而不是只看似然

⚠ 数值上的两个坑

- **某个成分几乎得不到责任度时，除以 N_k 会不稳定**；
- **一个成分可能塌缩到某个点上、方差趋近 0。**实现里会用协方差正则化和合理初始化来防护 —— **似然高本身不保证模型有用。**

附录 A • 公式速查表

名称	公式	备注
一维高斯密度	$N(x\|\mu,\sigma^2) = 1/\sqrt{(2\pi\sigma^2)} \cdot \exp(-(x-\mu)^2/(2\sigma^2))$	**第二个参数是方差**
多维高斯密度	$1/((2\pi)^{d/2}\|\Sigma\|^{1/2}) \cdot \exp(-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu))$	要求 Σ 正定
混合密度	$p(x) = \Sigma_k \pi_k N(x\|\mu_k,\Sigma_k)$	$\Sigma_k\pi_k = 1$，$\pi_k \geq 0$
责任度（E 步）	$r_{ik} = \pi_k N(x_i\|\mu_k,\Sigma_k) / \Sigma_j\pi_j N(x_i\|\mu_j,\Sigma_j)$	对每个 i，$\Sigma_k r_{ik}=1$
有效计数	$N_k = \Sigma_i r_{ik}$	**分数**；$\Sigma_k N_k = N$
权重更新	$\pi_k = N_k/N$	成分占数据集的份额
均值更新	$\mu_k = (1/N_k) \Sigma_i r_{ik}x_i$	**分母是 N_k**
方差更新（1 维）	$\sigma_k^2 = (1/N_k) \Sigma_i r_{ik}(x_i-\mu_k')^2$	**用新均值；除 N_k 不是 N_k-1**
协方差更新（多维）	$\Sigma_k = (1/N_k) \Sigma_i r_{ik}(x_i-\mu_k')(x_i-\mu_k')^T$	外积
对数似然	$\ell(\theta) = \Sigma_i \log[\ \Sigma_k \pi_k N(x_i\|\mu_k,\Sigma_k)\ ]$	外层对 i，内层对 k
AIC	$-2 \log L + 2p$	低者优
BIC	$-2 \log L + p\cdot\log N$	罚得更重，偏好简单模型
一维参数个数	$p = 3K - 1$	(K−1) 权重 + K 均值 + K 方差
两阶段抽样	先按 π 选 k，再 $x = \mu_k + \sigma_k z$, $z\sim N(0,1)$	**σ 是标准差，不是方差**

附录 B • 高频易错点清单

#	易错点	正确做法
1	均值/方差更新时除以 N	**除以 N_k**（该成分的有效计数）
2	方差更新用了旧均值	**必须用刚算出的新均值**
3	方差更新除以 $N_k - 1$	**除以 N_k** —— 这是极大似然，不是无偏样本方差
4	把 $N(x\|\mu,\sigma^2)$ 的第二个参数当成标准差	**是方差**；NumPy 的 `scale` 才是标准差
5	把有效计数取整	**1.6 是合法的**，它是期望的观测数
6	把密度当成概率，看到 >1 就以为算错	**密度可以大于 1**；概率是面积
7	混合权重 π_k 和责任度 r_{ik} 混用	π 是成分级先验；r 是观测级后验
8	以为先验权重大的成分责任度一定大	**责任度 = 先验 × 密度**；密度能反转结果
9	在 M 步中途重算责任度	**整个 M 步里责任度固定不变**
10	把 `n_init` 当成 EM 迭代次数	是**完整重跑的次数**
11	拿 AIC 值和 BIC 值直接比较	**同类相比**，且须同数据同特征
12	由「BIC 最低」推出「存在这么多自然分组」	只是**模型选择的证据**
13	认为 EM 似然不降就等于找到全局最优	**可能停在局部最优**（对称初始化会直接卡死）
14	混合的方差 = 各成分方差的加权平均	**还有「成分均值之间」的那一部分变异**
15	用 `predict` 后还谈不确定性	硬标签丢掉了责任度，要用 `predict_proba`
16	抽样时拿方差当标准差	**$x = \mu + \sigma z$，$\sigma = \sqrt{\text{方差}}$**

附录 C • 术语中英对照

英文	中文	一句话
Gaussian mixture model (GMM/MoG)	高斯混合模型	若干高斯的加权混合
component	成分	混合里的一个高斯（**不自动等于簇**）
mixture weight π_k	混合权重	成分的**先验**概率，和为 1
responsibility r_{ik}	责任度	观测后的**后验**成员概率，按行和为 1
effective count N_k	有效计数	责任度按列求和，**可以是分数**
latent variable z	隐变量	未观测的 one-hot 成分指示
prior / posterior	先验 / 后验	观测之前 / 观测之后的概率
density	密度	曲线高度，可以 > 1
probability	概率	曲线下的面积，0 到 1
E-step / M-step	E 步 / M 步	固定参数算责任度 / 固定责任度更新参数
log-likelihood	对数似然	连乘变连加，EM 要最大化它
soft / hard assignment	软 / 硬指派	概率向量 / 单一标签
covariance type	协方差类型	spherical / diag / tied / full
equal-density contour	等密度轮廓	描述**一个成分**的密度，不是簇边界
AIC / BIC	赤池 / 贝叶斯信息准则	拟合与复杂度的权衡，**低者优**
local optimum	局部最优	EM 可能停在这里
component collapse	成分塌缩	方差趋近 0，需要正则化防护