M3 官方练习全解

Tutorial 与 Practical —— 逐问解出，数字全部复算

ARTI2001 Machine Learning · 2026 Semester 2

T1 Tutorial Q1–Q3 + 选做 extension 完整解答

T1 Practical 官方 worked discussion 要点（五题 + 扩展自学）

⚠ **两张学习率表的对照**（极易记混的一处）

⭐ **「ReLU 不激活」的三个层级**（官方措辞）

T2 Practical 五题的考点定位 · 还缺哪些材料

ARTI2001 · Module 3 测验：Week 13（2026-11-09 ~ 11-15）· 开卷

目录

这一册是什么

T1 Tutorial · 网络基础（Network foundations）

T1 Practical · 官方 worked discussion 要点

T2 Practical · 五道题在考什么

还缺什么

这一册是什么

来源文件	带不带答案	这里做了什么
`M3 T1 Tutorial.pdf`（5 页）	**不带**（堂内交，tutor 批改）	Q1–Q3 与选做 extension **逐问完整解出**，每个数字都复算过
`M3 T1 Prac solution.html`	**带**官方 worked discussion	把五道题的官方讲解要点与数字摘出来，并复算核对
`M3 T2 Prac (2).ipynb`	空白版（无解答）	只摘题目结构与官方要求，说明每题在考什么

> ⚠ **两件要说清楚的事**
>
> - **Tutorial 那部分的解答是我算的，不是官方答案。**官方不发 Tutorial 答案，所以请把它当成「一份写全了过程的参考解」——和 tutor 当堂的讲解逐条对照，有出入以 tutor 为准。
> - **Practical 那部分是官方原文的要点摘录**，措辞尽量保留英文原句，因为扩展题的评分口径就看这些措辞。

⚠ **M3 T2 与 T3 的 Tutorial 原件本地还没有。**在拿到之前，T2 的题型看《M3T2 逐页精读》p13–p18（复习课件把 Q1/Q2/Q3 的结构、要求和评分口径都写出来了），T3 看《M3T3 逐页精读》p13–p16。

T1 Tutorial • 网络基础（Network foundations）

官方给的设定（Tutorial 第 1 页）。这一份只考到输出层；**隐藏层的反向传播在 Topic 2 教、在 Topic 2 考，这里不要求。**

$$z = W_1 x + b_1,\quad h = \mathrm{ReLU}(z),\quad s = W_2 h + c,\quad p = \sigma(s)$$

$$x = [0, 3]^T,\ y = 1,\ \eta = 0.1$$

$$W_1 = \begin{bmatrix} 1 & 2 \\ -1 & 1 \\ 0 & 1 \end{bmatrix},\ b_1 = \begin{bmatrix} 0 \\ 1 \\ -4 \end{bmatrix},\ W_2 = [1\ \ -1\ \ 2],\ c = -1$$

★ 官方写明的约定（照抄到答卷上）

- **自然对数**（log = ln），**判类阈值 0.5**，答案保留 **4–6 位小数**，⚠ **中间值不要四舍五入**；
- **ReLU′(z) = 1（z > 0）、0（z < 0）**；这份题里**没有任何隐藏预激活恰好为零**，所以不必纠结 z = 0 的约定；
- **下标是层号不是幂次也不是元素**：W_1、b_1 属隐藏层，W_2 属输出层；
- **w_ji 连接输入 i 到隐藏单元 j（接收端在前）**；输出权重 $W_2 = [v_1, v_2, v_3]$；
- **s 也叫 logit，δ = ∂L/∂s。**

Q1 • 前向传播，以及 ReLU 为什么重要

1

形状与参数个数。 W_1 是 **3×2**，W_2 是 **1×3。**

W_1: 3×2 = 6 个权重　　b_1: 3 个偏置
W_2: 1×3 = 3 个权重　　c : 1 个偏置
可训练参数合计 = 6 + 3 + 3 + 1 = 13

⚠ 题目问的是 *all trainable weights **and biases***，**偏置要算进去。**

2

隐藏层。

$$z_1 = 1(0) + 2(3) + 0 = 6$$
$$z_2 = -1(0) + 1(3) + 1 = 4$$
$$z_3 = 0(0) + 1(3) - 4 = -1$$

$$h = \mathrm{ReLU}(z) = [6, 4, 0]^T \quad \leftarrow ⚠ \text{第三个单元被截断，} h_3 = 0$$

⭐ **$h_3 = 0$ 是这整份 Tutorial 的枢纽**：Q2 第 4 问「为什么第三个输出权重的梯度是零」和 Q1 第 5 问「去掉 ReLU 会怎样」都落在它身上。

3

输出层。

$$s = 1(6) + (-1)(4) + 2(0) + (-1) = 6 - 4 + 0 - 1 = 1$$
$$p = \sigma(1) = 1/(1 + e^{-1}) = 0.731059$$

4

损失与解读。 $y = 1$，所以 $L = -\log p$。

$$L = -\log(0.731059) = 0.313262$$

解读：$p = 0.731059 \geq 0.5$ ⇒ 预测类别 **1**，**和目标一致，判对了。**但模型仍把约 **26.9%** 的概率分给了错误的类，所以损失不为零——⭐ **这正是「损失提供了阈值判定之外的连续信号」那一点。**

5

去掉 ReLU（$h = z$），证明整串塌缩成一个仿射函数。

$$s = W_2(W_1 x + b_1) + c = (W_2 W_1)x + (W_2 b_1 + c)$$

$$W_2 W_1 = [1, -1, 2] \cdot W_1 = [1(1)+(-1)(-1)+2(0),\ 1(2)+(-1)(1)+2(1)] = [2, 3]$$
$$W_2 b_1 + c = 1(0) + (-1)(1) + 2(-4) + (-1) = -10$$

$$\Rightarrow \tilde{w} = [2, 3]^T,\ \tilde{c} = -10 \qquad (\text{这就是题目要的 } s = \tilde{w}^T x + \tilde{c})$$

$$\text{在 } x = [0,3]^T \text{ 处：}\ s = 2(0) + 3(3) - 10 = -1 \quad p = \sigma(-1) = 0.268941$$

为什么和第 3 问不同：ReLU 把 $z_3 = -1$ 截成了 0，于是第三条路径对 s 的贡献从 **$v_3 \cdot z_3 = 2(-1) = -2$** 变成 **$v_3 \cdot h_3 = 0$**。差额正好是 **$1 - (-1) = 2$**。

⚠⚠ **后果比数字更重要**：去掉 ReLU 后 $p = 0.2689 < 0.5$，**预测从类别 1 翻成类别 0，判错了。** ⭐ 这一问是「深度本身不增加表达力、必须有非线性隐藏激活」在具体数字上的演示。

Q2 · 推导并使用学习信号

1

依赖路径（题目要求画出来并给每个箭头标局部导数）：

$$v_1 \xrightarrow{(\partial s/\partial v_1 = h_1)} s \xrightarrow{(\partial p/\partial s)} p \xrightarrow{(\partial L/\partial p)} L$$

其中 $h_1 = 6$ 就是「乘在 v_1 上的那个值」

2

三个局部导数，相乘得到 $\partial L/\partial v_1$。

$$\partial s/\partial v_1 = h_1 \quad = 6$$
$$\partial p/\partial s = p(1-p) \quad = 0.731059 \times 0.268941 = 0.196612$$
$$\partial L/\partial p = -1/p \quad = -1.367879 \qquad (y = 1 \text{ 时 } L = -\log p)$$

$$\partial L/\partial v_1 = (-1.367879)(0.196612)(6) = -1.613649$$

再证 δ = p − y，题目要求**数值上和代数上各证一遍**：

数值：$\delta = (\partial L/\partial p)(\partial p/\partial s) = (-1.367879)(0.196612) = -0.268941$

$p - y = 0.731059 - 1 = -0.268941$ ✓ 相等

代数：$\delta = (-1/p) \cdot p(1-p) = -(1-p) = p - 1 = p - y$ （因为 $y = 1$）

3

用捷径一次算完四个梯度。

$$\partial L/\partial W_2 = \delta\, h^T = (-0.268941)\cdot[6, 4, 0]$$

$\partial L/\partial v_1 = -1.613649$ $\partial L/\partial v_2 = -1.075766$ $\partial L/\partial v_3 = 0$

$\partial L/\partial c = \delta = -0.268941$

4

解读（这一问全是文字分）。

- **负梯度的局部含义**：梯度下降 θ ← θ − η·∂L/∂θ，梯度为负 ⇒ 参数会**变大**；也就是说**在当前这一点上，略微增大 v_1、v_2 和 c 会降低损失。**⚠ 这是**局部**方向，不保证大步更新也成立。
- **为什么第三个输出权重的梯度是零**：$\partial L/\partial v_3 = \delta \cdot h_3$，而 **$h_3$ = ReLU(−1) = 0。**⚠ 不是因为 δ 为零，也不是因为 v_3 本身有什么特别——**是这个隐藏单元对这一个观测不激活**，这条路径被 ReLU 掐断了。
- **算梯度 ≠ 改参数**：这一问算出来的是**反向传播的产物**；**参数要等到 Q3 用梯度下降才真正改变。** ⭐ 这两件事是本模块反复考的区分。

Q3 • 更新一次，然后复查预测

1

梯度下降规则与更新（η = 0.1）。

$$\theta_new = \theta - \eta \cdot \partial L/\partial\theta$$

$$v_1 = 1 \quad - 0.1(-1.613649) = 1 + 0.161365 = 1.161365 \quad \leftarrow \text{一次数值代入}$$
$$v_2 = -1 \quad - 0.1(-1.075766) = -0.892423$$
$$v_3 = 2 \quad - 0.1(0) \quad = 2 \quad \text{（没变）}$$
$$c = -1 \quad - 0.1(-0.268941) = -0.973106$$

⚠ **减去一个负数 = 增大**，和 Q2 第 4 问的解读一致。⚠ 四个梯度都是在**更新前**的参数状态上算的，然后**一起**更新。

2

用新参数重新跑一次输出计算（隐藏层与 h 保持不变，题目这样规定）。

$$s = 1.161365(6) + (-0.892423)(4) + 2(0) + (-0.973106) = 2.425390$$
$$p = \sigma(2.425390) = 0.918743$$
$$L = -\log(0.918743) = 0.084749$$

量	Q1（更新前）	Q3（更新后）
s	1.000000	**2.425390**
p	0.731059	**0.918743**
L	0.313262	**0.084749**

3

判类有没有变？为什么损失能改善而类别不变？

- **没变**：更新前 p = 0.731059 ≥ 0.5 判类 1，更新后 p = 0.918743 ≥ 0.5 还是类 1。
- **损失仍然改善了 0.228513**，因为 **BCE 看的是概率本身，不是阈值判定之后的类别。** ⭐ 概率从 0.731 推到 0.919，更靠近目标 y = 1，所以 −log p 明显变小。这正是「准确率没动、损失却在降」那种情形的微观版本。
- **这能说明在没见过的数据上也好吗？不能。** ⚠ 这只是**同一个观测**上的一次局部改进；它既不证明收敛，也不是泛化的证据。要判断泛化，必须看**留出数据**上的表现（Topic 3）。

⭐ **这份 Tutorial 的答题骨架（扩展题可直接套）**

① 前向（z → h → s → p → L，每步留 6 位）→ **② 写出 δ = p − y 并说明它是 sigmoid+BCE 的化简** → **③ 用 $\partial L/\partial W_2 = \delta h^T$、$\partial L/\partial c = \delta$ 一次算完** → **④ 同步更新，明说「所有梯度用更新前的参数算」** → **⑤ 重新跑前向给出新的 s、p、L** → **⑥ 收一句局限：只证明这一个样本上有改进，不是泛化的证据。**

选做 extension • 同样的预测，目标改成 y = 0

起点完全不变（原参数 $W_2 = [1,-1,2]$、$c = -1$，以及 Q1 算出的 s 和固定的 h），**只把观测到的标签改成 y = 0。**

> **1**
>
> **先预测符号，再算。** p 没变还是 0.731059，而现在 y = 0：
>
> $$\delta = p - y = 0.731059 - 0 = +0.731059 \quad \leftarrow ⚠ \text{由负转正}$$
>
> $$\partial L/\partial v_1 = 0.731059 \times 6 = 4.386351$$
> $$\partial L/\partial v_2 = 0.731059 \times 4 = 2.924234$$
> $$\partial L/\partial v_3 = 0.731059 \times 0 = 0 \qquad \leftarrow h_3 = 0，\text{仍然是零}$$
> $$\partial L/\partial c = 0.731059$$
>
> $$\text{更新}（\eta = 0.1）：\ v_1 = 0.561365 \quad v_2 = -1.292423 \quad v_3 = 2 \quad c = -1.073106$$

> **2**
>
> **重新计算分数、概率与 BCE。**
>
> $$s = 0.561365(6) + (-1.292423)(4) + 2(0) + (-1.073106) = -2.874610$$
> $$p = \sigma(-2.874610) = 0.053423$$
> $$L = -\log(1 - p) = -\log(0.946577) = 0.054903 \quad \leftarrow y = 0 \text{ 时用 } -\log(1-p)$$

为什么更新方向反过来了？ ⭐ 因为 **δ = p − y 里变的是 y，不是 p。**原来的预测一个字都没改（p 还是 0.731059），但现在这个概率是「分给错误类别的」，所以损失要求把 logit **往下**推。

⚠ **顺带注意判类也翻了**：p = 0.053423 < 0.5 ⇒ 预测类别 0，与新的 y = 0 一致。

⚠ extension 真正在考的一句话

同一个预测，好不好完全取决于目标是什么。δ = p − y 把这件事写死了：预测 p 只决定大小，**目标 y 决定方向。** ⭐ 这也解释了为什么「前向传播没用到 y」——因为方向要等损失出现才有。

T1 Practical • 官方 worked discussion 要点

⚠ **Practical 用的是另一个网络**（2 → 3 → 1，四个观测），和上面 Tutorial 的 3 隐藏单元网络**不是同一套数字**，别混。

第一个观测的完整前向（官方给的，已复算核对）：

> $x = [1, -1]$
> 单元 1：$1(0.6) + (-1)(-0.2) + 0.1 = 0.9$
> 单元 2：$1(-0.4) + (-1)(0.7) + 0.2 = -0.9$ ⇒ ReLU 截断
> 单元 3：$1(0.3) + (-1)(-0.5) - 0.1 = 0.7$
> $h = [0.9, 0, 0.7]$
> $\text{logit} = 0.9(0.8) + 0(-0.6) + 0.7(0.5) + 0.1 = 1.17$
> $p = \sigma(1.17) = 0.763145$ BCE（y=1）$= 0.270307 \approx 0.2703$

⚠ **官方在这里专门提醒的两点**

- **四个观测的平均 BCE 是 0.745984，不是第一个观测的 0.2703。**报「平均损失」时别拿单个样本的数去填。
- **权重是题目给的，不是学出来的。**官方原话：“A confident output alone shows neither accurate training nor generalisation.” 而且**第四个观测就是反例：p ≈ 0.7658 而 y = 0**——很自信，而且错了。

Q2 要点 • 平均损失的 1/N 与「用原始 W_2 反传」

- **平均损失下，每个观测只贡献它自己梯度的 1/N。**四个观测的输出 logit delta **(p − y)/4 ≈ [−0.059214, 0.096154, −0.134979, 0.191462]。**⚠ 官方把两种错法都点名了：**除两次会让梯度太小；不除则求的是「和」的导数而不是「平均」的。**
- **形状**：`h.T @ delta2` 是 (3,4)×(4,1) ⇒ **(3,1)**，每个输出权重一个梯度。第一个输出权重：0.9(−0.059214) + 0(0.096154) + 0.2(−0.134979) + 1.2(0.191462) = **0.149466**，**为正 ⇒ 梯度下降会把它减小**，η = 0.1 时从 0.8 变成约 **0.785053。**
- **往回传时乘的是「原始」输出权重，再乘 ReLU 掩码。**观测 1 得到 **[−0.047371, 0, −0.029607]**，⚠ **中间那个是零，因为那个隐藏预激活是负的。**
- **偏置的梯度是 delta 求和**，因为「加偏置」这一步的导数是 1。
- ⚠⚠ 官方收尾那句要背：“All gradients must refer to the same forward-pass parameter state. **Using an already-updated W_2 mixes two states and no longer differentiates the original loss.**”

⚠⚠ Q3 要点 • 两张学习率表，别记混

M3 里有**两个**「四个观测、单步比较学习率」的实验，**网络不同、数字不同、最优 η 也不同。**考场上看到学习率表，先确认是哪一个。

学习率 η	Canvas 课程页 / T3 复习课件那张	T1 Practical 那张
（起点）	0.580352	0.745984
0	0.580352（参数没变）	0.745984（参数没变）
0.1	0.574996	0.733989
1	0.533347	**0.664890** ← 这张表里最低
10	**0.371611** ← 这张表里最低	（没做这一档）
100	9.965953（飞了）	4.621223（飞了）

★ 两张表都在说同一句话

- **η = 0 一定复现原损失**——官方把这当成实现是否正确的自检。
- **每一档都从同一组初始参数和同一个梯度出发**，所以差异只来自 η 本身；“chaining updates would confound the rate comparison”——**把更新串起来做就毁了这个对比。**
- **大步会越过激活边界**：官方原话 “a finite large step can cross activation boundaries and move into a much worse region”。
- ⚠⚠ **一次改善既不证明收敛，也不估计未见数据上的表现。**
- ⭐ 两张表最优的 η 不同（一张是 10、一张是 1），**正好说明没有普适最佳学习率。**

⭐ Q4 要点 • 「ReLU 不激活」有三个层级（官方措辞）

层级	官方说法	能得出什么结论
① 对**一个观测**不激活	“Inactive for one observation means only that observation's path is blocked.”	**只有那一个观测**的这条路径被掐断
② 对**这一批**都不激活	“Inactive for this whole batch means no incoming gradient from these four observations at this state.”	在**当前参数状态**下，这批数据给不了它任何输入权重的梯度
③ **永久**死亡	“Other inputs could still activate the unit, so this experiment does not prove permanent inactivity.”	⚠ **这个实验证明不了**

官方的具体数字：第三个单元原本输出 **[0.7, 0, 0, 0.25]**，所以观测 1 和 4 仍能通过它贡献梯度，对应的两个输入权重梯度约 **[0.161855, 0.077472]**。把它的偏置改成 **−10** 之后，四个预激活变成 **[−9.2, −10.55, −10.35, −9.65]**，**全为负** ⇒ 输出和输入权重梯度**这一批**全变成零。

⚠ 机制要说对

官方原话： “The ReLU derivative mask blocks the gradient along this path; **a nonzero output error alone cannot pass through it.**” —— **输出端的误差不为零也没用，过不了那道零导数的闸。**

Q5 要点 • 一段代码里的两个独立错误

题目给的场景：某同学算完输出层梯度后**立刻更新 W_2**，然后**用更新后的 W_2** 去算隐藏层梯度；并且用 `W1 + learning_rate*dW1` 更新 W_1。官方说这里有**两个彼此独立**的错误：

#	错在哪	为什么错
①	**在算隐藏层梯度之前就更新了 W_2**	“mixes parameter states”——两个参数状态混在一起，算出来的不再是原损失的导数
②	**把梯度加上去**（`W1 + rate*dW1`）	“is an ascent step”——学习率为正时，最小化损失必须**减**

> 官方给的正确写法：
>
> ```
> old = [a.copy() for a in parameters]
> grads = gradients(X, y, old)          # 全部梯度在同一个状态上算
> parameters = [a - rate*d for a, d in zip(old, grads)]
> ```

> ⭐ **自动微分那一问的标准答法**
>
> **自动微分会算什么**：追踪这一次前向计算里的各个运算，按链式法则给出**各参数的梯度。优化器随后做什么**：用这些梯度**执行参数更新。它能保证学习率合适吗——不能。** ⭐ 官方要你把这一问**接回 Q3**：Q3 那张表里 η = 100 把损失推到 4.62，而自动微分对此毫无意见——**它只负责求导，不负责步长。**

扩展自学要点 • 数值梯度检查

- **做法**：对每个参数元素，复制一份、把那一个元素 **±ε** 扰动，用**中心差分 $(L_+ - L_-)/(2\varepsilon)$** 和解析梯度比。
- ⚠ **这是调试手段，不是训练算法**；而且 “near a ReLU kink the derivative may not exist”——**在 ReLU 的折点附近导数可能不存在**，那里对不上是正常的。
- **重复训练**：30 步、η = 0.1，**每一步都要重新算梯度**，记录初始损失和每步之后的损失。
- ⚠ 官方要求解释三件事：**为什么梯度必须每步重算**（参数变了，所有依赖参数的量都过期）、**为什么损失曲线下降不是泛化的证明**、**为什么数值检查比反向传播慢**（每个参数要跑两次完整前向）。

T2 Practical • 五道题在考什么

本地只有**空白版** notebook，没有解答。下面是题目要求的摘录，用来判断「这一题在考哪个知识点」。

题	要求	落在哪个考点
Q1 激活值与梯度	实现六个函数，比较值域与饱和，**解释 ReLU 在零处的导数约定**，说明只叠仿射层为什么限制表达力	sigmoid/tanh/ReLU 及导数；饱和
Q2 损失强调哪种误差	实现逐观测 BCE，**找出一个「自信但判错」的概率**并解释裁剪；先预测「A 和 B 能否准确率相同而 BCE 不同」，再验证	MSE 与交叉熵；损失 ≠ 准确率
Q3 前向与偏置干预	追第一个观测；**先用那个隐藏单元输出权重的符号预测「把第二个隐藏偏置减 2」会怎样**，再实际算、再解释别的观测为何反应不同	隐藏层的作用；先预测再验证
Q4 公平地比较激活函数	只在训练集上拟合 logistic / tanh / relu，**按验证 log loss 选**，再用 train+validation 重拟合，**测试集只评一次**	⭐ 这就是 T3 的流程；并要求说明单次划分/初始化的局限
Q5 选对输出与损失	三个设计各有一处输出激活或损失不合适（如预测摄氏温度，**预测值必须允许负数**），要指出问题、给出正确搭配、并说明为什么匹配	四种任务的输出层与损失

★ Q4 和 Q5 直接就是扩展题素材

- **Q4 的流程**（训练集拟合 → 验证选择 → 合并重拟合 → 测试评一次）是 T3 考纲第一条的落地版，扩展题问「如何选定并报告」时照搬即可。
- **Q5 是配对表的反向用法**：给一个错配让你诊断。⭐ 练熟了正向（给任务选搭配）之后，一定要再练一遍反向。

还缺什么

材料	状态	替代办法
M3 T2 Tutorial 原件	**本地没有**	《M3T2 逐页精读》**p13–p18**：复习课件把 Q1/Q2/Q3 的结构、要求、评分口径全写出来了（含「没有单独 Q4、extension 不计分」）
M3 T3 Tutorial 原件	**本地没有**	《M3T3 逐页精读》**p13–p16**：三题的链条是「数据划分 → 指标 → ROC/AUC」，讲稿还写明 Q3 含**一个平局**、要用**配对法**核对 AUC
M3 T3 Practical	**不存在**	官方写明 **Topic 3 没有排定的 practical**，只有两个选做不计分的 notebook
T2 Practical 解答	**本地没有**	题目结构见上一节；Q4/Q5 的思路在备考包里有对应模板

⚠ 以上四项如果之后拿到了，**把文件放进** `M3材料/Tutorial与Practical/` **再重跑** `_src/tutorials.py` 即可；数字复算脚本是 `_src/verify_tut_t1.py`。