M3 官方练习全解

三份官方 Tutorial 答案 + Practical 要点，数字全部复算

ARTI2001 Machine Learning · 2026 Semester 2

⭐ **T1 / T2 / T3 三份官方 Tutorial 答案，Q1–Q3 与 extension 全解**
T1 Practical 官方 worked discussion 要点（五题 + 扩展自学）
⚠ **两张学习率表的对照** · ⚠ **混淆矩阵摆法：三份官方材料的统计**
⭐ **三种不同成因的零梯度** · **两种搭配 logit 梯度的幅度比 1/[p(1−p)]**
T2 Practical 五题的考点定位 · 剩下几天怎么用这一册

ARTI2001 · Module 3 测验：Week 13（2026-11-09 ~ 11-15）· 开卷

目录

这一册是什么

T1 Tutorial · 网络基础（Network foundations）

T2 Tutorial · 训练一个网络（Training a network）

T3 Tutorial · 模型评估（Model evaluation）

⚠⚠ 混淆矩阵的摆法：三份官方材料的统计

T1 Practical · 官方 worked discussion 要点

T2 Practical · 五道题在考什么

材料清点与还缺什么

这一册是什么

来源文件	带不带答案	这里做了什么
`M3 T1 Tutorial_ans.pdf`	⭐ **官方答案**	Q1–Q3 与 extension 全解；⚠ 我 10-30 自己解的那一版**与官方逐个数字吻合**
`M3 T2 tutorial_ans.pdf`	⭐ **官方答案**	Q1–Q3 与 extension 全解（Q3 复用 T1 的网络做隐藏层任务）
`M3 T3 Tutorial_ans.pdf`	⭐ **官方答案**	Q1–Q3 与 extension 全解（划分诊断 / 指标与代价 / ROC 与 AUC）
`M3 T1 Tutorial.pdf`（题目卷）	不带	上面 T1 全解的题面来源
`M3 T1 Prac solution.html`	**带**官方 worked discussion	把五道题的官方讲解要点与数字摘出来，并复算核对
`M3 T2 Prac (2).ipynb`	空白版（无解答）	只摘题目结构与官方要求，说明每题在考什么

> ⭐ **一件值得知道的事**
>
> **10-30 我在没有答案的情况下把 T1 Tutorial 解了一遍；11-03 拿到官方答案后逐项核对，每一个数字都吻合**（形状与参数个数、z/h/s/p/L、w̃ 与 c̃、三个局部导数、四个梯度、更新后的 s/p/L，以及 extension 的全部）。⇒ 下面写的过程可以放心照着练；**措辞上尽量保留了官方的英文原句**，因为扩展题的评分口径就看这些措辞。

⭐ **三份 Tutorial 答案已于 2026-11-03 全部到手**，本册据此重写。⚠ 原件在 `.gitignore` 内，不随公开仓库发布；本册里的数字全部由 `_src/verify_tut_all.py` 独立复算（**105/105 通过**）。

T1 Tutorial • 网络基础（Network foundations）

官方给的设定（Tutorial 第 1 页）。这一份只考到输出层；**隐藏层的反向传播在 Topic 2 教、在 Topic 2 考，这里不要求。**

$$z = W_1 x + b_1,\quad h = \mathrm{ReLU}(z),\quad s = W_2 h + c,\quad p = \sigma(s)$$

$$x = [0, 3]^T,\ y = 1,\ \eta = 0.1$$

$$W_1 = \begin{bmatrix} 1 & 2 \\ -1 & 1 \\ 0 & 1 \end{bmatrix},\ b_1 = \begin{bmatrix} 0 \\ 1 \\ -4 \end{bmatrix},\ W_2 = [1\ \ -1\ \ 2],\ c = -1$$

★ 官方写明的约定（照抄到答卷上）

- **自然对数**（log = ln），**判类阈值 0.5**，答案保留 **4–6 位小数**，⚠ **中间值不要四舍五入**；
- **ReLU′(z) = 1（z > 0）、0（z < 0）**；这份题里**没有任何隐藏预激活恰好为零**，所以不必纠结 z = 0 的约定；
- **下标是层号不是幂次也不是元素**：W_1、b_1 属隐藏层，W_2 属输出层；
- **w_ji 连接输入 i 到隐藏单元 j（接收端在前）**；输出权重 $W_2 = [v_1, v_2, v_3]$；
- **s 也叫 logit，δ = ∂L/∂s。**

Q1 • 前向传播，以及 ReLU 为什么重要

1

形状与参数个数。 W_1 是 **3×2**，W_2 是 **1×3。**

W_1: 3×2 = 6 个权重　　b_1: 3 个偏置
W_2: 1×3 = 3 个权重　　c : 1 个偏置
可训练参数合计 = 6 + 3 + 3 + 1 = 13

⚠ 题目问的是 *all trainable weights **and biases***，**偏置要算进去。**

2

隐藏层。

$$z_1 = 1(0) + 2(3) + 0 = 6$$
$$z_2 = -1(0) + 1(3) + 1 = 4$$
$$z_3 = 0(0) + 1(3) - 4 = -1$$

$$h = \mathrm{ReLU}(z) = [6, 4, 0]^T \quad \leftarrow ⚠ \text{第三个单元被截断，} h_3 = 0$$

⭐ **$h_3 = 0$ 是这整份 Tutorial 的枢纽**：Q2 第 4 问「为什么第三个输出权重的梯度是零」和 Q1 第 5 问「去掉 ReLU 会怎样」都落在它身上。

3

输出层。

$$s = 1(6) + (-1)(4) + 2(0) + (-1) = 6 - 4 + 0 - 1 = 1$$
$$p = \sigma(1) = 1/(1 + e^{-1}) = 0.731059$$

4

损失与解读。 $y = 1$，所以 $L = -\log p$。

$$L = -\log(0.731059) = 0.313262$$

解读：$p = 0.731059 \geq 0.5$ ⇒ 预测类别 **1**，**和目标一致，判对了。**但模型仍把约 **26.9%** 的概率分给了错误的类，所以损失不为零——⭐ **这正是「损失提供了阈值判定之外的连续信号」那一点。**

5

去掉 ReLU（$h = z$），证明整串塌缩成一个仿射函数。

$$s = W_2(W_1 x + b_1) + c = (W_2 W_1)x + (W_2 b_1 + c)$$

$$W_2 W_1 = [1, -1, 2] \cdot W_1 = [1(1)+(-1)(-1)+2(0),\ 1(2)+(-1)(1)+2(1)] = [2, 3]$$
$$W_2 b_1 + c = 1(0) + (-1)(1) + 2(-4) + (-1) = -10$$

$$\Rightarrow \tilde{w} = [2, 3]^T,\ \tilde{c} = -10 \qquad (\text{这就是题目要的 } s = \tilde{w}^T x + \tilde{c})$$

$$\text{在 } x = [0,3]^T \text{ 处：}\ s = 2(0) + 3(3) - 10 = -1 \quad p = \sigma(-1) = 0.268941$$

为什么和第 3 问不同：ReLU 把 $z_3 = -1$ 截成了 0，于是第三条路径对 s 的贡献从 **$v_3 \cdot z_3 = 2(-1) = -2$** 变成 **$v_3 \cdot h_3 = 0$**。差额正好是 **$1 - (-1) = 2$**。

⚠⚠ **后果比数字更重要**：去掉 ReLU 后 $p = 0.2689 < 0.5$，**预测从类别 1 翻成类别 0，判错了。** ⭐ 这一问是「深度本身不增加表达力、必须有非线性隐藏激活」在具体数字上的演示。

Q2 · 推导并使用学习信号

1

依赖路径（题目要求画出来并给每个箭头标局部导数）：

$$v_1 \xrightarrow{(\partial s/\partial v_1 = h_1)} s \xrightarrow{(\partial p/\partial s)} p \xrightarrow{(\partial L/\partial p)} L$$

其中 $h_1 = 6$ 就是「乘在 v_1 上的那个值」

2

三个局部导数，相乘得到 $\partial L/\partial v_1$。

$$\partial s/\partial v_1 = h_1 \quad = 6$$
$$\partial p/\partial s = p(1-p) \quad = 0.731059 \times 0.268941 = 0.196612$$
$$\partial L/\partial p = -1/p \quad = -1.367879 \qquad (y = 1 \text{ 时 } L = -\log p)$$

$$\partial L/\partial v_1 = (-1.367879)(0.196612)(6) = -1.613649$$

再证 δ = p − y，题目要求**数值上和代数上各证一遍**：

数值：$\delta = (\partial L/\partial p)(\partial p/\partial s) = (-1.367879)(0.196612) = -0.268941$

$p - y = 0.731059 - 1 = -0.268941$ ✓ 相等

代数：$\delta = (-1/p) \cdot p(1-p) = -(1-p) = p - 1 = p - y$ （因为 $y = 1$）

3

用捷径一次算完四个梯度。

$$\partial L/\partial W_2 = \delta\, h^T = (-0.268941)\cdot[6, 4, 0]$$

$\partial L/\partial v_1 = -1.613649$ $\partial L/\partial v_2 = -1.075766$ $\partial L/\partial v_3 = 0$

$\partial L/\partial c = \delta = -0.268941$

4

解读（这一问全是文字分）。

- **负梯度的局部含义**：梯度下降 θ ← θ − η·∂L/∂θ，梯度为负 ⇒ 参数会**变大**；也就是说**在当前这一点上，略微增大 v_1、v_2 和 c 会降低损失。**⚠ 这是**局部**方向，不保证大步更新也成立。
- **为什么第三个输出权重的梯度是零**：$\partial L/\partial v_3 = \delta \cdot h_3$，而 **$h_3$ = ReLU(−1) = 0。**⚠ 不是因为 δ 为零，也不是因为 v_3 本身有什么特别——**是这个隐藏单元对这一个观测不激活**，这条路径被 ReLU 掐断了。
- **算梯度 ≠ 改参数**：这一问算出来的是**反向传播的产物**；**参数要等到 Q3 用梯度下降才真正改变。** ⭐ 这两件事是本模块反复考的区分。

Q3 • 更新一次，然后复查预测

1

梯度下降规则与更新（η = 0.1）。

$$\theta_new = \theta - \eta \cdot \partial L/\partial\theta$$

$$v_1 = 1 \quad - 0.1(-1.613649) = 1 + 0.161365 = 1.161365 \quad \leftarrow \text{一次数值代入}$$
$$v_2 = -1 \quad - 0.1(-1.075766) = -0.892423$$
$$v_3 = 2 \quad - 0.1(0) \quad = 2 \quad \text{（没变）}$$
$$c = -1 \quad - 0.1(-0.268941) = -0.973106$$

⚠ **减去一个负数 = 增大**，和 Q2 第 4 问的解读一致。⚠ 四个梯度都是在**更新前**的参数状态上算的，然后**一起**更新。

2

用新参数重新跑一次输出计算（隐藏层与 h 保持不变，题目这样规定）。

$$s = 1.161365(6) + (-0.892423)(4) + 2(0) + (-0.973106) = 2.425390$$
$$p = \sigma(2.425390) = 0.918743$$
$$L = -\log(0.918743) = 0.084749$$

量	Q1（更新前）	Q3（更新后）
s	1.000000	**2.425390**
p	0.731059	**0.918743**
L	0.313262	**0.084749**

3

判类有没有变？为什么损失能改善而类别不变？

- **没变**：更新前 p = 0.731059 ≥ 0.5 判类 1，更新后 p = 0.918743 ≥ 0.5 还是类 1。
- **损失仍然改善了 0.228513**，因为 **BCE 看的是概率本身，不是阈值判定之后的类别。** ⭐ 概率从 0.731 推到 0.919，更靠近目标 y = 1，所以 −log p 明显变小。这正是「准确率没动、损失却在降」那种情形的微观版本。
- **这能说明在没见过的数据上也好吗？不能。** ⚠ 这只是**同一个观测**上的一次局部改进；它既不证明收敛，也不是泛化的证据。要判断泛化，必须看**留出数据**上的表现（Topic 3）。

⭐ **这份 Tutorial 的答题骨架（扩展题可直接套）**

① 前向（z → h → s → p → L，每步留 6 位）→ **② 写出 δ = p − y 并说明它是 sigmoid+BCE 的化简** → **③ 用 $\partial L/\partial W_2 = \delta h^T$、$\partial L/\partial c = \delta$ 一次算完** → **④ 同步更新，明说「所有梯度用更新前的参数算」** → **⑤ 重新跑前向给出新的 s、p、L** → **⑥ 收一句局限：只证明这一个样本上有改进，不是泛化的证据。**

选做 extension • 同样的预测，目标改成 y = 0

起点完全不变（原参数 $W_2 = [1,-1,2]$、$c = -1$，以及 Q1 算出的 s 和固定的 h），**只把观测到的标签改成 y = 0。**

> **1**
>
> **先预测符号，再算。** p 没变还是 0.731059，而现在 y = 0：
>
> $$\delta = p - y = 0.731059 - 0 = +0.731059 \quad \leftarrow ⚠ \text{由负转正}$$
>
> $$\partial L/\partial v_1 = 0.731059 \times 6 = 4.386351$$
> $$\partial L/\partial v_2 = 0.731059 \times 4 = 2.924234$$
> $$\partial L/\partial v_3 = 0.731059 \times 0 = 0 \qquad \leftarrow h_3 = 0，\text{仍然是零}$$
> $$\partial L/\partial c = 0.731059$$
>
> $$\text{更新}（\eta = 0.1）：\ v_1 = 0.561365 \quad v_2 = -1.292423 \quad v_3 = 2 \quad c = -1.073106$$

> **2**
>
> **重新计算分数、概率与 BCE。**
>
> $$s = 0.561365(6) + (-1.292423)(4) + 2(0) + (-1.073106) = -2.874610$$
> $$p = \sigma(-2.874610) = 0.053423$$
> $$L = -\log(1 - p) = -\log(0.946577) = 0.054903 \quad \leftarrow y = 0 \text{ 时用 } -\log(1-p)$$

为什么更新方向反过来了？ ⭐ 因为 **δ = p − y 里变的是 y，不是 p。**原来的预测一个字都没改（p 还是 0.731059），但现在这个概率是「分给错误类别的」，所以损失要求把 logit **往下**推。

⚠ **顺带注意判类也翻了**：p = 0.053423 < 0.5 ⇒ 预测类别 0，与新的 y = 0 一致。

⚠ extension 真正在考的一句话

同一个预测，好不好完全取决于目标是什么。δ = p − y 把这件事写死了：预测 p 只决定大小，**目标 y 决定方向。** ⭐ 这也解释了为什么「前向传播没用到 y」——因为方向要等损失出现才有。

T2 Tutorial • 训练一个网络（Training a network）

⭐ **官方答案。**Q3 **复用 T1 那个网络**做隐藏层任务，所以上一节的前向结果可以直接接着用：$z = [6, 4, -1]^T$，$h = [6, 4, 0]^T$，$s = 1$，$p = \sigma(1)$，$\delta = p - 1 \approx -0.268941$。

> **★ 这份 worksheet 的约定（和 T1 略有不同，注意）**
>
> - **ReLU′(0) = 0** 被写成 implementation convention —— T1 那份说「没有预激活恰好为零」所以不必纠结，**这一份明确给了约定**；
> - **观测是列向量**（Observations are columns）；
> - 半平方误差 L_half = ½(p − y)²，**logit 梯度是 (p − y)p(1 − p)**；
> - ⭐ 官方一句很精炼的总结：**sigmoid 输出配 BCE 时链式化简成 p − y，但隐藏激活自己的局部导数仍然留在链条里。**

Q1 • 激活值与模型选择

1. 补上 z = −1 那一行（另外两行题目已给，用来对照）。

z	σ(z)	σ′(z)	tanh(z)	tanh′(z)	ReLU	ReLU′
−3	.0474	.0452	−.9951	.0099	0	0
−1	**.2689**	**.1966**	**−.7616**	**.4200**	**0**	**0**
1	.7311	.1966	.7616	.4200	1	1

$$\sigma(-1) = 1/(1+e) = 0.268941 \quad \sigma' = .268941(1 - .268941) = .196612$$
$$\tanh(-1) = (e^{-1} - e)/(e^{-1} + e) = -.761594 \quad \tanh' = 1 - (-.761594)^2 = .419974$$
$$\mathrm{ReLU}(-1) = \max(0, -1) = 0 \quad \mathrm{ReLU}'(-1) = 0$$

2. 饱和与「零导数能否证明死亡」。官方原话要点：sigmoid 和 tanh 在 **−3 处的斜率比 −1 处小得多**——输出已经接近极限值，分数再变也动不了多少。**小斜率连乘会削弱隐藏层的学习信号。**

> **⚠ 官方对「零导数」的措辞（和 T1 Practical 完全一致）**
>
> **一个负的 ReLU 分数只挡住「这个观测」的传入梯度；别的观测仍可能激活同一个单元。这不能证明永久失活。**

3. 四个任务的输出与损失（官方逐条给了理由）：

任务	输出 + 损失	官方给的理由
(a) 有符号的温度异常	**线性 + MSE 或 MAE**	线性输出允许**带符号的数值**
(b) 二元记录匹配	**sigmoid + BCE**	sigmoid 表示一个二元概率；⚠ **ReLU 上方无界，保证不了概率落在 [0,1]**
(c) 五种状态之一、存成整数	**五个 softmax + sparse categorical CE**	互斥的整数标签用 sparse 版；⚠ **若标签是 one-hot 则用 categorical CE**
(d) 六种可能同时出现的故障	**六个 sigmoid + 各一项 BCE**	⚠ **softmax 会强迫输出之和为 1、互相竞争**；分开的 sigmoid **不要求观测到的标签统计独立**

Q2 • 损失值与学习信号

1

回归损失。 预测 $\hat{y} = (2.5, 4)$，目标 $y = (3, 1)$ ⇒ 残差 $y - \hat{y}$ = **0.5 和 −3**。

$$\text{MSE} = (0.25 + 9)/2 = 4.625 \qquad \text{MAE} = (0.5 + 3)/2 = 1.75$$

⭐ **官方用占比把「谁更敏感」量化了**：大的那个残差贡献了平方误差总量的 **9/9.25 ≈ 97%**，却只占绝对误差总量的 **3/3.5 ≈ 86%**。⇒ **平方把大误差放得更大，所以 MSE 对它更敏感。**

⚠ 另一句也要写：**MAE 保持目标的单位；MSE 的单位是目标单位的平方。**

2

三个 BCE 值。

$$(y, p) = (1, .9) \Rightarrow -\ln(.9) = 0.105361$$
$$(y, p) = (0, .2) \Rightarrow -\ln(1 - .2) = 0.223144$$
$$(y, p) = (1, .6) \Rightarrow -\ln(.6) = 0.510826$$

$$\text{和} = 0.839330 \qquad \text{均值} = 0.839330/3 = 0.279777$$

哪一个贡献最大：第三个。官方的理由写得很准——**它给自己那个真实类别分配的概率最低。**

3

两种搭配的 logit 梯度对比（$y = 1$、$p = .6$）。

$$\text{BCE：} \quad p - y = -0.4$$
$$\text{半平方：} \quad (p - y)\cdot p(1-p) = (-0.4)(0.6)(0.4) = -0.096$$

多出来的那个 sigmoid 斜率在这里是 $p(1-p) = 0.24$

⚠ 官方的限定句：**p 趋近 0 或 1 时这个因子趋近于零，所以即使是「有把握却判错」的预测，它也会削弱输出端的学习信号。**

⭐ 还有一句很值钱：**输出端的这个约分并不消除隐藏激活的导数**——BCE 救的是输出层，救不了隐藏层。

4

多分类。 p = (.2, .5, .3)，真实类别是第 3 类。

> one-hot 目标 $y = (0, 0, 1)$
> $L = -[0 \cdot \ln(.2) + 0 \cdot \ln(.5) + 1 \cdot \ln(.3)] = -\ln(.3) = 1.203973$
> logit 梯度 $p - y = (.2, .5, -.7)$ ← 三项之和为 0

符号怎么读：减去**正的**梯度会**压低** logit 1 和 2；减去**负的**梯度会**抬高** logit 3。

5

解读后来的结果（题目直接给：p = (.1, .3, .6)、损失 .510826、梯度 (.1, .3, −.4)）。

> 真实类别的概率 .3 → .6，翻了一倍
> 损失下降 $\ln 2 \approx 0.693147$ （$1.203973 - 0.510826 = 0.693147$）
> 预测类别从第 2 类变成第 3 类

⚠ **最后那一问是概念分**：为什么更新一个网络权重还需要链式法则？官方答——**logit 取决于权重和激活，所以权重的梯度还要包含「这个权重如何影响各个 logit」；logit 梯度本身不是权重梯度。**

Q3 • 一个隐藏权重的梯度与训练过程

1

追 $w_{12} \to z_1 \to h_1 \to s \to p \to L$（注意这里是 T1 那个网络）。

> $\partial L/\partial w_{12} = (\partial L/\partial p)(\partial p/\partial s)(\partial s/\partial h_1)(\partial h_1/\partial z_1)(\partial z_1/\partial w_{12})$
> $= \delta \times v_1 \times \mathrm{ReLU}'(z_1) \times x_2$
> $= (-0.268941) \times 1 \times 1 \times 3 = -0.806824$
>
> 更新：$w_{12} = 2 - 0.1(-0.806824) = 2.080682$

符号的含义：梯度为负 ⇒ **局部增大这个权重会降低损失。**

⚠ 官方补了一句很好的对照：**如果隐藏层用的是 sigmoid，它自己的那个导数因子就会留在链条里**（这里因为 ReLU 在正半轴导数是 1，才「看不见」）。

2

隐藏单元 3 的两个零，原因不同（这是本题的概念重点）。

哪个梯度为零	直接原因
它的**输入权重与偏置**梯度	⚠ **$\partial L/\partial h_3$ 其实不为零（= 2δ）**，但它的分数是负的 ⇒ **ReLU 导数为 0，把传入的梯度挡住了**
它的**输出权重** v_3 的梯度	因为它的**输入激活 $h_3 = 0$**

⚠⚠ **官方明确写了：两者都不能确立永久失活。**

3

训练过程三连问。

- **自动微分算什么**：对记录下来的运算应用链式法则，**算出梯度**；**优化器**随后**用这些梯度改变参数。**
- **为什么要全部算完再更新**：**所有梯度必须对应同一个原始的前向状态。**
- **计数**：100 个观测、批大小 20 ⇒ 一个 epoch **5 次**更新，三个 epoch **15 次。** ⭐ 官方的一句定义很好用：**一个 epoch 覆盖整个数据集；一次更新改变一次参数。**

选做 extension • 把整个第一层算完

$$g = \partial L/\partial z = W_2^T \delta \odot \mathrm{ReLU}'(z) \qquad \odot \text{ 是逐元素相乘}$$
$$= [1, -1, 2]^T(-0.268941) \odot [1, 1, 0]^T = [-0.268941, 0.268941, 0]^T$$

$\partial L/\partial W_1 = g\, x^T$，$x = [0, 3]^T$：　　$\partial L/\partial b_1 = g$

$$\begin{bmatrix} 0 & -0.806824 \\ 0 & 0.806824 \\ 0 & 0 \end{bmatrix} \Rightarrow W_1,\text{new} \approx \begin{bmatrix} 1 & 2.080682 \\ -1 & 0.919318 \\ 0 & 1 \end{bmatrix}$$

新的偏置列 $b_1,\text{new} \approx [0.026894, 0.973106, -4]^T$

⚠⚠ 零条目有两个不同的成因（官方点名要你分开说）

- **第一列全是零** —— 因为 **$x_1 = 0$**（这个输入本身是零，和激活无关）；
- **第三行全是零** —— 因为**那个单元的 ReLU 导数是零。**
- ⭐ 加上 Q3 里 v_3 的那个零（**$h_3 = 0$**），这份 Tutorial 一共演示了 **三种不同成因的零梯度**：输入为零 / 导数为零 / 激活为零。

第二问：把 Q2(3) 的对比移到 p = .02、y = 1 处。

BCE：　$p - y$　　$= -0.98$
半平方：　$(-0.98)(.02)(.98) = -0.019208$

幅度比 $= 1/[p(1-p)] = 1/(0.02 \times 0.98) \approx 51.0204$

⭐ 这个比值有闭式，记它比记数字值钱

两种搭配的 logit 梯度幅度比永远是 1/[p(1−p)]。 p = .6 时只有 1/0.24 ≈ 4.17，p = .02 时就涨到 **51**。⇒ 官方收尾：**它取决于 sigmoid 的局部斜率，不是一个普适常数。**

T3 Tutorial • 模型评估（Model evaluation）

★ 这份 worksheet 的约定

- **类别 1 是正类**；**分数 ≥ 阈值**就预测为正；
- ⚠ **混淆矩阵：真实类别在行、预测类别在列**；
- **TPR = TP/(TP+FN) 就是 recall，FPR = FP/(FP+TN)**；
- **比例报到小数点后 3 位。**

Q1 • 数据角色、泄漏、拟合诊断与停止

1

10,000 个观测按 60% / 20% / 20% 划分。

> 训练 6000：拟合参数**与预处理**
> 验证 2000：挑选设置
> 测试 2000：评估**已经冻结**的那个选择

2

四个操作，哪些不合适。

操作	判定	官方理由
划分**之前**就在全部观测上拟合缩放器	**不合适**	**缩放的统计量是学出来的量**：要在训练数据上拟合，再在别处复用
用验证表现挑超参数	合适	这正是验证集的用途
反复用测试表现挑模型	**不合适**	这会让测试集参与选择
所有模型与预处理选择定稿后，用测试集**一次**	合适	这是最终评估

⚠ 官方的限定句很值得抄：**泄漏会带来偏乐观的评估，但它并不必然抬高每一个观测到的分数。**

3

三个模型的诊断（平衡任务，多数类基线 50%，benchmark 约 90% 验证准确率，且已充分优化）。

模型	训练 / 验证	诊断
A	60% / 58%	**欠拟合**（两边都远低于 90% 的 benchmark）
B	99% / 72%	**过拟合**（差距很大）
C	88% / 86%	**这里验证证据最强**

⚠⚠ **官方收尾那句一定要写：这些是有条件的诊断，不是保证；差距小本身也不能证明拟合得好。**

4

学习率（就是 T3 复习课件那张表，起点 0.580352）。

$$\eta = 0.1 \Rightarrow 0.574996 \quad \eta = 1 \Rightarrow 0.533347 \quad \eta = 100 \Rightarrow 9.965953$$

哪些有帮助：0.1 和 1 都降低了初始平均损失，**1 在这一步给出最低值**；**100 把损失大幅抬高。**

⚠ 官方的两条否定：**这种单状态的比较既不能确立普适最佳学习率，也不能确立每个观测都被正确分类——平均值可以下降而某些样本仍然是错的。**

5

早停用哪部分数据?

用验证证据选停止点和最佳检查点；测试数据保持不被碰过。

⚠ **训练损失几乎不动不能证明收敛到最好的模型**——官方说它可能只是**优化变慢或卡住**，而不是全局最优或泛化良好。

Q2 • 混淆计数、指标与错误代价

官方给的验证集混淆矩阵（⚠ 注意这一份是**正类在前**）：

真实 / 预测	Positive	Negative
Positive	**TP = 42**	**FN = 8**
Negative	**FP = 18**	**TN = 132**

四格之和 $= 42 + 8 + 18 + 132 = 200$ ✓

$$\text{Accuracy} = (42 + 132)/200 = 174/200 = 0.870$$
$$\text{Precision} = 42/(42 + 18) = 42/60 = 0.700$$
$$\text{Recall} = 42/(42 + 8) = 42/50 = 0.840$$
$$\text{F1} = 2(0.700)(0.840)/(0.700 + 0.840) \approx 0.764$$

⚠ **第 3 问是文字分，照这个结构写**

- **漏报（FN）让一个次品流到顾客手里** ⇒ 顾客会受到伤害时，**recall 优先**；
- **误报（FP）消耗有限的检验产能** ⇒ **precision 仍然重要**；
- ⭐ 官方收尾：**工作阈值应当在「漏掉次品的代价」与「可用检验资源」之间权衡；指标本身定义不了什么是可以接受的。**

4

基线、代价与阈值。

> 真实负例共 150 ⇒ 全判负的基线准确率 = 150/200 = 0.750
>
> 总代价 = 5·FN + 1·FP
> 原阈值： 5(8) + 18 = 58
> 低阈值（TP=47, FN=3, FP=35, TN=115）： 5(3) + 35 = 50 ← 在这组代价下更优
>
> 低阈值下： recall 0.840 → 0.940 （变好）
> precision 0.700 → 47/82 ≈ 0.573 （变差）
> accuracy 0.870 → (47+115)/200 = 0.810 （也变差）

⭐⭐ **官方这里有一句极漂亮的话：准确率也下降了，尽管代价改善了——准确率并不编码错误的代价。**

⚠ 还有一句限定：**precision 不保证在每个数据集上都会下降**（这里只是这个例子）。

流程：在验证数据上选阈值 → 冻结 → 再到没碰过的测试集上评估。

Q3 • ROC 曲线与 AUC

六个打分案例（标签 1 为正）：A .9/1、B .8/0、**C .7/1、D .7/0**（同分）、E .4/1、F .2/0。⇒ 3 个正例、3 个负例，所以 **TPR = TP/3、FPR = FP/3。**

阈值	被判为正	FPR	TPR	ROC 点
高于 0.9	无	0	0	**(0, 0)**
0.9	A	0	0.333	**(0, 0.333)**
0.8	A, B	0.333	0.333	**(0.333, 0.333)**
0.7	**加 C 和 D**	0.667	0.667	**(0.667, 0.667)**
0.4	加 E	0.667	1	**(0.667, 1)**
0.2	加 F	1	1	**(1, 1)**

⭐ **为什么 C 和 D 必须一起进，曲线是什么形状**

它们分数相同，所以没有哪个阈值能只收进其中一个。 于是 TP 和 FP 同时加一 ⇒ 点**同时往上又往右**，从 (0.333, 0.333) **斜着**走到 (0.667, 0.667)——**是一段对角线，不是阶梯。**官方的措辞：**分数不支持给它们排序。**

2

配对法核对（3 正 × 3 负 = 9 对，平局算半个）。

A(.9) 赢 B(.8)、D(.7)、F(.2) ⇒ 3
C(.7) 赢 F(.2)；与 D(.7) 平局 = 0.5；输给 B(.8) ⇒ 1.5
E(.4) 赢 F(.2)；输给 B 和 D ⇒ 1

正确排序 = 5.5 / 9 ⇒ AUC ≈ 0.611 （梯形法给出同一个值）

3

第二个分类器（题目给了六个阈值点，⚠ **FPR 画横轴、TPR 画纵轴**）。

(0, 0) → (0.1, 0.4) → (0.2, 0.5) → (0.4, 0.7) → (0.8, 0.9) → (1.0, 1.0)

梯形面积 = 宽 × (两端 TPR 的平均)

$A_1 = 0.020$（题目给） $A_2 = 0.045$（题目给）

$A_3 = (0.4-0.2)(0.5+0.7)/2 = 0.120$

$A_4 = (0.8-0.4)(0.7+0.9)/2 = 0.320$

$A_5 = (1.0-0.8)(0.9+1.0)/2 = 0.190$

$AUC = 0.020 + 0.045 + 0.120 + 0.320 + 0.190 = 0.695$

⚠ **第 5 问的解读，三句都要写**

- **AUC ≈ 0.70 的含义**：随机取一个正例、随机取一个负例，**正例得分更高的概率大约是 70%**（平局算半个）。
- ⚠ **0.695 只是近似**——它是从**六个工作点**估出来的，不是完整经验曲线的面积。
- ⭐ **AUC 概括跨阈值的排序，但它不替你选工作点。漏报更贵就用较低的阈值抬高 TPR（接受更多误报）；误报更贵就用较高的阈值。**

选做 extension • 稀有正例

2000 个验证案例，其中只有 20 个是正例。阈值处 TPR = 0.8、FPR = 0.05：

$TP = 0.8(20) = 16$ $FN = 20 - 16 = 4$

$FP = 0.05(1980) = 99$ $TN = 1980 - 99 = 1881$

$precision = 16/115 \approx 0.139$

$accuracy = (16 + 1881)/2000 = 0.9485$

全判负的基线 $accuracy = 1980/2000 = 0.990$ ← 比模型还高

⚠⚠ **这一段是 T3 最锋利的结论，几乎一定会考**

- **模型找到了 80% 的正例，准确率却低于「全判负」的基线。**
- **准确率被大量负例主导**;
- ⭐ **ROC 用的是类内条件率，所以很小的 FPR 仍然可以意味着「99 次误报换 16 次命中」**;
- ⇒ **正例稀少时，precision 和 recall 才说明正类预测的质量与覆盖面。**

⚠⚠ 混淆矩阵的摆法：三份官方材料的统计

这是 10-26 查出、11-03 拿到 Tutorial 答案后**可以给出确定口径**的一处。

官方材料	摆法	左上角
Canvas 讲义页（Accuracy, precision, recall）	行=真实、列=预测，**正类在前**	**TP**
M3 T3 Tutorial（计分的 worksheet）	行=真实、列=预测，**正类在前**	**TP**
M3 T3 复习课件（Build the Confusion Matrix）	行=真实、列=预测，**负类在前**	**TN**
sklearn `labels=[0,1]`	同上，**负类在前**	TN

★ 结论（比 10-26 那版更明确）

- **三份官方材料里有两份是「正类在前」，包括那份要计分的 Tutorial。**所以如果题目不给标签，**正类在前是更可能的默认。**
- ⚠ **但复习课件确实是反的**，所以**仍然不能背摆法。**
- ⭐ 三份材料都写了同一句话：**行是真实类别、列是预测类别**，而且都要求**先确定正类。⇒ 照构造规则逐格认**（TP = 真实正、预测正……），**四个计数在两种摆法下完全相同。**
- **答题时写一句「本题约定正类为 X，行为真实、列为预测」，再逐格标注——这样无论题目用哪种排法都不会错。**

T1 Practical • 官方 worked discussion 要点

⚠ **Practical 用的是另一个网络**（2 → 3 → 1，四个观测），和上面 Tutorial 的 3 隐藏单元网络**不是同一套数字**，别混。

第一个观测的完整前向（官方给的，已复算核对）：

$$x = [1, -1]$$
$$\text{单元 1：}\ 1(0.6) + (-1)(-0.2) + 0.1 = 0.9$$
$$\text{单元 2：}\ 1(-0.4) + (-1)(0.7) + 0.2 = -0.9 \quad \Rightarrow \text{ReLU 截断}$$
$$\text{单元 3：}\ 1(0.3) + (-1)(-0.5) - 0.1 = 0.7$$
$$h = [0.9, 0, 0.7]$$
$$\text{logit} = 0.9(0.8) + 0(-0.6) + 0.7(0.5) + 0.1 = 1.17$$
$$p = \sigma(1.17) = 0.763145 \quad \text{BCE（y=1）} = 0.270307 \approx 0.2703$$

⚠ 官方在这里专门提醒的两点

- **四个观测的平均 BCE 是 0.745984，不是第一个观测的 0.2703。**报「平均损失」时别拿单个样本的数去填。
- **权重是题目给的，不是学出来的。**官方原话：“A confident output alone shows neither accurate training nor generalisation.” 而且**第四个观测就是反例：p ≈ 0.7658 而 y = 0**——很自信，而且错了。

Q2 要点 • 平均损失的 1/N 与「用原始 W_2 反传」

- **平均损失下，每个观测只贡献它自己梯度的 1/N。**四个观测的输出 logit delta **(p − y)/4 ≈ [−0.059214, 0.096154, −0.134979, 0.191462]。**⚠ 官方把两种错法都点名了：**除两次会让梯度太小；不除则求的是「和」的导数而不是「平均」的。**
- **形状**：`h.T @ delta2` 是 (3,4)×(4,1) ⇒ **(3,1)**，每个输出权重一个梯度。第一个输出权重：0.9(−0.059214) + 0(0.096154) + 0.2(−0.134979) + 1.2(0.191462) = **0.149466**，**为正 ⇒ 梯度下降会把它减小**，η = 0.1 时从 0.8 变成约 **0.785053。**
- **往回传时乘的是「原始」输出权重，再乘 ReLU 掩码。**观测 1 得到 **[−0.047371, 0, −0.029607]**，⚠ **中间那个是零，因为那个隐藏预激活是负的。**
- **偏置的梯度是 delta 求和**，因为「加偏置」这一步的导数是 1。
- ⚠⚠ 官方收尾那句要背：“All gradients must refer to the same forward-pass parameter state. **Using an already-updated W_2 mixes two states and no longer differentiates the original loss.**”

⚠⚠ Q3 要点 • 两张学习率表，别记混

M3 里有**两个**「四个观测、单步比较学习率」的实验，**网络不同、数字不同、最优 η 也不同。**考场上看到学习率表，先确认是哪一个。

学习率 η	Canvas 课程页 / T3 复习课件那张	T1 Practical 那张
（起点）	0.580352	0.745984
0	0.580352（参数没变）	0.745984（参数没变）
0.1	0.574996	0.733989
1	0.533347	**0.664890** ← 这张表里最低
10	**0.371611** ← 这张表里最低	（没做这一档）
100	9.965953（飞了）	4.621223（飞了）

★ 两张表都在说同一句话

- **η = 0 一定复现原损失**——官方把这当成实现是否正确的自检。
- **每一档都从同一组初始参数和同一个梯度出发**，所以差异只来自 η 本身；“chaining updates would confound the rate comparison”——**把更新串起来做就毁了这个对比。**
- **大步会越过激活边界**：官方原话 “a finite large step can cross activation boundaries and move into a much worse region”。
- ⚠⚠ **一次改善既不证明收敛，也不估计未见数据上的表现。**
- ⭐ 两张表最优的 η 不同（一张是 10、一张是 1），**正好说明没有普适最佳学习率。**

⭐ Q4 要点 • 「ReLU 不激活」有三个层级（官方措辞）

层级	官方说法	能得出什么结论
① 对**一个观测**不激活	“Inactive for one observation means only that observation's path is blocked.”	**只有那一个观测**的这条路径被掐断
② 对**这一批**都不激活	“Inactive for this whole batch means no incoming gradient from these four observations at this state.”	在**当前参数状态**下，这批数据给不了它任何输入权重的梯度
③ **永久**死亡	“Other inputs could still activate the unit, so this experiment does not prove permanent inactivity.”	⚠ **这个实验证明不了**

官方的具体数字：第三个单元原本输出 **[0.7, 0, 0, 0.25]**，所以观测 1 和 4 仍能通过它贡献梯度，对应的两个输入权重梯度约 **[0.161855, 0.077472]**。把它的偏置改成 **−10** 之后，四个预激活变成 **[−9.2, −10.55, −10.35, −9.65]**，**全为负** ⇒ 输出和输入权重梯度**这一批**全变成零。

⚠ 机制要说对

官方原话： “The ReLU derivative mask blocks the gradient along this path; **a nonzero output error alone cannot pass through it.**” —— **输出端的误差不为零也没用，过不了那道零导数的闸。**

Q5 要点 • 一段代码里的两个独立错误

题目给的场景：某同学算完输出层梯度后**立刻更新 W_2**，然后**用更新后的 W_2** 去算隐藏层梯度；并且用 `W1 + learning_rate*dW1` 更新 W_1。官方说这里有**两个彼此独立**的错误：

#	错在哪	为什么错
①	**在算隐藏层梯度之前就更新了 W_2**	“mixes parameter states”——两个参数状态混在一起，算出来的不再是原损失的导数
②	**把梯度加上去**（`W1 + rate*dW1`）	“is an ascent step”——学习率为正时，最小化损失必须**减**

> 官方给的正确写法：
>
> ```
> old = [a.copy() for a in parameters]
> grads = gradients(X, y, old)          # 全部梯度在同一个状态上算
> parameters = [a - rate*d for a, d in zip(old, grads)]
> ```

> ⭐ **自动微分那一问的标准答法**
>
> **自动微分会算什么**：追踪这一次前向计算里的各个运算，按链式法则给出**各参数的梯度。优化器随后做什么**：用这些梯度**执行参数更新。它能保证学习率合适吗——不能。** ⭐ 官方要你把这一问**接回 Q3**：Q3 那张表里 η = 100 把损失推到 4.62，而自动微分对此毫无意见——**它只负责求导，不负责步长。**

扩展自学要点 • 数值梯度检查

- **做法**：对每个参数元素，复制一份、把那一个元素 **±ε** 扰动，用**中心差分 $(L_+ - L_-)/(2\varepsilon)$** 和解析梯度比。
- ⚠ **这是调试手段，不是训练算法**；而且 “near a ReLU kink the derivative may not exist”——**在 ReLU 的折点附近导数可能不存在**，那里对不上是正常的。
- **重复训练**：30 步、η = 0.1，**每一步都要重新算梯度**，记录初始损失和每步之后的损失。
- ⚠ 官方要求解释三件事：**为什么梯度必须每步重算**（参数变了，所有依赖参数的量都过期）、**为什么损失曲线下降不是泛化的证明**、**为什么数值检查比反向传播慢**（每个参数要跑两次完整前向）。

T2 Practical • 五道题在考什么

本地只有**空白版** notebook，没有解答。下面是题目要求的摘录，用来判断「这一题在考哪个知识点」。

题	要求	落在哪个考点
Q1 激活值与梯度	实现六个函数，比较值域与饱和，**解释 ReLU 在零处的导数约定**，说明只叠仿射层为什么限制表达力	sigmoid/tanh/ReLU 及导数；饱和
Q2 损失强调哪种误差	实现逐观测 BCE，**找出一个「自信但判错」的概率**并解释裁剪；先预测「A 和 B 能否准确率相同而 BCE 不同」，再验证	MSE 与交叉熵；损失 ≠ 准确率
Q3 前向与偏置干预	追第一个观测；**先用那个隐藏单元输出权重的符号预测「把第二个隐藏偏置减 2」会怎样**，再实际算、再解释别的观测为何反应不同	隐藏层的作用；先预测再验证
Q4 公平地比较激活函数	只在训练集上拟合 logistic / tanh / relu，**按验证 log loss 选**，再用 train+validation 重拟合，**测试集只评一次**	⭐ 这就是 T3 的流程；并要求说明单次划分/初始化的局限
Q5 选对输出与损失	三个设计各有一处输出激活或损失不合适（如预测摄氏温度，**预测值必须允许负数**），要指出问题、给出正确搭配、并说明为什么匹配	四种任务的输出层与损失

★ Q4 和 Q5 直接就是扩展题素材

- **Q4 的流程**（训练集拟合 → 验证选择 → 合并重拟合 → 测试评一次）是 T3 考纲第一条的落地版，扩展题问「如何选定并报告」时照搬即可。
- **Q5 是配对表的反向用法**：给一个错配让你诊断。⭐ 练熟了正向（给任务选搭配）之后，一定要再练一遍反向。

材料清点与还缺什么

材料	状态
M3 T1 / T2 / T3 **Tutorial 答案**	⭐ **三份齐全**（2026-11-03），本册已全解
M3 T1 Tutorial 题目卷	有
M3 T1 Practical 解答	有（官方 worked discussion）
M3 T2 Practical	**只有空白版**，没有解答 —— 题目结构见上一节
M3 T3 Practical	**不存在。**官方写明 **Topic 3 没有排定的 practical**，只有两个选做不计分的 notebook
M3 T2 / T3 Tutorial 的**题目卷**	本地只有带答案的版本；⚠ 想先自己做一遍的话，**遮住每页的 Solution 方框**即可，题面是完整的

⭐ **剩下 6 天怎么用这一册**

- **先遮住 Solution 自己做一遍** T1/T2/T3 的 Q1–Q3——它们是三种最可能的大题原型：**前向+梯度+更新**、**隐藏权重的链式梯度**、**指标+代价+ROC**；
- **对答案时重点看措辞**，不是看数字对不对。官方每一问后面那一两句限定（「这不能证明……」「这取决于……」）就是扩展题后半段的分；
- **三个 extension 也值得做**：T1 的「换目标」、T2 的「整层梯度 + 幅度比」、T3 的「稀有正例」，每一个都把对应 Topic 最锋利的那条结论演示了一遍；
- ⚠ **最后一天只看**：本册的三张速算表（激活函数三行表、混淆矩阵四格、ROC 点）+《M3 考前框架走查》。

⚠ 之后若拿到 T2 Practical 的解答，**放进** `M3材料/Tutorial与Practical/` **再重跑** `_src/tutorials.py`。数字复算脚本：`_src/verify_tut_all.py`（官方答案 105 项）与 `_src/verify_tut_t1.py`（T1 自解 54 项）。