神经网络基础

Module 3 · Topic 1 — 题库与解析

ARTI2001 Machine Learning · 2026 Semester 2

共 13 组 • 65 道选择题

覆盖：神经元三件事 · 前向传播 · **为什么一个神经元不够**
层间非线性的塌缩论证 · 计算图 · **链式法则（相乘与相加）**
BCE · **δ = p − y** · 一次梯度下降更新的完整算例
含考纲给的官方示例大题（拆成 4 道选择）

配套：《M3T1 神经网络基础 知识点整理》· M3 测验 Week 13

目录

使用方法

第 1 组：一个神经元做什么（T1-1 §1）

第 2 组：前向传播与「概率 vs 类别」（T1-1 §2）

第 3 组：为什么一个神经元不够（T1-1 §3）

第 4 组：连成网络与下标读法（T1-1 §4）

第 5 组：为什么层间必须非线性（T1-1 §5）

第 6 组：学习时改变的是什么（T1-1 §6–7）

第 7 组：计算图与局部导数（T1-2 §3–4）

第 8 组：链式法则：相乘与相加（T1-2 §5–6）

第 9 组：接到损失上（T1-2 §7）

第 10 组：BCE 损失（T1-3 §1）

第 11 组：δ = p − y（T1-3 §2）

第 12 组：一次梯度下降更新（T1-3 §3）

第 13 组：反向传播 vs 梯度下降 · 考纲示例题

使用方法

每组 5 题，题目与选项在前，答案与解析在该组末尾。建议先遮住解析区独立作答，整组做完再核对。做错的题回到《M3T1 神经网络基础 知识点整理》对应章节复习。

组标题后括号里是对应的讲义小节编号（T1-1 §3 = 第 1 课第 3 节），方便回查。

第 1 组：一个神经元做什么（T1-1 §1）

1. 一个人工神经元依次做哪三件事?

A. 过激活函数 → 加权求和 → 加偏置
B. 加权求和 → 加偏置 → 过激活函数
C. 加偏置 → 过激活函数 → 加权求和
D. 加权求和 → 过激活函数 → 加偏置

2. 下面哪一组量是训练时会被更新的「参数」?

A. 输入特征 x 与目标 y
B. 预激活 z 与激活输出 a
C. 权重 w 与偏置 b
D. 权重 w、偏置 b 与激活输出 a

3. 偏置 b 的作用是什么?

A. 与当前输入无关地平移分数
B. 给每个输入特征一个各自的缩放倍数
C. 把分数压缩到 0 和 1 之间
D. 决定隐藏层里有几个神经元

4. 某个输入的权重是负的，这意味着:

A. 该输入必须先取绝对值再参与计算
B. 该输入的数值越大，分数越大
C. 该输入会被忽略
D. 该输入的数值越大，分数越小

5. x = [1, 2]，w = [0.2, 0.4]，b = 0.1，则预激活 z 等于多少?

A. 0.7
B. 1.1
C. 1.0
D. 1.3

答案与解析

1. B —— $z = w_1x_1 + w_2x_2 + b$ 先得到预激活，再 $a = g(z)$。⚠ 偏置是加在激活函数**之前**的。

2. C —— 只有**权重和偏置**是存下来的可调量。z 和 a 是每个样本现算的中间值，x 和 y 是给定的数据。⚠「优化器调整哪些量」是高频概念题。

3. A —— 偏置不乘任何输入，只整体**平移** z。缩放是权重的事，压缩到 (0,1) 是 sigmoid 的事。

4. D —— 正权重 ⇒ 输入变大分数变大；负权重 ⇒ 反之。权重为 0 才是忽略该输入。

5. B —— 0.2×1 = 0.2，0.4×2 = 0.8，z = 0.2 + 0.8 + 0.1 = **1.1**。这是贯穿整个 Topic 1 的那个算例。

第 2 组：前向传播与「概率 vs 类别」（T1-1 §2）

1. 接上题，p = σ(1.1) ≈ 0.750260，按「p ≥ 0.5 判类 1」规则，预测类别是：

A. 类别 0，因为 0.750260 不等于 1
B. 无法判定，还需要知道目标 y
C. 类别 1
D. 类别 1 的概率是 75.0%，但类别要等训练完才能定

2. 前向传播这一步里，目标 y 起了什么作用？

A. 被用来计算预激活 z
B. 被用来决定判类阈值
C. 被用来初始化权重
D. 完全没有被用到

3. 跑完一次前向传播之后，网络的参数发生了什么变化？

A. 什么都没变，所以还没有发生学习
B. 权重变了，偏置没变
C. 权重和偏置都朝降低损失的方向变了一点
D. 偏置变了，权重没变

4. 只把 b 从 0.1 提到 0.6、其余不变，类别 1 的概率会怎样？

A. 下降，因为偏置变大会压低 sigmoid
B. 不变，因为偏置不乘输入
C. 上升，因为 z 从 1.1 变成 1.6
D. 先上升后下降，取决于输入的符号

5. 某模型对一个样本给出 p = 0.99。仅凭这个数可以断定什么？

A. 什么都不能断定——高置信度既不等于学过，也不等于正确
B. 这个预测一定是正确的
C. 它至少在训练集上已经收敛
D. 它的参数一定是从数据里学来的

答案与解析

1. C —— 0.750260 ≥ 0.5 ⇒ 判类 1。⭐ **概率（≈0.75）和类别标签（1）是两个不同的量**，考试很爱考这个区分。

2. D —— ⚠ 前向传播只用**当前参数**把输入算到输出，**y 在这一步没有被用到**，它是后面算损失时用来评判这个预测的。

3. A —— ⚠ 前向传播**不改变任何参数**。改参数要等反向传播算出梯度、梯度下降执行更新之后。

4. C —— z = 0.2 + 0.8 + 0.6 = 1.6，sigmoid 递增 ⇒ 概率上升。这是讲义给的自测题。

5. A —— ⚠ 讲义原文的自测点：**高置信度 ≠ 学过 ≠ 正确**。随便设一组参数也能产生 0.99。

第 3 组：为什么一个神经元不够（T1-1 §3）

1. 单个 sigmoid 神经元在两个输入下的决策边界是什么形状?

A. 若干条互相平行的直线
B. 一条 S 形曲线，因为 sigmoid 是非线性的
C. 一个圆，半径由偏置决定
D. 一条直线

2. 「sigmoid 明明是非线性的，为什么决策边界还是直的？」正确的解释是：

A. sigmoid 在 0 附近可以近似成线性，所以边界近似是直线
B. 概率输出确实非线性，但类别改变恰好发生在 $z = 0$ 处，而 $z = 0$ 是一条直线
C. 只有当权重很小时边界才是直线，权重大了就会弯
D. 因为计算时做了四舍五入，边界被近似成了直线

3. 两类数据各占对角线上的两个角（异或型）。一个 sigmoid 神经元训练很久之后：

A. 能分对，但需要把输入先标准化
B. 只要学习率够小，最终一定能分对
C. 只要迭代次数够多，最终一定能分对
D. 仍然分不全对，这是模型表达能力的限制

4. $w_1 = -1$、$w_2 = 0$、$b = 0$ 的神经元，它的决策边界是：

A. 一条水平线 $x_2 = 0$
B. 过原点的 45° 斜线
C. 一条竖直线 $x_1 = 0$
D. 不存在边界，输出恒为常数

5. 如果两个权重都为 0，这个神经元会怎样?

A. 对任何输入都输出同一个常数
B. 边界退化成一个点
C. 输出等于偏置本身
D. 自动忽略偏置，输出恒为 0.5

答案与解析

1. D —— 阈值 0.5 对应 **$z = 0$**，即 $w_1x_1 + w_2x_2 + b = 0$ —— 两个输入时这是**一条直线**。

2. B —— ⭐ 关键在 **sigmoid 保序**：正分数给出 >0.5、负分数给出 <0.5。所以「在哪里越过 0.5」完全由「在哪里 z 越过 0」决定。

3. D —— ⚠ 讲义专门警告：「再 train 久一点」是**错误选项**。任何一条直线都会把两类混在一起。

4. C —— $z = -x_1$，边界 $z = 0$ 就是 $x_1 = 0$，一条**竖线**。这是讲义里「蓝点全在左、橙点全在右」那个能搞定的例子。

5. A —— $z = b$ 与输入无关 ⇒ $p = \sigma(b)$ 是常数。⚠ 输出是 $\sigma(b)$ 而不是 b 本身。

第 4 组：连成网络与下标读法（T1-1 §4）

1. 记号 w_ji 里两个下标分别指什么？

A. j 是输入编号，i 是接收的隐藏神经元
B. j 是接收的隐藏神经元，i 是输入编号
C. j 是层号，i 是神经元编号
D. j 是训练轮次，i 是样本编号

2. 「隐藏层」里的「隐藏」指的是什么？

A. 这些神经元的数量由数据自动决定
B. 这些值在训练完成后会被丢弃
C. 这些权重不参与梯度更新
D. 这些值是内部中间值，既不是观测到的输入也不是要求的输出

3. 隐藏激活 h 和权重 w 的根本区别是什么？

A. h 是存下来的参数，w 是每个样本现算的
B. h 是每个样本重新算的中间值，w 是存下来的参数
C. 两者都是参数，只是所在层不同
D. h 只在训练时存在，推理时不计算

4. 网络结构图上两条箭头交叉，这意味着什么？

A. 交叉处存在一个额外的神经元
B. 这两个权重被强制共享同一个数值
C. 什么也不意味着，交叉只是画图造成的
D. 信号在交叉处会相互抵消

5. 本课在隐藏层和二分类输出层分别用什么激活函数？

A. 隐藏层 ReLU，输出层 sigmoid
B. 两层都用 sigmoid
C. 隐藏层 sigmoid，输出层 ReLU
D. 两层都用 ReLU

答案与解析

1. B —— ⚠ 容易记反：**第一个下标是接收端**。所以 w_{11} 和 w_{12} 都喂给 h_1。

2. D —— 隐藏层在输入与最终预测之间计算中间值。⚠ 这些特征**不一定对应人能读懂的概念**。

3. B —— ⚠ **激活是针对每个样本重新算的，本身不是存下来的权重。**

4. C —— ⚠ 讲义专门提醒：**交叉的箭头不构成额外的神经元**；神经元里标的字母是它的**输出名**，不是它的权重。

5. A —— 隐藏层 ReLU：$g(z) = \max(0, z)$，$\text{ReLU}(-2) = 0$、$\text{ReLU}(2) = 2$；二分类输出层用 sigmoid 给出概率。

第 5 组：为什么层间必须非线性（T1-1 §5）

1. h = 2x + 1、s = 3h + 4，中间不加激活函数。整串等价于下面哪一个单层?

A. s = 6x + 5
B. s = 6x + 7
C. s = 5x + 7
D. s = 2x + 4

2. 「加权和 + 偏置」这种函数的专门叫法是:

A. 单调函数（monotonic function）
B. 凸函数（convex function）
C. 仿射函数（affine function）
D. 分段函数（piecewise function）

3. 把隐藏层换成 h = max(0, 2x + 1)、s = 3h + 4。x ≤ −0.5 时 s 等于多少?

A. 4
B. 0
C. 6x + 7
D. 3

4. x = 1 时，加 ReLU 与不加 ReLU 算出的 s 为什么相同?

A. 因为第二层的偏置抵消了 ReLU 的影响
B. 因为 x = 1 恰好是两段的折点
C. 因为 ReLU 对任何输入都不改变结果
D. 因为 ReLU 在正输入上是恒等映射，x = 1 落在不被截断的区域

5. 「隐藏层不放激活函数，只在最后放一个 sigmoid」行不行?

A. 行，sigmoid 已经提供了所需的非线性
B. 不行，因为 sigmoid 的输出不在 (0,1) 区间
C. 行，但需要把学习率调小
D. 不行，送进 sigmoid 之前的分数仍是输入的仿射函数，边界还是直线

答案与解析

1. B —— s = 3(2x + 1) + 4 = 6x + 3 + 4 = **6x + 7**。⇒ 一个权重 6、偏置 7 的单层给出完全相同的输出，两层**塌缩**了。

2. C —— 「层塌缩成一个仿射函数」就是说整串可以被那一个等价计算替换掉。

3. A —— 此时 2x+1 ≤ 0 ⇒ h = 0 ⇒ s = 3×0 + 4 = **4**（一段水平线）。x > −0.5 时才是 s = 6x + 7。两段在 x = −0.5 处相接。

4. D —— x = 1 ⇒ 2x+1 = 3 > 0，ReLU 原样输出，两者都得 s = 13。而 x = −1 落在被截断的区域：有 ReLU 得 4，无 ReLU 得 1。

5. D —— ⚠ sigmoid 让**概率输出**非线性，但 0.5 阈值仍对应分数为零 ⇒ 两个输入时仍是**一条直边界**。

第 6 组：学习时改变的是什么（T1-1 §6–7）

1. 监督训练的循环是哪四步？

A. Adjust → Predict → Compare → Repeat
B. Compare → Predict → Repeat → Adjust
C. Predict → Compare → Adjust → Repeat
D. Predict → Adjust → Compare → Repeat

2. 为了降低误差，可不可以修改输入值 x 或目标标签 y？

A. 可以，这叫数据增强
B. 绝对不可以，x 和 y 是给定的数据
C. 可以，但只能改 y
D. 可以，只要在验证集上也同步修改

3. 一次参数更新之后，同样的输入再过一遍网络，激活和预测会怎样？

A. 会变，因为参数变了
B. 完全不变，因为输入没变
C. 只有输出层变，隐藏层不变
D. 无法确定，取决于学习率是否大于 1

4. 网络学到的「知识」存放在哪里？

A. 集中在输出层的偏置里
B. 分布在全部权重和偏置里
C. 每个神经元各存一条完整的事实
D. 存放在训练数据的副本里

5. 「前馈（feed-forward）」和「深度（deep）」分别指什么？

A. 前馈指没有回环；深度指层层复合，不是指像人一样思考
B. 前馈指没有回环；深度指网络参数超过一百万
C. 前馈指梯度只向前传；深度指使用了 GPU
D. 前馈指必须使用 ReLU；深度指至少有十层

答案与解析

1. C —— 用当前参数预测 → 用损失函数评判 → 用「参数如何影响损失」更新 → 重复。

2. B —— ⚠ 一次更新里**只有权重和偏置改变**。

3. A —— 参数变了，前向算出的所有中间值和最终预测都会变。

4. B —— ⭐ **单个神经元一般不存储一条完整的事实。**

5. A —— ⚠ **深度不是指像人一样思考**，优化器是「更新参数的那条规则」。

第 7 组：计算图与局部导数（T1-2 §3–4）

1. 计算图画的是什么?

A. 数据点的散点图
B. 损失随训练轮次变化的曲线
C. 运算及其依赖关系的示意图
D. 网络各层神经元数量的柱状图

2. 在同一个算例里 $u = w_1x_1$、$v = w_2x_2$，那么 u 和 v 是什么?

A. 输出层的两个权重
B. 两个隐藏神经元的偏置
C. 两个输入特征的别名
D. 临时的中间计算值

3. $r = a \cdot b$ 时，$\partial r/\partial a$ 等于多少?

A. 1
B. b
C. a
D. 2a

4. $p = \sigma(z)$ 的局部导数 $\partial p/\partial z$ 等于:

A. $p(1-p)$
B. $\sigma(z)(1-z)$
C. $1 - p$
D. p^2

5. $f(u) = u^2$ 在 $u = 3$ 处斜率为 6。u 从 3 变到 3.01，导数估计的变化与实际变化:

A. 完全相等，都是 0.06
B. 无法比较，因为导数只在极限意义下有定义
C. 估计 0.0601，实际 0.06
D. 估计 0.06，实际 0.0601，差别来自斜率本身在变化

答案与解析

1. C —— ⚠ **不是数据点的散点图**。运算节点做小计算，箭头表示它们需要哪些值。

2. D —— ⚠ 讲义专门提醒：**u、v 是临时中间值，不是输出层权重**，别和 v_1、v_2 混。数值上 u = 0.2、v = 0.8。

3. B —— 乘法的局部导数是**另一个因子**。对照：加法 r = a + b 原样传递（导数为 1）；$r = a^2$ 的导数是 2a。

4. A —— ⭐ 这是必背的一条：sigmoid 的敏感度取决于**它自己的输出**。本例 p = 0.750260 ⇒ $p(1-p) \approx 0.187370$。

5. D —— ⭐ 这说明导数是**局部近似**。对照：仿射函数斜率不变，变化是**精确的**。

第 8 组：链式法则：相乘与相加（T1-2 §5–6）

1. 沿路径 $w_2 \to v \to z \to p$，$\partial p/\partial w_2$ 怎么组合?

A. 把三个局部导数相加
B. 把三个局部导数相乘
C. 取三个局部导数里最小的那个
D. 把前两个相乘再减去第三个

2. 代入 $p(1-p) \approx 0.187370$、$x_2 = 2$，$\partial p/\partial w_2$ 约等于多少?

A. 0.093685
B. 0.187370
C. 0.749480
D. 0.374740

3. 官方把 w_2 真的加 0.01 后算出实际增量 ≈ 0.003729，而导数预测 0.003747。差别的原因是:

A. 计算中有舍入错误
B. 导数公式用错了，应该乘 x_1
C. sigmoid 是非线性的，斜率在这一步里略有变化
D. 0.01 这个步长太小，数值不稳定

4. 共享值 q 分别喂给 r = 2q 和 t = 3q，再合并成 F = r + t。dF/dq 等于:

A. 2
B. 5
C. 3
D. 6

5. 一个隐藏激活同时喂给后面多个单元时，它的梯度应该怎么处理?

A. 把所有路径的贡献相加
B. 只取贡献最大的那条路径
C. 把所有路径的贡献相乘
D. 对所有路径的贡献取平均

答案与解析

1. B —— $\partial p/\partial w_2 = (\partial p/\partial z)\cdot(\partial z/\partial v)\cdot(\partial v/\partial w_2) = p(1-p)\cdot 1\cdot x_2$。**一条路径内部相乘。**

2. D —— $0.187370 \times 1 \times 2 \approx$ **0.374740**。⇒ w_2 增加 0.01，p 大约增加 0.003747。

3. C —— 二者**接近但不相同**，这正是局部近似的含义。

4. B —— $1\times2 + 1\times3 =$ **5**。校验：q = 1 时 F = 5，q = 1.01 时 F = 5.05。⚠ 只沿一支算会得到 2，**漏掉另一支的贡献。**

5. A —— ⭐ **相乘只在一条路径内部用；路径汇合处要相加。**

第 9 组：接到损失上（T1-2 §7）

1. $\partial L/\partial w_2$ 和 $\partial p/\partial w_2$ 的关系是：

A. $\partial L/\partial w_2 = (\partial p/\partial w_2) \div (\partial L/\partial p)$
B. $\partial L/\partial w_2 = (\partial L/\partial p) + (\partial p/\partial w_2)$
C. 两者相等，因为损失是概率的单调函数
D. $\partial L/\partial w_2 = (\partial L/\partial p) \times (\partial p/\partial w_2)$

2. $y = 1$ 且用 BCE 时，$\partial L/\partial p$ 的符号是什么？

A. 正，因为损失总是正的
B. 负，因为增大 p 会降低损失
C. 零，因为 p 已经大于 0.5
D. 取决于学习率的大小

3. 反向传播从哪个值开始往回累积？

A. $\partial L/\partial L = 1$
B. $\partial L/\partial p = -1/p$
C. 学习率 η
D. 第一层权重的初始值

4. 参数梯度算到一半时，梯度下降可以先把已经算好的那几个参数更新掉吗？

A. 可以，这样收敛更快
B. 可以，只要学习率足够小
C. 不可以，必须等全部参数梯度算完之后才更新
D. 不可以，但偏置是例外，可以先更新

5. 只知道 $\partial p/\partial w_2$ 够不够决定一次更新？

A. 够，它已经告诉我们该往哪个方向调
B. 够，只要再乘上输入 x_2
C. 不够：它没和目标比较过（缺 $\partial L/\partial p$），也不规定步长
D. 不够，但只缺学习率这一项

答案与解析

1. D —— 把依赖链延长一节 $w_2 \to v \to z \to p \to L$，反向就多乘一个局部导数。

2. B —— $\partial L/\partial p = -1/p \approx -1.332871$。配上 $\partial p/\partial w_2$ 为正 ⇒ 乘积 $\partial L/\partial w_2$ **为负** ⇒ 略微增大 w_2 会降低损失。

3. A —— 从选定的最终损失开始，每经过一个运算就乘局部导数，路径汇合处相加，**用的是同一次前向传播留下的值**。

4. C —— ⭐ **只有在参数梯度全部算完之后，梯度下降才去改变权重和偏置。**

5. C —— 知道「怎样增大 p」**并不能**告诉我们这个改变是否改进了预测。

第 10 组：BCE 损失（T1-3 §1）

1. 二元交叉熵在 y = 1 时化简成什么？

A. $L = -\log(1 - p)$
B. $L = -\log(p)$
C. $L = (p - 1)^2/2$
D. $L = |p - 1|$

2. 计算 BCE 时应该用哪个量？

A. 阈值判出来的类别标签
B. 概率四舍五入到两位小数后的值
C. 预激活分数 z
D. 概率 p 本身

3. y = 1、p = 0.750260 时，BCE 损失约等于多少？

A. 0.2874
B. 0.1054
C. 0.6931
D. 1.3329

4. p = 0.75 和 p = 0.90 在 0.5 阈值下都判类 1。BCE 还能区分它们吗？

A. 能，BCE 给 0.90 更小的损失
B. 不能，判类相同则损失相同
C. 能，但要先把概率归一化
D. 不能，除非把阈值改成 0.8

5. 「把置信度推向 1 总是好的」这个说法对吗？

A. 对，交叉熵在 p = 1 时取到最小值，把每个样本都推到那里模型就最好
B. 对，只要训练集足够大，置信度越高说明模型学到的规律越可靠
C. 不对，这只是对一个带标签样本的目标函数，在没见过或有噪声的数据上未必合适
D. 不对，因为 BCE 在 p = 1 处没有定义，数值上会直接溢出

答案与解析

1. B —— $L = -[y \cdot \log p + (1-y) \cdot \log(1-p)]$，y 非 0 即 1，**两项里只会剩一项**。y = 0 时才是 $-\log(1-p)$。

2. D —— ⚠⚠ **绝对不要**先把 p 四舍五入成类别标签再取对数——那样就丢掉了连续的学习信号。

3. A —— $-\log(0.750260) \approx$ **0.287335**。对照：p = 0.5 时 ≈ 0.6931，p = 0.9 时 ≈ 0.1054。

4. A —— ⭐ **这就是「对/错」之外多出来的信号**：即使类别标签不再变化，损失仍提供连续的学习信号。

5. C —— ⚠ 讲义专门加了这句警告。

第 11 组：δ = p − y（T1-3 §2）

1. 对 sigmoid 输出 + BCE，∂L/∂z 化简成什么？

A. p(1 − p)
B. −1/p
C. y − p
D. p − y

2. 本例 p = 0.750260、y = 1，δ 等于多少？

A. +0.249740
B. −0.249740
C. +0.187370
D. −0.750260

3. 已知 δ，参数梯度怎么算？

A. $\partial L/\partial w_i = \delta \cdot x_i$，$\partial L/\partial b = \delta$
B. $\partial L/\partial w_i = \delta \cdot w_i$，$\partial L/\partial b = \delta \cdot b$
C. $\partial L/\partial w_i = \delta + x_i$，$\partial L/\partial b = \delta + 1$
D. $\partial L/\partial w_i = \delta / x_i$，$\partial L/\partial b = \delta$

4. $x_1 = 1$、$x_2 = 2$ 时，w_2 的梯度绝对值是 w_1 的两倍。这说明什么？

A. 第二个特征更重要
B. w_2 的学习率应该调成一半
C. 只说明两个输入的数值不同，不构成重要性排序
D. 模型对第二个特征过拟合了

5. δ（小写 delta）和 Δ（大写 delta）分别表示什么？

A. δ 是有限变化量，Δ 是损失梯度
B. 两者是同一个量的两种写法
C. δ 是学习率，Δ 是步长
D. δ 是损失梯度，Δ 是有限变化量

答案与解析

1. D —— ⭐⭐⭐ 全课最该记的公式：δ = ∂L/∂z = **p − y**。推导是 (−1/p) × p(1−p) = −(1−p) = p − 1（y = 1 时）。

2. B —— δ = 0.750260 − 1 = **−0.249740**。⭐ δ 是**损失的敏感度**，不是一个新的预测值。

3. A —— 因为 $z = \Sigma w_i x_i + b \Rightarrow \partial z/\partial w_i = x_i$、$\partial z/\partial b = 1$。

4. C —— ⚠⚠ 讲义专门警告的一个误读。梯度分别是 −0.249740 和 −0.499480。

5. D —— ⚠ 跨 Topic 的记号陷阱。另外 **logit = 过 sigmoid 之前的原始分数**，这里就是 z。

第 12 组：一次梯度下降更新（T1-3 §3）

1. 梯度下降的更新式是什么？

A. $\theta_new = \theta + \eta\cdot(\partial L/\partial\theta)$
B. $\theta_new = \theta - \eta\cdot(\partial L/\partial\theta)$
C. $\theta_new = \theta\cdot(1 - \eta\cdot\partial L/\partial\theta)$
D. $\theta_new = \eta\cdot(\partial L/\partial\theta) - \theta$

2. $\eta = 0.1$、$w_2 = 0.4$、$\partial L/\partial w_2 = -0.499480$，更新后的 w_2 是多少？

A. 0.350052
B. 0.400000
C. 0.449948
D. 0.499480

3. 计算 w_1、w_2、b 的梯度时，应该用哪一组参数值？

A. 每算完一个就用更新后的值算下一个
B. 用上一轮迭代结束时的值
C. 权重用更新前的，偏置用更新后的
D. 全部用更新前的原始参数值

4. 一次更新后，z、p、L 分别变成多少？

A. $z \approx 1.100000$，$p \approx 0.750260$，$L \approx 0.287335$
B. $z \approx 1.249844$，$p \approx 0.777273$，$L \approx 0.251964$
C. $z \approx 1.249844$，$p \approx 0.750260$，$L \approx 0.287335$
D. $z \approx 1.349844$，$p \approx 0.794000$，$L \approx 0.230600$

5. 这次成功的更新证明了什么？

A. 只证明在这一个训练样本上损失下降了
B. 模型已经能泛化到新观测
C. 单个神经元能学会任何模式
D. 学习率 0.1 是最优的

答案与解析

1. B —— 梯度指向损失**局部上升**的方向，**减去**它就是朝相反方向走。

2. C —— $0.4 - 0.1\times(-0.499480) = 0.4 + 0.049948 = \mathbf{0.449948}$。⚠ **减去一个负数 = 增大。**

3. D —— ⭐⭐ **所有梯度都必须用更新前的原始参数算**，算完三个再从同一个状态一起更新。

4. B —— 新 $z = 0.224974\times1 + 0.449948\times2 + 0.124974 \approx 1.249844$。⭐ 概率朝目标移动、损失下降，**类别标签仍然是 1**。

5. A —— ⚠⚠ 讲义反复强调：**不证明泛化**。要再走一步必须重新跑前向、重新算梯度。

第 13 组：反向传播 vs 梯度下降 • 考纲示例题

1. 反向传播和梯度下降各自负责什么?

A. 反向传播计算梯度，梯度下降用梯度改参数
B. 反向传播改参数，梯度下降计算梯度
C. 两者是同一件事的两个名字
D. 反向传播算损失，梯度下降算梯度

2. 一个单元 $z = wx + b$、$a = \mathrm{ReLU}(z)$，$x = 3$、$w = 0.5$、$b = 0.5$，损失 $L = (a - y)^2/2$ 且 $y = 4$。z、a、L 分别是多少?

A. z = 2，a = 2，L = 4
B. z = 2，a = 2，L = 2
C. z = 1.5，a = 1.5，L = 3.125
D. z = 2，a = 0，L = 8

3. 接上题，规定 $z > 0$ 时 $\mathrm{ReLU}'(z) = 1$。$\partial L/\partial w$ 和 $\partial L/\partial b$ 分别是多少?

A. −2 和 −6
B. +6 和 +2
C. −6 和 −2
D. −6 和 −6

4. 接上题，学习率 0.05，做一次同步更新后 w 和 b 是多少?

A. w = 0.2，b = 0.4
B. w = 0.5，b = 0.5
C. w = 1.1，b = 0.7
D. w = 0.8，b = 0.6

5. 同一道考纲示例题还问：自动微分在这里算的是什么，为什么它本身不保证得到好模型?

A. 它算的是全局最优解，但需要更多数据才能找到
B. 它算的是损失的二阶导数，一阶信息不足以保证收敛
C. 它沿着被记录下来的运算求导数；合适的数据、建模选择与独立评估仍然必需
D. 它只能算 ReLU 这类分段线性函数的导数

答案与解析

1. A —— ⚠⚠ 这是「最容易答错的概念题」。**跑一次反向传播本身不改变任何权重**，它也**不是**把前向的算术倒着跑一遍去重建输入。

2. B —— $z = 0.5\times3 + 0.5 = 2$；$z > 0 \Rightarrow a = 2$；$L = (2-4)^2/2 = \mathbf{2}$。这是 M3 考纲页给的官方示例大题。

3. C —— 输出误差 $\partial L/\partial a = a - y = -2$；乘 $\mathrm{ReLU}' = 1$ 得 $\partial L/\partial z = -2$；再乘 $\partial z/\partial w = x = 3$ 得 **−6**，而 $\partial z/\partial b = 1$ 得 **−2**。

4. D —— $w = 0.5 - 0.05\times(-6) = \mathbf{0.8}$；$b = 0.5 - 0.05\times(-2) = \mathbf{0.6}$。⚠ 两个梯度都用**更新前**的原参数算。

5. C —— 官方答案校验里的原话要点。⭐ 大题要求写出中间步骤：「只给出正确的最终数字，可能不足以体现所需的理解」。