模型评估

Module 3 · Topic 3 — 题库与解析

ARTI2001 Machine Learning · 2026 Semester 2

共 14 组 • 70 道选择题

覆盖：三种数据角色 · **信息泄漏五步法** · 划分方式 · refit 工作流

欠拟合/过拟合的诊断措辞 · 学习率证据 · **基于验证集的早停**

混淆矩阵三套摆法 · **accuracy / precision / recall / F1**

ROC 构造 • AUC 两种算法 • 稀有正例的 precision 陷阱

含考纲给的两道官方示例题

配套：《M3T3 模型评估 知识点整理》· M3 测验 Week 13

目录

使用方法

第 1 组：三种数据角色（T3-1 §1）

第 2 组：划分方式（T3-1 §2）

第 3 组：信息泄漏（T3-1 §3）

第 4 组：refit 工作流与交叉验证（T3-1 §4–5）

第 5 组：欠拟合与过拟合的诊断（T3-1 §6 · §9）

第 6 组：学习率与重复更新的证据（T3-1 §7–8）

第 7 组：混淆矩阵的摆法（T3-2 §0–1）

第 8 组：四个指标（T3-2 §2–4）

第 9 组：计数版公式与基线（T3-2 §3–4 · §7）

第 10 组：阈值与代价（T3-2 §5–6 · 考纲示例题）

第 11 组：ROC 的构造（T3-3 §1–3）

第 12 组：AUC 的两种算法（T3-3 §4–5）

第 13 组：AUC 的解读分寸（T3-3 §6–8）

第 14 组：PR 视角与稀有正例（T3-3 §8–9 · 考纲大题）

使用方法

每组 5 题，题目与选项在前，答案与解析在该组末尾。建议先遮住解析区独立作答，整组做完再核对。做错的题回到《M3T3 模型评估 知识点整理》对应章节复习。

组标题后括号里是对应的讲义小节编号（T3-2 §5 = 第 2 课第 5 节），方便回查。

第 1 组：三种数据角色（T3-1 §1）

1. 缩放参数和缺失值填补参数应该在哪一部分数据上计算?

A. 用训练集加验证集，测试集除外，这样参数更稳定
B. 只用训练集，然后原样应用到验证集和测试集
C. 用全部数据，因为这些步骤不使用标签所以安全
D. 分别在三个子集上各自拟合一次，各用各的

2. 判定阈值和停止点属于哪一类决定，应该用哪部分数据选?

A. 属于模型权重，用训练集拟合
B. 属于最终评估，用测试集选
C. 属于开发决策，用验证集选
D. 属于超参数，必须用交叉验证之外的新数据选

3. 70/15/15 这样的划分比例是什么?

A. 只是举例，不是规则
B. 课程规定必须遵守的标准比例
C. 统计学上可以证明最优的比例
D. 只适用于分类任务的经验比例

4. 一个设计良好的数据划分能给出什么?

A. 对泛化能力的保证，只要留出集够大
B. 对分布漂移下稳健性的保证
C. 对模型容量是否足够的证明
D. 对未见数据表现的估计，前提是留出样本有代表性且没有泄漏

5. 只看训练表现有什么局限?

A. 完全没有诊断价值，必须配合测试集才能用
B. 无法可靠估计未见样本的表现，也看不出泛化差距
C. 只能诊断过拟合，不能诊断欠拟合
D. 只在类别不平衡时才会产生误导

答案与解析

1. B —— ⚠ 训练集用来拟合权重**以及其它学到的量**，包括缩放和填补参数。

2. C —— 验证集用来比较各种**选择**：隐藏层大小、激活函数、正则化、停止点、判定阈值。

3. A —— ⚠ 要留出足够多的相关案例——**包括足够多的正例事件。**具体数量取决于数据集大小、记录之间的依赖性、以及预期的预测场景。

4. D —— ⚠⚠ **它不保证泛化，也不保证在分布漂移下的稳健性。**

5. B —— ⚠ **训练表现差本身就已经能提示欠拟合或优化问题；把训练和验证结果对比，才是更强的诊断证据。**

第 2 组：划分方式（T3-1 §2）

1. 同一个病人贡献了 10 条记录，应该用哪种划分？

A. 分层划分，保持各类比例
B. 按时间划分，早的训练、晚的测试
C. 分组划分，把同一个人的记录放进同一个子集
D. 随机划分，只要每条记录独立编号即可

2. 预测未来的任务应该怎么划分？

A. 随机打乱后按比例切分
B. 按类别分层切分，保证各类比例一致
C. 按特征聚类切分，让各子集的分布尽量相似
D. 按时间切分，用较早的观测训练、较晚的观测验证

3. 类别不平衡时常用的划分方式是：

A. 分层划分，保持各类比例
B. 分组划分，按来源归并记录
C. 按时间划分，优先保留最新数据
D. 先过采样少数类再随机划分

4. 「过拟合是训练的必然后果」这个说法：

A. 正确，模型容量足够大时一定会过拟合
B. 正确，除非使用了正则化
C. 不对，它是一个需要诊断的风险，不是必然后果
D. 不对，过拟合只在数据量小于一千时发生

5. 「验证集」和「测试集」最根本的区别是什么？

A. 验证集参与选择，测试集只评估已经冻结的流程
B. 验证集更大，测试集更小，所以估计更稳
C. 验证集必须分层，测试集必须随机
D. 验证集在训练中使用，测试集在训练后重新采样

答案与解析

1. C —— 否则模型可以**记住这个病人特有的特征**，测试分数**偏乐观**——它衡量的不是「对新病人的表现」。

2. D —— ⚠⚠ **评估设计应当复现「真正没见过的数据将以什么方式到来」。**

3. A —— ⚠⚠ **随机划分不是自动就合适的。**

4. C —— ⚠ 讲义这里的措辞很审慎，答题时也要照这个分寸写。

5. A —— ⚠⚠ **不得用测试集的标签或结果来做这个选择。**

第 3 组：信息泄漏（T3-1 §3）

1. 数据泄漏的定义是什么？

A. 训练集和测试集有完全相同的样本
B. 训练过程中把标签当成了输入特征
C. 模型的参数数量超过了样本数量
D. 在预期预测场景中拿不到的信息，影响了训练或选择

2. 训练值是 [0, 2]、留出值是 100。正确的中心化结果是多少？

A. 100 − 34 = 66
B. 100 − 1 = 99
C. 100 − 51 = 49
D. 100 − 0 = 100

3. 「缩放器不用标签，所以可以在交叉验证之前对全部开发数据拟合一次」这个说法：

A. 正确，不用标签就不构成泄漏
B. 正确，只要之后不再改动缩放参数
C. 错误，但影响很小，实践中可以忽略
D. 错误，从输入里学习、即使没用到标签，一样可能越过评估边界

4. 防泄漏的正确顺序，第一步是什么？

A. 先选好模型和超参数
B. 先用全部数据算缩放参数
C. 先划分成训练 / 验证 / 测试
D. 先把类别不平衡处理掉

5. PCA 用在有监督模型之前时，应该在哪里拟合？

A. 在每个训练划分或折的内部拟合
B. 在全部数据上拟合一次，因为它是无监督的
C. 在验证集上拟合，这样能反映泛化
D. 在测试集上拟合，这样最接近部署场景

答案与解析

1. D —— 途径包括：**标签、学到的预处理、重复记录、未来信息。**

2. B —— 只用训练集算均值 = 1。若三个值放在一起算均值 ≈ 34，⇒ **留出的那个案例改变了连训练数据本身的表示方式。**

3. D —— ⚠⚠ 这是页面的关键一句。[0,2] vs 100 那个例子就是证明。

4. C —— 五步：划分 → 只在训练集上算预处理参数 → 原样应用到验证/测试 → 用验证选模型 → 全部定好后在测试集上评估一次。

5. A —— ⚠⚠ **「无监督」不等于「可以安全地在测试数据上拟合」。**k 折里要在**每一个训练折内部**单独拟合预处理。

第 4 组：refit 工作流与交叉验证（T3-1 §4–5）

1. 1000 个样本按 700/150/150 划分。选定流程后可以在多少个样本上重新拟合?

A. 仍然只用 700 个
B. 合并训练与验证的 850 个
C. 全部 1000 个
D. 随机抽取的 900 个

2. refit 之后，之前选定的阈值会怎样?

A. 完全不受影响，阈值与模型无关
B. 自动按样本量比例缩放
C. 必须用最终测试集的标签重新校正
D. 可能迁移得不完美，因为 refit 之后分数会变

3. 看过测试结果之后又继续开发，会有什么后果?

A. 没有后果，只要不改动模型结构
B. 那个旧测试集已成为开发历史的一部分，新结论需要一次全新的独立评估
C. 只需把测试集重新随机打乱一次即可继续使用
D. 需要把学习率调小以补偿这次泄漏

4. 五折交叉验证的验证准确率是 0.80, 0.82, 0.78, 0.84, 0.81。怎么解读这个平均 0.81?

A. 这是五次独立的测试实验，可以算标准误
B. 它等价于在一个 5 倍大的测试集上评估一次
C. 它们的训练集互相重叠，不是五次独立实验，而且仍带有不确定性
D. 它已经消除了划分带来的随机性，可以当作确定值

5. 验证表现很差，该不该去看测试结果来挑一个更好的模型?

A. 不该，一旦用测试结果做选择，它就不再是独立的最终评估
B. 该，只要只看一次就不算泄漏
C. 该，反正最后还要在测试集上评估
D. 不该，但可以看测试集的输入分布，不看标签

答案与解析

1. B —— ⚠⚠ **不要在报告那个测试结果之前，用全部 1000 个重新拟合。**重拟合的副本，其缩放器在这 850 个上重新拟合。

2. D —— 应当用开发数据或 out-of-fold 预测检查稳定性。⚠⚠ **绝对不要用最终测试集的标签去「修正」阈值。**

3. B —— ⚠⚠ 这是讲义第 4 节的第二条警告。

4. C —— ⚠⚠ **这个平均值仍然依赖于抽样和划分的假设。**每个候选配置都要有它自己的一套全新的交叉验证拟合。

5. A —— 超参数是「模型大小、正则化强度」这类**选择**，**用验证证据选出来，而不是像权重那样直接拟合出来。**

第 5 组：欠拟合与过拟合的诊断（T3-1 §6 • §9）

1. 训练和验证表现都差，说明什么？

A. 一定是统计偏差过高，需要换更复杂的模型
B. 可能欠拟合或优化困难：模型太受限、特征不足、或优化失败
C. 一定是过拟合，需要加正则化
D. 一定是验证集太小，需要重新划分

2. 训练准确率 98%、验证准确率 72%，在归因于方差之前还要检查什么？

A. 学习率是否过大、批大小是否过小
B. 激活函数是否饱和、权重是否初始化得当
C. 分布差异、验证样本是不是太小、以及有没有数据泄漏
D. 损失函数是否与任务匹配、标签是否 one-hot

3. 接上题，下一步可以做什么（都在验证集上做）？

A. 加正则化 / 减小模型 / 增加数据 / 早停，并复核划分方式是否合适
B. 直接在测试集上试几个候选模型，挑验证与测试都最好的那个
C. 把验证集并入训练集，让模型见到更多数据以缩小两者的差距
D. 降低判定阈值，让验证准确率上升到和训练准确率接近

4. 训练和验证都强且相当接近，说明什么？

A. 模型一定能在部署环境中保持这个表现
B. 可以跳过测试集评估，直接上线
C. 模型容量刚好等于任务的真实复杂度
D. 学到的模式迁移到了未见的验证样本

5. 基于验证集的早停，具体应该怎么做？

A. 训练损失连续三轮不降就停
B. 等训练准确率达到 100% 时停止
C. 固定训练 100 个 epoch，取最后一个检查点
D. 定期监控验证表现，用开发数据定停止规则，保留验证最好的检查点

答案与解析

1. B —— ⚠ **这个模式本身并不能断定「统计偏差高」。**

2. C —— ⚠⚠ 这是讲义诊断表里专门加的限定。

3. A —— **在最终模型和决策流程选定之前，测试集一直不要碰。**

4. D —— ⚠⚠ 讲义反复强调：**这些是诊断模式，不是证明。**

5. D —— **测试数据留给最终评估。**⚠ 讲义那个演示**是在固定的 100 次更新预算后停的，不是因为证明了收敛。**

第 6 组：学习率与重复更新的证据（T3-1 §7–8）

1. 学习率表里 η = 0 时一步之后的平均 BCE 是 0.580352，为什么?

A. 因为梯度恰好为零
B. 因为损失函数在这一点取到极小
C. 因为参数根本没变，这就是起始值
D. 因为这一步被优化器跳过了

2. 同一张表里 η = 100 时一步之后的平均 BCE 是 9.965953，这说明什么?

A. 学习率越大损失下降越快，这一行只是数值精度造成的假象
B. 非常大的步子会过冲，甚至改变「哪些 ReLU 单元是激活的」
C. 损失函数存在多个局部极小，这一步跳进了另一个盆地
D. 这一步的梯度计算出错了，应当把梯度重新归一化

3. η = 10 在这张表里一步后损失最低，它就是最佳学习率吗?

A. 不是，这只是单步结果，一步走得远不等于长期收敛得好
B. 是，但只对这个网络结构成立
C. 是，实验数据已经证明了这一点
D. 不是，因为最佳学习率必须小于 1

4. 连续训练 100 次更新后，样本 [−1,−2]（y=1）的概率是 0.4859。它被预测成哪一类?

A. 类别 1，因为概率在上升
B. 类别 0，判错了
C. 无法判定，需要知道阈值是否为 0.5
D. 类别 1，因为它的损失在下降

5. 接上题，这个正例为什么几乎没有改善?

A. 它的两个隐藏 ReLU 激活从一开始就是零，正类分数只依赖输出偏置
B. 它的学习率被单独设小了，所以更新幅度比别的样本小得多
C. 它的标签被错误地标成了负类，梯度一直在把它往反方向推
D. 它离决策边界太远，输出 sigmoid 已经饱和，梯度接近于零

答案与解析

1. C —— ⚠⚠ 表里**每一行都是「从同一个初始参数重置后，只走一步」的独立实验**，不是一次运行的连续步骤。

2. B —— ⭐ **小步子能改善损失**；对照 η = 10 时降到 0.371611（这张表里最低）。

3. A —— ⚠⚠ **这些结果只属于这个批次和这个起点，不能据此确定一个普适的最佳学习率。**

4. B —— 0.4859 < 0.5 ⇒ 判类 0。⚠⚠ **平均损失更低，不代表每个样本都被正确分类。**

5. A —— 隐藏层那条路对它完全没用。⚠ **一次损失下降不能确立收敛**，看起来稳定也可能只是优化卡住了。

第 7 组：混淆矩阵的摆法（T3-2 §0–1）

1. 做混淆矩阵题的第一件事是什么？

A. 先算出准确率作为基准
B. 先检查类别是否平衡
C. 先声明哪一类算正类
D. 先把概率按阈值 0.5 转成硬判定

2. 关于本课材料里混淆矩阵的摆法，下面哪一句是对的？

A. 摆法由题目的样本量决定，样本多时用正类在前
B. 全部官方材料都用正类在前，左上角一定是 TP
C. 全部官方材料都用负类在前，左上角一定是 TN
D. Canvas 讲义页正类在前、T3 复习课件负类在前，两份官方材料顺序相反

3. `sklearn.metrics.confusion_matrix(y_true, y_pred, labels=[0,1])` 输出的顺序是：

A. [[TP, FN], [FP, TN]]
B. [[TN, FP], [FN, TP]]
C. [[TP, FP], [FN, TN]]
D. [[TN, FN], [FP, TP]]

4. 在「类别 1 = 次品、预测为正触发一次检验」的场景里，FP 和 FN 各意味着什么？

A. FP 是一次不必要的检验，FN 是漏掉了一个次品
B. FP 是漏掉一个次品，FN 是一次不必要的检验
C. FP 和 FN 都表示检验结果与标签不符，代价相同
D. FP 是检验设备故障，FN 是标签录入错误

5. CS229 那份评估指标幻灯的摆法和本课是什么关系？

A. 完全一致，可以直接套用
B. 它不用混淆矩阵，只给公式
C. 行列都相同，只是正负类顺序相反
D. 列 = 真实，和本课互为转置

答案与解析

1. C —— ⚠⚠ **TP、FP、FN、TN 的含义完全取决于这个选择。**⚠「正类」指的是被指定的那一类，**不一定是「好的结果」**。

2. D —— ⚠⚠ **Canvas 讲义页**是 [[TP, FN], [FP, TN]]（左上角 TP）；而 **M3 T3 复习课件**画的是 `Pred -/Pred +` 作列、`Actual -/Actual +` 作行，**左上角是 TN**，即 [[TN, FP], [FN, TP]]，和 sklearn 一致。⇒ **不存在「本课固定一种摆法」，只能先定正类再逐格读行列标签。**四个计数在两种摆法下完全相同，变的只是位置。

3. B —— ⚠ 因为它把**类别 0 放在前面。**考试时**先看题目给的是哪种摆法**，不要凭肌肉记忆填。

4. A —— 这个对应关系是后面「用代价定阈值」那一节的基础。

5. D —— ⭐ 页面自己的提醒：**在给各个格子命名之前，先读清楚行标签和列标签。**

第 8 组：四个指标（T3-2 §2–4）

1. Precision 的分母是什么?

A. TP + FN，即真实为正的那一组
B. TP + TN，即全部判对的案例
C. TP + FP，即被预测为正的那一组
D. TP + FP + FN + TN，即全部案例

2. F1 公式 2PR/(P+R) 里的 P 指什么?

A. 预测概率
B. prevalence（正例占比）
C. 正例个数
D. precision

3. precision = 1、recall = 0.1 时，F1 约等于多少?

A. 0.55
B. 0.1
C. 0.182
D. 1.0

4. 关于 F1，下面哪一句是对的?

A. 它是不平衡问题的标准指标，总是优于 accuracy
B. 它忽略 TN，而且把 precision 和 recall 看得同等重要
C. 它同时考虑了四个格子，所以比 accuracy 全面
D. 它把误报的代价设为漏报的两倍

5. 真实 [1,1,1,1,1,0,0,0,0,0,0,0]、预测 [1,1,1,1,0,1,1,0,0,0,0,0]，四个计数是多少?

A. TP=4, FN=1, FP=2, TN=5
B. TP=5, FN=0, FP=2, TN=5
C. TP=4, FN=2, FP=1, TN=5
D. TP=6, FN=1, FP=2, TN=3

答案与解析

1. C —— ⭐ Recall 的分母才是 TP + FN。**这两组有重叠，但不是同一组。**

2. D —— ⚠⚠ R 指 recall。**TPR（真正率）是 recall 的另一个名字。**

3. C —— 2(1)(0.1)/(1+0.1) ≈ **0.182**，**被小的那个拖住**。算术平均才是 0.55。⭐ **高 F1 要求两者都相当高。**

4. B —— ⚠⚠ **它并不自动就是每个不平衡问题的正确指标**，也没有说明金钱上的代价。

5. A —— ⭐ **计数必须加起来等于 12** —— 这是个很好的自查。由此 accuracy = 9/12 = 0.75，precision = 4/6 ≈ 0.667，recall = 4/5 = 0.8。

第 9 组：计数版公式与基线（T3-2 §3–4 • §7）

1. F1 的计数版公式是什么？

A. (TP + TN) / (2TP + FP + FN)
B. 2TP / (TP + FP + FN + TN)
C. TP / (TP + FP + FN)
D. 2TP / (2TP + FP + FN)

2. 某个指标的分母为零时，讲义要求怎么处理？

A. 默认记为 1，保证公式可算
B. 把该指标报告为无定义，并说明采用的约定
C. 改用 accuracy 代替，它永远有定义
D. 把该样本从评估中剔除再重算

3. 正例稀少时，「把所有案例都预测为负」的分类器准确率会怎样？

A. 等于负例占比，可能相当高
B. 接近 0，因为一个正例也没找到
C. 恰好等于 0.5
D. 无法计算，因为 TP = 0

4. Metrics by hand 的 20 位顾客里，TP=6、FN=3、FP=2、TN=9。precision 和 recall 分别是：

A. precision 0.667，recall 0.75
B. precision 0.75，recall 0.75
C. precision 0.75，recall 0.667
D. precision 0.60，recall 0.80

5. 同一份数据里，「永远预测不点击」的基线准确率是多少？

A. 0.45
B. 0.50
C. 0.55
D. 0.75

答案与解析

1. D —— 用它可以**避免过早对 precision/recall 四舍五入**。上一组那道题用计数版得 8/11 ≈ 0.727，和公式版一致。

2. B —— **补充 practical 采用的约定是取 0。**

3. A —— ⇒ 这正是「**accuracy 的基线是多数类占比**」那条。它的 recall = 0，毫无用处。

4. C —— precision = 6/8 = 0.75，recall = 6/9 ≈ 0.667，accuracy = 15/20 = 0.75，F1 = 12/17 ≈ 0.706。

5. C —— 11 个真实负例全对 ⇒ 11/20 = **0.55**。模型的 0.75 确实高于基线。

第 10 组：阈值与代价（T3-2 §5–6 • 考纲示例题）

1. 在固定的分数上降低二分类阈值，recall 会怎样?

A. 一定下降，因为误报增多
B. 只要存在真实正例，就不会下降
C. 不变，recall 与阈值无关
D. 先升后降，存在一个最优阈值

2. 漏掉一个次品代价 5、一次不必要检验代价 1。阈值 0.5 给 FN=6/FP=4，阈值 0.3 给 FN=2/FP=12。哪个更优?

A. 0.5，总代价 34；0.3 的总代价是 22
B. 无法比较，因为误报数差太多
C. 两者相同，总代价都是 28
D. 0.3，总代价 22；0.5 的总代价是 34

3. 接上题，把两种错误的代价改成相等，结论会怎样?

A. 翻过来：0.5 的 10 优于 0.3 的 14
B. 仍然是 0.3 更优，差距更大
C. 两者相等，都是 12
D. 需要重新训练模型才能比较

4. 某团队反复调整阈值以最大化「最终测试集」上的 F1，再把这个 F1 当作无偏估计报告。主要问题是什么?

A. 测试集已经影响了模型选择；阈值应当用验证数据选，测试集留给最终评估
B. 二分类器算不出 F1，必须先转成多分类
C. 每个分类器都必须用 0.5 作为判定阈值
D. 阈值会自动改变已经拟合好的网络权重

5. 只给了硬类别判定（没有分数），能做什么、不能做什么?

A. 什么都算不了，必须有概率
B. 能画完整 ROC，但不能算 F1
C. 能算四个指标，但无法确定完整的 ROC 曲线或 AUC
D. 能算 AUC，但不能算 precision

答案与解析

1. B —— 预测为正的数量**只增不减** ⇒ TP 和 FP 都不会减少。⚠ 但 **precision 可能升，也可能降。**

2. D —— 5(6)+4 = 34 vs 5(2)+12 = 22。 ⭐ **0.3 更好——尽管它产生了更多的误报。**

3. A —— ⚠⚠ **代价和产能是决策的一部分；不存在普适最优的阈值。**

4. A —— 这是 **M3 考纲页给的官方示例选择题**，答案 A。反复基于测试集做选择，破坏了最终评估的独立性。

5. C —— ⚠ **硬类别预测只能提供一个工作点**——要画完整曲线必须用**原始分数。**

第 11 组：ROC 的构造（T3-3 §1–3）

1. TPR 和 FPR 分别等于什么？

A. TPR = TP/(TP+FP)，FPR = FP/(FP+TN)
B. TPR = TN/(TN+FP)，FPR = FN/(FN+TP)
C. TPR = TP/(TP+FN)，FPR = FP/(TP+FP)
D. TPR = TP/(TP+FN)，FPR = FP/(FP+TN)

2. 画 ROC 时，哪两个量在整个过程中固定不变？

A. TP 和 FP 的计数
B. 真实正例数和真实负例数这两个分母
C. 阈值的步长和曲线上点的个数
D. precision 和 recall 的比值

3. ROC 曲线从哪个点开始、到哪个点结束？

A. 从 (0,0) 开始，到 (1,1) 结束
B. 从 (1,1) 开始，到 (0,0) 结束
C. 从 (0,1) 开始，到 (1,0) 结束
D. 从 (0.5,0.5) 开始，向两端延伸

4. 阈值往下降时，加入一个正例和加入一个负例，点分别往哪移？

A. 正例往右，负例往上
B. 两者都往右上方移动相同距离
C. 正例往上，负例往右
D. 正例往上，负例往下

5. 共享同一个分数的多个观测，画 ROC 时应该怎么处理？

A. 按标签排序后逐个加入
B. 只保留其中一个，其余丢弃
C. 随机打乱后逐个加入
D. 必须一起加入

答案与解析

1. D —— TPR 就是 recall；FPR = 1 − specificity，而 specificity = TN/(TN+FP)。

2. B —— ⭐ 这是第 ② 步。⚠ **两个类别都必须存在**，否则这两个率没有定义。

3. A —— 起点是「比最大分数还高的阈值 ⇒ 全部预测为负」，终点是「比最小分数还低的阈值 ⇒ 全部预测为正」。

4. C —— ⭐⭐ 四样本算例里**每加入一个正例点向上移 1/2，每加入一个负例点向右移 1/2**。

5. D —— ⚠ 数据量小时，曲线是**一串阶梯**，不是一条光滑的物理定律。

第 12 组：AUC 的两种算法（T3-3 §4–5）

1. A(0.90,1)、B(0.80,0)、C(0.40,1)、D(0.10,0)。阈值从 0.60 降到 0.30，点怎么移动？

A. C 进来，C 是负例 ⇒ 从 (0.5,0.5) 向右移到 (1,0.5)
B. C 进来，C 是正例 ⇒ 从 (0.5,0.5) 向上移到 (0.5,1)
C. B 进来，点从 (0,0.5) 移到 (0.5,0.5)
D. D 进来，点从 (0.5,1) 移到 (1,1)

2. 梯形法算 AUC 时，FPR = 0 处那段竖直线段贡献多少面积？

A. 等于 TPR 的高度
B. 等于 TPR 的一半
C. 零，因为横向宽度为 0
D. 无法确定

3. 上面四个样本的 AUC 是多少？

A. 0.50
B. 0.625
C. 1.00
D. 0.75

4. AUC 的「排序解释」是什么？

A. 正例的平均分数减去负例的平均分数
B. 随机取一个正例、随机取一个负例，正例分数更高的概率
C. 被正确分类的样本占全部样本的比例
D. precision 与 recall 的调和平均在所有阈值上的平均

5. 用正负配对法复核上面四个样本：A vs B、A vs D、C vs B、C vs D，结果是多少？

A. 3 胜 / 4 对 ⇒ AUC = 0.75
B. 4 胜 / 4 对 ⇒ AUC = 1.00
C. 2 胜 / 4 对 ⇒ AUC = 0.50
D. 3 胜 / 6 对 ⇒ AUC = 0.50

答案与解析

1. B —— C 的分数是 0.40，落在 0.30 和 0.60 之间。

2. C —— 公式 Σ (ΔFPR) × (TPR_i + TPR_{i+1})/2 里，ΔFPR = 0 ⇒ 该项为 0。

3. D —— 梯形：0.5×0.5 + 0.5×1 = 0.25 + 0.50 = **0.75**。

4. B —— ⭐ **一个平局算半胜。** 这个办法**不需要选任何阈值**，考场上比画梯形快，而且能互验。

5. A —— 只有 C vs B（0.40 < 0.80）输掉。✓ 和梯形法完全一致。

第 13 组：AUC 的解读分寸（T3-3 §6–8）

1. AUC = 1 应该怎么解读?

A. 在被评估的这个样本上排序完美，但不保证未来的准确率
B. 模型完美，可以直接部署
C. 模型的概率校准也一定完美
D. 该模型在任何阈值下准确率都是 100%

2. AUC < 0.5 时应该怎么做?

A. 把模型的预测反过来用，AUC 就变成 1 − 原值
B. 去检查分数方向、标签约定和抽样，而不是拿测试结果自动把模型反过来用
C. 判定模型完全无效，重新训练
D. 改用 accuracy 评估，AUC 在这种情况下无意义

3. 下面哪一项不是 AUC 能决定的?

A. 哪个模型在整体排序上更强
B. 随机正负配对里正例分数更高的概率
C. 工作阈值、概率校准、以及误报漏报的真实代价
D. 曲线下方区域的面积大小

4. 单独改变 prevalence（正例占比），ROC AUC 会怎样?

A. 变成无定义，必须重新抽样
B. 一定按比例下降
C. 一定按比例上升
D. 不一定改变，因为 ROC 用的是类内条件率

5. 两个系统 AUC 相同，它们在实际使用的那个工作点上表现一定相同吗?

A. 一定相同，面积相同说明曲线相同
B. 一定相同，只要正例占比也相同
C. 不一定，两条形状不同的曲线完全可以有相同的面积
D. 不一定，但差距不会超过 AUC 的 10%

答案与解析

1. A —— ⚠ 讲义这一节措辞很讲究，答题要照着写。

2. B —— ⚠ AUC 接近 0.5 时，**单条经验曲线也不必恰好落在对角线上。**

3. C —— ⚠ 四条限制里还有一条：**负例很多时，它可能掩盖掉数量不可接受的误报。**

4. D —— **但 precision 和实际可用性可能变化很大** ⇒ 还要同时看 precision–recall 和 prevalence。

5. C —— **AUC 概括的是整条曲线（排序能力），而不是某一个工作点。**

第 14 组：PR 视角与稀有正例（T3-3 §8–9 • 考纲大题）

1. 同一组 A/B/C/D 样本的 PR 曲线里，precision 这一列是 0.5 → 2/3 → 0.5。这说明什么?

A. 计算出错了，precision 应当单调
B. 阈值下降时 precision 不必单调变化
C. 该模型的排序能力为零
D. PR 曲线只能在平衡数据上使用

2. 1000 个观测里只有 10 个正例。在 TPR = 0.8、FPR = 0.1 处，FP 是多少?

A. 8
B. 2
C. 100
D. 99

3. 接上题，precision 和 recall 分别是多少?

A. precision ≈ 7.5%，recall = 80%
B. precision = 80%，recall ≈ 7.5%
C. precision = 80%，recall = 80%
D. precision ≈ 7.5%，recall ≈ 7.5%

4. 某检测器在 200 个案例上 TP=18、FP=12、FN=6、TN=164。accuracy 和 precision 分别是多少?

A. accuracy 0.60，precision 0.91
B. accuracy 0.91，precision 0.75
C. accuracy 0.75，precision 0.60
D. accuracy 0.91，precision 0.60

5. 接上题，recall 和 F1 分别是多少?

A. recall 0.60，F1 ≈ 0.667
B. recall 0.75，F1 ≈ 0.60
C. recall 0.75，F1 ≈ 0.667
D. recall 0.90，F1 ≈ 0.72

答案与解析

1. B —— ⚠ 高于 0.90 时没有任何正类预测 ⇒ precision 的分母为零。随机排序的无技能参考线 = 正例占比 = 2/4 = 0.5。

2. D —— FP = 0.1 × 990 = **99**。同时 TP = 0.8 × 10 = 8，FN = 2。

3. A —— precision = 8/107 ≈ 7.5%，recall = 8/10 = 80%。⭐ **负例基数巨大时，很小的 FPR 也会压倒性地稀释 precision。**

4. D —— 这是 **M3 考纲页给的官方示例大题。**(18+164)/200 = 0.91；18/30 = 0.60。

5. C —— recall = 18/24 = 0.75；F1 = 2(18)/(2·18+12+6) = 36/54 = 2/3 ≈ 0.667。⚠ accuracy 被大量负例主导，表达不出漏报和误报各自的代价。