# 模型评估

Module 3 · Topic 3 — 题库与解析

ARTI2001 Machine Learning · 2026 Semester 2

**共 14 组 • 70 道选择题**

覆盖：三种数据角色 · **信息泄漏五步法** · 划分方式 · refit 工作流

欠拟合/过拟合的诊断措辞 · 学习率证据 · **基于验证集的早停**

混淆矩阵三套摆法 · **accuracy / precision / recall / F1**

**ROC 构造 • AUC 两种算法 • 稀有正例的 precision 陷阱**

**含考纲给的两道官方示例题**

配套：《M3T3 模型评估 知识点整理》· M3 测验 Week 13

# 目录

使用方法

第 1 组：三种数据角色（T3-1 §1）

第 2 组：划分方式（T3-1 §2）

第 3 组：信息泄漏（T3-1 §3）

第 4 组：refit 工作流与交叉验证（T3-1 §4–5）

第 5 组：欠拟合与过拟合的诊断（T3-1 §6 · §9）

第 6 组：学习率与重复更新的证据（T3-1 §7–8）

第 7 组：混淆矩阵的摆法（T3-2 §0–1）

第 8 组：四个指标（T3-2 §2–4）

第 9 组：计数版公式与基线（T3-2 §3–4 · §7）

第 10 组：阈值与代价（T3-2 §5–6 · 考纲示例题）

第 11 组：ROC 的构造（T3-3 §1–3）

第 12 组：AUC 的两种算法（T3-3 §4–5）

第 13 组：AUC 的解读分寸（T3-3 §6–8）

第 14 组：PR 视角与稀有正例（T3-3 §8–9 · 考纲大题）

## 使用方法

**每组 5 题，题目与选项在前，答案与解析在该组末尾。**建议先遮住解析区独立作答，整组做完再核对。做错的题回到《M3T3 模型评估 知识点整理》对应章节复习。

组标题后括号里是对应的讲义小节编号（T3-2 §5 = 第 2 课第 5 节），方便回查。

## 第 1 组：三种数据角色（T3-1 §1）

**1. 缩放参数和缺失值填补参数应该在哪一部分数据上计算?**

A. 用训练集加验证集，测试集除外，这样参数更稳定
B. 只用训练集，然后原样应用到验证集和测试集
C. 用全部数据，因为这些步骤不使用标签所以安全
D. 分别在三个子集上各自拟合一次，各用各的

**2. 判定阈值和停止点属于哪一类决定，应该用哪部分数据选?**

A. 属于模型权重，用训练集拟合
B. 属于最终评估，用测试集选
C. 属于开发决策，用验证集选
D. 属于超参数，必须用交叉验证之外的新数据选

**3. 70/15/15 这样的划分比例是什么?**

A. 只是举例，不是规则
B. 课程规定必须遵守的标准比例
C. 统计学上可以证明最优的比例
D. 只适用于分类任务的经验比例

**4. 一个设计良好的数据划分能给出什么?**

A. 对泛化能力的保证，只要留出集够大
B. 对分布漂移下稳健性的保证
C. 对模型容量是否足够的证明
D. 对未见数据表现的估计，前提是留出样本有代表性且没有泄漏

**5. 只看训练表现有什么局限?**

A. 完全没有诊断价值，必须配合测试集才能用
B. 无法可靠估计未见样本的表现，也看不出泛化差距
C. 只能诊断过拟合，不能诊断欠拟合
D. 只在类别不平衡时才会产生误导

---

**答案与解析**

**1. B** —— ⚠ 训练集用来拟合权重**以及其它学到的量**，包括缩放和填补参数。

**2. C** —— 验证集用来比较各种**选择**：隐藏层大小、激活函数、正则化、停止点、判定阈值。

**3. A** —— ⚠ 要留出足够多的相关案例——**包括足够多的正例事件。**具体数量取决于数据集大小、记录之间的依赖性、以及预期的预测场景。

**4. D** —— ⚠⚠ **它不保证泛化，也不保证在分布漂移下的稳健性。**

**5. B** —— ⚠ **训练表现差本身就已经能提示欠拟合或优化问题；把训练和验证结果对比，才是更强的诊断证据。**

## 第 2 组：划分方式（T3-1 §2）

**1. 同一个病人贡献了 10 条记录，应该用哪种划分？**

A. 分层划分，保持各类比例
B. 按时间划分，早的训练、晚的测试
C. 分组划分，把同一个人的记录放进同一个子集
D. 随机划分，只要每条记录独立编号即可

**2. 预测未来的任务应该怎么划分？**

A. 随机打乱后按比例切分
B. 按类别分层切分，保证各类比例一致
C. 按特征聚类切分，让各子集的分布尽量相似
D. 按时间切分，用较早的观测训练、较晚的观测验证

**3. 类别不平衡时常用的划分方式是：**

A. 分层划分，保持各类比例
B. 分组划分，按来源归并记录
C. 按时间划分，优先保留最新数据
D. 先过采样少数类再随机划分

**4. 「过拟合是训练的必然后果」这个说法：**

A. 正确，模型容量足够大时一定会过拟合
B. 正确，除非使用了正则化
C. 不对，它是一个需要诊断的风险，不是必然后果
D. 不对，过拟合只在数据量小于一千时发生

**5. 「验证集」和「测试集」最根本的区别是什么？**

A. 验证集参与选择，测试集只评估已经冻结的流程
B. 验证集更大，测试集更小，所以估计更稳
C. 验证集必须分层，测试集必须随机
D. 验证集在训练中使用，测试集在训练后重新采样

---

**答案与解析**

**1. C** —— 否则模型可以**记住这个病人特有的特征**，测试分数**偏乐观**——它衡量的不是「对新病人的表现」。

**2. D** —— ⚠⚠ **评估设计应当复现「真正没见过的数据将以什么方式到来」。**

**3. A** —— ⚠⚠ **随机划分不是自动就合适的。**

**4. C** —— ⚠ 讲义这里的措辞很审慎，答题时也要照这个分寸写。

**5. A** —— ⚠⚠ **不得用测试集的标签或结果来做这个选择。**

## 第 3 组：信息泄漏（T3-1 §3）

**1. 数据泄漏的定义是什么？**

A. 训练集和测试集有完全相同的样本
B. 训练过程中把标签当成了输入特征
C. 模型的参数数量超过了样本数量
D. 在预期预测场景中拿不到的信息，影响了训练或选择

**2. 训练值是 [0, 2]、留出值是 100。正确的中心化结果是多少？**

A. 100 − 34 = 66
B. 100 − 1 = 99
C. 100 − 51 = 49
D. 100 − 0 = 100

**3. 「缩放器不用标签，所以可以在交叉验证之前对全部开发数据拟合一次」这个说法：**

A. 正确，不用标签就不构成泄漏
B. 正确，只要之后不再改动缩放参数
C. 错误，但影响很小，实践中可以忽略
D. 错误，从输入里学习、即使没用到标签，一样可能越过评估边界

**4. 防泄漏的正确顺序，第一步是什么？**

A. 先选好模型和超参数
B. 先用全部数据算缩放参数
C. 先划分成训练 / 验证 / 测试
D. 先把类别不平衡处理掉

**5. PCA 用在有监督模型之前时，应该在哪里拟合？**

A. 在每个训练划分或折的内部拟合
B. 在全部数据上拟合一次，因为它是无监督的
C. 在验证集上拟合，这样能反映泛化
D. 在测试集上拟合，这样最接近部署场景

---

**答案与解析**

**1. D** —— 途径包括：**标签、学到的预处理、重复记录、未来信息。**

**2. B** —— 只用训练集算均值 = 1。若三个值放在一起算均值 ≈ 34，⇒ **留出的那个案例改变了连训练数据本身的表示方式。**

**3. D** —— ⚠⚠ 这是页面的关键一句。[0,2] vs 100 那个例子就是证明。

**4. C** —— 五步：划分 → 只在训练集上算预处理参数 → 原样应用到验证/测试 → 用验证选模型 → 全部定好后在测试集上评估一次。

**5. A** —— ⚠⚠ **「无监督」不等于「可以安全地在测试数据上拟合」。**k 折里要在**每一个训练折内部**单独拟合预处理。

## 第 4 组：refit 工作流与交叉验证（T3-1 §4–5）

**1. 1000 个样本按 700/150/150 划分。选定流程后可以在多少个样本上重新拟合?**

A. 仍然只用 700 个
B. 合并训练与验证的 850 个
C. 全部 1000 个
D. 随机抽取的 900 个

**2. refit 之后，之前选定的阈值会怎样?**

A. 完全不受影响，阈值与模型无关
B. 自动按样本量比例缩放
C. 必须用最终测试集的标签重新校正
D. 可能迁移得不完美，因为 refit 之后分数会变

**3. 看过测试结果之后又继续开发，会有什么后果?**

A. 没有后果，只要不改动模型结构
B. 那个旧测试集已成为开发历史的一部分，新结论需要一次全新的独立评估
C. 只需把测试集重新随机打乱一次即可继续使用
D. 需要把学习率调小以补偿这次泄漏

**4. 五折交叉验证的验证准确率是 0.80, 0.82, 0.78, 0.84, 0.81。怎么解读这个平均 0.81?**

A. 这是五次独立的测试实验，可以算标准误
B. 它等价于在一个 5 倍大的测试集上评估一次
C. 它们的训练集互相重叠，不是五次独立实验，而且仍带有不确定性
D. 它已经消除了划分带来的随机性，可以当作确定值

**5. 验证表现很差，该不该去看测试结果来挑一个更好的模型?**

A. 不该，一旦用测试结果做选择，它就不再是独立的最终评估
B. 该，只要只看一次就不算泄漏
C. 该，反正最后还要在测试集上评估
D. 不该，但可以看测试集的输入分布，不看标签

---

**答案与解析**

**1. B** —— ⚠⚠ **不要在报告那个测试结果之前，用全部 1000 个重新拟合。**重拟合的副本，其缩放器在这 850 个上重新拟合。

**2. D** —— 应当用开发数据或 out-of-fold 预测检查稳定性。⚠⚠ **绝对不要用最终测试集的标签去「修正」阈值。**

**3. B** —— ⚠⚠ 这是讲义第 4 节的第二条警告。

**4. C** —— ⚠⚠ **这个平均值仍然依赖于抽样和划分的假设。**每个候选配置都要有它自己的一套全新的交叉验证拟合。

**5. A** —— 超参数是「模型大小、正则化强度」这类**选择**，**用验证证据选出来，而不是像权重那样直接拟合出来。**

## 第 5 组：欠拟合与过拟合的诊断（T3-1 §6 • §9）

**1. 训练和验证表现都差，说明什么？**

A. 一定是统计偏差过高，需要换更复杂的模型
B. 可能欠拟合或优化困难：模型太受限、特征不足、或优化失败
C. 一定是过拟合，需要加正则化
D. 一定是验证集太小，需要重新划分

**2. 训练准确率 98%、验证准确率 72%，在归因于方差之前还要检查什么？**

A. 学习率是否过大、批大小是否过小
B. 激活函数是否饱和、权重是否初始化得当
C. 分布差异、验证样本是不是太小、以及有没有数据泄漏
D. 损失函数是否与任务匹配、标签是否 one-hot

**3. 接上题，下一步可以做什么（都在验证集上做）？**

A. 加正则化 / 减小模型 / 增加数据 / 早停，并复核划分方式是否合适
B. 直接在测试集上试几个候选模型，挑验证与测试都最好的那个
C. 把验证集并入训练集，让模型见到更多数据以缩小两者的差距
D. 降低判定阈值，让验证准确率上升到和训练准确率接近

**4. 训练和验证都强且相当接近，说明什么？**

A. 模型一定能在部署环境中保持这个表现
B. 可以跳过测试集评估，直接上线
C. 模型容量刚好等于任务的真实复杂度
D. 学到的模式迁移到了未见的验证样本

**5. 基于验证集的早停，具体应该怎么做？**

A. 训练损失连续三轮不降就停
B. 等训练准确率达到 100% 时停止
C. 固定训练 100 个 epoch，取最后一个检查点
D. 定期监控验证表现，用开发数据定停止规则，保留验证最好的检查点

---

**答案与解析**

**1. B** —— ⚠ **这个模式本身并不能断定「统计偏差高」。**

**2. C** —— ⚠⚠ 这是讲义诊断表里专门加的限定。

**3. A** —— **在最终模型和决策流程选定之前，测试集一直不要碰。**

**4. D** —— ⚠⚠ 讲义反复强调：**这些是诊断模式，不是证明。**

**5. D** —— **测试数据留给最终评估。**⚠ 讲义那个演示**是在固定的 100 次更新预算后停的，不是因为证明了收敛。**

## 第 6 组：学习率与重复更新的证据（T3-1 §7–8）

**1. 学习率表里 η = 0 时一步之后的平均 BCE 是 0.580352，为什么?**

A. 因为梯度恰好为零
B. 因为损失函数在这一点取到极小
C. 因为参数根本没变，这就是起始值
D. 因为这一步被优化器跳过了

**2. 同一张表里 η = 100 时一步之后的平均 BCE 是 9.965953，这说明什么?**

A. 学习率越大损失下降越快，这一行只是数值精度造成的假象
B. 非常大的步子会过冲，甚至改变「哪些 ReLU 单元是激活的」
C. 损失函数存在多个局部极小，这一步跳进了另一个盆地
D. 这一步的梯度计算出错了，应当把梯度重新归一化

**3. η = 10 在这张表里一步后损失最低，它就是最佳学习率吗?**

A. 不是，这只是单步结果，一步走得远不等于长期收敛得好
B. 是，但只对这个网络结构成立
C. 是，实验数据已经证明了这一点
D. 不是，因为最佳学习率必须小于 1

**4. 连续训练 100 次更新后，样本 [−1,−2]（y=1）的概率是 0.4859。它被预测成哪一类?**

A. 类别 1，因为概率在上升
B. 类别 0，判错了
C. 无法判定，需要知道阈值是否为 0.5
D. 类别 1，因为它的损失在下降

**5. 接上题，这个正例为什么几乎没有改善?**

A. 它的两个隐藏 ReLU 激活从一开始就是零，正类分数只依赖输出偏置
B. 它的学习率被单独设小了，所以更新幅度比别的样本小得多
C. 它的标签被错误地标成了负类，梯度一直在把它往反方向推
D. 它离决策边界太远，输出 sigmoid 已经饱和，梯度接近于零

---

**答案与解析**

**1. C** —— ⚠⚠ 表里**每一行都是「从同一个初始参数重置后，只走一步」的独立实验**，不是一次运行的连续步骤。

**2. B** —— ⭐ **小步子能改善损失**；对照 η = 10 时降到 0.371611（这张表里最低）。

**3. A** —— ⚠⚠ **这些结果只属于这个批次和这个起点，不能据此确定一个普适的最佳学习率。**

**4. B** —— 0.4859 < 0.5 ⇒ 判类 0。⚠⚠ **平均损失更低，不代表每个样本都被正确分类。**

**5. A** —— 隐藏层那条路对它完全没用。⚠ **一次损失下降不能确立收敛**，看起来稳定也可能只是优化卡住了。

## 第 7 组：混淆矩阵的摆法（T3-2 §0–1）

**1. 做混淆矩阵题的第一件事是什么？**

A. 先算出准确率作为基准
B. 先检查类别是否平衡
C. 先声明哪一类算正类
D. 先把概率按阈值 0.5 转成硬判定

**2. 本课的混淆矩阵摆法是什么？**

A. 行 = 预测，列 = 真实，负类在前
B. 行 = 预测，列 = 真实，正类在前
C. 行 = 真实，列 = 预测，负类在前
D. 行 = 真实，列 = 预测，正类在前

**3. `sklearn.metrics.confusion_matrix(y_true, y_pred, labels=[0,1])` 输出的顺序是：**

A. [[TP, FN], [FP, TN]]
B. [[TN, FP], [FN, TP]]
C. [[TP, FP], [FN, TN]]
D. [[TN, FN], [FP, TP]]

**4. 在「类别 1 = 次品、预测为正触发一次检验」的场景里，FP 和 FN 各意味着什么？**

A. FP 是一次不必要的检验，FN 是漏掉了一个次品
B. FP 是漏掉一个次品，FN 是一次不必要的检验
C. FP 和 FN 都表示检验结果与标签不符，代价相同
D. FP 是检验设备故障，FN 是标签录入错误

**5. CS229 那份评估指标幻灯的摆法和本课是什么关系？**

A. 完全一致，可以直接套用
B. 它不用混淆矩阵，只给公式
C. 行列都相同，只是正负类顺序相反
D. 列 = 真实，和本课互为转置

---

**答案与解析**

**1. C** —— ⚠⚠ **TP、FP、FN、TN 的含义完全取决于这个选择。**⚠「正类」指的是被指定的那一类，**不一定是「好的结果」**。

**2. D** —— 本课的矩阵是 [[TP, FN], [FP, TN]]。

**3. B** —— ⚠ 因为它把**类别 0 放在前面**。考试时**先看题目给的是哪种摆法**，不要凭肌肉记忆填。

**4. A** —— 这个对应关系是后面「用代价定阈值」那一节的基础。

**5. D** —— ⭐ 页面自己的提醒：**在给各个格子命名之前，先读清楚行标签和列标签。**

## 第 8 组：四个指标（T3-2 §2–4）

**1. Precision 的分母是什么?**

A. TP + FN，即真实为正的那一组
B. TP + TN，即全部判对的案例
C. TP + FP，即被预测为正的那一组
D. TP + FP + FN + TN，即全部案例

**2. F1 公式 2PR/(P+R) 里的 P 指什么?**

A. 预测概率
B. prevalence（正例占比）
C. 正例个数
D. precision

**3. precision = 1、recall = 0.1 时，F1 约等于多少?**

A. 0.55
B. 0.1
C. 0.182
D. 1.0

**4. 关于 F1，下面哪一句是对的?**

A. 它是不平衡问题的标准指标，总是优于 accuracy
B. 它忽略 TN，而且把 precision 和 recall 看得同等重要
C. 它同时考虑了四个格子，所以比 accuracy 全面
D. 它把误报的代价设为漏报的两倍

**5. 真实 [1,1,1,1,1,0,0,0,0,0,0,0]、预测 [1,1,1,1,0,1,1,0,0,0,0,0]，四个计数是多少?**

A. TP=4, FN=1, FP=2, TN=5
B. TP=5, FN=0, FP=2, TN=5
C. TP=4, FN=2, FP=1, TN=5
D. TP=6, FN=1, FP=2, TN=3

---

**答案与解析**

**1. C** —— ⭐ Recall 的分母才是 TP + FN。**这两组有重叠，但不是同一组。**

**2. D** —— ⚠⚠ R 指 recall。**TPR（真正率）是 recall 的另一个名字。**

**3. C** —— 2(1)(0.1)/(1+0.1) ≈ **0.182**，**被小的那个拖住**。算术平均才是 0.55。⭐ **高 F1 要求两者都相当高。**

**4. B** —— ⚠⚠ **它并不自动就是每个不平衡问题的正确指标**，也没有说明金钱上的代价。

**5. A** —— ⭐ **计数必须加起来等于 12** —— 这是个很好的自查。由此 accuracy = 9/12 = 0.75，precision = 4/6 ≈ 0.667，recall = 4/5 = 0.8。

## 第 9 组：计数版公式与基线（T3-2 §3–4 • §7）

**1. F1 的计数版公式是什么？**

A. (TP + TN) / (2TP + FP + FN)
B. 2TP / (TP + FP + FN + TN)
C. TP / (TP + FP + FN)
D. 2TP / (2TP + FP + FN)

**2. 某个指标的分母为零时，讲义要求怎么处理？**

A. 默认记为 1，保证公式可算
B. 把该指标报告为无定义，并说明采用的约定
C. 改用 accuracy 代替，它永远有定义
D. 把该样本从评估中剔除再重算

**3. 正例稀少时，「把所有案例都预测为负」的分类器准确率会怎样？**

A. 等于负例占比，可能相当高
B. 接近 0，因为一个正例也没找到
C. 恰好等于 0.5
D. 无法计算，因为 TP = 0

**4. Metrics by hand 的 20 位顾客里，TP=6、FN=3、FP=2、TN=9。precision 和 recall 分别是：**

A. precision 0.667，recall 0.75
B. precision 0.75，recall 0.75
C. precision 0.75，recall 0.667
D. precision 0.60，recall 0.80

**5. 同一份数据里，「永远预测不点击」的基线准确率是多少？**

A. 0.45
B. 0.50
C. 0.55
D. 0.75

---

**答案与解析**

**1. D** —— 用它可以**避免过早对 precision/recall 四舍五入**。上一组那道题用计数版得 8/11 ≈ 0.727，和公式版一致。

**2. B** —— **补充 practical 采用的约定是取 0。**

**3. A** —— ⇒ 这正是「**accuracy 的基线是多数类占比**」那条。它的 recall = 0，毫无用处。

**4. C** —— precision = 6/8 = 0.75，recall = 6/9 ≈ 0.667，accuracy = 15/20 = 0.75，F1 = 12/17 ≈ 0.706。

**5. C** —— 11 个真实负例全对 ⇒ 11/20 = **0.55**。模型的 0.75 确实高于基线。

## 第 10 组：阈值与代价（T3-2 §5–6 • 考纲示例题）

**1. 在固定的分数上降低二分类阈值，recall 会怎样?**

A. 一定下降，因为误报增多
B. 只要存在真实正例，就不会下降
C. 不变，recall 与阈值无关
D. 先升后降，存在一个最优阈值

**2. 漏掉一个次品代价 5、一次不必要检验代价 1。阈值 0.5 给 FN=6/FP=4，阈值 0.3 给 FN=2/FP=12。哪个更优?**

A. 0.5，总代价 34；0.3 的总代价是 22
B. 无法比较，因为误报数差太多
C. 两者相同，总代价都是 28
D. 0.3，总代价 22；0.5 的总代价是 34

**3. 接上题，把两种错误的代价改成相等，结论会怎样?**

A. 翻过来：0.5 的 10 优于 0.3 的 14
B. 仍然是 0.3 更优，差距更大
C. 两者相等，都是 12
D. 需要重新训练模型才能比较

**4. 某团队反复调整阈值以最大化「最终测试集」上的 F1，再把这个 F1 当作无偏估计报告。主要问题是什么?**

A. 测试集已经影响了模型选择；阈值应当用验证数据选，测试集留给最终评估
B. 二分类器算不出 F1，必须先转成多分类
C. 每个分类器都必须用 0.5 作为判定阈值
D. 阈值会自动改变已经拟合好的网络权重

**5. 只给了硬类别判定（没有分数），能做什么、不能做什么?**

A. 什么都算不了，必须有概率
B. 能画完整 ROC，但不能算 F1
C. 能算四个指标，但无法确定完整的 ROC 曲线或 AUC
D. 能算 AUC，但不能算 precision

---

**答案与解析**

**1. B** —— 预测为正的数量**只增不减** ⇒ TP 和 FP 都不会减少。⚠ 但 **precision 可能升，也可能降。**

**2. D** —— 5(6)+4 = 34 vs 5(2)+12 = 22。 ⭐ **0.3 更好——尽管它产生了更多的误报。**

**3. A** —— ⚠⚠ **代价和产能是决策的一部分；不存在普适最优的阈值。**

**4. A** —— 这是 **M3 考纲页给的官方示例选择题**，答案 A。反复基于测试集做选择，破坏了最终评估的独立性。

**5. C** —— ⚠ **硬类别预测只能提供一个工作点**——要画完整曲线必须用**原始分数。**

## 第 11 组：ROC 的构造（T3-3 §1–3）

**1. TPR 和 FPR 分别等于什么？**

A. TPR = TP/(TP+FP)，FPR = FP/(FP+TN)
B. TPR = TN/(TN+FP)，FPR = FN/(FN+TP)
C. TPR = TP/(TP+FN)，FPR = FP/(TP+FP)
D. TPR = TP/(TP+FN)，FPR = FP/(FP+TN)

**2. 画 ROC 时，哪两个量在整个过程中固定不变？**

A. TP 和 FP 的计数
B. 真实正例数和真实负例数这两个分母
C. 阈值的步长和曲线上点的个数
D. precision 和 recall 的比值

**3. ROC 曲线从哪个点开始、到哪个点结束？**

A. 从 (0,0) 开始，到 (1,1) 结束
B. 从 (1,1) 开始，到 (0,0) 结束
C. 从 (0,1) 开始，到 (1,0) 结束
D. 从 (0.5,0.5) 开始，向两端延伸

**4. 阈值往下降时，加入一个正例和加入一个负例，点分别往哪移？**

A. 正例往右，负例往上
B. 两者都往右上方移动相同距离
C. 正例往上，负例往右
D. 正例往上，负例往下

**5. 共享同一个分数的多个观测，画 ROC 时应该怎么处理？**

A. 按标签排序后逐个加入
B. 只保留其中一个，其余丢弃
C. 随机打乱后逐个加入
D. 必须一起加入

---

**答案与解析**

**1. D** —— TPR 就是 recall；FPR = 1 − specificity，而 specificity = TN/(TN+FP)。

**2. B** —— ⭐ 这是第 ② 步。⚠ **两个类别都必须存在**，否则这两个率没有定义。

**3. A** —— 起点是「比最大分数还高的阈值 ⇒ 全部预测为负」，终点是「比最小分数还低的阈值 ⇒ 全部预测为正」。

**4. C** —— ⭐⭐ 四样本算例里**每加入一个正例点向上移 1/2，每加入一个负例点向右移 1/2**。

**5. D** —— ⚠ 数据量小时，曲线是**一串阶梯**，不是一条光滑的物理定律。

## 第 12 组：AUC 的两种算法（T3-3 §4–5）

**1. A(0.90,1)、B(0.80,0)、C(0.40,1)、D(0.10,0)。阈值从 0.60 降到 0.30，点怎么移动？**

A. C 进来，C 是负例 ⇒ 从 (0.5,0.5) 向右移到 (1,0.5)
B. C 进来，C 是正例 ⇒ 从 (0.5,0.5) 向上移到 (0.5,1)
C. B 进来，点从 (0,0.5) 移到 (0.5,0.5)
D. D 进来，点从 (0.5,1) 移到 (1,1)

**2. 梯形法算 AUC 时，FPR = 0 处那段竖直线段贡献多少面积？**

A. 等于 TPR 的高度
B. 等于 TPR 的一半
C. 零，因为横向宽度为 0
D. 无法确定

**3. 上面四个样本的 AUC 是多少？**

A. 0.50
B. 0.625
C. 1.00
D. 0.75

**4. AUC 的「排序解释」是什么？**

A. 正例的平均分数减去负例的平均分数
B. 随机取一个正例、随机取一个负例，正例分数更高的概率
C. 被正确分类的样本占全部样本的比例
D. precision 与 recall 的调和平均在所有阈值上的平均

**5. 用正负配对法复核上面四个样本：A vs B、A vs D、C vs B、C vs D，结果是多少？**

A. 3 胜 / 4 对 ⇒ AUC = 0.75
B. 4 胜 / 4 对 ⇒ AUC = 1.00
C. 2 胜 / 4 对 ⇒ AUC = 0.50
D. 3 胜 / 6 对 ⇒ AUC = 0.50

---

**答案与解析**

**1. B** —— C 的分数是 0.40，落在 0.30 和 0.60 之间。

**2. C** —— 公式 Σ (ΔFPR) × (TPR_i + $TPR_{i+1}$)/2 里，ΔFPR = 0 ⇒ 该项为 0。

**3. D** —— 梯形：0.5×0.5 + 0.5×1 = 0.25 + 0.50 = **0.75**。

**4. B** —— ⭐ **一个平局算半胜。** 这个办法**不需要选任何阈值**，考场上比画梯形快，而且能互验。

**5. A** —— 只有 C vs B（0.40 < 0.80）输掉。✓ 和梯形法完全一致。

## 第 13 组：AUC 的解读分寸（T3-3 §6–8）

**1. AUC = 1 应该怎么解读?**

A. 在被评估的这个样本上排序完美，但不保证未来的准确率
B. 模型完美，可以直接部署
C. 模型的概率校准也一定完美
D. 该模型在任何阈值下准确率都是 100%

**2. AUC < 0.5 时应该怎么做?**

A. 把模型的预测反过来用，AUC 就变成 1 − 原值
B. 去检查分数方向、标签约定和抽样，而不是拿测试结果自动把模型反过来用
C. 判定模型完全无效，重新训练
D. 改用 accuracy 评估，AUC 在这种情况下无意义

**3. 下面哪一项不是 AUC 能决定的?**

A. 哪个模型在整体排序上更强
B. 随机正负配对里正例分数更高的概率
C. 工作阈值、概率校准、以及误报漏报的真实代价
D. 曲线下方区域的面积大小

**4. 单独改变 prevalence（正例占比），ROC AUC 会怎样?**

A. 变成无定义，必须重新抽样
B. 一定按比例下降
C. 一定按比例上升
D. 不一定改变，因为 ROC 用的是类内条件率

**5. 两个系统 AUC 相同，它们在实际使用的那个工作点上表现一定相同吗?**

A. 一定相同，面积相同说明曲线相同
B. 一定相同，只要正例占比也相同
C. 不一定，两条形状不同的曲线完全可以有相同的面积
D. 不一定，但差距不会超过 AUC 的 10%

---

**答案与解析**

**1. A** —— ⚠ 讲义这一节措辞很讲究，答题要照着写。

**2. B** —— ⚠ AUC 接近 0.5 时，**单条经验曲线也不必恰好落在对角线上。**

**3. C** —— ⚠ 四条限制里还有一条：**负例很多时，它可能掩盖掉数量不可接受的误报。**

**4. D** —— **但 precision 和实际可用性可能变化很大** ⇒ 还要同时看 precision–recall 和 prevalence。

**5. C** —— **AUC 概括的是整条曲线（排序能力），而不是某一个工作点。**

## 第 14 组：PR 视角与稀有正例（T3-3 §8–9 • 考纲大题）

**1. 同一组 A/B/C/D 样本的 PR 曲线里，precision 这一列是 0.5 → 2/3 → 0.5。这说明什么?**

A. 计算出错了，precision 应当单调
B. 阈值下降时 precision 不必单调变化
C. 该模型的排序能力为零
D. PR 曲线只能在平衡数据上使用

**2. 1000 个观测里只有 10 个正例。在 TPR = 0.8、FPR = 0.1 处，FP 是多少?**

A. 8
B. 2
C. 100
D. 99

**3. 接上题，precision 和 recall 分别是多少?**

A. precision ≈ 7.5%，recall = 80%
B. precision = 80%，recall ≈ 7.5%
C. precision = 80%，recall = 80%
D. precision ≈ 7.5%，recall ≈ 7.5%

**4. 某检测器在 200 个案例上 TP=18、FP=12、FN=6、TN=164。accuracy 和 precision 分别是多少?**

A. accuracy 0.60，precision 0.91
B. accuracy 0.91，precision 0.75
C. accuracy 0.75，precision 0.60
D. accuracy 0.91，precision 0.60

**5. 接上题，recall 和 F1 分别是多少?**

A. recall 0.60，F1 ≈ 0.667
B. recall 0.75，F1 ≈ 0.60
C. recall 0.75，F1 ≈ 0.667
D. recall 0.90，F1 ≈ 0.72

---

**答案与解析**

**1. B** —— ⚠ 高于 0.90 时没有任何正类预测 ⇒ precision 的分母为零。随机排序的无技能参考线 = 正例占比 = 2/4 = 0.5。

**2. D** —— FP = 0.1 × 990 = **99**。同时 TP = 0.8 × 10 = 8，FN = 2。

**3. A** —— precision = 8/107 ≈ 7.5%，recall = 8/10 = 80%。⭐ **负例基数巨大时，很小的 FPR 也会压倒性地稀释 precision。**

**4. D** —— 这是 **M3 考纲页给的官方示例大题。**(18+164)/200 = 0.91；18/30 = 0.60。

**5. C** —— recall = 18/24 = 0.75；F1 = 2(18)/(2·18+12+6) = 36/54 = 2/3 ≈ 0.667。⚠ accuracy 被大量负例主导，表达不出漏报和误报各自的代价。